

CHAPTER 1

인공지능 기초 수학

성명 : 최승호

이메일 : jcn99250@naver.com

학습 목표

- AI를 위한 주요 수학 개념
- 머신러닝 라이브러리 (Numpy)

벡터(Vectors)

- 벡터의 정의:
 - 컴퓨터 과학 : 벡터는 실수 값을 갖는 성분으로 구성된 1차원 배열
 - 물리 : 벡터는 크기와 방향을 가진 값 (방향은 화살표로 표기, 크기는 수치 값으로 표현)
 - 벡터는 값의 모임인데, 벡터를 구성하는 값에는 순서가 존재
- 유클리디안 공간의 벡터는 열 또는 행으로 표현
- 굵은 소문자로 표기
 - 벡터 x 에 대하여 x^T 는 전치 (Transpose) 연산의 결과물로 전치 연산은 열벡터를 행벡터로 혹은 행벡터를 열벡터로 변환하게 됨

$$\mathbf{x} = \begin{bmatrix} 1 \\ 7 \\ 0 \\ 1 \end{bmatrix} = [1 \quad 7 \quad 0 \quad 1]^T$$



*유클리디안 벡터 표현 방식

벡터(Vectors)

- n차원 공간과 n 벡터
 - N개의 성분이 있는 일반 형식의 벡터 (“n벡터”라 호칭)는 n차원 공간 $x \in \mathbb{R}^n$ 에 존재 ($\mathbb{R}$ 은 실수를 의미)
- 벡터의 표현:
 - 벡터는 $x = (x_1, x_2, x_3)$ 와 같은 형태로 표현하기도 함
 - 벡터는 $x = \langle x_1, x_2, x_3 \rangle$ 와 같은 형태로 표현하기도 함
 - 행렬과 함께 다루어질 때는 옆에 표현한 형태로 표현 $\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}$
 - 열벡터 (column vector) $\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}$
 - 행벡터 (row vector) $\mathbf{x} = [x_1 \quad x_2 \quad x_3]$
- Tip : 기계학습에서 벡터, 행렬, 텐서는 데이터, 모델의 가중치등을 표현할때 쓰임

벡터의 기하학 표현


- 벡터의 첫 번째 해석 : 공간의 점
 - 첫번째 그림처럼 n 차원 공간의 점으로 n 벡터를 표시
- 벡터의 두 번째 해석 : 공간에서의 방향
 - 예를 들어 벡터 $\vec{v} = [3 \ 2]^T$ 의 방향은 오른쪽 3단계, 위로 2단계
 - 표기법은 벡터의 방향을 강조할 때 사용
 - 두 번째 그림의 모든 벡터는 같은 방향을 가리킴



벡터의 기하학 표현

- 벡터 덧셈
 - 그림과 같이, 두 벡터의 합은 방향과 크기를 고려하여 정해짐

$$\mathbf{x}_1 = [x_{11} \ x_{12}]^T, \mathbf{x}_2 = [x_{21} \ x_{22}]^T$$
$$\mathbf{x}_1 + \mathbf{x}_2 = [x_{11} + x_{21} \ x_{12} + x_{22}]^T$$



- 벡터의 스칼라 곱
 - n 벡터 $\mathbf{x} = [x_1 \ \cdots \ x_n]^T$ 와 실수 a 에 대하여, 실수 a 와 벡터 $\mathbf{x}$ 의 스칼라 곱은 다음과 같이 정의됨

$$a\mathbf{x} = [ax_1 \ \cdots \ ax_n]^T$$

벡터 덧셈, 뺄셈 등 연산

$\mathbb{R}^3$ 의 벡터 $x = [1 \ 2 \ 3]^T, y = [-2 \ 3 \ 6]^T$ 에 대하여 $x + y, x - y, (-3)x$ 를 구하여라.

기계학습과 훈련 데이터

- 기계학습에는 대규모 데이터가 매우 중요
- 원하는 임무를 잘 해결하는 기계학습 모델을 찾으려면 해당 임무에 대한 데이터가 확보되어야 하는데, 해당 임무에 대하여 수집한 데이터를 훈련데이터라고 호칭
- 훈련 데이터 $D = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$
 - 모델이 해결해야 하는 임무에 따라 변화하지만 일반적으로 상기와 같이 훈련데이터 D 를 표현
 - 상기표현은 기계학습 모델에게 주어진 훈련 데이터는 N 개의 관측 값으로 구성된 샘플로 i 번째관측 값은 $(\mathbf{x}_i, y_i)$ 로 구성된다는 의미.
 - $\mathbf{x}_i$ 를 특징벡터, y_i 를 참값, 레이블, 목표 값 등으로호칭

기계학습과 훈련 데이터



- 훈련 데이터

- 예

- “대학생”, “고등학생”, “중학생”, “초등학생”, “학생 아님”의 5개 카테고리로 관측 값을 구분할때, 하나의 관측 값을 “나이”, “성별”, “이름”, “학교코드”로 설명한다고 가정하자.
 - 이때 i 번째 관측 값의 특징벡터 $\mathbf{x}_i$ 는 “나이”, “성별”, “이름”, “해당국가”에 해당하는 4개의 성분으로
 - 표시되며, 해당 관측 값의 y_i 레이블 에는 이진분류로 “학생“ 또는 “학생아님 ” 이부여된다.

벡터와 데이터

- 벡터를 공간의 점으로 기하학적으로 해석하면, 기계학습에서 다루는 훈련 데이터를 공간의 점들의 모음으로 간주할 수 있음
- 두 개의 집단 (예를 들어 고양이와 강아지)에 해당하는 벡터들(2개의 성분으로 구성)이 주어지고, 고양이 집단의 벡터를 파란색, 강아지 집단의 벡터를 주황색으로 표시하면 서로 다른 집단을 구분하는 구분선을 형성할 수 있음 (왼쪽 그림)
- 벡터를 공간의 점으로 간주하면, 훈련데이터를 다양한 방식으로 시각화 하여 데이터의 특성을 직관적으로 파악하는데 도움이 됨 (오른쪽 그림)



벡터와 데이터

- 벡터 노름은 벡터를 스칼라 값으로 매핑하는 함수
- 노름 (Norm)은 벡터 크기의 척도

- 노름 f 은 다음 속성을 충족해야 함

스케일링(Scaling): $f(\alpha \mathbf{x}) = |\alpha|f(\mathbf{x})$ (α 는 임의의 실수)

삼각 부등식(Triangle inequality): $f(\mathbf{x} + \mathbf{y}) \leq f(\mathbf{x}) + f(\mathbf{y})$

양의 함수: $f(\mathbf{x}) \geq 0$

- 벡터 $\mathbf{x}$ 의 일반 ℓ_p 노름은 다음과 같이 구함 (p 는 실수

참고로 $p = 1, 2$, and ∞ 가 일반적인 노름으로 사용

$\|\mathbf{x}\|_\infty = \max\{|x_1|, \dots, |x_n|\}$ 즉, 벡터 $\mathbf{x}$ 를 구성하는 성분의 절대값 중 가장 큰 값

$$\|\mathbf{x}\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}, \mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$$






그림: 벡터의 일반적인 노름 그래프

벡터 노름

$\mathbb{R}^3$ 의 벡터 $x = [1 \ 2 \ 3]^T, y = [-2 \ 3 \ 6]^T$ 에 대하여 $\|x\|_1, \|y\|_2, \|x\|_\infty$ 를 구하여라.

벡터 내적과 사잇각

벡터의 내적, $\mathbf{u} \cdot \mathbf{v} = \mathbf{u}^T \mathbf{v} = \sum_i u_i \cdot v_i = \|\mathbf{u}\| \|\mathbf{v}\| \cos(\theta)$

- 벡터의 내적 $\mathbf{u} \cdot \mathbf{v}$ 는 $\langle \mathbf{u}, \mathbf{v} \rangle$ 로도 종종 표시된다.
- $\|\mathbf{u}\|$ 는 $\|\mathbf{x}\|_p$ 에서 $p = 2$ 인 경우 *원래 표현은 $\|\mathbf{u}\|_2 \|\mathbf{v}\|_2 \cos(\theta)$ 이지만, 편의상 생략한다.
- θ : $\mathbf{u}$ 벡터와 $\mathbf{v}$ 벡터의 사잇각 *내적은 $L2$ 노름을 사용한다. $\|\mathbf{u}\| = \|\mathbf{u}\|_2$, $\|\mathbf{v}\| = \|\mathbf{v}\|_2$

내적 연산은 대칭 연산이다: $\mathbf{u} \cdot \mathbf{v} = \mathbf{u}^T \mathbf{v} = \mathbf{v}^T \mathbf{u} = \mathbf{v} \cdot \mathbf{u}$

내적의 기하학적 해석

- 두 벡터 사이의 각도에 대한 정보를 제공
- 벡터 내적에 대한 정의로부터 $\cos(\theta)$ 의 값을 유도할 수 있음

$$\cos(\theta) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|} = \frac{\sum_i u_i \cdot v_i}{\|\mathbf{u}\| \|\mathbf{v}\|}$$

직교


- 사잇각이 90도를 이루는 두 벡터를 서로 “직교”한다고 표현($\mathbf{u}$ 와 $\mathbf{v}$ 벡터가 직교하면 $\mathbf{u} \cdot \mathbf{v} = 0$)

코사인 유사성(Cosine similarity)

$$\cos(\theta) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|}$$

- 기계학습에서는 관측값을 벡터의 형태로 표현한다.
- 벡터 형태로 표현된 두 관측값 사이의 $\cos(\theta)$ 값으로 두 관측값의 유사 정도를 수치화

※ $\mathbf{u} \cdot \mathbf{v}$ 에서 $\mathbf{u}$ 와 $\mathbf{v}$ 는 벡터를 의미하며 이 때 “ $\cdot$ ”는 내적 연산을 의미한다.
 $\sum_i u_i \cdot v_i$ 에서 u_i 와 v_i 는 $\mathbf{u}$ 와 $\mathbf{v}$ 의 i 번째 성분을 의미하며 이 때 $u_i \cdot v_i$ 는 실수 u_i 와 실수 v_i 의 곱셈 연산을 의미한다.



※ Tip : 벡터 내적은 기계학습에서 자주 사용된다.
예시) 두 벡터 간의 유사성 측정

벡터 내적

세 개의 벡터 $x = [1 \ 2 \ 3]^T$, $y = [-2 \ 3 \ 6]^T$, $z = [1 \ 2 \ 4]^T$ 에 대하여 x 는 y 와 z 중에 코사인 유사도에서 어느 벡터와 더 가까운지 수식적으로 판단하시오.



초평면 (hyperplanes) (1/3)

초평면은 차원이 주변 공간보다 하나 작은 부분 공간이다.

- 이차원 공간에서 초평면은 직선(즉, 일차원)이다.
- 3차원 공간에서 초평면은 평면(즉, 이차원)이다.
- n 차원 벡터 공간에서 초평면은 $n - 1$ 차원을 가지며 공간을 두 개의 절반 공간으로 나눈다.

머신러닝(ML)에서 초평면은 선형 분류에 사용되는 결정 경계(decision boundaries)이다.

- 선형 분류에서는 초평면의 양쪽에 있는 데이터 포인트가 서로 다른 클래스 / 카테고리에 속한다고 해석



기계학습에서 초평면은 분류문제에서 주요 개념

초평면 (hyperplanes) (2/3)

초평면은 해당 초평면과 직교하는 벡터(법선 벡터, normal vector) w 와 해당 초평면상에 존재하는 벡터 x_0 를 이용하여 정의

- 정의하고자 하는 초평면에 존재하는 임의의 벡터를 x 라고 하면 아래의 관계가 성립:

$$w \cdot (x - x_0) = 0$$

- 예를 들어, $w = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$, $x_0 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$ 을 이용하여 정의되는 초평면상의 벡터를 $x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$ 라고 표현하면

$$w \cdot (x - x_0) = w^T(x - x_0) = 0 \text{으로부터 } 2x_1 + x_2 - 1 = 0 \text{으로 초평면을 표현}$$

법선 벡터 w 와 오프셋(Offset) b 를 이용하여 $w \cdot x + b = 0$ 의 형태로 초평면을 표현할 수도 있다.


- $w = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$ 이고 오프셋 $b = -1$ 이면 $w \cdot x + b = 0$ 으로부터 $2x_1 + x_2 - 1 = 0$ 으로 초평면을 표현

- 벡터가 표현되는 공간의 원점에서 초평면까지의 거리는 $|b|/\|w\|$

초평면 (hyperplanes) (3/3)

선형 분류라는 모델을 이용할 때 초평면은 서로 다른 클래스 / 카테고리에 속하는 관측값을 구분하는 기준으로 활용된다.

- 2개의 클래스 / 카테고리가 존재하는 이진 분류 문제에서 $w \cdot x + b = 0$ 은 두 클래스 / 카테고리를 구분하는 기준이 되며, $w \cdot x + b > 0$ 인지 여부를 검사하여 클래스 레이블을 모르는 관측 값의 소속 클래스를 결정한다.



※ 기계학습에서 x 는 관측 값의 특징 벡터를 의미한다. 초평면의 구체적인 형태를 결정하는 w 와 b 의 값은 학습 데이터에 기반하여 결정됨

예: 오프셋이 -1인 초평면

행렬 (Matrices)

행렬은 m 개의 가로 행과 n 개의 세로 열의 형태로 수나 식을 배열한 것이다

(※ 강의에서는 실수의 행렬에 집중)

- A행렬의 i 번째 행과 j 번째 열에 해당하는 행렬의 요소를 a_{ij} 로 표현
- A행렬의 i 번째 행과 j 번째 열에 해당하는 행렬의 요소를 a_{ij} 또는 A_{ij} 또는 $[A]_{ij}$ 또는 $A(i, j)$ 로 표기

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}$$

행렬 $A \in \mathbb{R}^{m \times n}$ 크기는 $m \times n$ 또는 (m, n) 이다.

- 행렬은 굵은 글꼴의 영문 대문자로 표시된다.

행렬 (Matrices)

덧셈과 뺄셈

$$(\mathbf{A} \pm \mathbf{B})_{i,j} = \mathbf{A}_{i,j} \pm \mathbf{B}_{i,j}$$

$$\begin{bmatrix} 1 & 3 & 1 \\ 1 & 0 & 0 \end{bmatrix} + \begin{bmatrix} 0 & 0 & 5 \\ 7 & 5 & 0 \end{bmatrix} = \begin{bmatrix} 1+0 & 3+0 & 1+5 \\ 1+7 & 0+5 & 0+0 \end{bmatrix} = \begin{bmatrix} 1 & 3 & 6 \\ 8 & 5 & 0 \end{bmatrix}$$

스칼라 곱셈

$$(c\mathbf{A})_{i,j} = c \cdot \mathbf{A}_{i,j}$$

$$2 \cdot \begin{bmatrix} 1 & 8 & -3 \\ 4 & -2 & 5 \end{bmatrix} = \begin{bmatrix} 2 \cdot 1 & 2 \cdot 8 & 2 \cdot -3 \\ 2 \cdot 4 & 2 \cdot -2 & 2 \cdot 5 \end{bmatrix} = \begin{bmatrix} 2 & 16 & -6 \\ 8 & -4 & 10 \end{bmatrix}$$

행렬 곱셈

$$(\mathbf{AB})_{i,j} = \mathbf{A}_{i,1}\mathbf{B}_{1,j} + \mathbf{A}_{i,2}\mathbf{B}_{2,j} + \cdots + \mathbf{A}_{i,n}\mathbf{B}_{n,j}$$

- 왼쪽 행렬의 열 수가 오른쪽 행렬의 행 수와 같은 경우에만 정의된다.
- 참고로 $\mathbf{AB} \neq \mathbf{BA}$ 이다.

$$\begin{bmatrix} 2 & 3 & 4 \\ 1 & 0 & 0 \end{bmatrix} \begin{bmatrix} 0 & \frac{1000}{1} \\ 1 & \frac{100}{10} \\ 0 & \frac{10}{1} \end{bmatrix} = \begin{bmatrix} 3 & \frac{2340}{1000} \\ 0 & 1000 \end{bmatrix}$$

행렬의 덧셈, 뺄셈 등 연산

$A = \begin{bmatrix} 1 & 2 & 3 \\ 3 & 1 & 4 \end{bmatrix}, B = \begin{bmatrix} 5 & 2 & 2 \\ -1 & 3 & 3 \end{bmatrix}, C = \begin{bmatrix} 1 & 3 \\ 2 & 7 \end{bmatrix}$ 일 때, $A + B, 3A, (-1)C$ 를 구하시오.

행렬 (Matrices)

행렬의 전치: 행렬 A의 행과 열을 교환하는 연산

$$(A^T)_{i,j} = A_{j,i}$$

$$\begin{bmatrix} 1 & 2 & 3 \\ 0 & -6 & 7 \end{bmatrix}^T = \begin{bmatrix} 1 & 0 \\ 2 & -6 \\ 3 & 7 \end{bmatrix}$$

- 중요 속성

$$A + B = B + A$$

$$(A + B)^T = A^T + B^T$$

$$(A^T)^T = A$$

$$A(B + C) = AB + AC$$

$$A(BC) = (AB)C$$

$$(AB)^T = B^T A^T$$

정방 행렬(Square matrix): 행과 열의 수가 동일

항등행렬(I_n): $n \times n$ 의 정방 행렬 중 $a_{ii} = 1$ ($1 \leq i \leq n$)이고 그 외 원소는 0인 행렬

- 예시) :

$$I_3 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

행렬 – 벡터 곱셈(Matrix-Vector Products)

행렬 $A \in \mathbb{R}^{m \times n}$ 와 벡터 $\mathbf{x} \in \mathbb{R}^n$ 라고 하자.

행렬을 행 벡터의 모음으로 표시할 수 있다.

- 아래 표현에서 (예: $\mathbf{a}_1^\top$ 는 첫 번째 행에 해당하는 원소들의 모음을 먼저 열 벡터 $\mathbf{a}_1$ 으로 표시한 후 전치시킨 형태).

$$A = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_m^\top \end{bmatrix}$$

행렬-벡터 곱은 길이 m 의 열 벡터이며 i 번째 번째 요소는 내적 $\mathbf{a}_i^\top \mathbf{x}$ 이다.

$$A\mathbf{x} = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_m^\top \end{bmatrix} \mathbf{x} = \begin{bmatrix} \mathbf{a}_1^\top \mathbf{x} \\ \mathbf{a}_2^\top \mathbf{x} \\ \vdots \\ \mathbf{a}_m^\top \mathbf{x} \end{bmatrix}$$

크기는 다음과 같다: $A(m \times n) \cdot \mathbf{x}(n \times 1) = A\mathbf{x}(m \times 1)$

행렬 – 벡터 곱셈(Matrix-Vector Products)

행렬 $A \in \mathbb{R}^{m \times n}$ 와 벡터 $\mathbf{x} \in \mathbb{R}^n$ 라고 하자.

행렬을 행 벡터의 모음으로 표시할 수 있다.

- 아래 표현에서 (예: $\mathbf{a}_1^T$ 는 첫 번째 행에 해당하는 원소들의 모음을 먼저 열 벡터 $\mathbf{a}_1$ 으로 표시한 후 전치시킨 형태).

$$A = \begin{bmatrix} \mathbf{a}_1^T \\ \mathbf{a}_2^T \\ \vdots \\ \mathbf{a}_m^T \end{bmatrix}$$

행렬-벡터 곱은 길이 m 의 열 벡터이며 i 번째 번째 요소는 내적 $\mathbf{a}_i^T \mathbf{x}$ 이다.

$$A\mathbf{x} = \begin{bmatrix} \mathbf{a}_1^T \\ \mathbf{a}_2^T \\ \vdots \\ \mathbf{a}_m^T \end{bmatrix} \mathbf{x} = \begin{bmatrix} \mathbf{a}_1^T \mathbf{x} \\ \mathbf{a}_2^T \mathbf{x} \\ \vdots \\ \mathbf{a}_m^T \mathbf{x} \end{bmatrix}$$

크기는 다음과 같다: $A(m \times n) \cdot \mathbf{x}(n \times 1) = A\mathbf{x}(m \times 1)$

행렬 – 벡터 곱셈(Matrix-Vector Products)

두 행렬 $A \in \mathbb{R}^{n \times k}$ 와 $B \in \mathbb{R}^{k \times m}$ 에 대해서 곱할 경우를 살펴보자.

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1k} \\ a_{21} & a_{22} & \cdots & a_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nk} \end{bmatrix}, \quad B = \begin{bmatrix} b_{11} & b_{12} & \cdots & b_{1m} \\ b_{21} & b_{22} & \cdots & b_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ b_{k1} & b_{k2} & \cdots & b_{km} \end{bmatrix}$$

행렬-행렬 곱을 $A \in \mathbb{R}^{n \times k}$ 의 행과 $B \in \mathbb{R}^{k \times m}$ 의 열의 내적으로 생각할 수 있다.

$$C = AB = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_n^\top \end{bmatrix} [\mathbf{b}_1 \quad \mathbf{b}_2 \quad \cdots \quad \mathbf{b}_m] = \begin{bmatrix} \mathbf{a}_1^\top \mathbf{b}_1 & \mathbf{a}_1^\top \mathbf{b}_2 & \cdots & \mathbf{a}_1^\top \mathbf{b}_m \\ \mathbf{a}_2^\top \mathbf{b}_1 & \mathbf{a}_2^\top \mathbf{b}_2 & \cdots & \mathbf{a}_2^\top \mathbf{b}_m \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{a}_n^\top \mathbf{b}_1 & \mathbf{a}_n^\top \mathbf{b}_2 & \cdots & \mathbf{a}_n^\top \mathbf{b}_m \end{bmatrix}$$

행렬의 크기: $A(n \times k) \cdot B(k \times m) = C(n \times m)$

행렬과 행렬 곱셈

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 3 & 1 & 4 \end{bmatrix}, B = \begin{bmatrix} 2 & 5 \\ 6 & 1 \\ -1 & 2 \end{bmatrix}, C = \begin{bmatrix} 1 & 3 \\ 2 & 7 \end{bmatrix} \text{일 때, } AB \text{와 } CA \text{를 구하시오.}$$

역행렬 (Inverse of a Matrix)

정방 행렬 A 에 대하여 곱하였을 때 항등행렬을 만드는 행렬을 A 행렬의 역행렬이라고 하고 A^{-1} 라고 표시

$$A^{-1}A = AA^{-1} = I$$

역행렬의 특성

$$(A^{-1})^{-1} = A$$

$$(AB)^{-1} = B^{-1}A^{-1}$$

큰 행렬의 역행렬을 찾는 것은 계산 비용이 많이 든다.

- 또한 수치적 불안정성을 초래할 수 있다.

행렬의 역행렬이 전치행렬과 같으면 직교 행렬(orthogonal matrix)이라고 한다.

$$A^{-1} = A^T \quad * \text{ cf. } A^T A = A A^T = I$$

텐서 (Tensors)

텐서(tensors)는 스칼라의 n 차원 배열이다.

- 벡터는 1차 텐서, $\mathbf{v} \in \mathbb{R}^n$
- 행렬은 2차 텐서, $\mathbf{A} \in \mathbb{R}^{m \times n}$
- 예를 들어, 4차 텐서는 $\mathbf{T} \in \mathbb{R}^{n_1 \times n_2 \times n_3 \times n_4}$

RGB 이미지는 3차원 배열이므로 3차 텐서이다.

- 3개의 축은 너비, 높이 및 채널에 해당된다.
- E.g., $224 \times 224 \times 3$
- 채널 축은 색상 채널(빨간색, 녹색 및 파란색)에 해당된다.

선형 결합, 선형 종속, 선형 독립

벡터 $\mathbf{b}_1$ 와 $\mathbf{b}_2$, 실수 a_1, a_2 에 대하여 $a_1\mathbf{b}_1 + a_2\mathbf{b}_2$ 를 벡터 $\mathbf{b}_1$ 와 $\mathbf{b}_2$ 의 선형 결합(Linear combination)이라고 한다.

선형 독립

- 아래의 관계가 $a_1 = \dots = a_k = 0$ 일 때만 성립하면, $\mathbf{v}_1, \dots, \mathbf{v}_k$ 는 선형 독립이라고 한다.

$$a_1\mathbf{v}_1 + \dots + a_k\mathbf{v}_k = 0$$

선형 종속(Linearly dependent)

- 임의의 벡터들의 집합 $\mathbf{v}_1, \dots, \mathbf{v}_k$ 에 대하여 $a_1\mathbf{v}_1 + \dots + a_k\mathbf{v}_k = 0$ 을 만족하는 0이 아닌 실수 $a_1, \dots, a_k$ 가 존재하면 $\mathbf{v}_1, \dots, \mathbf{v}_k$ 는 선형 의존 관계에 있다고 한다.

미분학 (Differential Calculus)

함수 $f: \mathbb{R} \rightarrow \mathbb{R}$ 의 경우 f 의 도함수(derivative)는 다음과 같이 정의된다.

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$

$f'(a)$ 가 극한 값이 존재하면, f 는 a 에서 미분 가능하다고 한다.

$f'(c)$ 가 $\forall c \in [a, b]$ 에 대해 존재하면 f 는 이 구간에서 미분 가능하다.

– 미분 $f'(x)$ 을 x 에 대한 $f(x)$ 의 순간 변화율로 해석할 수도 있다.

기호 $\frac{d}{dx}$, D , D_x 는 미분 연산을 나타내는 미분 연산자(differentiation operators)이다.

x 가 독립 변수이고 y 가 종속 변수인 $y = f(x)$ 가 주어지면 다음 식은 동일하다.

$$f'(x) = f' = \frac{dy}{dx} = \frac{df}{dx} = \frac{d}{dx}f(x) = Df(x) = D_x f(x)$$

미분학 (Differential Calculus)

다음 규칙은 명시적 함수의 도함수를 계산하는 데 사용된다.

- **Derivative of constants.** $\frac{d}{dx}c = 0$.
- **Derivative of linear functions.** $\frac{d}{dx}(ax) = a$.
- **Power rule.** $\frac{d}{dx}x^n = nx^{n-1}$.
- **Derivative of exponentials.** $\frac{d}{dx}e^x = e^x$.
- **Derivative of the logarithm.** $\frac{d}{dx}\log(x) = \frac{1}{x}$.
- **Sum rule.** $\frac{d}{dx}(g(x) + h(x)) = \frac{dg}{dx}(x) + \frac{dh}{dx}(x)$.
- **Product rule.** $\frac{d}{dx}(g(x) \cdot h(x)) = g(x)\frac{dh}{dx}(x) + \frac{dg}{dx}(x)h(x)$.
- **Chain rule.** $\frac{d}{dx}g(h(x)) = \frac{dg}{dh}(h(x)) \cdot \frac{dh}{dx}(x)$.

미분학 (Differential Calculus)

함수 $f(x)$ 의 1계 도함수의 미분은 $f(x)$ 의 2계 도함수(second derivative)이다.

$$\frac{d^2 f}{dx^2} = \frac{d}{dx} \left(\frac{df}{dx} \right)$$

2차 미분(2계 도함수)은 $f(x)$ 의 변화율의 변화 정도를 수치화.

- 예를 들어 물리학에서 함수가 물체의 변위를 설명하는 경우 1차 도함수는 물체의 속도(즉, 위치의 변화율)를 제공한다.
- 2차 도함수는 물체의 가속도(즉, 속도의 변화율)를 제공한다.

$f(x)$ 의 n -(계) 도함수(n -th derivative)를 아래와 같이 표현한다.

$$f^{(n)}(x) = \frac{d^n f}{dx^n} = \left(\frac{d}{dx} \right)^n f(x)$$

편미분(Partial Derivatives)

여러 개의 변수가 정의역을 구성하는 함수를 다변량 함수(Multivariate functions)라고 한다.

$y = f(\mathbf{x}) = f(x_1, x_2, \dots, x_n)$ 를 n 개의 변수가 있는 다변량 함수라고 한다.

– 입력은 n 차원 벡터 $\mathbf{x} = (x_1, x_2, \dots, x_n)$ 이고 출력은 스칼라 y 이다.

– $f: \mathbb{R}^n \rightarrow \mathbb{R}$

i 번째 매개변수 x_i 에 대한 y 의 편미분(Partial derivative)은 다음과 같다.

$$\frac{\partial y}{\partial x_i} = \lim_{h \rightarrow 0} \frac{f(x_1, x_2, \dots, x_i + h, \dots, x_n) - f(x_1, x_2, \dots, x_i, \dots, x_n)}{h}$$

$\frac{\partial y}{\partial x_i}$ (∂을 “round” 혹은 “partial y over partial x sub i”로 발음하거나 “편미분”이라고 표현)의 계산

– $x_1, x_2, \dots, x_{i-1}, x_{i+1}, \dots, x_n$ 를 상수로 취급하고 x_i 에 대해서만 y 의 도함수를 계산한다.

아래의 표현은 모두 동일한 상황을 의미

$$\frac{\partial y}{\partial x_i} = \frac{\partial f}{\partial x_i} = \frac{\partial}{\partial x_i} f(\mathbf{x}) = f_{x_i} = f_i = D_i f = D_{x_i} f$$

기울기(Gradient)

기울기(Gradient)

- n 차원 입력 벡터 $\mathbf{x} = [x_1, x_2, \dots, x_n]^T$ 에 대한 다변량 함수 $f(\mathbf{x})$ 의 기울기는 아래와 같이 편미분 결과로 구성된 벡터로 정의된다 :

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \left[\frac{\partial f(\mathbf{x})}{\partial x_1}, \frac{\partial f(\mathbf{x})}{\partial x_2}, \dots, \frac{\partial f(\mathbf{x})}{\partial x_n} \right]^T$$

$\nabla_{\mathbf{x}} f(\mathbf{x})$ 대신 표기법 $\nabla f(\mathbf{x})$ 또는 $\nabla_{\mathbf{x}} f$ 로 표기하기도 함

- 그레디언트의 표기 : 그리스 문자 ∇ ("nabla/del"로 발음)
- $\nabla_{\mathbf{x}} f(\mathbf{x})$ 는 "벡터 $\mathbf{x}$ 에 대한 f 의 기울기"라고 지칭.

기계학습에서 기울기는 모델의 인자를 갱신하는 과정에서 중요하게 활용됨

기계학습에서의 학습

기계학습에서는 모델의 출력과 참값의 차이를 최소화하거나, 분류 정확도를 최대화하는 등의 목표가 부여됨

- 학습 과정에서 부여되는 목표를 정량적으로 표현한 것을 목적함수(Objective function)이라고 함
- 최적화(Optimization) 과정을 통해 원하는 목적함수를 달성하는 모델의 인자 값을 탐색
- 최소화 문제에서 목적 함수는 종종 비용 함수(cost function) 또는 손실 함수(loss function) 또는 오류 함수(error function)라고 한다.

목적 함수와 인자 결정 방식은 매우 다양

- 기계학습에서는 주어진 학습 데이터에 기반하여 가장 바람직한 목적 함수 값을 달성하는 모델의 인자 값을 찾고자 함

경사하강법(Gradient descent)

- 기울기(Gradient)를 이용하여 모델의 인자 값을 탐색하는 방법

임계점(Stationary Points)


한 변수의 미분 함수 $f(x)$ 의 임계점(stationary point)은 함수의 도함수가 0인 점, 즉 $f'(x) = 0$ 이다.

임계점은 다음과 같다.:

- 최소값(Minimum), 도함수가 음수에서 양수로 변하는 지점
- 최대값(Maximum), 도함수가 양수에서 음수로 변하는 지점
- 안장점(Saddle point), 도함수는 점 양쪽에서 양수 또는 음수이다.

최소점과 최대점을 총칭하여 극점이라고 한다.

- 임계점의 특성은 점에서 $f(x)$ 의 2차 도함수를 기반으로 결정될 수 있다.
 - $f''(x) > 0$, 그 점은 최소값
 - $f''(x) < 0$, 그 점은 최대값
 - $f''(x) = 0$, 안장점이 될 수 있지만 그렇지 않을 수도 있음.(미정)
 - 동일한 개념이 다변량 함수의 그래디언트에도 적용된다.



극소점(Local Minima)

기계학습에서는 최적의 목표 함수 값을 달성하는 모델의 인자 값을 찾는 것이 매우 어려움

전역 최소값(Global minimum)

* Global Minimum 정의: * D 는 모든 정의역

$x \in D, f(x) \geq f(a)$ 일때 a 에서의 global minima

- 정의역의 모든 원소에 대하여 목적 함수 $f(x)$ 의 값이 최소가 되는 경우 해당 값을 전역 최소값이라고 호칭

* Local Minimum 정의:


$x \in (a - \epsilon, a + \epsilon), f(x) \geq f(a)$ 일 때 a 에서의 local minima

지역 최소값(Local minimum)

- 목적 함수 $f(x)$ 의 값이 x 주변의 아주 작은 범위의 다른 지점의 목적 함수의 값보다 작은 목적 함수 값을 지칭

기계학습의 목적 함수에는 여러 개의 지역 최소값이 존재

- 최소값을 찾는 과정에서 그래디언트를 활용하는데,
어느 한 지역 최소값을 생성하는 모델 인자 값에 도달하면 다른 인자 값을 탐색하기가 어려움



※ 모델의 인자, 매개변수, 파라미터, 가중치는 같은 용어로 혼용되어 사용됨.

확률과 확률 변수

확률 변수(Random variable)

- 사건의 표본 공간(시행에서 가능한 모든 결과의 모음)을 정의역으로 하는 함수
- 예 : 정상적인 주사위를 던졌을 때 앞 면의 수를 확률 변수 X 로 표현할 경우
 - ✓ X 의 정의역은 $\mathcal{S} = \{1, 2, 3, 4, 5, 6\}$
 - ✓ 주사위를 던졌을 때 5가 나오는 사건을 $\{X = 5\}$ 또는 $X = 5$ 로 표시
 - ✓ 해당 사건의 확률은 $P(\{X = 5\})$ 또는 $P(X = 5)$ 로 표시

확률 분포(probability distribution)는 확률 변수가 특정한 값을 가질 확률을 나타내는 함수

- $P(X)$: 확률 변수 X 가 갖는 확률을 의미
- $X \sim P(\cdot)$ 표기법은 확률 변수 X 가 임의의 확률 분포 $P(\cdot)$ 를 따른다는 의미

확률 변수는 이산형 또는 연속형일 수 있다.

- 이산형 확률 변수(Discrete random variables)는 확률 변수에 부여될 수 있는 값이 유한하거나(예: 한 개의 동전을 던졌을 때 나올 수 있는 경우의 수), 확률 변수에 부여될 수 있는 값이 셀 수 있는 값인 경우(예 : 2의 눈이 나올 때까지 주사위를 던지는 횟수는 1, 2, 3, 4, 5, ...)
- 연속 확률 변수(Continuous random variables)는 확률 변수에 부여될 수 있는 값에 끝김이 없는 확률 변수이다(예 : 아날로그 시계의 시침과 분침이 이루는 각도)

확률의 공리(Axioms of probability)

“공리”란 증명 없이 옳다고 간주되는 명제를 의미


어느 시행에서 발생 가능한 결과의 집합을 표본 공간 $\mathcal{S}$ 로 표시하면, 표본 공간에서 생각할 수 있는 이벤트 $\mathcal{A}$ 의 확률을 $P(\mathcal{A})$ 로 측정하게 되는데 $P(\cdot)$ 는 다음의 공리를 만족해야 한다.

1. $P(\mathcal{S}) = 1$
2. 모든 $\mathcal{A} \subseteq \mathcal{S}$ 에 대하여, $P(\mathcal{A}) \geq 0$
3. $\mathcal{A}_1 \cap \mathcal{A}_2 = \emptyset$ 인 모든 $\mathcal{A}_1, \mathcal{A}_2 \subset \mathcal{S}$ 에 대하여 $P(\mathcal{A}_1 \cup \mathcal{A}_2) = P(\mathcal{A}_1) + P(\mathcal{A}_2)$

확률 질량 함수와 확률 밀도 함수

이산형 확률 변수의 확률을 표시하는 함수를 확률 질량 함수 (Probability mass function, PMF)이라고 한다.


- 예시 : 두 주사위의 합을 확률 변수 X 로 표시할 때 $P(X = x)$, $x \in \{2, 3, \dots, 12\}$



연속 확률 변수의 확률을 표시하는 함수를 확률 밀도 함수 (Probability density function, PDF)이라고 한다.

- 예: 20대 남성의 키가 168cm에서 175cm일 확률
- 연속 확률 변수에 대해서는 확률 변수가 구간(예: $[a, b]$)에 속하는 값을 갖게 될 확률을 PDF에 대한 적분으로 계산한다.

$$P(X \in [a, b]) = \int_a^b P(X)dX$$



기대값(Expected Value)

확률 변수 X 가 확률 분포 $P(X)$ 를 따를 때 즉, $X \sim P(X)$ 일 때, X 의 함수 $f(X)$ 에 대한 기대값의 정의는 다음과 같다.

이산형 확률 변수 X 의 경우:

$$\mathbb{E}_{X \sim P}[f(X)] = \sum_X P(X)f(X)$$

연속형 확률 변수 X 의 경우:

$$\mathbb{E}_{X \sim P}[f(X)] = \int P(X)f(X) dX$$

- 문맥상 분포가 명확할 때, $\mathbb{E}_X[f(X)]$ 라고 쓸 수 있다.
- 문맥 상 확률 변수가 명확하다면 $\mathbb{E}[f(X)]$ 라고 쓸 수 있다.

분산(Variance)

분산(Variance)은 $X \sim P(X)$ 일 때 함수 $f(X)$ 의 값과 $\mathbb{E}[f(X)]$ 의 차이의 측도:

$$\text{Var}(f(X)) = \mathbb{E}[(f(X) - \mathbb{E}[f(X)])^2]$$

분산이 작으면, 반복 측정하였을 때 $f(X)$ 값이 기대값 주변에서 측정된다.

분산은 일반적으로 σ^2 로 표시된다.

$$\sigma^2 = \sum_i P(X_i) \cdot (X_i - \mu)^2$$

– 분산의 제곱근(standard deviation)은 표준 편차이다.

✓ $\sigma = \sqrt{\text{Var}(X)}$ 으로 표기 된다.

다변량 확률 변수(multivariate random variable)

관측 대상이 여러 개의 확률 변수를 이용하여 설명되는 경우가 보다 일반적임

- 예 : 가격, 배기량, 연비, 생산연도 등 네 개의 특성을 활용하여 자동차를 관찰

여러 개의 확률 변수를 동시에 관측해야 하는 경우, 해당 확률 변수들의 집합을 이용하여 관측 값을 표현

- 예 : 가격을 X_1 , 배기량을 X_2 , 연비를 X_3 , 생산연도를 X_4 라는 확률 변수로 표현할 경우 X_1, X_2, X_3, X_4 의 집합으로 자동차를 표현

여러 확률 변수의 리스트를 다변량 확률 변수라고 하며, 벡터 형태로 표현할 경우 확률 벡터 (Random vector)라고 한다.

결합 확률 분포(Joint Probability Distribution)

두 개의 확률 변수로 확률 벡터가 구성되는 경우에 대하여 설명

- 두 개의 이산 확률 변수 X, Y 에 대한 결합 확률 함수는 다음과 같이 정의됨

$$p(x, y) = P(X = x, Y = y)$$

✓ 상기 식은 확률 변수 X 와 Y 가 동시에 x 와 y 라는 값을 각각 갖게 될 확률을 표시

- 이산 확률 변수 X, Y 에 대한 결합 확률 함수가 $p(x, y)$ 의 형태로 주어졌을 때 다음이 성립

1. 모든 x, y 에 대하여 $p(x, y) \geq 0$

2. $\sum_{x,y} p(x, y) = 1.$




주변 확률 분포(Marginal Probability Distribution)

주변 확률 분포(Marginal probability distribution)는 단일 변수의 확률 분포이다.

- 결합 확률 분포 $P(X, Y)$ 를 기반으로 계산된다.
- $P(X = x) = \sum_y P(X = x, Y = y)$
 - ✓ 연속 확률 변수의 경우, 적분으로 계산: $P(X = x) = \int P(X = x, Y = y) dy$
- 이 과정을 주변화(Marginalization)라고 한다.

주변 확률 : $p(X = \text{minivan}) = 0.0741 + 0.1111 + 0.1481 = 0.3333$




조건부 확률 분포(Conditional Probability Distribution)

조건부 확률 분포(Conditional probability distribution)는 확률변수 Y 가 y 로 고정된(발생된) 상황에서 확률변수 X 에 대한 확률분포를 의미한다.

- $P(X = x | Y = y)$ 로 표기된다.
- 상기 식은 확률 변수 Y 에 해당하는 이벤트가 발생하여 확률 변수 Y 의 값이 y 가 된 상황에서 확률 변수 X 의 값이 x 일 확률을 의미

조건부확률의 계산

$$P(X = x | Y = y) = \frac{P(X=x, Y=y)}{P(Y=y)}$$



베이지 정리 (Bayes's Theorem)

베이지 정리(Bayes' theorem)

$$P(X|Y) = \frac{P(Y|X)P(X)}{P(Y)}$$


- 베이지 규칙이라고도 함
- 결합 분포에 대한 곱셈 규칙이 사용됨: $P(X, Y) = P(Y|X)P(X)$
- $P(Y, X) = P(X|Y)P(Y) = P(Y|X)P(X)$ 으로 표현 가능하다.

확률 분포 (Probability Distributions)

베르누이 분포(Bernoulli distribution)


- 한 개의 이진 확률 변수에 대한 확률 분포
- 시행 결과 두 가지 값 중 한 값이 관찰되며, 하나의 결과는 p 의 확률로 발생 (다른 결과는 $1 - p$ 의 확률로 발생)
- 표기: $X \sim \text{Bernoulli}(p)$
- 시행 결과를 x 으로 표시할 때, $x = 1$ 일 확률이 p 이면 $x = 0$ 일 확률은 $1 - p$.

$$P(X = x) = \begin{cases} p & x = 1 \text{일 때} \\ 1 - p & x = 0 \text{일 때} \end{cases} = p^x(1 - p)^{1-x}$$



균등 분포(Uniform distribution)

- 확률 변수가 가질 수 있는 모든 값을 취할 가능성이 동일한 경우에 대한 확률 분포
- 확률 변수 X 가 1부터 n 까지의 값 중 한 값을 동일한 확률로 취할 수 있는 경우 $P(X = i) = \frac{1}{n}$, $i \in \{1, 2, \dots, n\}$ 이며 이 상황을 $X \sim U(n)$ 와 같이 표기
- 그림 참고(오른쪽): $n = 5$, $p = 0.2$




확률 분포 (Probability Distributions)

베르누이 분포(Bernoulli distribution)


- 한 개의 이진 확률 변수에 대한 확률 분포
- 시행 결과 두 가지 값 중 한 값이 관찰되며, 하나의 결과는 p 의 확률로 발생 (다른 결과는 $1 - p$ 의 확률로 발생)
- 표기: $X \sim \text{Bernoulli}(p)$
- 시행 결과를 x 으로 표시할 때, $x = 1$ 일 확률이 p 이면 $x = 0$ 일 확률은 $1 - p$.

$$P(X = x) = \begin{cases} p & x = 1 \text{일 때} \\ 1 - p & x = 0 \text{일 때} \end{cases} = p^x(1 - p)^{1-x}$$



균등 분포(Uniform distribution)



- 확률 변수가 가질 수 있는 모든 값을 취할 가능성이 동일한 경우에 대한 확률 분포
- 확률 변수 X 가 1부터 n 까지의 값 중 한 값을 동일한 확률로 취할 수 있는 경우 $P(X = i) = \frac{1}{n}$, $i \in \{1, 2, \dots, n\}$ 이며 이 상황을 $X \sim U(n)$ 와 같이 표기
- 그림 참고(오른쪽): $n = 5$, $p = 0.2$



확률분포(Probability Distributions)

- 가우시안 분포(Gaussian distribution) 혹은 정규 분포(Normal distribution)
 - 평균 μ , 분산 σ^2 를 이용하여 정의됨
 - 표기: $X \sim \mathcal{N}(\mu, \sigma^2)$
 - 확률 밀도함수 표기:

$$P_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$



질문 및 정리

