

CHAPTER 1

로지스틱 회귀 1

성명 : 최승호

이메일 : jcn99250@naver.com

학습 목표

- 선형회귀 중요 내용
- 분류 기초
 - 분류의 정의
 - 특징 벡터와 특징 공간
 - 분류 규칙
- 선형 판별 함수
 - 선형 판별 함수의 이해
 - 선형 구분 가능성과 분류
- 로지스틱 함수의 특성

선형회귀 복습

단순 선형회귀

$$\hat{y}_i = w_0 + w_1 x_i$$

- 실수 x_i 는 입력, w_0, w_1 는 모델의 동작을 결정하는 인자
- 함수의 목표 : 주어진 학습 데이터를 이용하여 손실함수 $L(\mathbf{w})$ 를 최소화하는 $\mathbf{w}$ 를 탐색

$$L(\mathbf{w}) = \frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2$$

- 경사하강법 : $L(\mathbf{w})$ 를 최소화하는 $\mathbf{w}$ 를 탐색하는 방법($\mathbf{w}^* = \underset{\mathbf{w}}{\operatorname{argmin}} L(\mathbf{w})$)

$$w_0 \leftarrow w_0 - \alpha \frac{\partial L(\mathbf{w})}{\partial w_0}$$

$$w_1 \leftarrow w_1 - \alpha \frac{\partial L(\mathbf{w})}{\partial w_1}$$

다중 선형회귀

- 입력 $\mathbf{x}_i = [x_{i1} \ \dots \ x_{id}]^T$ 에 대하여, $\hat{y}_i = w_0 + w_1 x_{i1} + \dots + w_d x_{id}$
- 그런데 바이어스에 해당하는 특징 벡터의 성분을 1로 표시하면 $[1 \ x_{i1} \ \dots \ x_{id}]^T$ 로 특징벡터를 표기할 수 있고, 모델의 인자는 $\mathbf{w} = [w_0 \ \dots \ w_d]^T$ 로 표기할 수 있으므로 $\hat{y}_i = \mathbf{w}^T \mathbf{x}_i$ 의 형태로 다중 선형회귀를 표시 가능

분류의 정의

분류(Classification)

- 특성 값의 집합으로 설명되는 개체의 소속 클래스 / 카테고리를 예측하는 작업
- 분류 작업에서는 사전에 클래스 / 카테고리가 식별되며, 모든 개체가 어느 한 클래스 / 카테고리에 속한다고 가정
- 주어진 관측 값은 동일한 특징의 집합으로 설명됨
- 분류 문제의 학습 데이터는 아래의 형태로 주어진다.

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N, y_i \in \{C_1, C_2, \dots, C_K\}$$

- ✓ 데이터를 구성하는 i 번째 관측 값은 특징 벡터 $\mathbf{x}_i$ 와 클래스 / 카테고리 정보 y_i 로 구성
- ✓ K 는 클래스의 개수를 의미
- ✓ 만약 총 2개의 클래스가 존재하는 도메인에 대하여 관측하였다면 예를 들어 $C_1 = 1, C_2 = 0$ 의 형태로 구체적인 클래스를 표시. 즉, y_i 는 i 번째 관측 값이 속한 클래스 / 카테고리의 레이블 정보를 담고 있음

※ 메일을 “스팸메일”과 “스팸이 아닌 메일”로 분류할 경우 “스팸메일” 클래스를 C_1 으로 “스팸이 아닌 메일” 클래스를 C_2 로 표현한다. 그런데, 학습 데이터를 표기할 때는 구체적인 숫자를 사용하는 것이 편리하므로, 실제 데이터를 관리할 때는 C_1 클래스를 1이라는 값으로, C_2 클래스를 0이란 값으로 표기

특징 벡터와 특징 공간 (1/2)

관측된 특징 값들의 집합이 데이터를 구성함

- 예제 : “대학생”을 관측하는 경우

- ✓ 대학생을 “학과”와 “평점”으로 관측할 경우, “인공지능학과”에 재학 중이며 “평점”이 3.8인 “홍길동”이라는 개체를 (인공지능학과, 3.8)이라는 형태로 설명할 수도 있음.
- ✓ 컴퓨터의 동작 편의를 위하여 “학과”라는 클래스 정보를 숫자로 표현 → “인공지능학과”를 숫자 1, “기계공학과”를 숫자 2, “수학과”를 숫자 3, “물리학과”를 숫자 4로 표시할 경우 “홍길동” 개체를 $[1 \ 3.8]^T$ 이라는 벡터 형태로 표현 가능


특징 벡터(feature vector)

- 특정 대학에 재학 중인 모든 학생을 “학과”와 “평점”으로 설명할 경우, 개별 학생의 “학과”와 “평점”이라는 정보를 2개의 성분으로 구성된 벡터로 표현할 수 있음
- 모든 개체를 동일한 특징으로 설명하게 되면, 개별 관측 값이 하나의 벡터 형태로 표현되는데, 이와 같은 벡터 형태의 표현 형태를 “특징 벡터”라고 호칭
- 예제 : “인공지능학과”에 재학 중이며 “평점”이 3.8인 “홍길동” 개체는 $[1 \ 3.8]^T$ 의 특징 벡터 형태로 표현되며, “수학과”에 재학 중이고 “평점”이 4.0인 “성춘향” 개체는 $[3 \ 4.0]^T$ 의 특징 벡터 형태로 표현됨

특징 벡터와 특징 공간 (2/2)

특징 공간(feature space)

- 특징 벡터를 사용하면, 개별 관측 값을 특징 벡터의 성분의 개수와 동일한 차원의 공간에 존재하는 하나의 점으로 표시 가능
- 예제 : “홍길동” 개체와 “성춘향” 개체의 경우 각각 $[1 \ 3.8]^T$, $[3 \ 4.0]^T$ 의 특징 벡터로 표현되며 두 개의 특징 벡터는 우측의 그림처럼 표현 가능
- 관측 값이 d 개의 성분으로 구성된 특징 벡터로 표시될 경우 모든 특징 벡터를 d 차원의 공간에 표시할 수 있는데, 특징 벡터들이 표시되는 공간을 “특징 공간”이라고 호칭



분류 규칙 (1/3)

특징 공간에서의 분류

- 예제 : “인공지능학과”와 “수학과” 학생의 “정수론” 과목 수강 여부(“학과”와 “평점”의 특징 사용)

✓ “인공지능학과”에 재학 중인 3명의 학생의 특징 벡터 : $\mathbf{x}_1 = [1 \ 2.2]^T$, $\mathbf{x}_2 = [1 \ 3.8]^T$, $\mathbf{x}_3 = [1 \ 3.9]^T$

✓ “수학과”에 재학 중인 3명의 학생의 특징 벡터 :

$\mathbf{x}_4 = [3 \ 2.2]^T$, $\mathbf{x}_5 = [3 \ 4.0]^T$, $\mathbf{x}_6 = [3 \ 3.2]^T$


✓ “정수론”이라는 과목의 수강 여부를 조사한 결과 인공지능학과 재학생은 수강하지 않으며, 수학과 재학생은 수강. 수강을 1, 미수강을 0의 값으로 표현하면 아래와 같이 데이터가 구성됨

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^6 = \left\{ ([1 \ 2.2]^T, 0), ([1 \ 3.8]^T, 0), ([1 \ 3.9]^T, 0), ([3 \ 2.2]^T, 1), ([3 \ 4.0]^T, 1), ([3 \ 3.2]^T, 1) \right\}$$

✓ “정수론”과목의 수강생을 파란색 원으로, 미수강생을 주황색

원으로 표시할 경우 오른쪽 그림과 같이 표시되며,

“구분선 1” 혹은 “구분선 2”를 이용하여 수강생과 미수강생을 구분할 수 있음




분류 규칙 (2/3)

확률 분포를 활용한 분류

– 예제 : “체조 동아리 회원”과 “체조 동아리 비회원”

- ✓ A대학교의 “체조” 동아리에 속한 학생들과 해당 동아리에 속하지 않은 학생들의 몸무게를 조사한 결과 몸무게의 분포가 아래의 히스토그램과 같이 주어졌다고 가정



분류 규칙 (3/3)

확률 분포를 활용한 분류

- 질문 : “체조 동아리 회원과 비회원” 예제에서 몸무게 52kg인 학생이 체조 동아리 소속인지 여부를 판단할 수 있는 방법은?

- ✓ 표기 : “체조 동아리 회원”과 “체조 동아리 비회원”라는 클래스를 각각 C_1 , C_2 로 표기하고, 몸무게 52kg인 관측 값을 x 라고 표기
- ✓ 사후확률의 활용 : $P(C_1|x)$ 와 $P(C_2|x)$ 의 비교
- ✓ 베이즈 규칙에 의하면

$$P(C_1|x) = \frac{P(C_1, x)}{P(x)} = \frac{P(C_1, x)}{P(C_1, x) + P(C_2, x)} = \frac{P(x|C_1)P(C_1)}{P(x|C_1)P(C_1) + P(x|C_2)P(C_2)}$$
$$P(C_2|x) = 1 - P(C_1|x)$$

※ 사후 확률(Posterior probability)은 조건부 확률인데, $P(C_1|x)$ 는 x 를 관찰하였을 때(혹은 x 가 주어졌을 때) x 의 소속 클래스로 C_1 이 가능할 / 성립할 정도를 수치로 표현한 값

- ✓ 분류 규칙
 - $P(C_1|x) > P(C_2|x)$, 즉 $P(C_1|x) > 0.5$ ($P(C_1|x) > 1 - P(C_1|x)$)이면 x 의 동아리를 C_1 으로 그 외의 경우에는 C_2 로 결정
- ✓ 사후 확률을 비교하기 위해서는 $P(C_1)$, $P(C_2)$, $P(x|C_1)$, $P(x|C_2)$ 의 정보가 필요

선형 판별함수의 이해 (3/3)

정의

- 분류를 위한 선형판별함수는 아래의 형태로 정의됨

$$g(\mathbf{x}) = \mathbf{w} \cdot \mathbf{x} = \mathbf{w}^T \mathbf{x}$$

- ✓ 여기서 $\mathbf{x}$ 는 $d + 1$ 개의 성분으로 구성된 특징 벡터(바이어스에 해당하는 성분의 값을 1로 고정), $\mathbf{w}$ 는 $d + 1$ 개의 성분으로 구성된 가중치 벡터
- ✓ $\mathbf{w} \cdot \mathbf{x}$ 와 $\mathbf{w}^T \mathbf{x}$ 는 모두 벡터 $\mathbf{w}$ 와 $\mathbf{x}$ 의 내적 연산을 의미

이진 분류(binary classification)

- 특징 벡터로 표현된 개체들이 C_1 과 C_2 의 2개의 클래스 중 한 클래스에 속하는 분류 문제
- 선형판별함수 $g(\mathbf{x})$ 가 확보된 경우, 특징 벡터 $\mathbf{x}$ 에 대하여 $g(\mathbf{x}) > 0$ 이면 C_1 으로, 그 외 경우에는 C_2 로 개체 $\mathbf{x}$ 의 소속 클래스를 결정

참고

내적 연산의 활용

$$g(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$$

$\mathbf{w} = [w_0 \quad w_1 \quad w_2 \quad w_3]^T$ (여기서 w_0, w_1, w_2, w_3 은 모두 실수),



$\mathbf{x} = [x_0 \quad x_1 \quad x_2 \quad x_3]^T$ (여기서 x_1, x_2, x_3 은 모두 실수이고 $x_0 = 1$)라고 하면

$$\mathbf{w}^T \mathbf{x} = w_0 + w_1 x_1 + w_2 x_2 + w_3 x_3$$

선형판별함수의 이해 (2/3)

선형판별함수와 분류


- 분류를 위하여 사용되는 기계학습 모델에서는 분류에 도움이 되도록 특징 공간을 분할
- 선형판별함수에 의한 특징 공간의 분할
 - ✓ 특징 공간이 1차원일 경우 점(point)에 의해 특징 공간을 분할
 - ✓ 특징 공간이 2차원일 경우 선(line)에 의해 특징 공간을 분할
 - ✓ 특징 공간이 3차원일 경우 평면(plane)에 의해 특징 공간 분할
 - ✓ 특징 공간이 4차원 이상의 고차원일 경우 초평면(hyperplane)에 의해 특징 공간 분할



선형판별함수의 이해 (3/3)

예제 : “정수론” 수강생(9번 슬라이드 예제)

- “학과”와 “학점”이라는 2개의 특징을 사용하는 상황
- 특징 벡터 $\mathbf{x} = [x_1 \ x_2]^T$ 에서 x_1 이 “학과”, x_2 가 “학점”을 나타낸다고 가정할 경우, $g(\mathbf{x})$ 의 값을 0으로 설정하면 즉 $g(\mathbf{x}) = 20x_1 + 3x_2 - 36 = 0$ 으로 구분선을 표현 가능 ($\mathbf{w} = [-36 \ 20 \ 3]^T$)
- $g(\mathbf{x})$ ($g(\mathbf{x}) = 20x_1 + 3x_2 - 36$)에 $\mathbf{x}_2 = [1 \ 3.8]^T$, $\mathbf{x}_4 = [3 \ 2.2]^T$ 를 대입하면 $g(\mathbf{x}_2) < 0$, $g(\mathbf{x}_4) > 0$.
 $g(\mathbf{x})$ 를 사용하면 “정수론” 수강 관점에서 $\mathbf{x}_2$ 와 $\mathbf{x}_4$ 를 구분 가능
- 정리 : $g(\mathbf{x}) = 0$ 이 “정수론”을 수강하는 학생들과 수강하지 않는 학생들이 모여 있는 공간으로 특징 공간을 분할하며, $g(\mathbf{x})$ 의 부호를 이용하여 “정수론” 학생의 수강생과 미수강생을 구분 가능



선형판별함수를 사용한 소속 클래스 예측

소속 클래스를 모르는 관측 값 x' 이 주어졌을 때 x' 의 소속 클래스 예측 절차

- 절차 1(학습) : 주어진 학습데이터 $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N, y_i \in \{0,1\}$ 를 이용하여 선형판별함수 $g(x) = w^T x$ 의 구체적인 인자(w^*)를 결정
- 절차 2(예측) : 절차 1에서 확보한 w^* 를 적용하였을 때 $g(x') > 0$ 이면 C_1 으로, 그 외 경우에는 C_2 로 x' 의 소속 클래스를 예측

기계학습과 분류

- 선형 판별 함수를 사용하여 분류를 수행하는 기계학습 모델에서는 선형 판별 함수의 동작을 결정하는 w 를 다양한 접근법을 통하여 결정

선형 구분 가능성과 분류

선형 구분 가능성(linear separability)

- N 개의 관측 값 ($\{(x_i, y_i)\}_{i=1}^N, y_i \in \{0,1\}$)이 주어진 상황에서 $g(x) = \mathbf{w}^T \mathbf{x}$ 로 표시되는 선형 판별 함수를 이용하여 두 클래스에 속하는 관측 값을 정확하게 구분할 수 있을 때 $\{(x_i, y_i)\}_{i=1}^N$ 가 “선형 구분 가능하다(linearly separable)”고 표현
- 정확한 구분 : 한 클래스에 속하는 모든 개체의 관측 값에 대하여 $g(x) > 0$, 다른 클래스에 속하는 모든 개체의 관측 값에 대하여 $g(x) < 0$ 으로 계산될 경우 “정확하게 구분”된다고 표현

초평면(hyperplane)

- N 개의 관측 값의 집합($\{(x_i, y_i)\}_{i=1}^N, y_i \in \{0,1\}$)이 선형 구분 가능할 경우 두 클래스를 구분하는 $g(x) = 0$ 은 특징 벡터를 구성하는 성분의 수에 따라 선, 평면, 초평면(hyperplane)을 표현

특징 공간의 분할

- 선형 구분 가능할 경우 선, 평면, 초평면은 특징 공간을 2개로 분할하게 됨

로지스틱 함수 (1/2)


정의

- 로지스틱 함수는 (1) 정의역을 0과 1사이의 값으로 사상해주며 (2) 미분 가능하다는 특징을 보유하고 있어 기계학습에 많이 사용되는 함수

$$\sigma(x) = \frac{1}{1 + e^{-x}} = \frac{e^x}{1 + e^x}$$

- 미분형태

$$\begin{aligned}\frac{d}{dx} \sigma(x) &= \frac{e^x(1 + e^x) - e^x \cdot e^x}{(1 + e^x)^2} = \frac{e^x}{(1 + e^x)^2} \\ &= \frac{e^x}{(1 + e^x)} \cdot \frac{1}{1 + e^x} = \frac{e^x}{(1 + e^x)} \left(1 - \frac{e^x}{(1 + e^x)}\right) \\ &= \sigma(x)(1 - \sigma(x))\end{aligned}$$



로지스틱 함수의 그래프

로지스틱 함수 (2/2)

로지스틱 함수의 활용 1

- 특정 사건이 발생할 확률을 표현
- 로지스틱 함수는 0과 1사이의 값을 출력하기 때문에 정의역에 해당하는 확률 변수의 값에 따라 특정 카테고리가 발생할 확률을 표현하는데 활용(로지스틱 회귀)

로지스틱 함수의 활용 2

- 인공신경망의 연산 과정에서 활성화 함수(activation function)로 활용
- 로지스틱 함수 및 로지스틱 함수의 미분 형태가 모두 중요하게 사용됨

질문 및 정리

