

CHAPTER 1

선형 회귀

성명 : 최승호

이메일 : jcn99250@naver.com


학습 목표

- 회귀의 주요 개념
 - 회귀와 분류문제, 회귀 예시, 회귀의 정의, 데이터 셋, 회귀의 목적, 회귀 함수
- 단순 선형 회귀 및 손실함수 (모델 정의, 손실함수)
- 단순 선형 회귀의 학습 방법 (경사하강법)
- 다중 선형 회귀

회귀 문제와 분류 문제

- 예시:


- 회귀 : 가까운 정도(거리)를 색깔로 표현함 (파란색이면 가까운 곳, 빨간색이면 거리가 먼 곳등)
- 분류 : 물체의 종류별로 다른 색깔로 표현함 (각 픽셀별로 구분되는 것으로 세그멘테이션으로 볼 수 있음)



회귀 예시


- 집값 예측 문제 -> 관계 (Relation), 예측 (Prediction)
- (Relation) 집 값 (Price)과 집 크기 (Size)의 관계는 어떻게 되는가?
- (Prediction) 집 크기가 1,202 일 때, 예상되는 집 가격은 어떻게 되는가?

크기(단위 : feet ²)(x)	가격 (단위 : 1,000\$) (y)
2,104	460
1,416	232
1,534	315



회귀 예시

- 회귀(Regression)은
 - 독립 변수(Independent variable)와 종속 변수(Dependent variable)간의 관계를 분석
 - 새로운 입력 값(Input)에 대한 출력 값(Output)을 예측 (Prediction),
 - 종속 변수에 대한 독립 변수의 효과를 이해하는 것



회귀에서 데이터셋

- 회귀에서 데이터셋은 아래와 같이 표현 (지도학습 데이터셋)

$$\{(\mathbf{x}_i, y_i)\}_{i=1}^N$$

- y_i 은 i 번째 실제 값, $\mathbf{x}_i$ 은 i 번째의 특징 벡터로 d 차원의 벡터 형식으로 표현된 입력 값이다.

- N 은 전체 관측 값의 수(데이터셋의 크기)를 의미

- d 는 관측 값을 구성하는 특징의 수, 특징벡터의 차원.

* $\mathbf{x}_i = [x_{i1} \ x_{i2} \ x_{i3} \ \dots \ x_{ij} \ \dots \ x_{id}]^T \in \mathbb{R}^d$

- i^{th} 번째 관측 값의 특징 벡터: $\mathbf{x}_i$

- i^{th} 번째 관측 값의 j 번째 특징 값(Feature): x_{ij}

* y_i 는 스칼라 값($y_i \in \mathbb{R}$)이라고 하자.
(벡터형식으로 표현된 다변량 변수 y_i 도
가능하나 이 챕터에서는 스칼라 값으로 한정)


- 참고
 - 입력 변수 (Input variable)는 특징 (Features), 독립변수 (Independent variable)등으로도 표현
 - 출력 변수(Output variable)는 종속 변수(Dependent variable)라고도 표현

회귀의 두가지 목적

- (예측 측면) 새로운 입력 값에 대한 출력 값을 예측하는 것
 - 예시 : 키가 170cm 인 사람의 몸무게는 얼마인가?
- (해석 또는 관계 측면) 입력 값에 대한 출력 값의 변화는 어떻게 되는가?
 - 예시 : 키가 큰 사람은 몸무게가 무거운가?



회귀에서의 학습

- 입력 값이 주어졌을 때, 적합한 출력 값을 내는 함수(Function)을 찾는 과정
- 독립변수와 종속변수간의 관계를 표현하는 함수를 찾는 과정



참고 : 상관 관계(correlation) 는 인과관계와 같지 않음

- 회귀는 상관관계를 찾는 것으로 인과 관계를 의미하지 않음
- 따라서 해석할때 ,인과 관계로 해석해서는 안됨



단순 선형 회귀 (Simple Linear Regression)

- 입력 값의 차원이 1개 일때, 아래와 같은 식(함수 또는 모델)을 단순 선형 회귀라 함


$$y_i \approx \underline{f(x_i)} = f_{\mathbf{w}}(x_i) = w_0 + w_1 x_i$$

$f(x_i)$ 를 $\hat{y}_i$ 으로 표기하기도 함.

* $\mathbf{x}_i = [x_{i1} \ x_{i2} \ x_{i3} \ \dots \ x_{ij} \ \dots \ x_{id}]^T \in \mathbb{R}^d$ 에서 차원 d 가 1로
 $\mathbf{x}_i = [x_{i1}] = x_i \in \mathbb{R}$ 로 하자.
 $\mathbf{w} = [w_0 \ w_1]^T$ 라고 하자. (단순 선형 회귀)

- 여기서, $\mathbf{w} = [w_0 \ w_1]^T$ 는 파라미터(매개변수)들의 벡터로 2개의 파라미터를 갖는다.
→ 또 다른 말로 가중치라고 하기도 함

단순 선형 회귀 모델 $f_{\mathbf{w}}(x_i) = w_0 + w_1 x_i$ 는 독립변수와 종속변수간의 관계를 아래의 그림과 같이 표현



손실 함수(Cost function 또는 Loss function)


- 집 값(Price)에 대한 훈련 데이터셋

크기(단위 : feet ²)(x)	가격 (단위 : 1,000\$) (y)
2,104	460
1,416	232
1,534	315

- 모델은 $y_i \approx f(x_i) = f_{\mathbf{w}}(x_i) = w_0 + w_1 x_i$ 로 즉 단순 선형 회귀 모델로 선정
- 훈련 데이터가 주어졌을때, $\mathbf{w} = [w_0 \ w_1]^T$ 의 값을 어떻게 설정할 수 있을까?

손실 함수(Cost function 또는 Loss function)

- 핵심 아이디어 : 훈련 데이터 $\{(x_i, y_i)\}_{i=1}^N$ 를 이용하여 $f_{\mathbf{w}}(x_i)$ 가 y_i 값에 가깝도록, $\mathbf{w} = [w_0 \ w_1]^T$ 을 정하는 것



$$L(\mathbf{w}) = \frac{1}{N} \sum_{i=1}^N (f_{\mathbf{w}}(x_i) - y_i)^2$$

$$\mathbf{w}^* = \underset{\mathbf{w}}{\operatorname{argmin}} L(\mathbf{w})$$

$$\underset{\mathbf{w}}{\operatorname{argmin}} \frac{1}{N} \sum_{i=1}^N (f_{\mathbf{w}}(x_i) - y_i)^2$$

손실 함수(Cost function 또는 Loss function)

- 손실 함수 (비용 함수, 훈련 목적 함수 등)는 모델의 파라미터 $\mathbf{w} = [w_0 \ w_1]^T$ 를 학습 할때 사용 함
- 손실함수 $L(\mathbf{w})$ 를 작게 할 수록, 훈련 데이터에 대해 모델이 예측한 출력 값 $f_{\mathbf{w}}(x_i)$ 이 실제 값 y_i 과 유사하다는 것을 의미함

손실 함수 (예시)

- Model:

$$f_{\mathbf{w}}(x) = w_0 + w_1 x$$

- Parameters:

$$\mathbf{w} = [w_0 \ w_1]^T$$

- Cost function:

$$L(\mathbf{w}) = \frac{1}{N} \sum_{i=1}^N (f_{\mathbf{w}}(x_i) - y_i)^2$$

- Goal:

$$\mathbf{w}^* = \underset{\mathbf{w}}{\operatorname{argmin}} L(\mathbf{w})$$

- Model:

$$f_{\mathbf{w}}(x) = w_1 x \quad (w_0 = 0)$$

- Parameters:

$$w_1$$

- Cost function:


$$L(w_1) = \frac{1}{N} \sum_{i=1}^N (f_{w_1}(x_i) - y_i)^2$$

- Goal:


$$w_1^* = \underset{w_1}{\operatorname{argmin}} L(w_1)$$

손실 함수 (예시)

$f_{w_1}(x) = w_1 x$ ($w_0 = 0$)
(w_1 이 고정된 경우, x 의 함수)




$L(w_1)$
(매개변수 w_1 의 함수)



손실 함수 (예시)


$$f_w(x) = w_0 + w_1 x$$

(w 가 고정된 경우, x 의 함수)




$$L(w)$$

(매개 변수 w 의 함수)



<수업시간 때 도식>


손실 함수 (예시)




* $\mathbf{w} = [w_0 \ w_1]^T$

손실 함수 (예시)

$f_w(x)$
(w 가 고정된 경우, x 의 함수)




$L(w)$
(매개변수 w 의 함수)




손실 함수 (예시)

$f_w(x)$
(w 가 고정된 경우, x 의 함수)




$L(w)$
(매개변수 w 의 함수)




손실 함수 (예시)

$f_w(x)$
(w 가 고정된 경우, x 의 함수)




$L(w)$
(매개변수 w 의 함수)




손실 함수 (예시)

$f_w(x)$
(w 가 고정된 경우, x 의 함수)



$L(w)$
(매개변수 w 의 함수)



손실 함수 (예시)

평균 제곱 오차 (Mean square error, MSE)

$$\frac{1}{N} \sum_{i=1}^N (f_{\mathbf{w}}(x_i) - y_i)^2$$

평균 절대 오차 (Mean absolute error, MAE)

$$\frac{1}{N} \sum_{i=1}^N |f_{\mathbf{w}}(x_i) - y_i|$$

이외에도 다양한 손실함수가 존재하지만 대표적으로 MSE, MAE가 있다.

경사하강법 (Gradient descent)

- 모델의 학습 방법으로 손실함수 $L(\mathbf{w})$ 가 주어졌을 때, 손실함수를 가장 최소화하는 파라미터


$\mathbf{w}^* = [w_0^* \ w_1^*]^T$ 를 찾는 것

$$\mathbf{w}^* = \underset{\mathbf{w}}{\operatorname{argmin}} L(\mathbf{w})$$

- 가장 간단한 방법으로 파라미터 $\mathbf{w} = [w_0 \ w_1]^T$ 에 넣을 후보 값을 몇 개 정하고, 각 후보 값을 모델에 학습 시켰을 때, 손실함수 값이 가장 작은 파라미터를 선정한다. 하지만 이 방법은 후보 값을 정하는 것이 쉽지 않음


경사하강법 (Gradient descent)

- 손실함수 $L(\mathbf{w})$ 가 주어졌을때, $\mathbf{w}^* = \underset{\mathbf{w}}{\operatorname{argmin}} L(\mathbf{w})$ 를 찾는 것이 목표



경사하강법 (Gradient descent)

- 손실함수 $L(\mathbf{w})$ 가 주어졌을때, $\mathbf{w}^* = \underset{\mathbf{w}}{\operatorname{argmin}} L(\mathbf{w})$ 를 찾는 것이 목표
- 기울기(Gradient) 이용 : (한 지점에서의) 기울기는 함수의 접선 기울기
- 이 기울기는 함수를 가장 최대로 증가시키는 방향을 나타냄
- 따라서 현재 지점 ($\mathbf{w} = [w_0 \ w_1]^T$)에서의 음의 기울기 방향 $-\frac{\partial}{\partial \mathbf{w}} L(\mathbf{w})$ 은 손실함수 $L(\mathbf{w})$ 를 최대로 감소시키는 방향을 의미하고 경사하강 (gradient descent)의 방향이라고 함



경사하강법 (Gradient descent)


- 손실함수 $L(\mathbf{w})$ 가 주어졌을때, $\mathbf{w}^* = \underset{\mathbf{w}}{\operatorname{argmin}} L(\mathbf{w})$ 를 찾는 것이 목표
- 절차:
 - (1) 초기 값 $\mathbf{w} = [w_0 \ w_1]^T$ 에서 시작한다. (예를 들어 $w_0 = 0, w_1 = 1$)
 - (2) 종료조건을 만족할 때까지 $L(\mathbf{w})$ 를 감소하는 방향으로 $\mathbf{w} = [w_0 \ w_1]^T$ 를 반복적으로 업데이트 함

경사하강법 (Gradient descent)

Q1: w 는 어디에서 시작하는가?

Q2: 어느 방향으로 w 를 업데이트 하는가?

Q3: w 를 업데이트 할 때, 얼마큼 움직이는가?




경사하강법 (Gradient descent)

Q1: w 는 어디에서 시작하는가? → 초기화(Initialization)


Q2: 어느 방향으로 w 를 업데이트 하는가? → 기울기(Gradient)

Q3: w 를 업데이트 할 때, 얼마큼 움직이는가? → 학습률(Learning rate)



경사하강법 (Gradient descent)

- W 의 최초 값에 따라 탐색 결과가 틀려 질 수 있다
- 따라서 w 의 초기 상태도 중요한 이슈 중에 하나이다.



경사하강법 (Gradient descent)

- 경사하강법 알고리즘

종료조건을 만족할 때까지 아래 과정을 반복한다. ← 예시) for loop, while loop, ...


{

$$w_0 \leftarrow w_0 - \alpha \frac{\partial}{\partial w_0} L(w_0, w_1)$$

Annotations:
- 학습률 (Learning rate) points to α
- 기울기 (Gradient) points to $\frac{\partial}{\partial w_0} L(w_0, w_1)$
- w의 현재 상태 (Current state of w) points to w_0 in the term $L(w_0, w_1)$


}

$$w_1 \leftarrow w_1 - \alpha \frac{\partial}{\partial w_1} L(w_0, w_1)$$




참고-기울기 계산(Computing Gradients)

- 기울기 계산법 (고등학교 미분학 참고)



경사하강법의 특성



$$w_1 \leftarrow w_1 - \alpha \frac{\partial}{\partial w_1} L(w_0, w_1)$$

$$w_1 \leftarrow w_1 - \alpha(\text{positive number})$$


$$w_1 \leftarrow w_1 - \alpha(\text{negative number})$$

경사하강법의 특성


$$w_1 \leftarrow w_1 - \alpha \frac{\partial}{\partial w_1} L(w_0, w_1)$$

α 가 너무 작으면, 경사 하강이 천천히 발생함.

α 가 너무 크면, 수렴되지 않고 발산 등이 됨.



경사하강법의 한계점



$$w_1 \leftarrow w_1 - \alpha \frac{\partial}{\partial w_1} L(w_0, w_1)$$

$$w_1 \leftarrow w_1 - \alpha(0)$$

다중 선형 회귀 (Multiple linear regression)

크기 (단위:feet ²)	방의 수	총 수	집 연식 (단위:year)	가격 (단위 : \$1000)
2,104	5	1	45	460
1,416	3	2	40	232
1,534	3	2	30	315
852	2	1	36	178
...	...	...	...	...


$$\mathbf{x}_i = [x_{i1} \ x_{i2} \ \dots \ x_{ij} \ \dots \ x_{id}]^T$$


$$y_i$$

i^{th} 번째 훈련데이터의 입력 값: $\mathbf{x}_i$

i^{th} 번째 훈련데이터 입력 값의 j 번째 특징 값(feature): x_{ij}

다중 선형 회귀 (Multiple linear regression)

매핑 함수 (Mapping Function)

* $\mathbf{x}_i = [x_{i1} \ x_{i2} \ x_{i3} \ \dots \ x_{ij} \ \dots \ x_{id}]^T \in \mathbb{R}^d$ 에서 차원 d 가 1로

- **단순 선형 회귀**: $f_{\mathbf{w}}(\mathbf{x}_i) = w_0 + w_1 x_i$ $\mathbf{x}_i = [x_{i1}] = x_i \in \mathbb{R}$ 로 하자. (i 의 의미는 i 번째 데이터셋)
 $\mathbf{w} = [w_0 \ w_1]^T$ 라고 하자. (단순 선형 회귀)
- **다중 선형 회귀**: $f_{\mathbf{w}}(\mathbf{x}_i) = w_0 + w_1 x_{i1} + w_2 x_{i2} + w_3 x_{i3} + w_4 x_{i4}$

e.g., $f_{\mathbf{w}}(\mathbf{x}_i) = 80 + 0.1 x_{i1} + 0.01 x_{i2} + 5 x_{i3} - 2 x_{i4}$

다중 선형 회귀 (Multiple linear regression)

매핑 함수 (Mapping Function)

$$f_{\mathbf{w}}(\mathbf{x}_i) = w_0 + w_1 x_{i1} + w_2 x_{i2} + w_3 x_{i3} + w_4 x_{i4}$$

간편한 표기를 위해서, $x_{i0} = 1$ 로 정의하자.

$$\mathbf{x}_i = [x_{i0} \ x_{i1} \ \dots \ x_{ij} \ \dots \ x_{id}]^T \in \mathbb{R}^{d+1},$$

$$\mathbf{w} = [w_0 \ w_1 \ \dots \ w_j \ \dots \ w_d]^T \in \mathbb{R}^{d+1}$$

$$f_{\mathbf{w}}(\mathbf{x}_i) = \mathbf{w}^T \mathbf{x}_i$$

※ 이를 다중 선형 회귀 (Multiple Linear Regression)라고 한다.

다중 선형 회귀 (Multiple linear regression)

매핑 함수(Mapping Function)

$$f_{\mathbf{w}}(\mathbf{x}_i) = \mathbf{w}^T \mathbf{x}_i$$

파라미터(Parameters) $\mathbf{w} = [w_0 \ w_1 \ \dots \ w_j \ \dots \ w_d]^T \in \mathbb{R}^{d+1}$

손실함수:

$$L(\mathbf{w}) = \frac{1}{N} \sum_{i=1}^N (f_{\mathbf{w}}(\mathbf{x}_i) - y_i)^2$$

다중 선형 회귀 (Multiple linear regression)

- 단순선형회귀:

Repeat{

$$w_0 \leftarrow w_0 - \alpha \frac{\partial}{\partial w_0} L(w_0, w_1)$$

$$w_1 \leftarrow w_1 - \alpha \frac{\partial}{\partial w_1} L(w_0, w_1)$$

}

- 다중 선형 회귀:

Repeat{

$$w_j \leftarrow w_j - \alpha \frac{\partial}{\partial w_j} L(\mathbf{w})$$

$$\leftarrow w_j - \alpha \frac{\partial}{\partial w_j} \left(\frac{1}{N} \sum_{i=1}^N (f_{\mathbf{w}}(\mathbf{x}_i) - y_i)^2 \right)$$

$$\leftarrow w_j - \alpha \frac{2}{N} \sum_{i=1}^N (f_{\mathbf{w}}(\mathbf{x}_i) - y_i) x_{ij}$$

}

질문 및 정리

