

CHAPTER 1

로지스틱 회귀 2

성명 : 최승호

이메일 : jcn99250@naver.com

학습 목표

- 복습
 - 로지스틱 회귀 1부 내용 복습
- 로지스틱 회귀와 이진 분류
 - 로그 오드
 - 이진 분류에서의 접근
- 로지스틱 회귀의 모델 학습
 - 이진 분류와 베르누이 분포
 - 모델 학습

로지스틱 회귀 1부 복습

이진 분류

- 모든 개체가 클래스 C_1 혹은 C_2 에 속하는 상황
- 접근법 1 : 클래스 C_1 과 C_2 에 속하는 개체들을 구분할 수 있도록 특징 공간을 분할
- 접근법 2 : $P(C_1|\mathbf{x})$ 와 $P(C_2|\mathbf{x})$ 를 비교하여 클래스 / 카테고리 레이블 결정
 - ✓ C_1 클래스의 레이블을 1, C_2 클래스의 레이블을 0으로 표시할 경우 특징 벡터 $\mathbf{x}$ 에 대하여 $P(C_1|\mathbf{x})$ 과 $P(C_2|\mathbf{x}) = 1 - P(C_1|\mathbf{x})$ 을 비교
 - ✓ $P(C_1|\mathbf{x})$ 는 분류 모델에서 주어진 $\mathbf{x}$ 의 클래스 레이블을 1(C_1 클래스)로 예측할 사후확률

선형 판별

- 선형 판별 함수 : $g(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$ ($\mathbf{w}^T = [w_0 \quad \dots \quad w_d]$, $\mathbf{x}^T = [1 \quad x_1 \quad \dots \quad x_d]$)

로지스틱 함수

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

$$\frac{d}{dx} \sigma(x) = \sigma(x)(1 - \sigma(x))$$

로그 오드(Log-odds)

오드(Odds)

- 특정 사건이 p 의 확률로 발생할 때 해당 사건의 오드는 다음 식으로 정의됨:


$$\frac{p}{1-p}$$

- 예 : 모든 눈이 나올 확률이 동일한 공정한 주사위에서 3의 배수가 아닌 눈이 나올 확률은 $2/3$ ($p = 2/3$)이므로, 해당 주사위를 한 번 던졌을 때 3의 배수가 아닌 눈이 나오는 사건의 오드는 2

로그 오드(log-odds)

$$\ln \frac{p}{1-p}$$

- 오드의 로그 값
- 로지스틱 회귀에서는 선형 함수 표현을 이용하여 로그 오드를 근사



<https://en.wikipedia.org/wiki/Logit>

이진 분류에서의 접근

이진 분류

- 모든 개체들이 클래스 C_1 혹은 C_2 에 속하는 상황
 - ✓ 예제 : “스팸메일 여부”, “대학생 여부”
 - ✓ 클래스 레이블을 $\{C_1 = 1, C_2 = 0\}$ 로 표현 가능
- 사후 확률을 계산할 수 있다면 $P(C_1|\mathbf{x})$ 와 $P(C_2|\mathbf{x})$ 를 비교하여 특징 벡터 $\mathbf{x}$ 로 관측된 개체의 클래스를 결정 할 수 있음 : $P(C_1|\mathbf{x}) > 0.5$ 이면 C_1 클래스로 결정
- 특징 벡터 $\mathbf{x}$ 로 관측된 개체가 C_1 에 속할 확률은 $P(C_1|\mathbf{x})$ 로 표현됨
- 특징 벡터 $\mathbf{x}$ 로 관측된 개체가 C_1 에 속할 확률의 로그 오드

$$\ln \frac{P(C_1|\mathbf{x})}{1 - P(C_1|\mathbf{x})}$$

로지스틱 회귀 모델

로지스틱 회귀에서는 로그 오드를 선형 함수 형태로 표현. 즉:

$$\ln \frac{P(C_1|\mathbf{x})}{1 - P(C_1|\mathbf{x})} = \mathbf{w}^T \mathbf{x}$$

$$\ln \frac{P(C_1|\mathbf{x})}{1 - P(C_1|\mathbf{x})} = \mathbf{w}^T \mathbf{x} \text{에서 } \frac{P(C_1|\mathbf{x})}{1 - P(C_1|\mathbf{x})} = e^{\mathbf{w}^T \mathbf{x}}$$

따라서

$$P(C_1|\mathbf{x}) = \frac{e^{\mathbf{w}^T \mathbf{x}}}{1 + e^{\mathbf{w}^T \mathbf{x}}} = \frac{1}{1 + e^{-\mathbf{w}^T \mathbf{x}}} = \sigma(\mathbf{w}^T \mathbf{x})$$

$$P(C_2|\mathbf{x}) = 1 - P(C_1|\mathbf{x}) = \frac{e^{-\mathbf{w}^T \mathbf{x}}}{1 + e^{-\mathbf{w}^T \mathbf{x}}} = 1 - \sigma(\mathbf{w}^T \mathbf{x})$$

※ 특징 벡터 $\mathbf{x}$ 는 $[x_1 \ \dots \ x_d]^T$ 와 같이 d 개 특징의 관측 값으로 구성되지만, 바이어스를 함께 고려하는 경우 $[1 \ x_1 \ \dots \ x_d]^T$ 처럼 특징 벡터가 표현됨을 이미 살펴보았다.

이진 분류와 베르누이 분포

기억 환기 : 베르누이 분포(Bernoulli distribution)

- 0과 1의 두 값 중 하나의 값을 갖는 이진 확률 변수 X 가 1의 값을 가질 확률이 p (즉, $P(X = 1) = p$, $P(X = 0) = 1 - p$ 일 때), 확률 변수 X 의 확률 분포는 $p^x(1 - p)^{1-x}$, $x \in \{0,1\}$ 의 형태로 표현됨.

이진 분류와 베르누이 분포

- 클래스 / 카테고리 레이블 y_i
 - ✓ 이진 분류의 학습 데이터($\mathcal{D}$)에서는 i 번째 개체의 클래스 / 카테고리 레이블을 y_i 로 표현. 이 때 y_i 에는 1과 0의 값 중 하나의 값이 부여됨(예 : 클래스 C_1 에 속하면 1로 클래스 C_2 에 속하면 0으로 표현)
 - ✓ 이 경우 특징 벡터 $\mathbf{x}_i$ 로 표시된 개체가 클래스 C_1 에 속할 확률은 $P(C_1|\mathbf{x}_i)$ 로 표현되는데 로지스틱 회귀에서는 $\sigma(\mathbf{w}^T \mathbf{x}_i)$ 로 $P(C_1|\mathbf{x}_i)$ 를 근사
- 이진 분류를 위해 사후 확률을 활용하는 경우 학습 데이터를 구성하는 i 번째 개체에 대한 카테고리 레이블 y_i 의 조건부 확률 분포를 다음과 같이 표현 가능:

$$P(y_i|\mathbf{x}_i) = \sigma(\mathbf{w}^T \mathbf{x}_i)^{y_i} (1 - \sigma(\mathbf{w}^T \mathbf{x}_i))^{1-y_i}$$

로지스틱 회귀를 이용한 이진 분류

학습 데이터 : $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N, y_i \in \{0,1\}$

- ※ x_i 가 하나의 실수 값으로 표현되는 상황임에 주의

사후 확률의 표현 : $P(C_1|x_i) = \sigma(w_0 + w_1x_i)$

- 주어진 학습 데이터에 대하여 분류 결과를 변경하는 요소는 인자인 w_0 와 w_1

$$P(y_i|x_i) = \sigma(w_0 + w_1x_i)^{y_i}(1 - \sigma(w_0 + w_1x_i))^{1-y_i}$$

학습 데이터 $\mathcal{D}$ 의 우도(Likelihood), $\ell(w_0, w_1)$ 의 표현

$$\begin{aligned}\ell(w_0, w_1) &= P(y_1|x_1) \times \cdots \times P(y_N|x_N) = \prod_{i=1}^N P(y_i|x_i) \\ &= \prod_{i=1}^N \sigma(w_0 + w_1x_i)^{y_i}(1 - \sigma(w_0 + w_1x_i))^{1-y_i}\end{aligned}$$

Negative log likelihood

$$-\ln \ell(w_0, w_1)$$

※우도(Likelihood)의 해석

1. y_i 의 값이 1이면 $P(y_i = 1|x_i) = \sigma(w_0 + w_1x_i)$, y_i 의 값이 0이면 $P(y_i = 0|x_i) = 1 - \sigma(w_0 + w_1x_i)$ 로 표현됨
2. 따라서, $P(y_i|x_i)$ 는 i 번째 관측 값에 대하여, 현재 모델의 인자 w_0, w_1 로 계산되는 사후 확률을 이용하여 x_i 가 속한 클래스를 정확하게 추정할 확률을 의미
3. 우도 $\ell(w_0, w_1)$ 는 $P(y_i|x_i)$ 의 곱이므로, 큰 값일수록 선호됨
4. $-\ln \ell(w_0, w_1)$ 은 우도 로그값의 음수이므로 작은 값일수록 선호됨

로지스틱 회귀에서의 손실함수 표현

모델 학습 목표 : 우도를 최대화하거나 혹은 Negative log likelihood ($-\ln \ell(w_0, w_1)$)을 최소화하는 w_0, w_1 의 탐색

- $-\ln \ell(w_0, w_1)$ 은 우도의 로그 값의 음수이므로 “우도의 최대화”와 “ $-\ln \ell(w_0, w_1)$ 의 최소화”는 같은 의미

손실함수의 표현

$$\times P(C_1|x_i) = \sigma(w_0 + w_1 x_i)$$

- N 개의 관측값이 존재하므로 $-\frac{1}{N} \ln \ell(w_0, w_1)$ 을 손실함수 $L(w_0, w_1)$ 로 사용

$$\begin{aligned} L(w_0, w_1) &= -\frac{1}{N} \sum_{i=1}^N \ln \sigma(w_0 + w_1 x_i)^{y_i} (1 - \sigma(w_0 + w_1 x_i))^{1-y_i} \\ &= -\frac{1}{N} \sum_{i=1}^N \{y_i \ln \sigma(w_0 + w_1 x_i) + (1 - y_i) \ln(1 - \sigma(w_0 + w_1 x_i))\} \end{aligned}$$

로지스틱 회귀에서 인자 갱신

편미분

$$w_0 \leftarrow w_0 - \alpha \frac{\partial L(w_0, w_1)}{\partial w_0}$$

$$\frac{\partial L(w_0, w_1)}{\partial w_0} = -\frac{1}{N} \sum_{i=1}^N \{y_i - \sigma(w_0 + w_1 x_i)\}$$

$$w_1 \leftarrow w_1 - \alpha \frac{\partial L(w_0, w_1)}{\partial w_1}$$

$$\frac{\partial L(w_0, w_1)}{\partial w_1} = -\frac{1}{N} \sum_{i=1}^N x_i (y_i - \sigma(w_0 + w_1 x_i))$$

모델 학습 요약 (1/2)

로지스틱 회귀의 학습 목표($\mathbf{x}_i = [1 \ x_{i1} \ \cdots \ x_{id}]^T$ 에 대한 일반화된 표현)

– N 개의 관측값으로 구성된 학습 데이터 $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N, y_i \in \{0,1\}$ 에 대하여

$$\mathbf{w}^* = \underset{\mathbf{w}}{\operatorname{argmin}} L(\mathbf{w})$$

$$= \underset{\mathbf{w}}{\operatorname{argmin}} -\frac{1}{N} \sum_{i=1}^N \left\{ y_i \ln \sigma(\mathbf{w}^T \mathbf{x}_i) + (1 - y_i) \ln (1 - \sigma(\mathbf{w}^T \mathbf{x}_i)) \right\}$$

$$\mathbf{w} = [w_0 \ w_1 \ \cdots \ w_d]^T$$

$$L(\mathbf{w}) = -\frac{1}{N} \ln \ell(\mathbf{w})$$

$$P(C_1 | \mathbf{x}_i) = \sigma(\mathbf{w}^T \mathbf{x}_i)$$

모델 학습 요약 (2/2)

바이너리 크로스 엔트로피(binary cross-entropy), $CE(y_i, \hat{y}_i)$ ($y_i \in \{0,1\}$)

$$CE(y_i, \hat{y}_i) = -y_i \ln P(C_1|\mathbf{x}_i) - (1 - y_i) \ln(1 - P(C_1|\mathbf{x}_i))$$

✓ ※주의 : 로지스틱 회귀에서 $P(C_1|\mathbf{x}_i) = \frac{1}{1+e^{-\mathbf{w}^T \mathbf{x}_i}} = \sigma(\mathbf{w}^T \mathbf{x}_i)$

$$\mathbf{w}^* = \operatorname{argmin}_{\mathbf{w}} \frac{1}{N} \sum_{i=1}^N CE(y_i, \hat{y}_i)$$

$$= \operatorname{argmin}_{\mathbf{w}} -\frac{1}{N} \sum_{i=1}^N \left\{ y_i \ln \sigma(\mathbf{w}^T \mathbf{x}_i) + (1 - y_i) \ln (1 - \sigma(\mathbf{w}^T \mathbf{x}_i)) \right\}$$

✓ 경사하강법을 이용하여 $\mathbf{w}^*$ 를 탐색

경사하강법의 적용 I (1/2)

$$w_k \leftarrow w_k - \alpha \frac{\partial}{\partial w_k} \frac{1}{N} \sum_{i=1}^N CE(y_i, \hat{y}_i)$$

w_k : k 번째 인자의 값 ($k = 0, \dots, d$)

$y_i \in \{0, 1\}$

α : 학습율

편미분 수행

$$\begin{aligned} \frac{\partial}{\partial w_k} \frac{1}{N} \sum_{i=1}^N CE(y_i, \hat{y}_i) &= -\frac{\partial}{\partial w_k} \frac{1}{N} \sum_{i=1}^N \left\{ y_i \ln \sigma(\mathbf{w}^T \mathbf{x}_i) + (1 - y_i) \ln (1 - \sigma(\mathbf{w}^T \mathbf{x}_i)) \right\} \\ &= -\frac{1}{N} \sum_{i=1}^N (y_i - \sigma(\mathbf{w}^T \mathbf{x}_i)) x_{ik} \end{aligned}$$

✓ x_{ik} : i 번째 개체의 특징 벡터 $\mathbf{x}_i$ 의 k 번째 성분 ($x_{i0} = 1$)

경사하강법의 적용 I (2/2)

경사하강법의 적용 : 그레디언트 획득

$$\frac{\partial}{\partial w_k} \frac{1}{N} \sum_{i=1}^N CE(y_i, \hat{y}_i) = -\frac{1}{N} \sum_{i=1}^N (y_i - \sigma(\mathbf{w}^T \mathbf{x}_i)) x_{ik}$$

- 동작 :

(1) $\mathbf{w}$ 를 임의의 값으로 초기화

(2) $\mathbf{w}$ 를 구성하는 모든 성분 w_k 에 대하여 아래 식을 활용하여 w_k 를 갱신

$$w_k \leftarrow w_k + \frac{\alpha}{N} \sum_{i=1}^N (y_i - \sigma(\mathbf{w}^T \mathbf{x}_i)) x_{ik}$$

경사하강법의 적용 II

학습 데이터를 구성하는 모든 관측값으로부터 확보된 CE의 평균이 아니라, 개별 관측값의 CE를 이용하여 인자를 갱신

$$w_k \leftarrow w_k - \alpha \frac{\partial}{\partial w_k} CE(y_i, \hat{y}_i)$$

동작 :

(1) w 를 임의의 값으로 초기화

(2) 종료조건을 만족할 때까지 반복

- (2-1) 학습 데이터를 구성하는 개별 관측 값에 대하여 i 번째 관측 값의 특징 벡터 $\mathbf{x}_i$ 를 이용하여 가중치 갱신

$$w_k \leftarrow w_k - \alpha \frac{\partial}{\partial w_k} CE(y_i, \hat{y}_i) = w_k + \alpha \left(y_i - \sigma(\mathbf{w}^T \mathbf{x}_i) \right) x_{ik}, (k = 0, \dots, d)$$

질문 및 정리

