

CHAPTER 1

퍼셉트론

성명 : 최승호

이메일 : jcn99250@naver.com

학습 목표

- 로지스틱 회귀 복습
- 퍼셉트론의 구조
- 퍼셉트론의 순전파
- 퍼셉트론의 학습
- 논리게이트와 퍼셉트론

로지스틱 회귀 복습

이진 분류

- 모든 개체들이 클래스 C_1 혹은 C_2 에 속하는 상황
- 접근법 1 : 클래스 C_1 과 C_2 에 속하는 개체들을 구분할 수 있도록 특징 공간을 분할
- 접근법 2 : $P(C_1|\mathbf{x})$ 와 $P(C_2|\mathbf{x})$ 를 비교하여 클래스 / 카테고리 레이블 결정

선형 판별

- 선형 판별 함수 : $g(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$
 - ✓ 특징 벡터의 성분에 대한 가중합으로 판별 함수를 표현

로지스틱 회귀

- 클래스 C_1 에 대한 사후 확률의 로그 오드를 $\exp(\mathbf{w}^T \mathbf{x})$ 로 근사. 즉 $\ln \frac{P(C_1|\mathbf{x})}{1-P(C_1|\mathbf{x})} = \exp(\mathbf{w}^T \mathbf{x})$
- $P(C_1|\mathbf{x}) = \sigma(\mathbf{w}^T \mathbf{x})$ 를 이용하여 이진 분류 작업 수행

퍼셉트론과 인공신경망

퍼셉트론(Perceptron)

- 인공신경망의 기본 정보처리 유닛

학습 중점

- 퍼셉트론 모델의 구조를 그림으로 표현할 수 있는 능력 확보
- 퍼셉트론 구성 단위의 역할을 이해
- 퍼셉트론의 순전파를 이해
- 퍼셉트론의 학습 규칙을 이해

퍼셉트론의 구조(1/4)

퍼셉트론 개요

- 퍼셉트론은 다층 인공신경망의 기본 구성 단위로 주로 활용됨
- 퍼셉트론은 특징 벡터를 구성하는 성분의 가중합 연산에 활성화 함수가 추가된 모델

데이터 표현

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_d \end{bmatrix}$$


- d 개의 성분으로 구성된 특징 벡터로 개별 관측값이 설명됨
- 학습 데이터의 구성

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$$

- ✓ $\mathbf{x}_i = [x_{i1} \ \cdots \ x_{id}]^T$: x_{ij} 는 i 번째 특징 벡터의 j 번째 성분을 의미
- ✓ y_i : 관측된 특성 벡터 $\mathbf{x}_i$ 에 대응하는 참값 / 목표값

퍼셉트론의 구조(2/4)

퍼셉트론의 가시적 표현 : 간단한 예제



※ 특징 벡터가 퍼셉트론의 입력임(위 예제에서 x_0, x_1, x_2)

※ 바이어스 노드(값이 항상 1인 노드, x_0)가 존재할 경우 입력층을 구성하는 노드의 수는 특징벡터 성분의 수 + 1

퍼셉트론의 구조(3/4)

퍼셉트론의 가시적 표현 : 간단한 예제


- 입력 : 2개의 성분으로 구성된 특징 벡터 $\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$
- 출력 : 특징 벡터 성분의 가중합($\mathbf{w}^T \mathbf{x} = \sum_{k=0}^2 w_k x_k$) 결과를 활성화 함수를 통과시킨 값
- 참고 1 : 퍼셉트론 모델의 가시적 표현을 구성하는 키워드는 다층 퍼셉트론에서도 계속 등장하기 때문에 정확한 이해가 중요
- 참고 2 : 퍼셉트론과 다층 퍼셉트론 모두에서 **모델의 그림이 중요**

퍼셉트론의 구조(4/4)

퍼셉트론의 가시적 표현 : 간단한 예제

- 노드(node) : ○
- 에지(edge) : →
- 퍼셉트론은 노드와 에지의 결합으로 표현됨
- 에지를 따라 정보가 흐른다고 해석
- 입력 노드 : 특징 벡터를 구성하는 개별 성분 하나 하나가 입력 노드에 해당(8번 슬라이드 예제 : 특징 벡터의 성분 x_1, x_2 와 바이어스 노드 x_0 에 해당하는 3개의 입력 노드 존재)
 - ✓ x_0 노드 : 항상 1의 값을 갖는 노드로 바이어스 표현용
- 출력 노드 : 퍼셉트론의 동작 결과를 출력하는 노드(8번 슬라이드 예제 : $\hat{y}$ 으로 표현)
- 가중치(weight) : w_0, w_1, w_2
 - ✓ 퍼셉트론은 특징 벡터를 구성하는 성분의 가중합(예 : $z = \mathbf{w}^T \mathbf{x} = w_0 + w_1 x_1 + w_2 x_2$)을 활용
 - ✓ 각 에지의 정보흐름에 “가중치(weight)”를 부여하여 해당 에지의 정보흐름의 기여도를 표현

퍼셉트론의 동작(1/4)




입력의 가중합 : $z = \mathbf{w}^T \mathbf{x} = \sum_{k=0}^2 w_k x_k$

활성화 함수 : $f(z) = \frac{1}{1 + \exp(-z)}$



출력 : $f(z) = \frac{1}{1 + \exp(-\mathbf{w}^T \mathbf{x})}$

퍼셉트론의 동작 예제

- 상기 예제에서는 (1) 입력된 특징 벡터 $\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$ 의 성분과 $x_0 = 1$ 에 대하여 가중합($z = \mathbf{w}^T \mathbf{x}$)을 계산한 후 (2) 가중합 계산결과를 활성화함수(예제에서는 시그모이드 함수 )를 통과시켜 출력 값을 생성

퍼셉트론의 동작(2/4)

퍼셉트론의 입력 : 특징 벡터 $\mathbf{x} = [x_1 \ \cdots \ x_d]^T$ 로 표시되는 개체의 관측 값

퍼셉트론의 출력 : 퍼셉트론이 해결해야 하는 임무에 해당하는 값

퍼셉트론의 내부 동작 : 특징 벡터의 성분에 대한 가중합 결과를 “활성화 함수(activation function)”를 통과시켜 출력 값을 결정

- 특징 벡터를 $\mathbf{x} = [x_1 \ \cdots \ x_d]^T$ 로 표시하는 경우 특징 벡터 성분의 가중합 계산(바이어스 성분을 추가하여 원래 주어진 $\mathbf{x} = [x_1 \ \cdots \ x_d]^T$ 를 $\mathbf{x} = [1 \ x_1 \ \cdots \ x_d]^T$ 로 변환)

$$z = \mathbf{w}^T \mathbf{x} = \sum_{k=0}^d w_k x_k = w_0 + w_1 x_1 + \cdots + w_d x_d$$

- i 번째 샘플이라는 의미를 명시하고 싶은 경우 즉, $\mathbf{x}_i = [x_{i1} \ \cdots \ x_{id}]^T$ 의 특징 벡터 성분의 가중합 계산
 - ✓ 바이어스 성분이 추가된 $\mathbf{x}_i = [1 \ x_{i1} \ \cdots \ x_{id}]^T$ 에 대하여

$$z_i = \mathbf{w}^T \mathbf{x}_i = \sum_{k=0}^d w_i x_{ik} = w_0 + w_1 x_{i1} + \cdots + w_d x_{id}$$

퍼셉트론의 동작(3/4)

활성화 함수(activation function)

- 특징 벡터 성분의 가중합 결과는 부호 함수, 계단 함수, 시그모이드 함수, 항등 함수 등 다양한 활성화 함수를 거쳐 출력됨

✓ 부호 함수(sign function) : $\text{sgn}(z) = \begin{cases} 1 & \text{if } z > 0 \\ 0 & \text{if } z = 0 \\ -1 & \text{if } z < 0 \end{cases}$

✓ 계단 함수(step function) : $f(z) = \begin{cases} 1 & \text{if } z \geq 0 \\ 0 & \text{if } z < 0 \end{cases}$

✓ 시그모이드 함수(sigmoid function)

$$\sigma(z) = \frac{1}{1 + \exp(-z)}$$

✓ 항등 함수(identity function)

$$f(z) = z$$

퍼셉트론의 동작(4/4)

퍼셉트론의 순전파(feedforward propagation)

- 퍼셉트론에 입력으로 주어진 특징 벡터가 출력 값으로 변환되는 일련의 과정
- 특징 벡터를 $\mathbf{x}$, $\mathbf{x}$ 에 해당하는 퍼셉트론의 출력을 $\hat{y}$, 활성화 함수를 f 라고 표시하면, 입력된 특징 벡터에 대한 퍼셉트론의 출력은 다음의 수식으로 표현됨 :

$$\hat{y} = f(\mathbf{w}^T \mathbf{x}) = f\left(\sum_{k=0}^d w_k x_k\right)$$

- 예를 들어 12번 슬라이드 예제의 경우, 활성화 함수로 시그모이드 함수를 사용하였으므로 퍼셉트론의 출력은 아래의 수식으로 표현됨.

$$\hat{y} = \sigma(\mathbf{w}^T \mathbf{x}) = \frac{1}{1 + \exp(-\mathbf{w}^T \mathbf{x})}$$

퍼셉트론 이해도 확인

x_1, x_2, x_3 의 세 개의 성분으로 개체의 특성 벡터가 구성된다고 하자.

$0.3x_1 + 0.2x_2 - 1.7x_3 > 0.5$ 이면 1을 출력하고 그렇지 않으면 0을 출력하는 퍼셉트론을 그려 보시오.

퍼셉트론 학습(1/8)


퍼셉트론의 학습 대상 : 가중치($w_0, w_1, \dots, w_d$)

가중치 갱신 방법

1. 초기화 : 정해진 구간에 존재하는 임의의 수로 가중치의 값을 결정
2. 개별 가중치(w_k)의 값을 갱신

$$w_k \leftarrow w_k - \alpha \frac{\partial L(\mathbf{w})}{\partial w_k}$$

- ✓ w_k : 특징 벡터의 성분 x_k 와 연계되는 가중치 벡터의 성분
- ✓ x_{ik} : 특징 벡터 $\mathbf{x}_i$ 의 k 번째 성분
- ✓ $\alpha \frac{\partial L(\mathbf{w})}{\partial w_k}$
 - α : 학습률 ($0 < \alpha < 1$)
 - $L(\mathbf{w})$: **최소화**하려는 손실 함수
 - $\frac{\partial L(\mathbf{w})}{\partial w_k}$: $L(\mathbf{w})$ 를 w_k 에 대하여 편미분한 결과




퍼셉트론 학습(2/8)

예제 - 계속

- 가중치 벡터와 학습 비용

- ✓ 학습 데이터 $\mathcal{D}$ 가 동일하여도 가중치의 구체적인 값에 따라 손실함수 $L(\mathbf{w})$ 의 값이 틀림
- ✓ 경사하강법을 이용하여 종료 조건을 만족할 때까지 가중치를 갱신



퍼셉트론 학습(3/8)

예제 : 활성화함수로 로지스틱 함수를, 손실함수로 $\frac{1}{N} \sum_{i=1}^N CE(y_i, \hat{y}_i)$ 를 사용하는 이진 분류문제

- 데이터의 구성 : $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$: N 개의 관측값으로 구성된 학습 데이터

✓ $\mathbf{x}_i = [x_{i1} \ x_{i2}]^T$, $x_{i1}, x_{i2} \in \mathcal{R}$ (※ 바이어스를 고려하여 학습 과정에서는 $[1 \ x_{i1} \ x_{i2}]^T$ 를 활용)

✓ y_i : 특징 벡터 $\mathbf{x}_i$ 에 대응하는 목표 값 / 참값 ($y_i \in \{0,1\}$)


✓ $\hat{y}_i$: 특징 벡터 $\mathbf{x}_i$ 에 대한 퍼셉트론의 출력 값

- 활성화 함수 : 시그모이드 함수

$$\sigma(\mathbf{w}^T \mathbf{x}_i) = \frac{1}{1 + \exp(-\mathbf{w}^T \mathbf{x}_i)}$$

- 손실함수 :

$$L(\mathbf{w}) = -\frac{1}{N} \sum_{i=1}^N \left\{ y_i \ln \sigma(\mathbf{w}^T \mathbf{x}_i) + (1 - y_i) \ln (1 - \sigma(\mathbf{w}^T \mathbf{x}_i)) \right\}$$



※ 주의 : 활성화 함수와 손실 함수에 따라 구체적인 편미분 결과가 변함

퍼셉트론 학습(4/8)

예제 - 계속

- 손실함수에 대한 편미분

$$\frac{d\sigma(x)}{dx} = \sigma(x)(1 - \sigma(x))$$

$$\frac{\partial L(\mathbf{w})}{\partial w_0} = -\frac{1}{N} \sum_{i=1}^N \{y_i - \sigma(\mathbf{w}^T \mathbf{x}_i)\}$$

$$\frac{\partial L(\mathbf{w})}{\partial w_1} = -\frac{1}{N} \sum_{i=1}^N (y_i - \sigma(\mathbf{w}^T \mathbf{x}_i)) x_{i1}$$

$$\frac{\partial L(\mathbf{w})}{\partial w_2} = -\frac{1}{N} \sum_{i=1}^N (y_i - \sigma(\mathbf{w}^T \mathbf{x}_i)) x_{i2}$$

퍼셉트론 학습(5/8)

예제 - 계속

- 가중치 벡터의 성분 w_i 갱신 $w_i \leftarrow w_i - \alpha \frac{\partial L(\mathbf{w})}{\partial w_i}, \alpha : \text{학습률}(0 < \alpha < 1)$

$$w_0 \leftarrow w_0 - \alpha \frac{\partial L(\mathbf{w})}{\partial w_0} = w_0 + \frac{\alpha}{N} \sum_{i=1}^N \{y_i - \sigma(\mathbf{w}^T \mathbf{x}_i)\}$$

$$w_1 \leftarrow w_1 - \alpha \frac{\partial L(\mathbf{w})}{\partial w_1} = w_1 + \frac{\alpha}{N} \sum_{i=1}^N (y_i - \sigma(\mathbf{w}^T \mathbf{x}_i)) x_{i1}$$

$$w_2 \leftarrow w_2 - \alpha \frac{\partial L(\mathbf{w})}{\partial w_2} = w_2 + \frac{\alpha}{N} \sum_{i=1}^N (y_i - \sigma(\mathbf{w}^T \mathbf{x}_i)) x_{i2}$$

퍼셉트론 학습(6/8)

예제 : 활성화함수로 항등함수로 손실함수로 MSE 를 사용하는 회귀 문제

- 데이터의 구성 : $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$: N 개의 관측값으로 구성된 학습 데이터

✓ $\mathbf{x}_i = [x_{i1} \ x_{i2}]^T, x_{i1}, x_{i2} \in \mathcal{R}$ (※ 바이어스를 고려하여 학습 과정에서는 $[1 \ x_{i1} \ x_{i2}]^T$ 를 활용)

✓ y_i : 특징 벡터 $\mathbf{x}_i$ 에 대응하는 목표 값 / 참값 ($y_i \in \mathcal{R}$)


✓ $\hat{y}_i$: 특징 벡터 $\mathbf{x}_i$ 에 대한 퍼셉트론의 출력 값

- 활성화 함수 : 항등함수

$$f(\mathbf{w}^T \mathbf{x}_i) = \mathbf{w}^T \mathbf{x}_i$$

- 손실함수 :

$$L(\mathbf{w}) = \frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2$$



퍼셉트론 학습(7/8)

예제 - 계속

- 손실함수에 대한 편미분

$$\frac{\partial L(\mathbf{w})}{\partial w_0} = \frac{2}{N} \sum_{i=1}^N (\hat{y}_i - y_i)$$

$$\frac{\partial L(\mathbf{w})}{\partial w_1} = \frac{2}{N} \sum_{i=1}^N (\hat{y}_i - y_i) x_{i1}$$

$$\frac{\partial L(\mathbf{w})}{\partial w_2} = \frac{2}{N} \sum_{i=1}^N (\hat{y}_i - y_i) x_{i2}$$

퍼셉트론 학습(8/8)

예제 - 계속

- 가중치 벡터의 성분 w_i 갱신 $w_i \leftarrow w_i - \alpha \frac{\partial L(\mathbf{w})}{\partial w_i}, \alpha : \text{학습률}(0 < \alpha < 1)$

$$w_0 \leftarrow w_0 - \alpha \frac{\partial L(\mathbf{w})}{\partial w_0} = w_0 - \frac{2\alpha}{N} \sum_{i=1}^N (\hat{y}_i - y_i)$$

$$w_1 \leftarrow w_1 - \alpha \frac{\partial L(\mathbf{w})}{\partial w_1} = w_1 - \frac{2\alpha}{N} \sum_{i=1}^N (\hat{y}_i - y_i) x_{i1}$$

$$w_2 \leftarrow w_2 - \alpha \frac{\partial L(\mathbf{w})}{\partial w_2} = w_2 - \frac{2\alpha}{N} \sum_{i=1}^N (\hat{y}_i - y_i) x_{i2}$$

배치 모드 학습과 온라인 모드 학습

배치 모드 학습에서는 학습 데이터를 구성하는 모든 샘플에 대하여 목표 값과 출력 값의 차이를 계산한 후 가중치 벡터의 성분 w_k 를 갱신

온라인 모드 학습에서는 매 특징 벡터에 대하여 목표 값과 출력 값의 차이를 계산한 후 가중치 벡터의 성분 w_k 를 갱신

논리게이트의 표현(1/6)

논리게이트의 동작을 퍼셉트론으로 설명하는 예제는 매우 유명한 예제

AND, OR, XOR 게이트와 같은 논리게이트는 2개의 성분으로 구성된 특징 벡터를 입력으로 받아 하나의 값으로 구성된 출력을 생성




논리게이트의 입력과 출력 값은 기본적으로 불린 값(Boolean value)이나 계산의 편의를 위해 “True”는 “1”로 , “False”는 “0”으로 표현

구분	x_i		y_i		
	x_{i1}	x_{i2}	AND	OR	XOR
$i = 1$	0	0	0	0	0
$i = 2$	0	1	0	1	1
$i = 3$	1	0	0	1	1
$i = 4$	1	1	1	1	0

논리게이트의 표현(2/6)


AND, OR, XOR 게이트의 시각적 표현

– 입력과 출력 모두 1 혹은 0의 값으로 구성됨



■ : 출력 1
● : 출력 0

논리게이트의 표현(3/6)




· 퍼셉트론을 활용한 논리게이트의 표현

- 특징 벡터 성분의 가중합을 $z = \mathbf{w}^T \mathbf{x}$ 라고 표현할 때
- AND 게이트의 표현

$$z = x_1 + x_2 - 1.5$$

- ✓ $x_1 = [0 \ 0]^T$ 이면 $z_1 = -1.5 < 0$, $x_2 = [0 \ 1]^T$ 이면 $z_2 = -0.5 < 0$
- ✓ $x_3 = [1 \ 0]^T$ 이면 $z_3 = -0.5 < 0$, $x_4 = [1 \ 1]^T$ 이면 $z_4 = 0.5 > 0$
- ✓ 시그모이드 함수를 활성화 함수로 사용하고, 임의의 특징 벡터 $\mathbf{x}$ 에 대하여 $z > 0$ (즉, $\sigma(z) > 1/2$)이면 $\mathbf{x}$ 에 해당하는 퍼셉트론의 출력을 1로, 그 외의 경우 퍼셉트론의 출력을 0으로 정할 경우 주어진 퍼셉트론은 AND 게이트의 동작을 표현

논리게이트의 표현(4/6)



퍼셉트론을 활용한 논리게이트의 표현

- 특징 벡터 성분의 가중합을 $z = \mathbf{w}^T \mathbf{x}$ 라고 표현할 때
- OR 게이트의 표현



$$z = x_1 + x_2 - 0.5$$

- ✓ $x_1 = [0 \ 0]^T$ 이면 $z_1 = -0.5 < 0$, $x_2 = [0 \ 1]^T$ 이면 $z_2 = 0.5 > 0$
- ✓ $x_3 = [1 \ 0]^T$ 이면 $z_3 = 0.5 > 0$, $x_4 = [1 \ 1]^T$ 이면 $z_4 = 1.5 > 0$
- ✓ 시그모이드 함수를 활성화 함수로 사용하고 임의의 특징 벡터 $\mathbf{x}$ 에 대하여 $z > 0$ (즉, $\sigma(z) > 1/2$)이면 $\mathbf{x}$ 에 해당하는 퍼셉트론의 출력을 1로, 그 외의 경우 퍼셉트론의 출력을 0으로 정할 경우 주어진 퍼셉트론은 OR 게이트의 동작을 표현

논리게이트의 표현(5/6)

퍼셉트론을 활용한 논리게이트의 표현

- $z = \mathbf{w}^T \mathbf{x} = \sum_i w_i x_i$: 특징 벡터 성분의 가중합을 의미
- $z = 0$: (1) 특징 벡터 성분의 가중합으로 만들어진 직선 (2) 논리게이트의 “1” 출력과 “0” 출력을 구분할 수 있게 특징 공간을 분할




$z = 0$: 논리게이트의 “1” 출력과 “0” 출력을 구분하는 구분선

논리게이트의 표현(6/6)

퍼셉트론을 활용한 논리게이트의 표현 : XOR게이트

- XOR 게이트에서 “0”의 출력과 “1”의 출력을 구분하려면 2개의 구분선이 필요 → AND 게이트나 OR 게이트의 경우처럼 단일 퍼셉트론을 이용하여 **XOR 게이트의 동작을 표현할 수 없음**
- 퍼셉트론의 동작을 개선할 필요가 관찰됨 → 여러 개의 퍼셉트론을 결합한 새로운 모델을 활용(다층 신경망)



질문 및 정리

