

CHAPTER 1

다층 퍼셉트론의 학습


성명 : 최승호

이메일 : jcn99250@naver.com

학습 목표

- 퍼셉트론 복습
 - 다층 퍼셉트론의 순전파 복습
- 다층 퍼셉트론(MLP) 학습
 - 데이터
 - 손실 함수
 - 오차 역전파
- 모델의 성능 평가 지표
- 텐서플로를 활용한 코드실습

다층 퍼셉트론 복습



$\begin{pmatrix} z_j^{(k)} \\ h_j^{(k)} \end{pmatrix}$: 가중합 + 활성화 함수
(k번째 은닉층, j번째 노드)

- $h_j^{(k)}$: k번째 은닉층의 j번째 노드의 출력
- $h_j^{(k)}$ 는 해당 노드에 주어지는 다른 노드들의 출력값에 대한 가중합($z_j^{(k)}$)을 활성화함수로 계산한 결과임,

$$f_1 \left(\begin{bmatrix} z_1^{(1)} \\ z_2^{(1)} \end{bmatrix} \right) = \begin{bmatrix} f_1(z_1^{(1)}) \\ f_1(z_2^{(1)}) \end{bmatrix} = \begin{bmatrix} h_1^{(1)} \\ h_2^{(1)} \end{bmatrix}$$

* f_1, f_2 는 활성화 함수

* 은닉층 개수가 증가해도 동일하게 계산

$$\begin{bmatrix} \hat{y}_1 \\ \hat{y}_2 \end{bmatrix} = f_2 \left(\underbrace{\begin{bmatrix} w_{11}^{(1)} & w_{12}^{(1)} \\ w_{21}^{(1)} & w_{22}^{(1)} \end{bmatrix}}_{\mathbf{w}_1^T} \underbrace{\left(\underbrace{\begin{bmatrix} w_{11}^{(0)} & w_{12}^{(0)} \\ w_{21}^{(0)} & w_{22}^{(0)} \end{bmatrix}}_{\mathbf{w}_0^T} \underbrace{\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}}_{\mathbf{x}} + \underbrace{\begin{bmatrix} w_{10}^{(0)} \\ w_{20}^{(0)} \end{bmatrix}}_{bias^{(0)}} \right)}_{\text{입력층} \rightarrow \text{은닉층}} + \underbrace{\begin{bmatrix} w_{10}^{(1)} \\ w_{20}^{(1)} \end{bmatrix}}_{bias^{(1)}} \right) = f_2(\mathbf{w}_1^T f_1(\mathbf{w}_0^T \mathbf{x} + bias^{(0)}) + bias^{(1)})$$

은닉층 → 출력층

다층 퍼셉트론 학습 1 (1/3)

1. 학습 데이터 : $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$ or $\mathcal{D} = \{(\mathbf{x}_i, \mathbb{y}_i)\}_{i=1}^N$

- 1) 어떤 문제를 해결하기 위해 제공되는 관측 값들의 특징 벡터 $\mathbf{x}_i$
 - 2) 다층 퍼셉트론 모델이 예측하고자 하는 실제 값 y_i , 또는 클래스별 실제 값의 모음 $\mathbb{y}_i$
- ✓ 데이터 수집 과정을 통해 N 개의 샘플로 구성된 학습 데이터가 확보됨

※ MNIST 예제에서 $\mathbb{y}_i$ 는 이산형 값이고 0, 1, 2, ..., 9 중에 한 개 값이 되며 원-핫 인코딩 방식으로 표현됨. (분류 문제)

2차원 행렬 표현

16 pixel (4 × 4)

	1	2	3	4
1				
2				
3				
4				

그림. MNIST
데이터셋 중 숫자 1

$$\left\{ \mathbf{x}_1 = \begin{bmatrix} 255 & 255 & 0 & 255 \\ 255 & 0 & 0 & 255 \\ 255 & 255 & 0 & 255 \\ 255 & 255 & 0 & 255 \end{bmatrix}, \mathbb{y}_1 = \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} \right\}$$

다층 퍼셉트론 학습 1 (2/3)

1. 학습 데이터 : $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$

– 예시 1 : 주가 예측(회귀) (Regression)

- ✓ 300일 동안 한국의 PMI (Purchasing Manager Index)와 VIX (Volatility Index), 코스피 지수를 수집한 후 특정일의 코스피 지수(y_i)를 해당 일의 특징 벡터 PMI 지수(x_{i1})와 VIX 지수(x_{i2})로 설명할 경우,

➤ $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^{300}$, $\mathbf{x}_i = [x_{i1} \ x_{i2}]^T$ 로 표현됨, $y_i \in \mathcal{R}(\text{실수})$

– 예시 2 : 이진 분류 (Binary Classification)

- ✓ 600×800 의 해상도로 고양이와 개의 사진을 10,000장 확보한 학습 데이터의 경우, i 번째 사진의 특징 벡터는 600×800 크기의 픽셀 값을 표현하는 벡터로 구성되며, y_i 는 0 (고양이) 혹은 1 (개)의 카테고리 레이블을 갖게 됨

➤ $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^{10000}$, $\mathbf{x}_i = [x_1 \ x_2 \ \dots \ x_{480000}]^T$, $y_i \in \{0, 1\}$.

다층 퍼셉트론 학습 1 (3/3)


1. 학습 데이터 : $\mathcal{D} = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^N$

– 예시 3 : 다중 클래스 분류

- ✓ 28×28 의 해상도로 Fashion-MNIST의 사진을 60,000장 확보한 학습 데이터의 경우, i 번째 사진의 특징 벡터는 28×28 크기(784개)의 픽셀 값을 표현하는 벡터로 구성되며, 실제 값은 여러 개의 카테고리 레이블(클래스별 실제 값)을 갖게 되어 $\mathbf{y}_i$ 로 표현 :

➤ $\mathcal{D} = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^{60000}$

➤ $(\mathbf{x}_1 = [1, 25, \dots, 255]^T, \mathbf{y}_1 = [1, 0, 0, \dots, 0, 0]^T), (\mathbf{x}_2 = [3, 5, \dots, 221]^T, \mathbf{y}_2 = [0, 1, 0, \dots, 0, 0]^T)$
 $\dots, (\mathbf{x}_{10} = [0, 0, \dots, 255, \dots, 0]^T, \mathbf{y}_{10} = [0, \dots, 0, 1]^T), \dots, (\mathbf{x}_{60000}, \mathbf{y}_{60000})$



*원-핫 인코딩으로 표현

$\mathbf{y}_{10} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{bmatrix}$

레이블	클래스
1	T-shirt/top
2	Trouser
3	Pullover
4	Dress
5	Coat
6	Sandal
7	Shirt
8	Sneaker
9	Bag
10	Ankle boot

다층 퍼셉트론 학습 2 (1/3)

2. 손실 함수(Loss Function)

* 실제값 : 정답, Label, Ground Truth

- 개념 : 데이터를 통해 산출한 다층 퍼셉트론 모델의 예측값과 실제값의 차이를 표현하는 지표
- 세부 내용 : 모델(MLP)이 얼마나 잘못 예측하는지 정도를 확인하는 함수

(1) y_i 가 연속형 값인 경우, 대표적인 함수

✓ 회귀(Regression) 문제 : 회귀 모델에서는 평균제곱오차 사용

➤ MSE (Mean Squared Error)

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

* y_i : i 번째 샘플에 대한 정답 레이블, 실제값

* $\hat{y}_i$: i 번째 샘플에 대한 다층 퍼셉트론의 출력, 예측값

* $\hat{y}_i = w^T x_i = w_0 + w_1 x_{i1} + w_2 x_{i2} + \dots + w_i x_{id}$

다층 퍼셉트론 학습 2 (2/3)

2. 손실 함수(Loss Function)

(2) y_i 가 이산형 값이고 0 또는 1 값을 갖는 경우, 대표적인 함수

✓ 이진 분류(Binary Classification) 문제 : 이진 분류 모델에서 바이너리 크로스 엔트로피 사용

➤ BCE (Binary Cross Entropy)

$$BCE = -\frac{1}{N} \sum_{i=1}^N \{y_i \cdot \ln \hat{y}_i + (1 - y_i) \cdot \ln(1 - \hat{y}_i)\}$$

* y_i : 0(False) 혹은 1(True)의 값으로 표현된 i 번째 샘플의 카테고리 레이블

* $\hat{y}_i$: i 번째 샘플에 대한 다층 퍼셉트론의 출력으로 i 번째 샘플이 첫 번째 클래스에 속할 확률 값이 출력됨

* $\hat{y}_i = \sigma(z_i) = \text{Sigmoid}(z_i) = \frac{1}{1+e^{-z_i}}$

다층 퍼셉트론 학습 2 (3/3)

2. 손실 함수(Loss Function)

(3) y_i 가 이산형 값이고 일반적으로 3개 이상 클래스를 갖는 경우, 대표적인 함수

✓ 다중 클래스 분류(Multi-class Classification)

➤ CCE (Categorical Cross Entropy)

$$CCE = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^C y_{ik} \ln \hat{y}_{ik}$$

$$* \text{ cf. } y_i = \begin{bmatrix} y_{i1} \\ y_{i2} \\ \dots \\ y_{ik} \\ \dots \\ y_{iC} \end{bmatrix}$$

* y_{ik} : i 번째 샘플의 k 번째 클래스에 대한 카테고리 레이블

* $\hat{y}_{ik}$: i 번째 샘플에 대한 다층 퍼셉트론의 출력으로 i 번째 샘플이 k 번째 클래스에 속할 확률 값이 출력됨

* if. $k = 2$ 일때, $\hat{y}_{i2} = \sigma(z_{i2}) = \text{Softmax}(z_{i2}) = \frac{e^{z_{i2}}}{\sum_{k=1}^C e^{z_{ik}}}$

참고 : 손실함수 연습 문제

■ 예제 : 모델에 i 번째 관측값이 입력될 때, 다중 클래스 분류 문제의 손실함수 계산

➤ ① → ② → ③ → ④





그림 1. 출력층의 동작 예시

③

$$-\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^C y_{ik} \ln \hat{y}_{ik} \Leftrightarrow - \sum_{k=1}^{C=5} y_{ik} \ln \hat{y}_{ik}$$

배치 모드 온라인 모드

그림 3. 손실함수 온라인 모드로 적용

②

$$\hat{\mathbf{y}}_i = \begin{bmatrix} \hat{y}_{i1} \\ \hat{y}_{i2} \\ \hat{y}_{i3} \\ \hat{y}_{i4} \\ \hat{y}_{i5} \end{bmatrix} = \begin{bmatrix} 0.02 \\ 0.90 \\ 0.05 \\ 0.01 \\ 0.02 \end{bmatrix} \Leftrightarrow \mathbf{y}_i = \begin{bmatrix} y_{i1} \\ y_{i2} \\ y_{i3} \\ y_{i4} \\ y_{i5} \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

그림 2. 예측값과 실제값의 비교

④ *수식 전개 : $L(w)$

$$= -1 \cdot \{0 \cdot \ln(0.02) + 1 \cdot \ln(0.9) + 0 \cdot \ln(0.05) + 0 \cdot \ln(0.01) + 0 \cdot \ln(0.02)\}$$

≈ 0.105 (오차)

그림 4. 크로스 엔트로피 손실함수 풀이

다층 퍼셉트론 학습 3 (1/5)


3. 오차 역전파(Backpropagation)

- 정의 : 예측값과 실제값 간의 차이인 손실함수(오차)를 최소화하기 위해서 출력층에서 입력층 방향 순서대로 모든 노드들의 가중치($w_{ji}^{(k)}$, 매개변수)들을 업데이트하는 과정임.
- 대표적인 방법으로 경사하강법을 이용하여 가중치를 갱신

$$w_{ji}^{(k)} \leftarrow w_{ji}^{(k)} - \alpha \cdot \frac{\partial L(\mathbf{w})}{\partial w_{ji}^{(k)}}$$

- ✓ $w_{ji}^{(k)}$: $k + 1$ 번째 층의 j 번째 노드와 k 번째 층의 i 번째 노드 를 연결하는 엣지와 연계된 가중치
- ✓ α : 학습률

다층 퍼셉트론 학습 3 (2/5)



$$f_2(\mathbf{w}_1^T \cdot \underbrace{f_1(\mathbf{w}_0^T \cdot \mathbf{x} + \text{bias}^{(0)})}_{\text{입력층} \rightarrow \text{은닉층}} + \text{bias}^{(1)})$$

입력층 → 은닉층

은닉층 → 출력층

$$\mathbf{H}^{(1)} = \begin{bmatrix} h_1^{(1)} \\ h_2^{(1)} \end{bmatrix} = \begin{bmatrix} f_1(z_1^{(1)}) \\ f_1(z_2^{(1)}) \end{bmatrix}$$

$$\mathbf{H}^{(2)} = \begin{bmatrix} h_1^{(2)} \\ h_2^{(2)} \end{bmatrix} = \begin{bmatrix} f_2(z_1^{(2)}) \\ f_2(z_2^{(2)}) \end{bmatrix} = \begin{bmatrix} \hat{y}_1 \\ \hat{y}_2 \end{bmatrix} = \hat{\mathbf{y}}$$

※ 학습 목표



$$\underset{\mathbf{w}_{(0)}^T, \mathbf{w}_{(1)}^T}{\operatorname{argmin}} \{ L(\mathbf{y}, \hat{\mathbf{y}}) \}$$

※ 경사하강법

$$\mathbf{w}_{(0)}^T \leftarrow \mathbf{w}_{(0)}^T - \alpha \cdot \frac{\partial L}{\partial \mathbf{w}_{(0)}^T}$$

$$\mathbf{w}_{(1)}^T \leftarrow \mathbf{w}_{(1)}^T - \alpha \cdot \frac{\partial L}{\partial \mathbf{w}_{(1)}^T}$$

다층 퍼셉트론 학습 3 (3/5)



$$f_2(\mathbf{w}_1^T \cdot f_1(\mathbf{w}_0^T \cdot \mathbf{x} + \text{bias}^{(0)}) + \text{bias}^{(1)})$$

입력층 → 은닉층

은닉층 → 출력층

$$\mathbf{W}_{(0)}^T = \begin{bmatrix} w_{11}^{(0)} & w_{12}^{(0)} \\ w_{21}^{(0)} & w_{22}^{(0)} \end{bmatrix} \quad \text{bias}^{(0)} = \begin{bmatrix} w_{10}^{(0)} \\ w_{20}^{(0)} \end{bmatrix} \quad \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

$$\mathbf{W}_{(1)}^T = \begin{bmatrix} w_{11}^{(1)} & w_{12}^{(1)} \\ w_{21}^{(1)} & w_{22}^{(1)} \end{bmatrix} \quad \text{bias}^{(1)} = \begin{bmatrix} w_{10}^{(1)} \\ w_{20}^{(1)} \end{bmatrix} \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \end{bmatrix}$$

$$\hat{\mathbf{y}} = \begin{bmatrix} \hat{y}_1 \\ \hat{y}_2 \end{bmatrix}$$

※ 학습 목표

$$\underset{\mathbf{w}_{(0)}^T, \mathbf{w}_{(1)}^T}{\operatorname{argmin}} \{ L(\mathbf{y}, \hat{\mathbf{y}}) \}$$

※ 경사하강법


$$\mathbf{W}_{(0)}^T \leftarrow \mathbf{W}_{(0)}^T - \alpha \cdot \frac{\partial L}{\partial \mathbf{W}_{(0)}^T}$$

$$\mathbf{W}_{(1)}^T \leftarrow \mathbf{W}_{(1)}^T - \alpha \cdot \frac{\partial L}{\partial \mathbf{W}_{(1)}^T}$$

$$w_{ji}^{(0)} \leftarrow w_{ji}^{(0)} - \alpha \cdot \frac{\partial L}{\partial w_{ji}^{(0)}}$$

$$w_{ji}^{(1)} \leftarrow w_{ji}^{(1)} - \alpha \cdot \frac{\partial L}{\partial w_{ji}^{(1)}}$$

다층 퍼셉트론 학습 3 (4/5)



* 1. 순전파 : 입력 데이터에 각 층의 가중치들의 가중합과 활성화 함수를 적용하여 예측값을 출력

* 2. 손실값 계산 : 예측값과 실제값의 차이인 오차를 손실 함수로 계산

다층 퍼셉트론 학습 3 (5/5)

3. 역전파 : 미분 연쇄법칙을 적용하여 가중치를 업데이트


오차 역전파 (Error-Backpropagation)

$$\frac{\partial L}{\partial \mathbf{w}_{(0)}^T}, \frac{\partial L}{\partial \mathbf{w}_{(1)}^T}$$

$$\underset{\mathbf{w}_{(0)}^T, \mathbf{w}_{(1)}^T}{\operatorname{argmin}} L(\mathbf{y}, \hat{\mathbf{y}})$$

Update

$$\left\{ \begin{array}{l} \mathbf{w}_{(0)}^T \leftarrow \mathbf{w}_{(0)}^T - \alpha \cdot \frac{\partial L}{\partial \mathbf{w}_{(0)}^T} \\ \mathbf{w}_{(1)}^T \leftarrow \mathbf{w}_{(1)}^T - \alpha \cdot \frac{\partial L}{\partial \mathbf{w}_{(1)}^T} \end{array} \right\}$$



순전파 (Feed-forward Calculation)

$$f_2(\mathbf{w}_1^T \cdot f_1(\mathbf{w}_0^T \cdot \mathbf{x} + \text{bias}^{(0)}) + \text{bias}^{(1)})$$

* 1. 순전파 : 입력 데이터에 각 층의 가중치들의 가중합과 활성화 함수를 적용하여 예측값을 출력

No

Error < 허용범위

Yes


학습 종료

Error $L(\mathbf{y}, \hat{\mathbf{y}})$

$$\text{ex) } CCE = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^{C=2} y_{ik} \ln \hat{y}_{ik}$$

* 2. 손실값 계산 : 예측값과 실제값의 차이인 오차를 손실 함수로 계산

은닉 노드(Neuron)



가중합($z_1^{(1)}$) → 활성화 함수(f_1) → 출력($h_1^{(1)}$)
(1번째 은닉 층, 1번째 노드)

* 모델의
성능 평가
지표

모델의 성능 평가 지표

기계 학습 모델의 성능을 측정하는 지표(Evaluation Metrics)

- 기계 학습 모델의 목적에 따라 다양한 성능 평가 지표를 활용.

- ✓ ① 회귀(Regression) : R2 square, ...
- ✓ ② 분류(Classification) : Confusion Matrix, ...

* 참고 :


	Positive	Negative
Positive	True Positive (TP)	False Positive (FP)
Negative	False Negative (FN)	True Negative (TN)

$$\textcircled{1} \quad R^2 = 1 - \frac{SSR}{SST} = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y}_i)^2}$$


* SSR(Residual Sum of Squares)

* SST(Total Sum of Squares)

* $\bar{y}_i$ 는 y_i 의 평균값, $\hat{y}_i$ 는 예측값



참고 : 다층 퍼셉트론 세부 구조




예제 : 다층 퍼셉트론의 세부 구조(예시)

- 다층 퍼셉트론의 입력 $\mathbf{x} = [x_1 \ x_2]$
- 입력층 : 특징 벡터 $\mathbf{x}$ 의 두 성분 x_1, x_2 에 대응하는 노드 2개 그리고 바이어스(bias) 노드 x_0 로 총 3개 노드로 구성됨
 - ✓ 바이어스 노드는 1의 값을 출력
 - ✓ 바이어스 노드가 아닌 입력 노드는 해당 노드에 대응하는 특성 벡터의 성분 값을 출력
- 은닉층 : 바이어스 노드를 포함한 3개의 노드로 구성됨
 - ✓ 바이어스 노드 $h_0^{(1)}$ 는 1의 값을 출력
 - ✓ 바이어스 노드가 아닌 은닉 노드는 엣지를 통해 전달된 값들의 가중합 결과($z_j^{(1)}$)를 활성화 함수가 처리한 후 결과값($h_j^{(1)}$)을 출력하여 다음 층($\rightarrow$ 은닉 or $\rightarrow$ 출력) 노드의 연산에 활용
- 출력층 : 2개 노드
 - ✓ 출력 노드는 엣지를 통해 전달된 은닉 노드의 출력 값들의 가중합 결과($z_j^{(2)}$)를 출력층 활성화 함수가 처리한 후 결과값($h_j^{(2)}$)을 출력하여 $\hat{y}$ 예측값으로 쓰임
- 가중치 $w_{ji}^{(k)}$: $k+1$ 번째 층의 j 번째 노드와 k 번째 층의 i 번째 노드와 연결된 엣지와 연계된 가중치

참고 : 미분 연쇄법칙과 역전파

■ 오차 역전파(Backpropagation)



* 그림. MLP 모델의 생략된 구조 (일부 노드만 관찰)

cf. 즉, 모델의 깊이가 깊어질수록, 은닉 노드 개수가 많아질수록 모델의 앞단에 있는 가중치를 갱신하기 위해서는 편미분이 계산해야 할 항이 무수히 많이 증가하게 된다.

■ 경사하강법을 위한 편미분

$$w_{ji}^{(k)} \leftarrow w_{ji}^{(k)} - \alpha \cdot \frac{\partial L(\mathbf{w})}{\partial w_{ji}^{(k)}}$$

$$* L(\mathbf{w}) = \sum_{k=1}^C y_k \ln \hat{y}_k$$

(온라인 모드로 학습하는 상황)

* 체인 룰(Chain Rule): 미분의 연쇄 법칙

- 역전파 1단계 예시

$$\frac{\partial L(\mathbf{w})}{\partial w_{11}^{(1)}} = \frac{\partial L(\mathbf{w})}{\partial \hat{y}_1} \cdot \frac{\partial \hat{y}_1}{\partial z_1^{(2)}} \cdot \frac{\partial z_1^{(2)}}{\partial w_{11}^{(1)}} \quad \because \hat{y}_1 = h_1^{(2)} = \sigma(z_1^{(2)}) = \text{Softmax}(z_1^{(2)})$$

$$= (\hat{y}_1 - y_1) \cdot h_1^{(1)}$$

- 역전파 2단계 예시

$$\frac{\partial L(\mathbf{w})}{\partial w_{11}^{(0)}} = \frac{\partial L(\mathbf{w})}{\partial \hat{y}_1} \cdot \frac{\partial \hat{y}_1}{\partial z_1^{(2)}} \cdot \frac{\partial z_1^{(2)}}{\partial h_1^{(1)}} \cdot \frac{\partial h_1^{(1)}}{\partial z_1^{(1)}} \cdot \frac{\partial z_1^{(1)}}{\partial w_{11}^{(0)}} \quad \because h_1^{(1)} = f(z_1^{(1)}) = \text{ReLU}(z_1^{(1)})$$

$$= (\hat{y}_1 - y_1) \cdot w_{11}^{(1)} \cdot 1 \cdot x_1$$

* cf. ReLU 활성화 함수를 사용하기 때문에 은닉 노드의 편미분은 간단하다.

질문 및 정리

