CHAPTER 1

k 최근접 이웃

성명 : 최승호
이메일 : jcn99250@naver.com

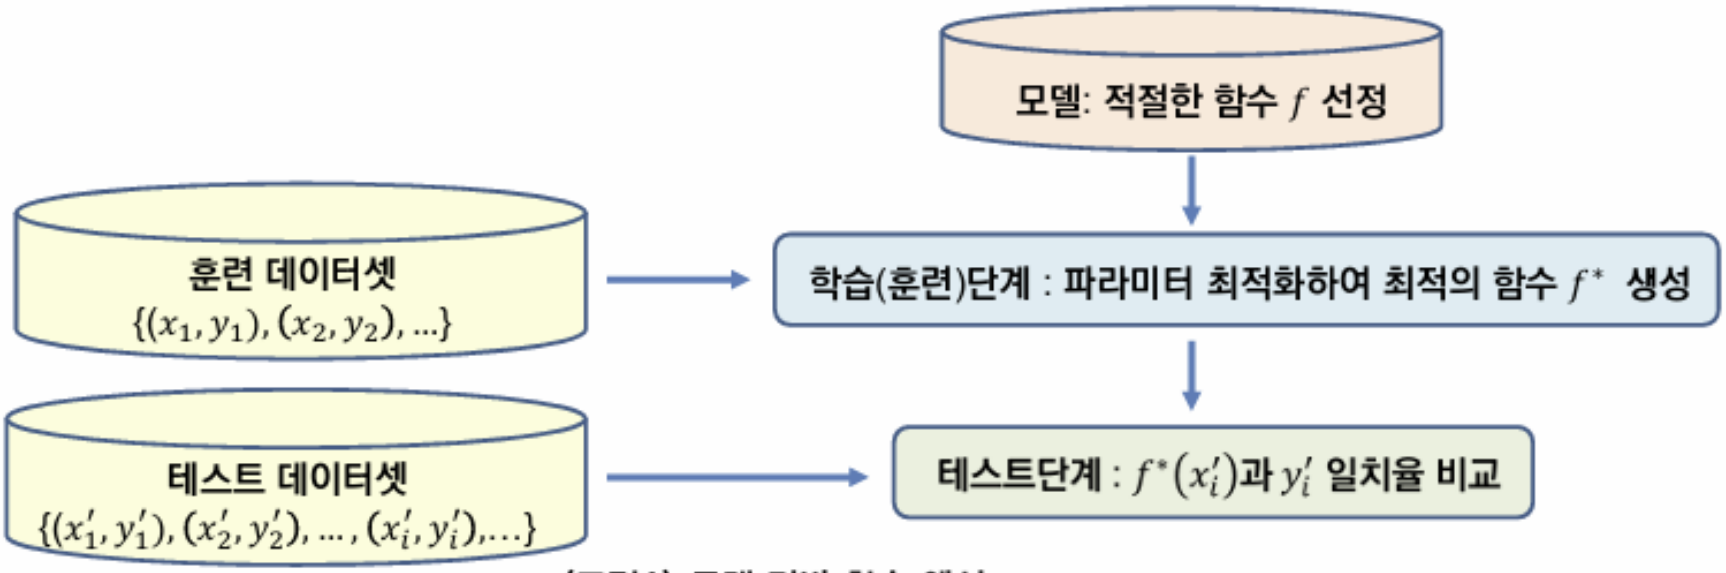
학습 목표

- 모델 기반 학습과 사례 기반 학습
- K 최근접 이웃 (kNN)

모델 기반 학습

분류 및 예측 태스크를 위한 학습

- 모델 기반 학습(Model-based Learning)
  - ✓ 훈련 데이터로부터 모델 f의 파라미터를 최적화하여 최적의 함수 f^* 생성
  - ✓ 한 번 모델 생성을 완료하면 테스트 데이터에 대해서는 단순하게 함수 f^*의 연산으로 예측값 도출
  - ✓ 선형회귀, 로지스틱회귀, 퍼셉트론, 다층 퍼셉트론 등 앞서 배운 모델이 모두 모델 기반 학습 방법

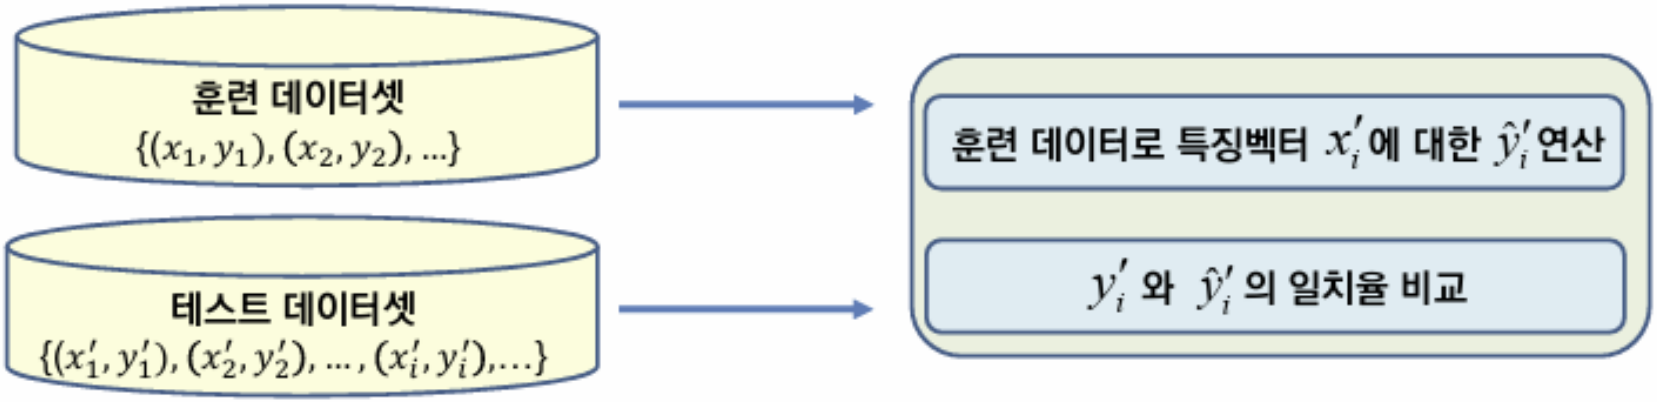


〈그림1〉 모델 기반 학습 예시

사례 기반 학습

분류 및 예측 태스크를 위한 학습

- 사례 기반 학습(Instance-based Learning)
  - ✓ 별도의 모델을 생성하지 않는 방식
  - ✓ 테스트 데이터가 들어올 때마다 학습 데이터를 기반으로 예측값 연산
  - ✓ k 최근접 이웃이 대표적인 사례 기반 학습 방법임

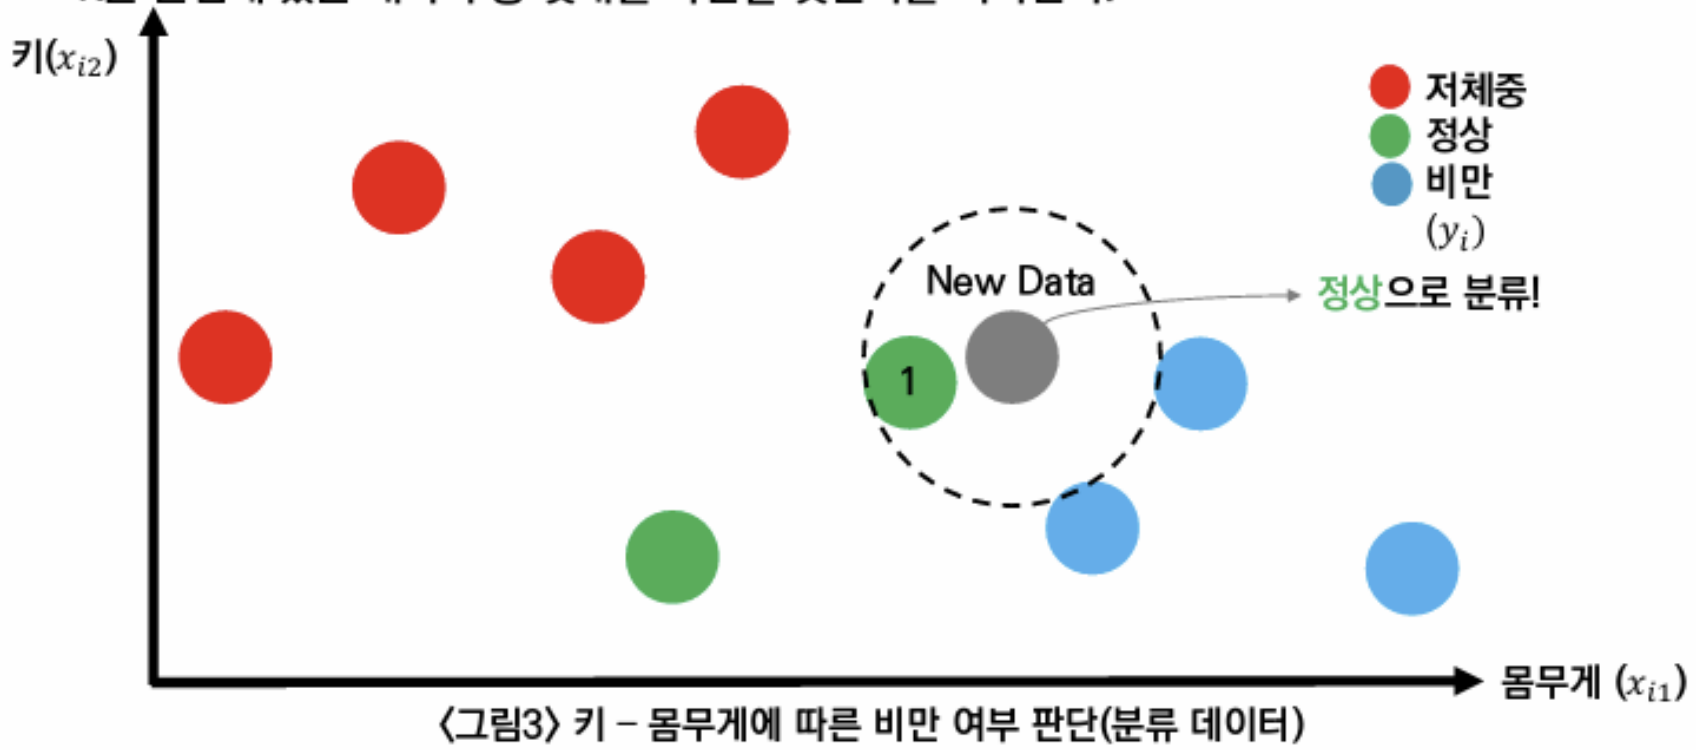


〈그림2〉 인스턴스 기반 학습 예시

K 최근접 이웃(kNN)

k 최근접 이웃 (k-Nearest Neighbor)

- 1 최근접 이웃 (k = 1)
  - ✓ 새로운 관측치에 대해서 기존 데이터와 가장 유사한 데이터는? 해당 데이터와 동일한 라벨로 설정
  - ✓ K는 근접해 있는 데이터 중 몇개를 확인할 것인지를 의미한다.

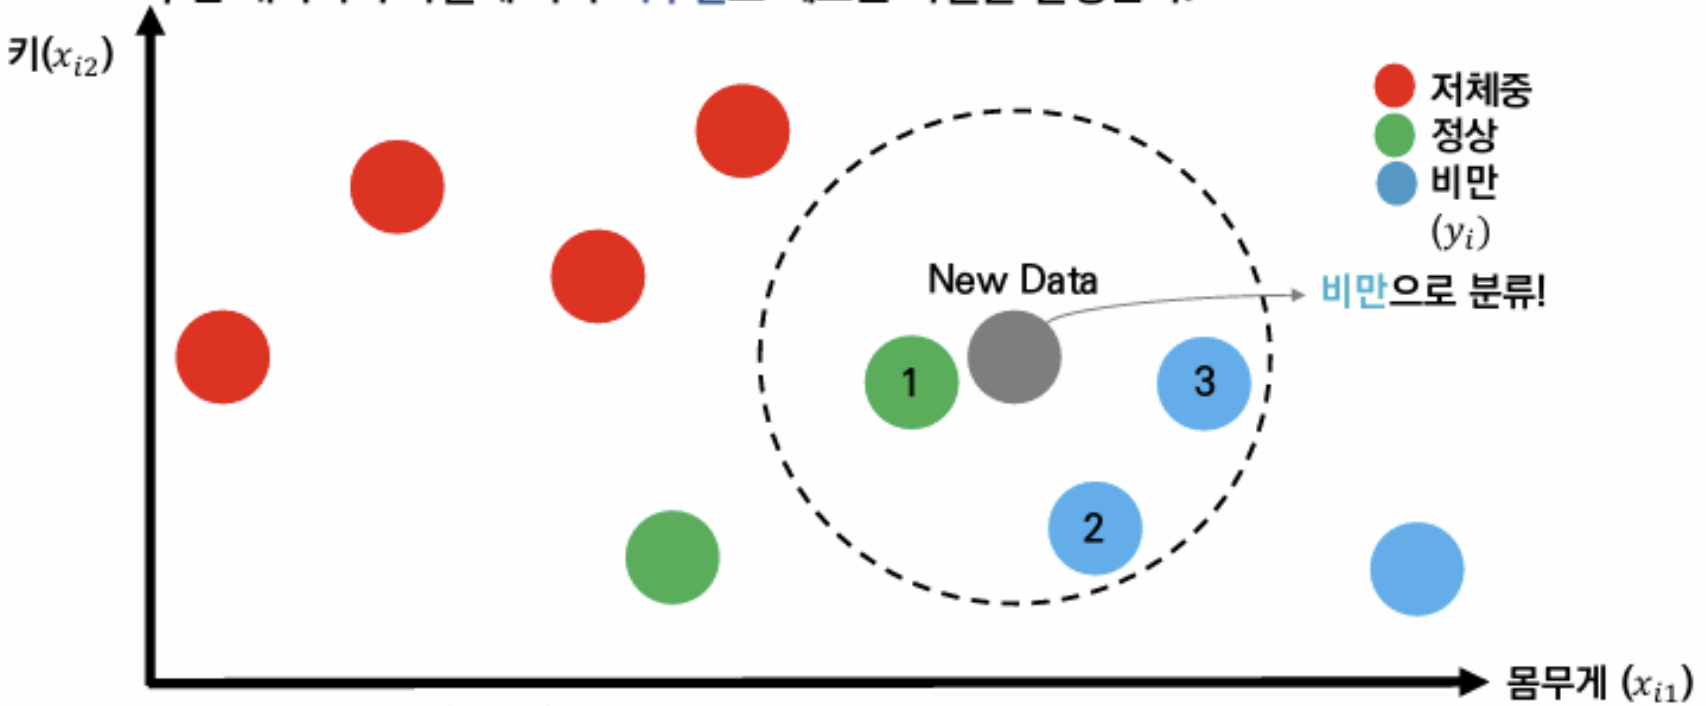


〈그림3〉 키 – 몸무게에 따른 비만 여부 판단(분류 데이터)

K 최근접 이웃(kNN)

k 최근접 이웃 (k-Nearest Neighbor)

- 3 최근접 이웃 (k = 3)
  - ✓ k=3 일 때 새로운 관측치는 어떻게 새로운 라벨을 결정해줄까?
    - ➢ 주변 데이터의 라벨에 따라 다수결로 새로운 라벨을 결정한다.



〈그림3〉 키 – 몸무게에 따른 비만 여부 판단(분류 데이터)

K 최근접 이웃(kNN)

k 최근접 이웃

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^{7},\ \mathbf{x}_i = [x_{i1}\ x_{i2}]^T, y_i \in \{0,1\}.$$

- 테이블 데이터에서는 근접한 관측치를 어떻게 계산할까? 거리측도
  - ✓ 〈그림3〉처럼 테이블 데이터의 특징 벡터를 좌표 공간에 표현할 수 있음을 기억
- 새로운 데이터가 발생한 이후에 클래스 예측 수행됨 –〉 사례 기반 학습의 특징

	몸무게 (x_{i1})	키 (x_{i2})	비만여부 (y_i)
생도1	1	0	0
생도2	2	1	0
생도3	3	3	0
생도4	5	2	1
생도5	5	4	1
생도6	6	5	1
생도7	9	2	1
신입생도	3	4	???

〈표1〉 키 – 몸무게 등급에 따른 비만 여부 판단 (테이블 데이터)

거리측도

유클리디안 거리

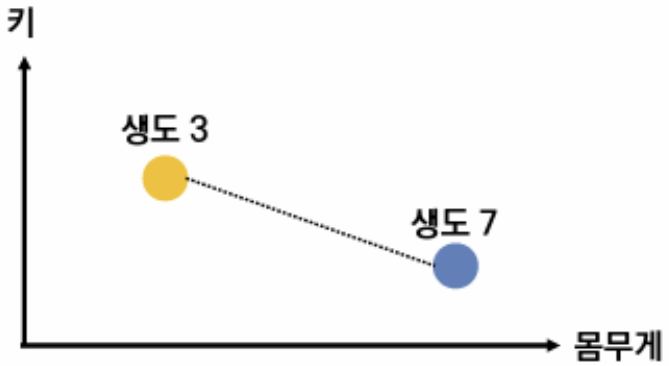
- 가장 많이 사용하는 거리측도 -〉 고등수학 과정의 직선거리, 점과 점 사이의 거리
- 대응되는 관측치의 특징벡터 간 차이 제곱 합의 제곱근

	몸무게 (x_{i1})	키 (x_{i2})	비만여부 (y_i)
생도1	1	0	0
생도2	2	1	0
생도3	3	3	0
생도4	5	2	1
생도5	5	4	1
생도6	6	5	1
생도7	9	2	1

〈표1〉 키 – 몸무게 등급에 따른 비만 여부

$$Euclidean\ Distance(\mathbf{x}_1, \mathbf{x}_2) = \sqrt{\sum_{j=1}^{p=2} (x_{1j} - x_{2j})^2}$$, p는 특징벡터 성분의 수

$$Euclidean\ Distance(\mathbf{x}_7, \mathbf{x}_3) = \sqrt{(9-3)^2 + (2-3)^2} = \sqrt{37} \approx 6.08$$



거리측도

맨하탄 거리

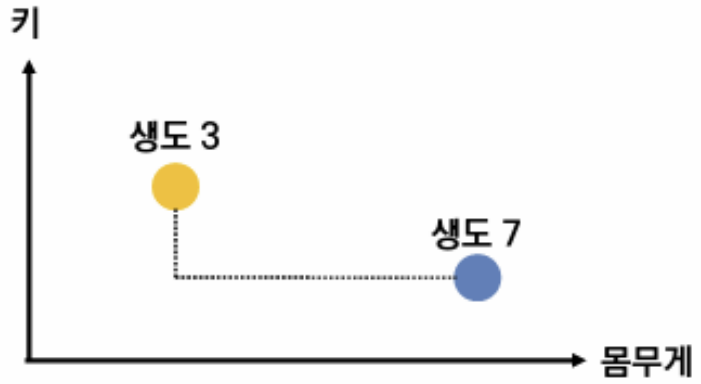
- 일상생활에서는 잘 사용하지 않으나, 머신러닝 혹은 프로그래밍에서 사용되는 경우도 있음
- 실제 뉴욕의 맨하탄과 같은 구획에서 이동할 때는 맨하탄 거리처럼 이동 해야함

	몸무게 (x_{i1})	키 (x_{i2})	비만여부 (y_i)
생도1	1	0	0
생도2	2	1	0
생도3	3	3	0
생도4	5	2	1
생도5	5	4	1
생도6	6	5	1
생도7	9	2	1

〈표1〉 키 – 몸무게 등급에 따른 비만 여부

$$Manhattan\ Distance(\mathbf{x}_1, \mathbf{x}_2) = \sum_{j=1}^{p=2} |x_{1j} - x_{2j}|, p\text{는 특징벡터 성분의 수}$$

$$Manhattan\ Distance(\mathbf{x}_7, \mathbf{x}_3) = |9-3| + |2-3| = 7$$



K 최근접 이웃 (kNN)

k 최근접 이웃

* 유클리디안 거리 사용

– 3 최근접 이웃 (k = 3)

- ✓ 새로운 관측치(신입생도)가 발생한 이후에 클래스 예측 수행됨 –〉 인스턴스 기반 학습의 특징
- ✓ 클래스 예측은 새로운 관측치와의 거리를 계산하여 가장 가까운 3개(k)의 데이터를 추출 –〉 거리측도
- ✓ 추출된 데이터로 새로운 관측치의 클래스를 결정 –〉 다수결

	몸무게 (x_{i1})	키 (x_{i2})	비만여부 (y_i)	새 관측치와의 거리 (Distance)	가까운 순서
생도1	1	0	0	4.47	6th
생도2	2	1	0	3.16	4th
생도3	3	3	0	1.00	1st
생도4	5	2	1	2.82	3rd
생도5	5	4	1	2.00	2nd
생도6	6	5	1	3.16	5th
생도7	9	2	1	6.32	7th
신입생도	3	4	???		

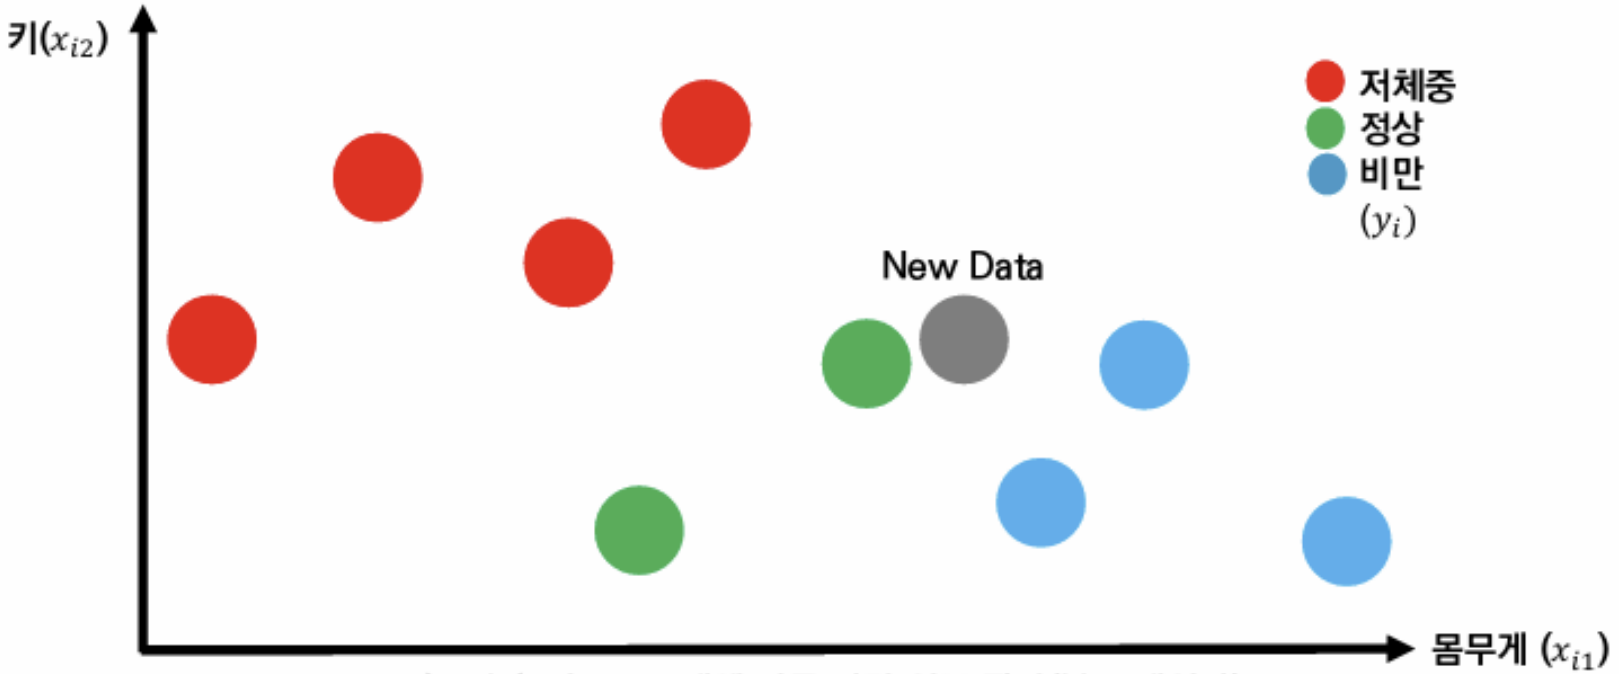
k = 3일 때,
$y'_1 = 1$ (비만)

〈표1〉 키 – 몸무게 등급에 따른 비만 여부 판단 (테이블 데이터)

K 최근접 이웃 (분류)

k 최근접 이웃 알고리즘 (분류 문제)

- Step1. 새로운 관측치가 들어옴

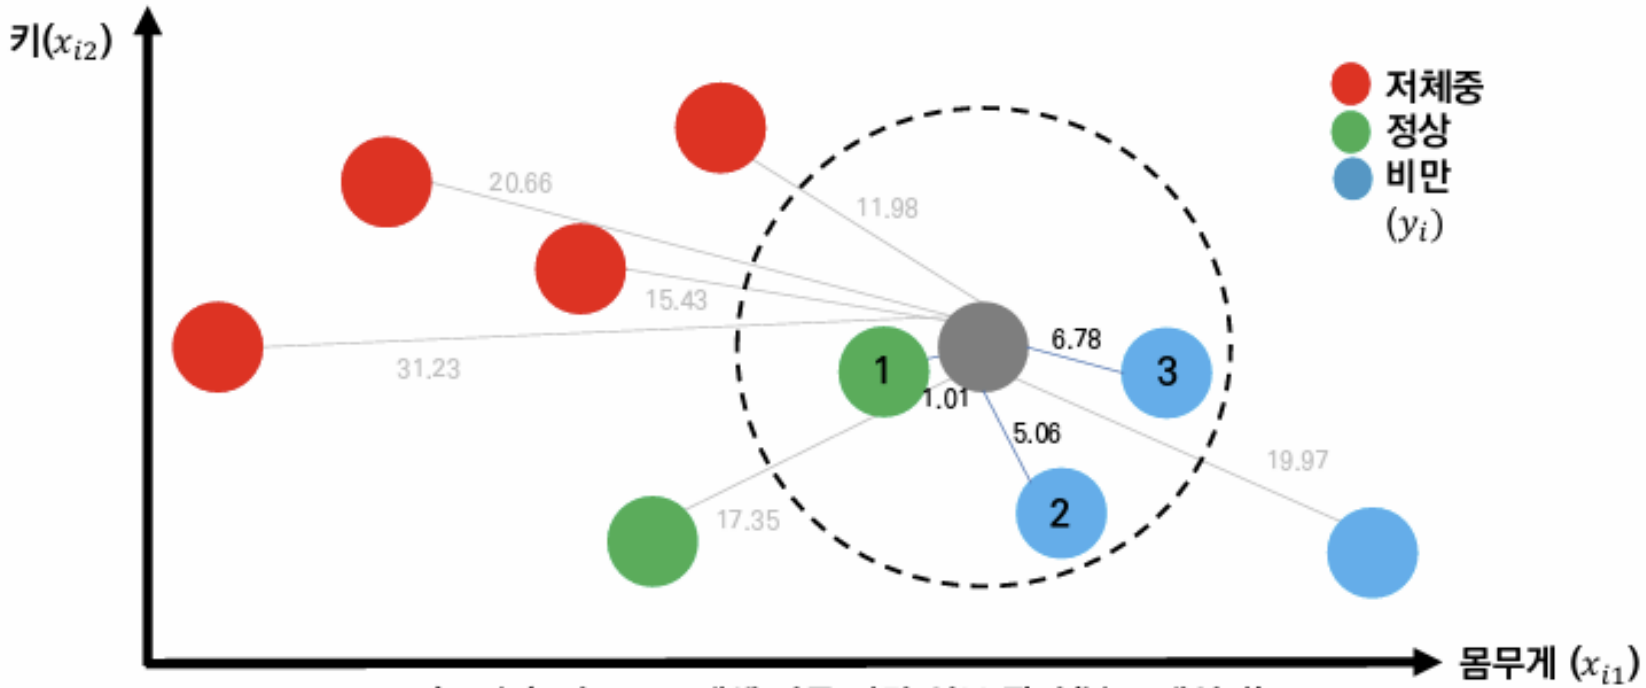


〈그림3〉 키 – 몸무게에 따른 비만 여부 판단(분류 데이터)

K 최근접 이웃 (분류)

k 최근접 이웃 알고리즘 (분류 문제)

– Step2. 관측치로부터 인접한 k 개의 학습 데이터를 탐색 (거리측도)

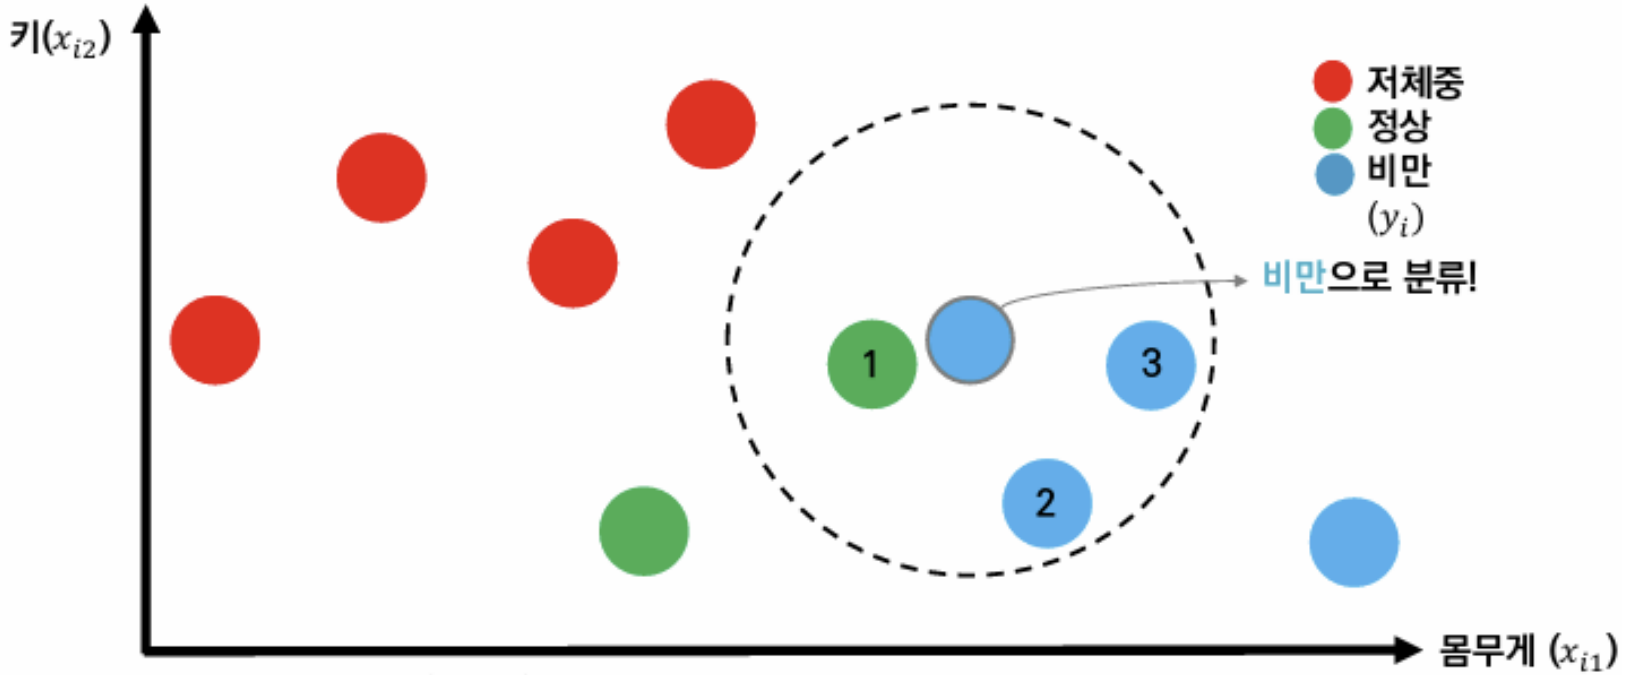


〈그림3〉 키 – 몸무게에 따른 비만 여부 판단(분류 데이터)

K 최근접 이웃 (분류)

k 최근접 이웃 알고리즘 (분류 문제)

- Step3. 탐색된 k개의 학습 데이터로 새 관측치의 클래스를 정의 (k개의 데이터 다수결)



〈그림3〉 키 – 몸무게에 따른 비만 여부 판단(분류 데이터)

K 최근접 이웃 (분류)

k 최근접 이웃 예제 (분류)

- 생도의 유전자 정보와 코로나 확진 여부가 주어졌다.
- 신입 생도의 코로나 확진 여부를 k 최근접 이웃 문제를 통해 예측해보자. (k=1, k=3)

	유전자1	유전자2	유전자3	유전자4	확진여부	새 관측치와의 거리
생도A	2.54	4.33	3.99	2.57	정상	
생도B	3.12	3.87	3.84	3.04	정상	
생도C	2.76	4.17	5.63	3.28	정상	
생도D	3.87	3.56	4.25	3.65	확진	
생도E	3.55	3.91	2.68	4.22	확진	
생도F	4.12	2.86	3.30	3.71	확진	
신입생도	3.24	3.68	3.82	3.77	???	

〈표2〉 유전자 정보에 따른 코로나 확진 여부 데이터 (분류 문제)

K 최근접 이웃 (분류)

k 최근접 이웃 예제 (분류)

* 유클리디안 거리 사용

- 생도A~F와 신입생도의 유전자 정보를 통해 거리를 연산한다.
- 가장 가까운 데이터의 라벨을 통해 신입생도의 확진 여부를 결정한다. (k=1)

	유전자1	유전자2	유전자3	유전자4	확진여부	새 관측치와의 거리
생도A	2.54	4.33	3.99	2.57	정상	1.54
생도B	3.12	3.87	3.84	3.04	정상	0.76
생도C	2.76	4.17	5.63	3.28	정상	2.00
생도D	3.87	3.56	4.25	3.65	확진	0.78
생도E	3.55	3.91	2.68	4.22	확진	1.28
생도F	4.12	2.86	3.30	3.71	확진	1.31
신입생도	3.24	3.68	3.82	3.77	정상	

〈표2〉 유전자 정보에 따른 코로나 확진 여부 데이터 (분류 문제)

K 최근접 이웃 (분류)

k 최근접 이웃 예제 (분류)

* 유클리디안 거리 사용

- 생도A~F와 신입생도의 유전자 정보를 통해 거리를 연산한다.
- 가장 가까운 3개의 데이터의 라벨을 통해 신입생도의 확진 여부를 결정한다. (k=3)

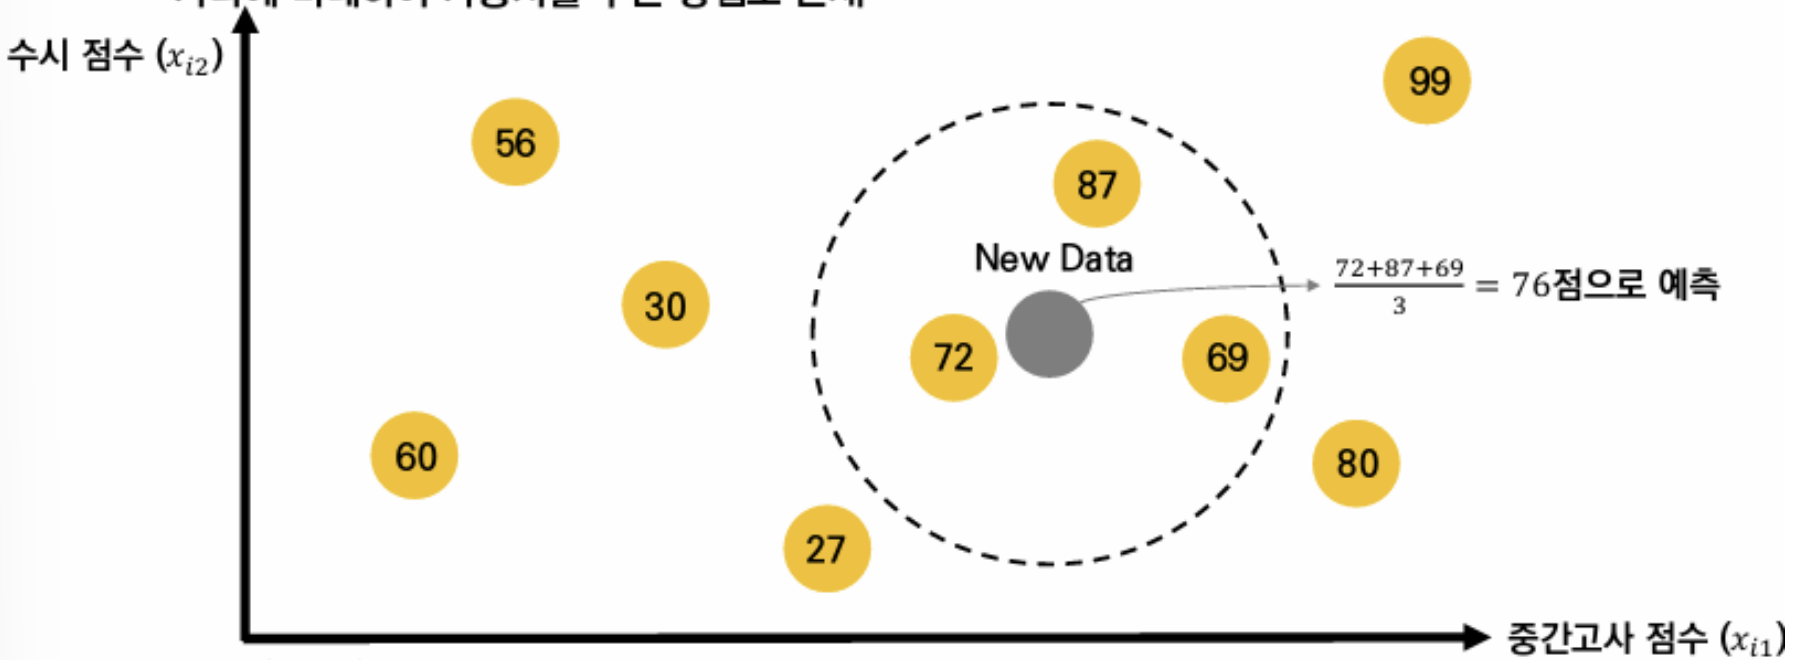
	유전자1	유전자2	유전자3	유전자4	확진여부	새 관측치와의 거리
생도A	2.54	4.33	3.99	2.57	정상	1.54
생도B	3.12	3.87	3.84	3.04	정상	0.76
생도C	2.76	4.17	5.63	3.28	정상	2.00
생도D	3.87	3.56	4.25	3.65	확진	0.78
생도E	3.55	3.91	2.68	4.22	확진	1.28
생도F	4.12	2.86	3.30	3.71	확진	1.31
신입생도	3.24	3.68	3.82	3.77	확진	

〈표2〉 유전자 정보에 따른 코로나 확진 여부 데이터 (분류 문제)

K 최근접 이웃 (회귀)

y_i 생도 i의 기말 성적

- k 최근접 이웃 알고리즘 (회귀 문제)
  - y_j의 값이 범주형 데이터가 아닌 연속형 데이터일 경우에는 회귀를 수행
  - 알고리즘의 동작은 동일하나, k 개 데이터의 값의 평균을 회귀값으로 반환
    - ✓ 거리에 비례하여 가중치를 주는 방법도 존재



〈그림4〉 인공지능 입문 중간고사 점수와 수시 점수에 따른 기말고사 점수 예측(회귀 데이터)

K 최근접 이웃 (회귀)

* 유클리디안 거리 사용

k 최근접 이웃 예제 (회귀)

- 생도의 과목별 최종 점수와 인공지능 입문 최종 점수 정보가 주어졌다.
- 신입 생도의 인공지능 최종 점수를 k 최근접 이웃을 통해 예측해보자. (k=1, k=3)

	미적분학	기초물리학	프로그래밍	통계의이해	군사영어	인공지능 입문	새 관측치와의 거리
생도A	7.5	7.5	7.0	9.5	8.5	5.0	
생도B	7.5	7.0	7.5	8.0	8.0	6.0	
생도C	8.0	7.0	8.0	8.0	8.5	8.5	
생도D	8.5	8.0	9.5	7.5	6.0	7.0	
생도E	10.0	9.5	9.0	7.5	7.5	10.0	
생도F	9.0	9.0	8.0	8.0	8.0	9.0	
신입생도	9.0	8.5	8.0	7.0	8.0	???	

〈표3〉 타과목 점수에 따른 인공지능 입문 점수 데이터 (회귀 문제)

K 최근접 이웃 (회귀)

* 유클리디안 거리 사용

k 최근접 이웃 예제 (회귀)

- 생도의 과목별 최종 점수와 인공지능 입문 최종 점수 정보가 주어졌다.
- 신입 생도의 인공지능 최종 점수를 k 최근접 이웃을 통해 예측해보자. (k=1, k=3)

	미적분학	기초물리학	프로그래밍	통계의이해	군사영어	인공지능 입문	새 관측치와의 거리
생도A	7.5	7.5	7.0	9.5	8.5	5.0	3.28
생도B	7.5	7.0	7.5	8.0	8.0	6.0	2.40
생도C	8.0	7.0	8.0	8.0	8.5	8.5	2.12
생도D	8.5	8.0	9.5	7.5	6.0	7.0	2.65
생도E	10.0	9.5	9.0	7.5	7.5	10.0	1.87
생도F	9.0	9.0	8.0	8.0	8.0	9.0	1.12
신입생도	9.0	8.5	8.0	7.0	8.0	???	

k = 1 9.0
k = 3 (9.0 + 10.0 +8.5)/3 = 9.17

〈표3〉 타과목 점수에 따른 인공지능 입문 점수 데이터 (회귀 문제)

K 최근접 이웃의 특성

* 유클리디안 거리 사용

k 최근접 이웃의 초매개변수 초매개변수란? 자동으로 결정 되는 매개변수가 아닌 직접 입력해주는 매개변수

- k
  - ✓ 인접한 학습 데이터를 몇 개까지 탐색할 것인가?
- 거리 측도
  - ✓ 데이터 간 거리는 어떻게 측정할 것인가? 유클리디안 거리, 맨하탄 거리 등등



1-nearest neighbor



5-nearest neighbor



15-nearest neighbor

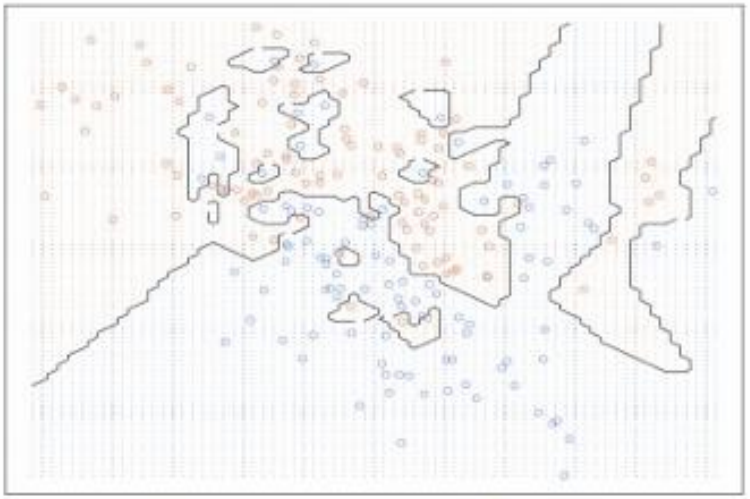


50-nearest neighbor

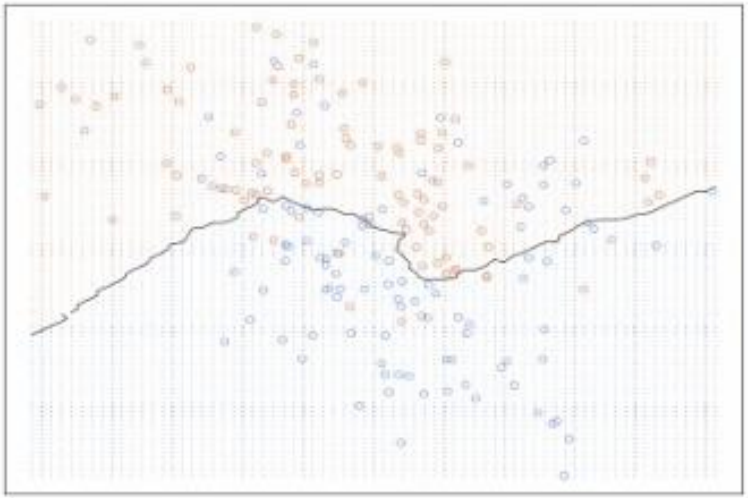
K 최근접 이웃의 특성

k 최근접 이웃의 초매개변수

- k가 매우 작을 경우 : 데이터의 지역적 특성을 지나치게 반영함 (과대적합)
- k가 매우 클 경우 : 다른 범주의 개체를 너무 많이 포함하여 잘못 예측할 위험 (과소적합)



1-nearest neighbor

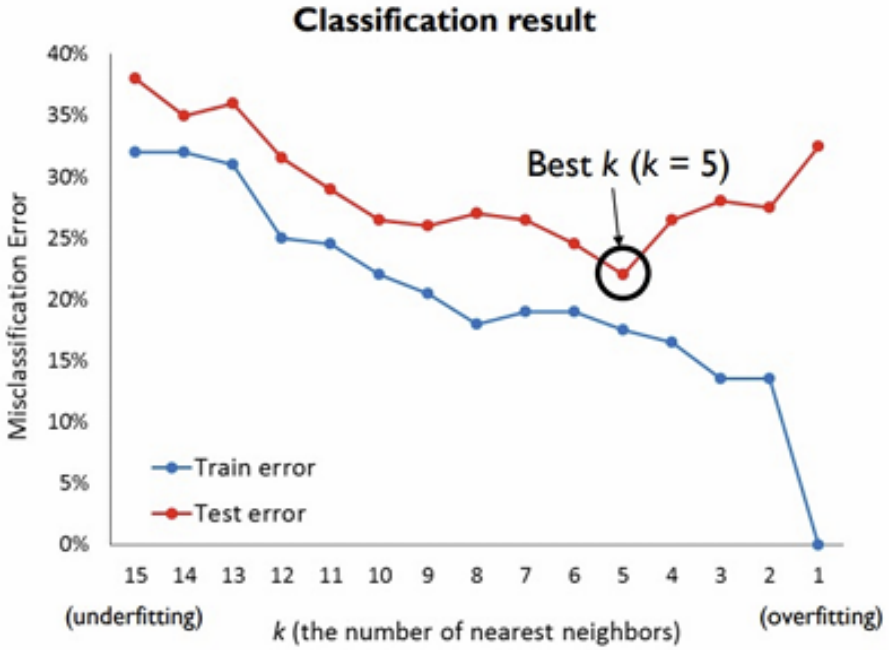


50-nearest neighbor

K 최근접 이웃의 특성

k 선택 방법

- 일정 범위 내에서 k를 조정하여, 가장 좋은 예측 결과를 보이는 k 값을 선정
  - ✓ k의 값을 1부터 15까지 실험해보면서 성능이 가장 좋을 때의 결과 값을 설정한다.
  - ✓ 학습데이터를 기준으로 설정하는 것이 아니라, 테스트 데이터(새로운 관측치)에 대한 결과가 중요



질문 및 정리

