기계학습특론

XAI



목차

1 XAI



AI에게 '설명'이 필요한 이유

AI 보급과 새로운 요구 사항

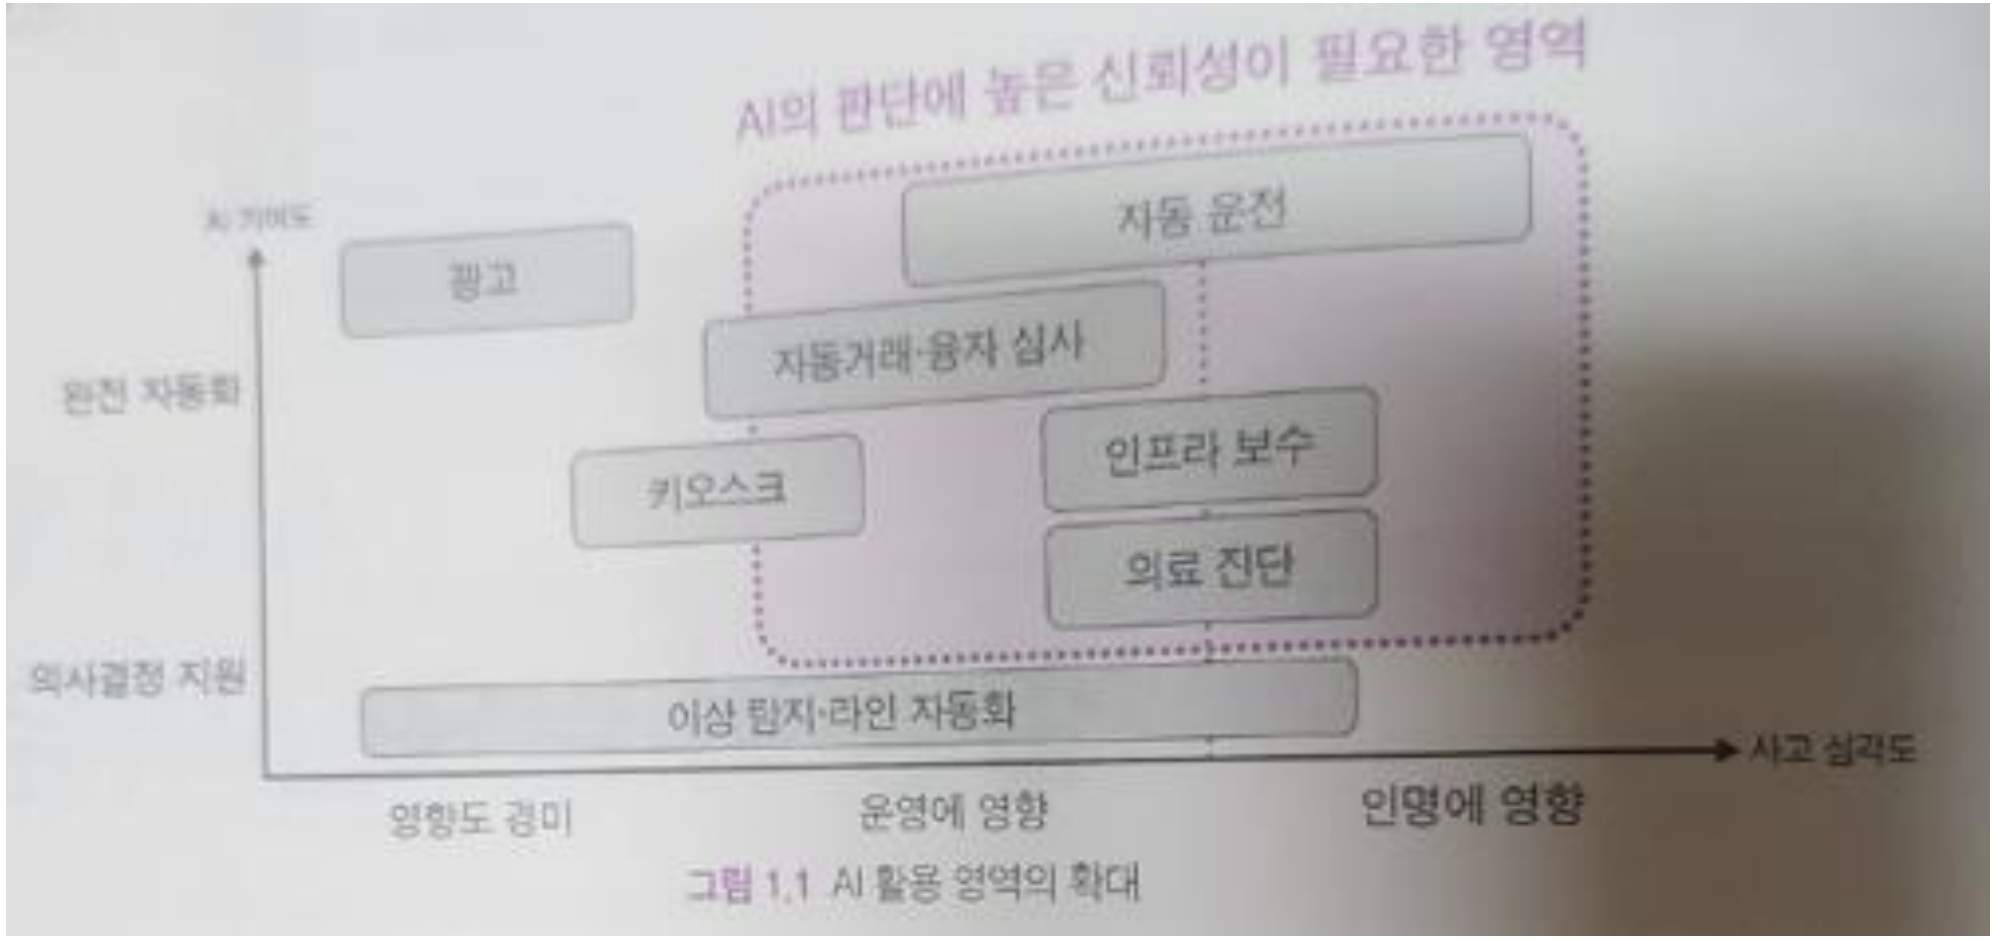


그림 1.1 AI 활용 영역의 확대

AI에게 '설명'이 필요한 이유

AI 보급과 새로운 요구 사항

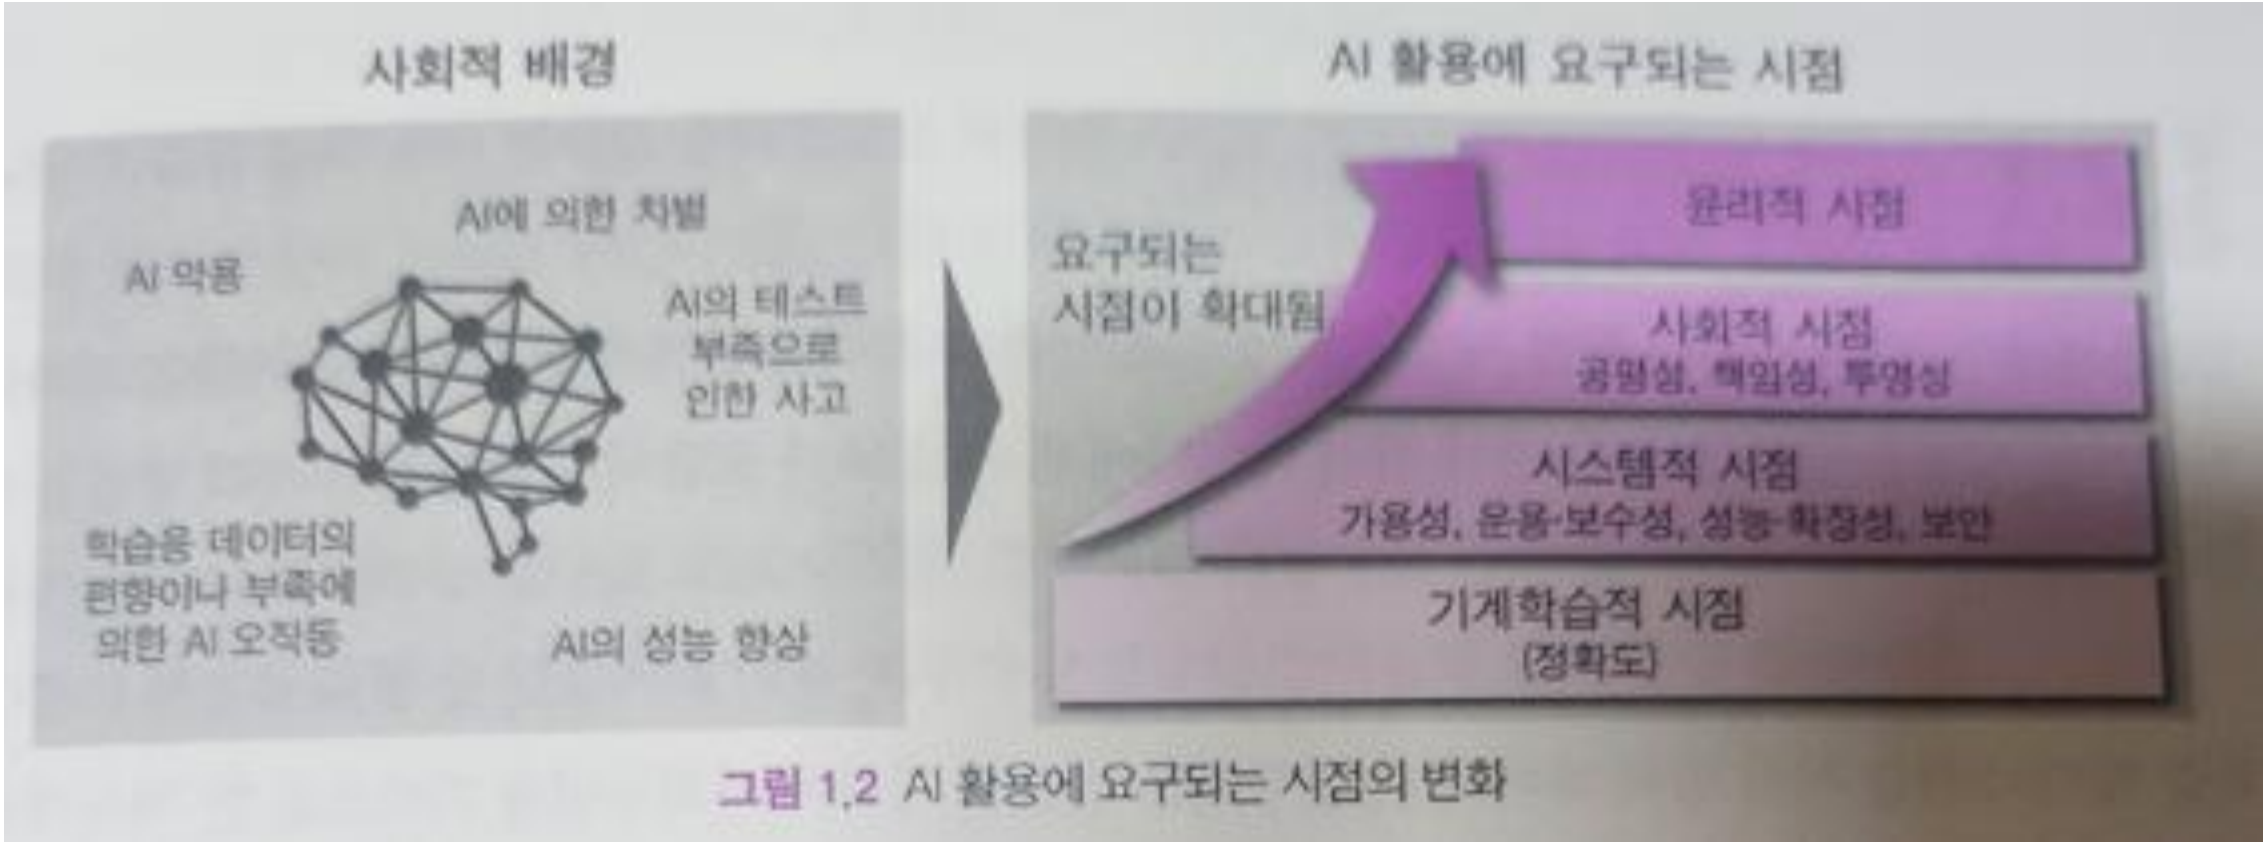


그림 1.2 AI 활용에 요구되는 시점의 변화

AI의 공평성, 책임성, 투명성

AI의 공평성

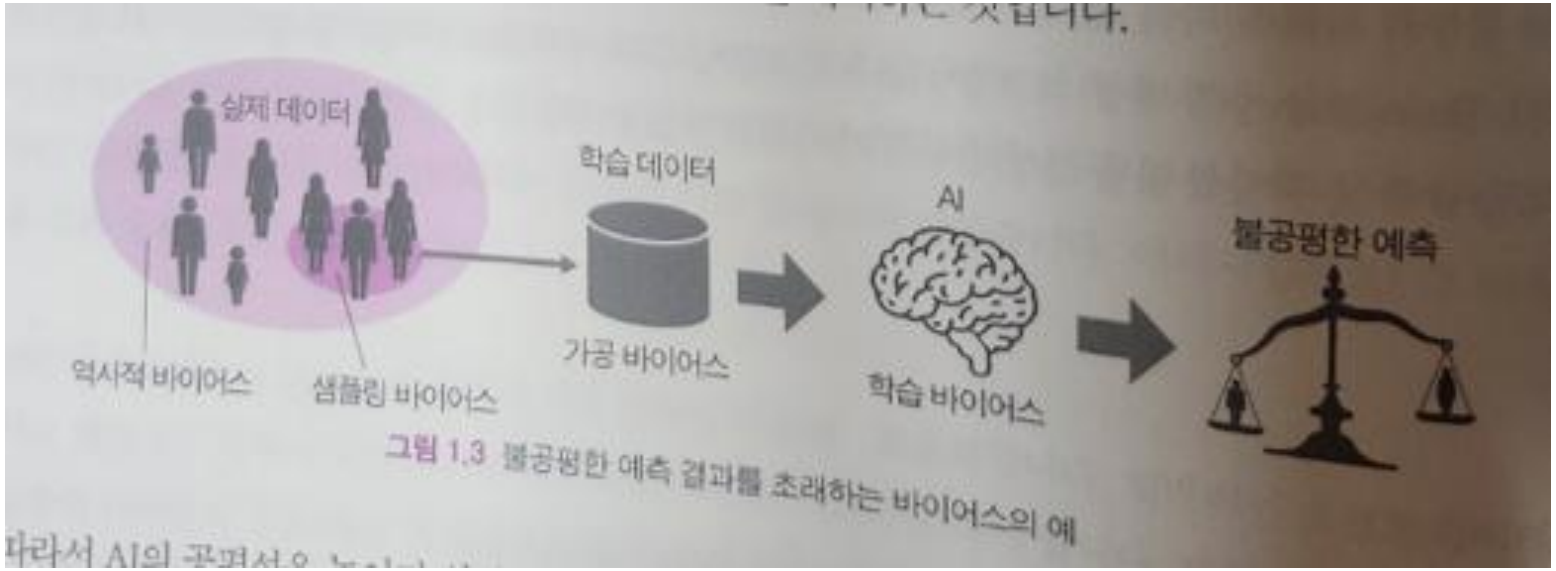


그림 1.3 불공평한 예측 결과를 초래하는 바이어스의 예

따라서 AI의 공평성은

AI의 책임성 (Accountability)

AI의 투명성 (Transparency)

AI의 설명 가능성

AI의 설명 가능성

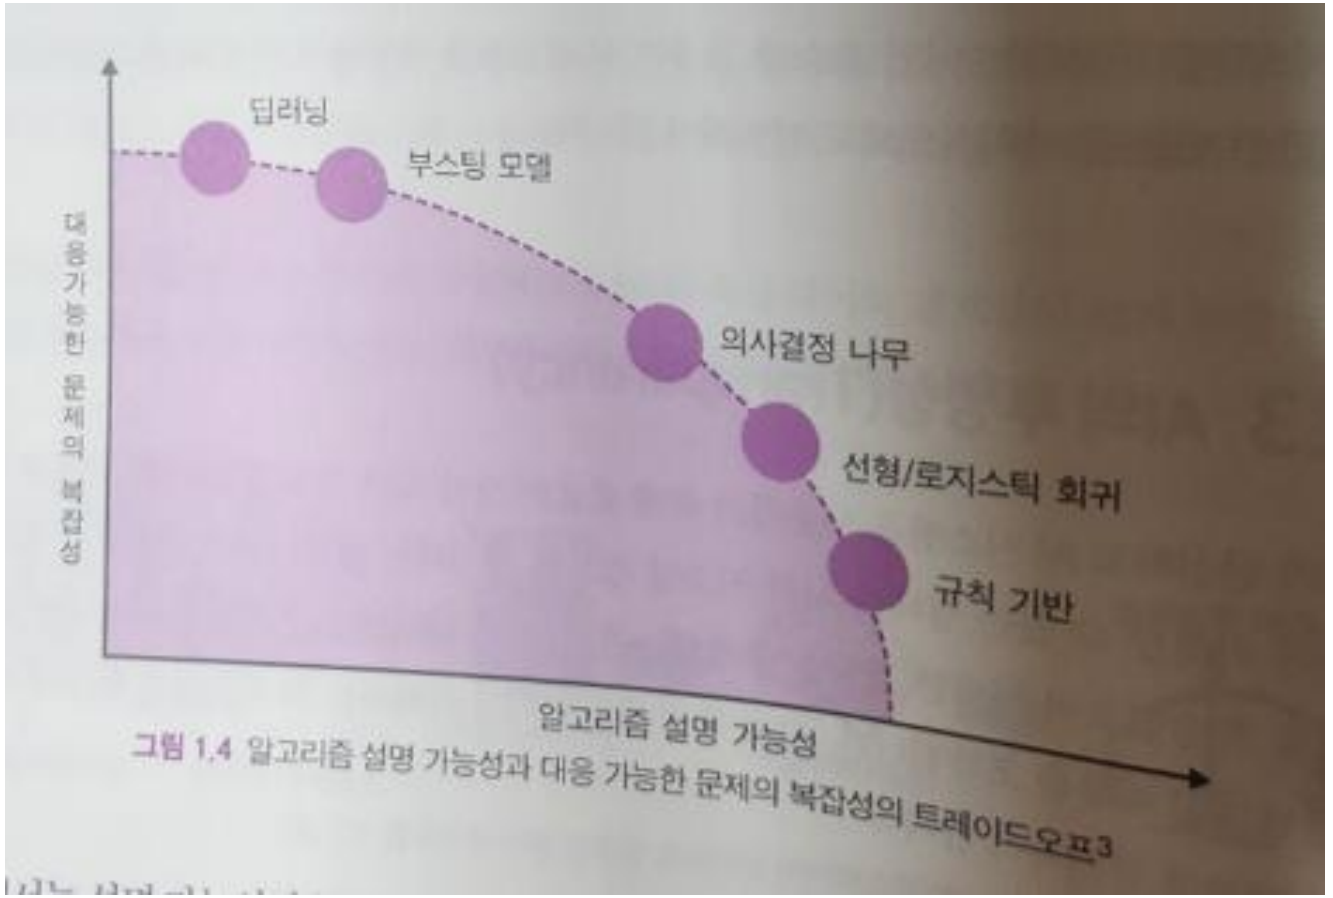


그림 1.4 알고리즘 설명 가능성과 대응 가능한 문제의 복잡성의 트레이드오프3

AI의 설명 가능성

설명 가능성이 높은 알고리즘

- 의사결정트리

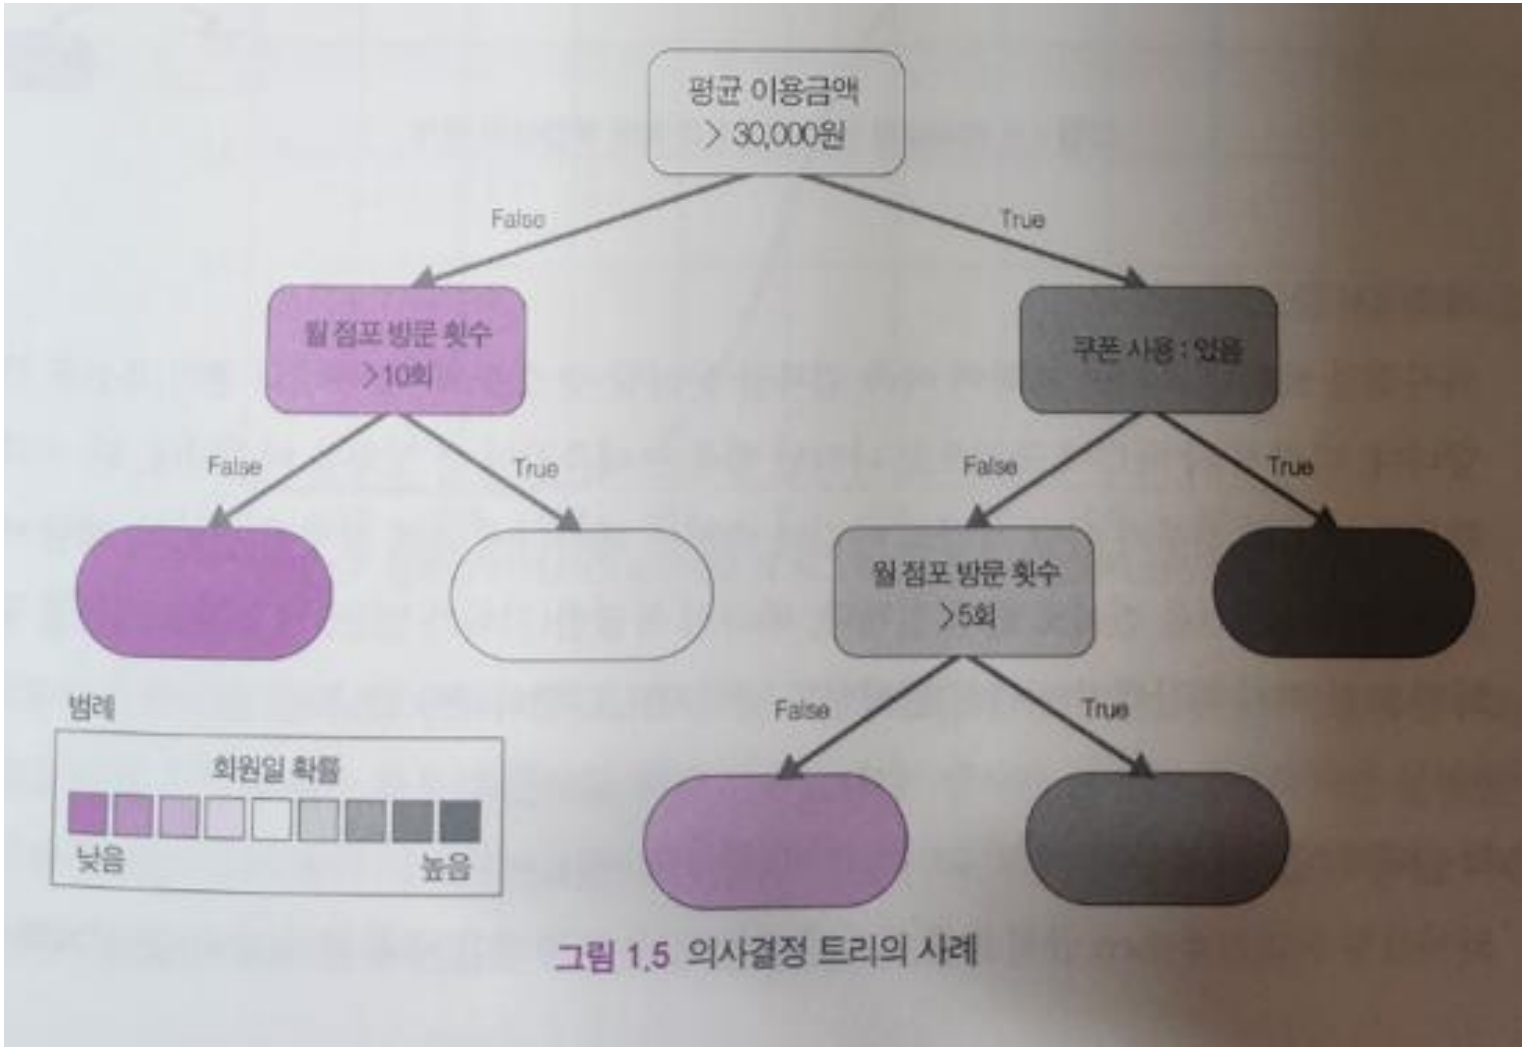
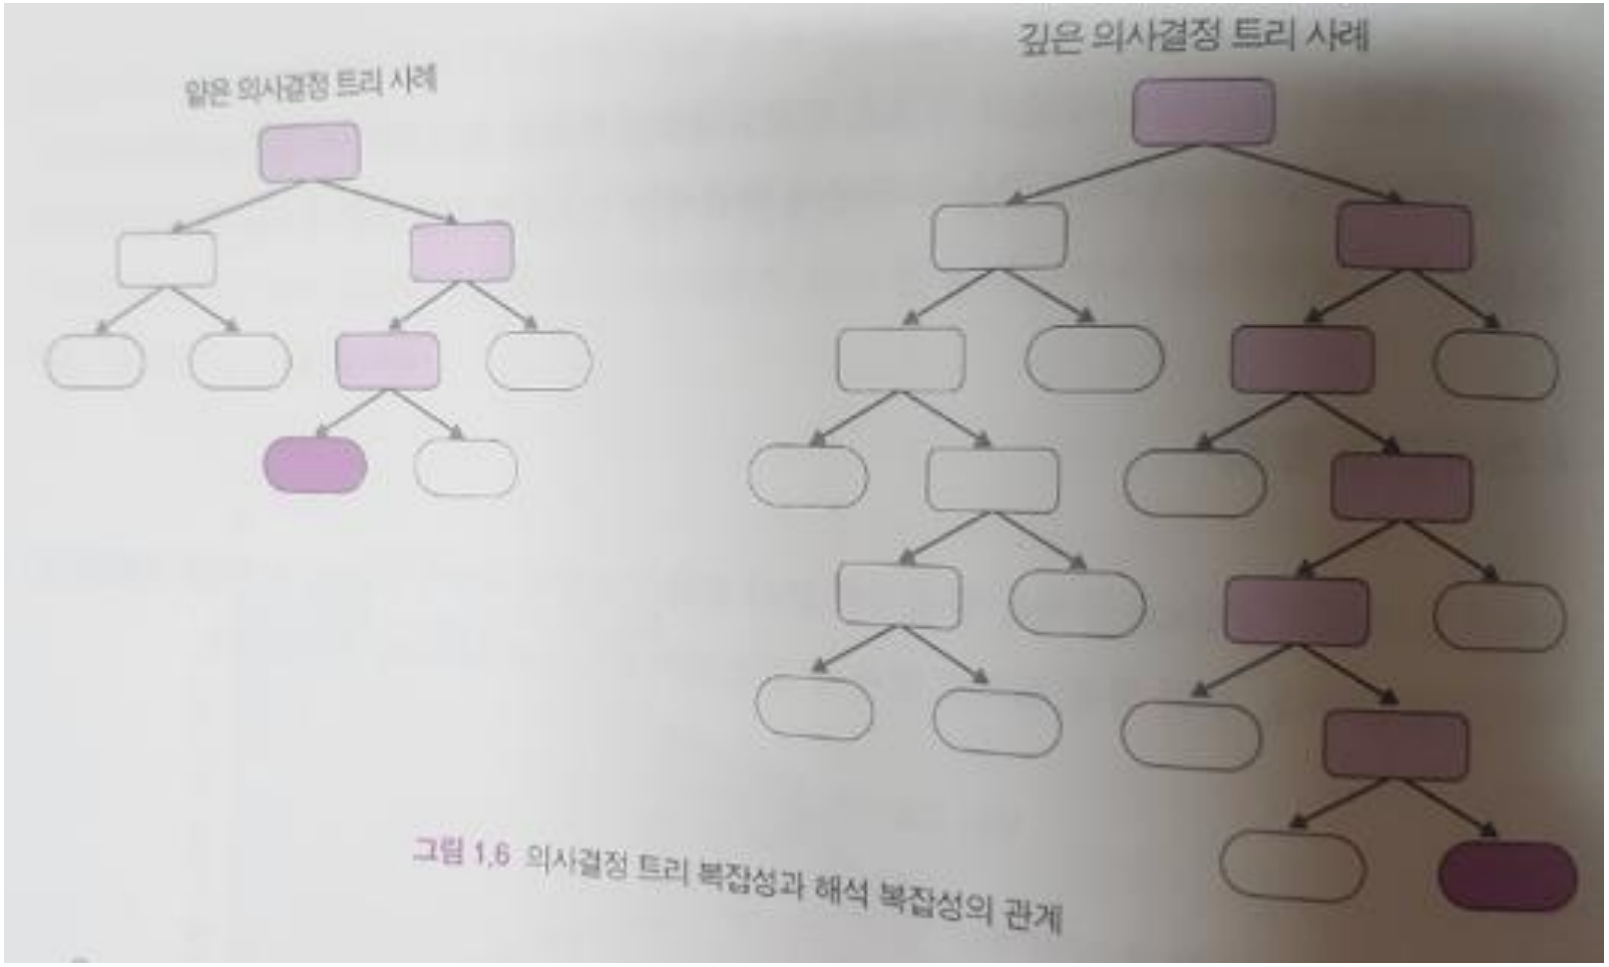


그림 1.5 의사결정 트리의 사례

AI의 설명 가능성

설명 가능성이 높은 알고리즘

- 의사결정트리
- 1. 예측에서 중요한 항목
- 2. 각 입력에 대한 예측 근거



AI의 설명 가능성

설명 가능성이 높은 알고리즘

- 로지스틱 회귀
- 1. 예측에서 중요한 항목
- 각 입력에 대한 예측 근거

$$P_{(y=[\text{yes}])} = \frac{1}{1+e^{-(\alpha_1 x_1+\alpha_2 x_2+\cdots+\alpha_n x_n+\beta)}}$$

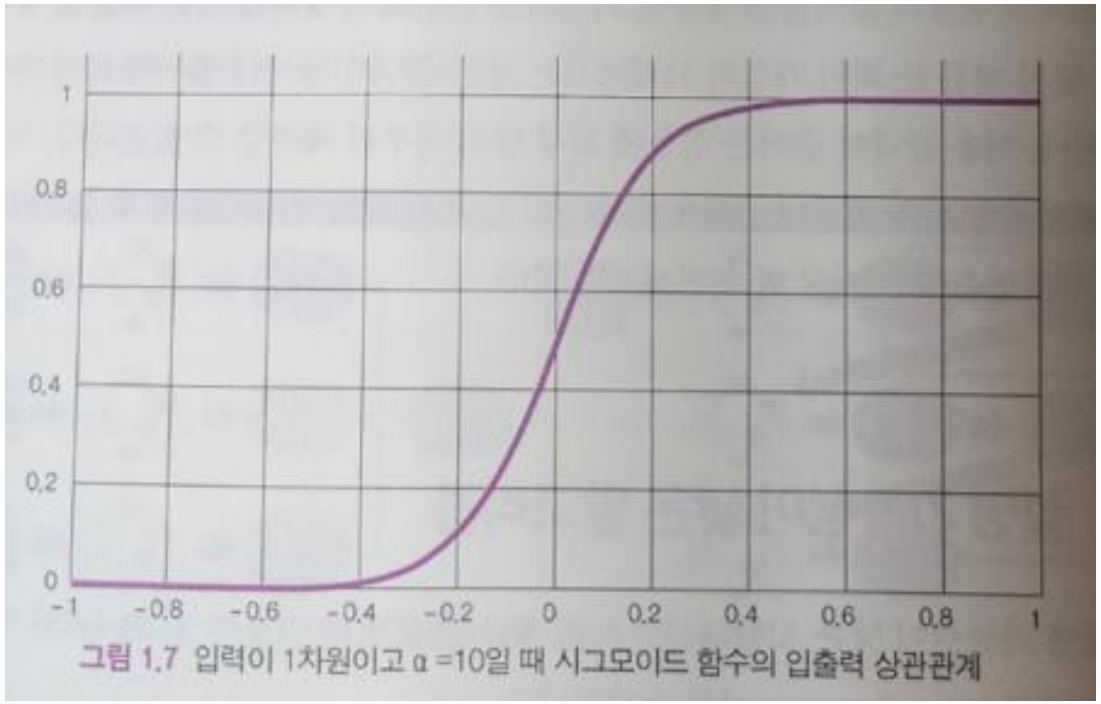


그림 1.7 입력이 1차원이고 α =10일 때 시그모이드 함수의 입출력 상관관계

AI의 설명 가능성

설명 가능성이 낮은 알고리즘

- XGBoost
- 1. 예측에서 중요한 항목
- 2. 각 입력에 대한 예측 근거

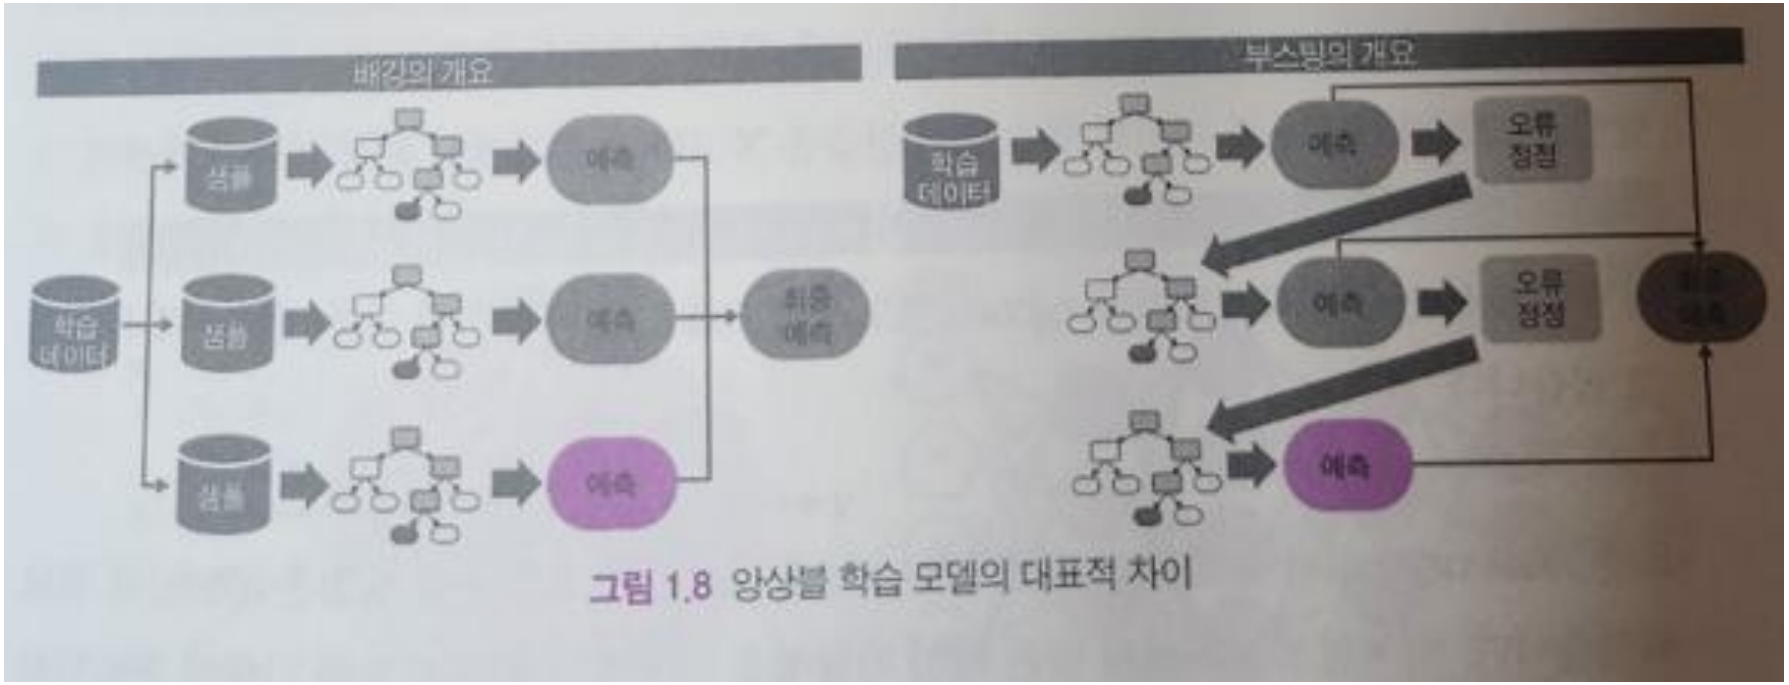


그림 1.8 앙상블 학습 모델의 대표적 차이

AI의 설명 가능성

설명 가능성이 낮은 알고리즘

- MLP

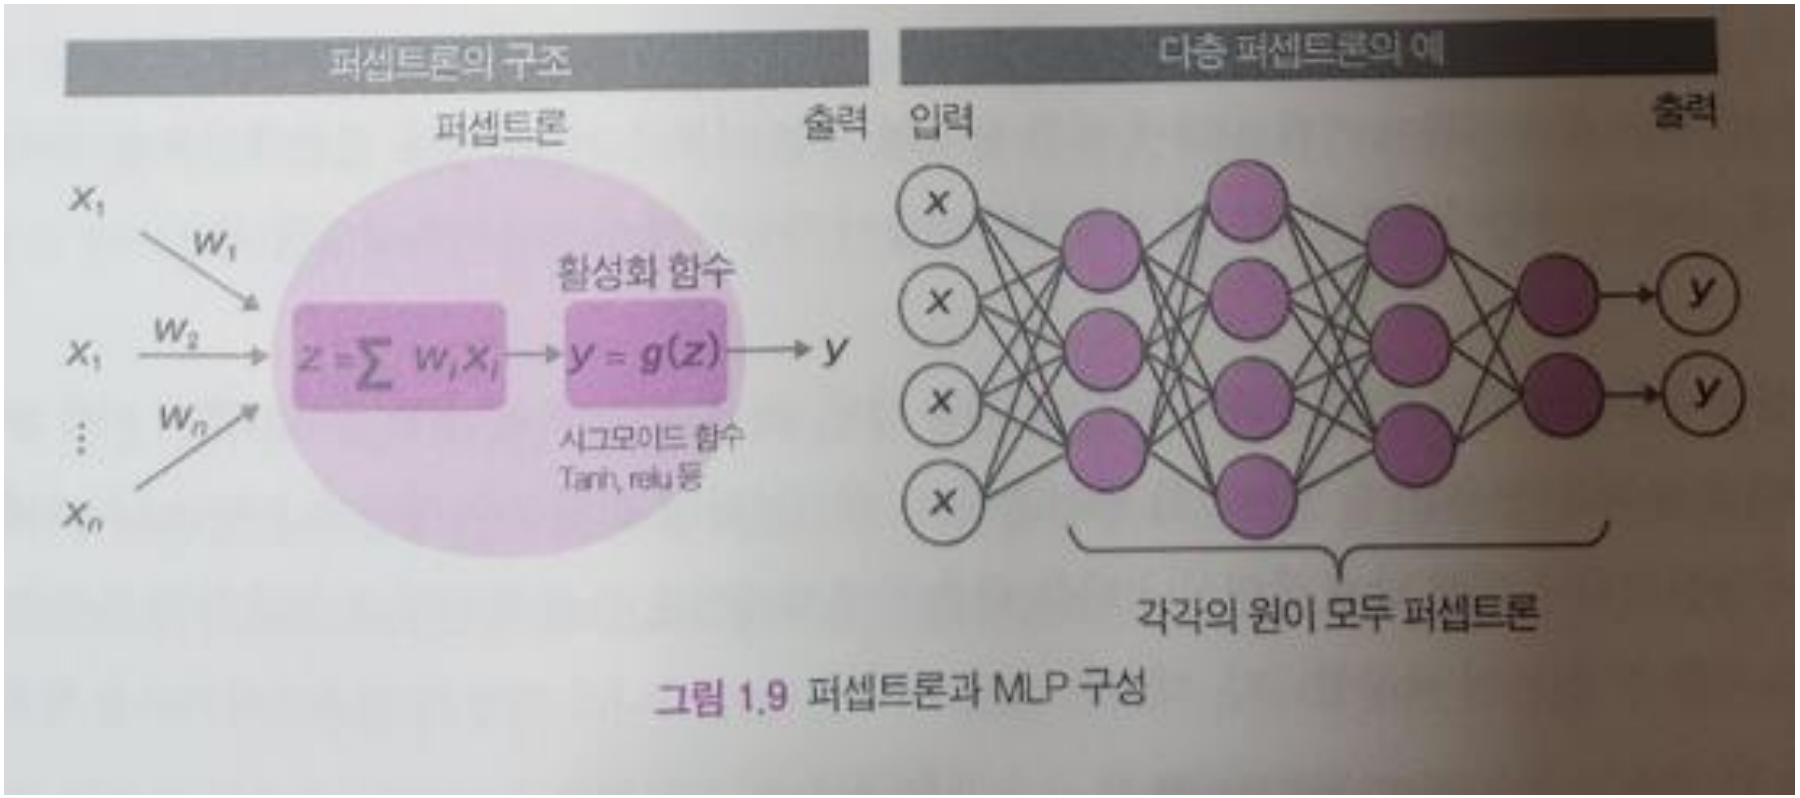


그림 1.9 퍼셉트론과 MLP 구성

AI의 설명 가능성

설명 가능성이 낮은 알고리즘

- MLP

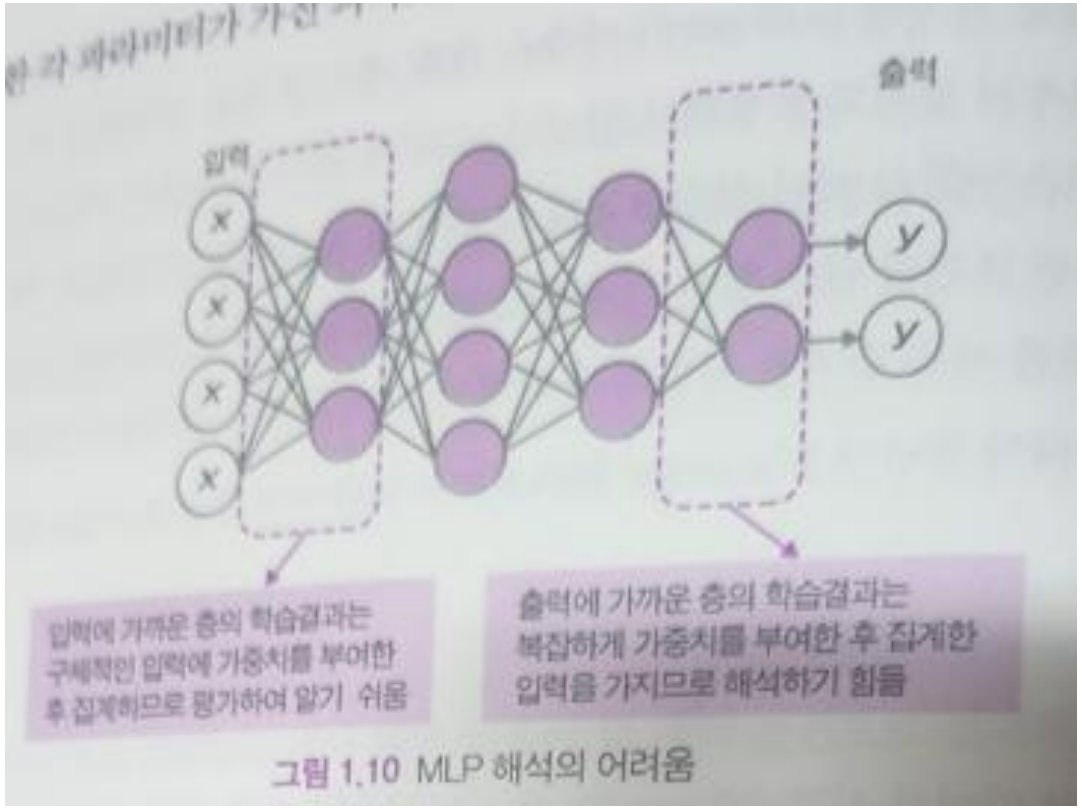


그림 1.10 MLP 해석의 어려움

설명가능한 AI

AI를 업무에 적용할 때 AI 설명이 필요한 이유

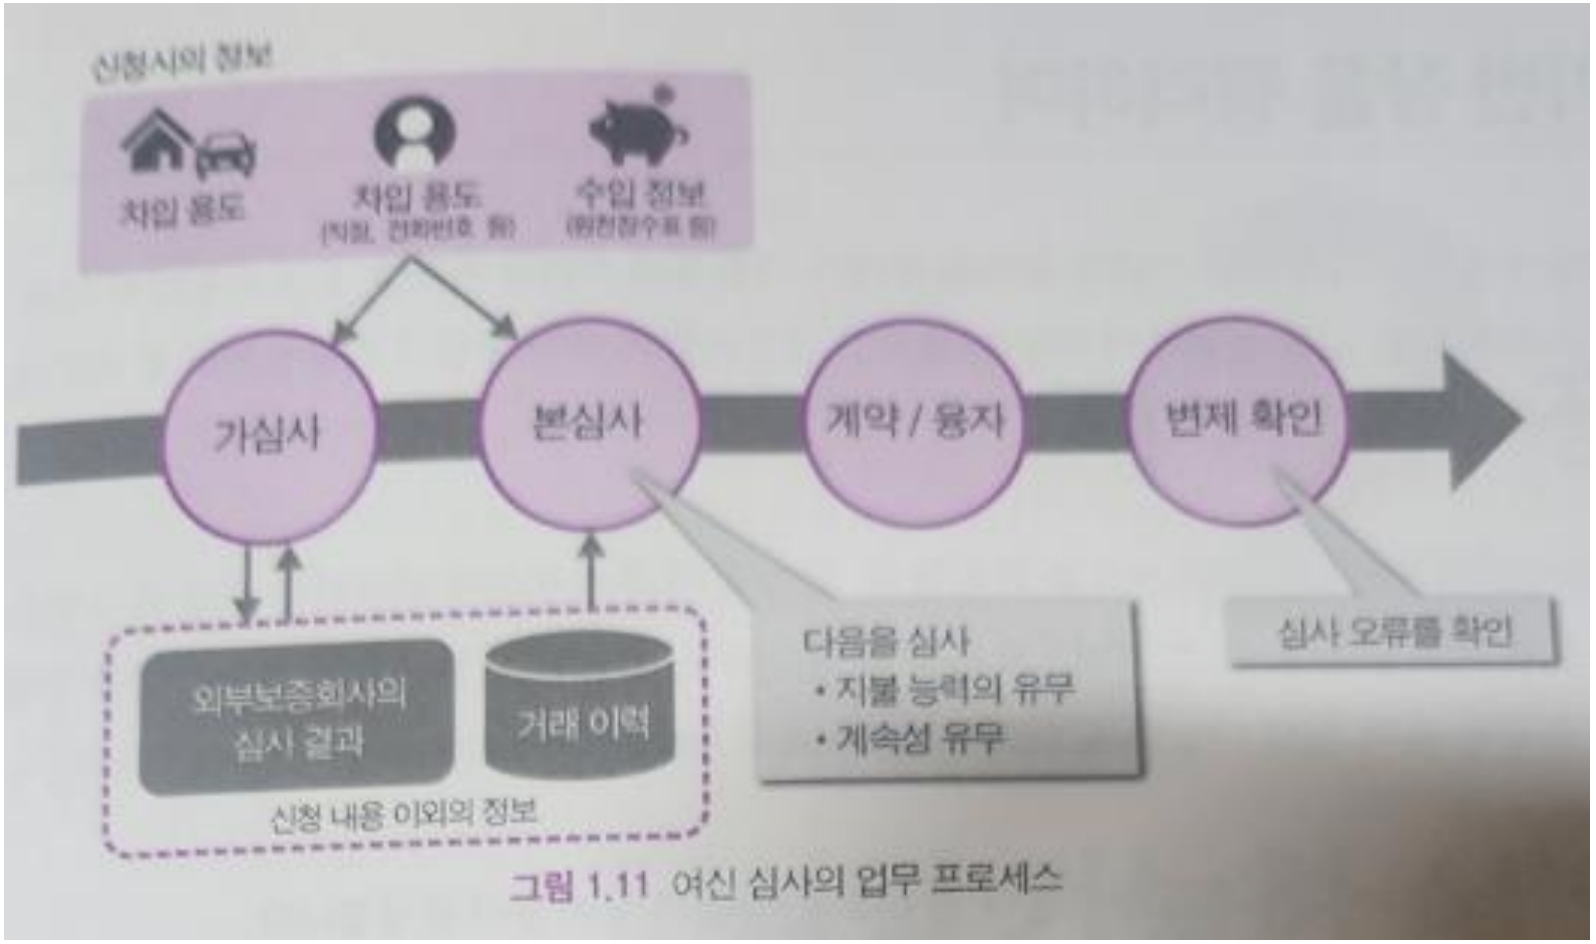


그림 1.11 여신 심사의 업무 프로세스

업무에서 필요한 설명 능력

비즈니스상의 설명

- AI활용 상황

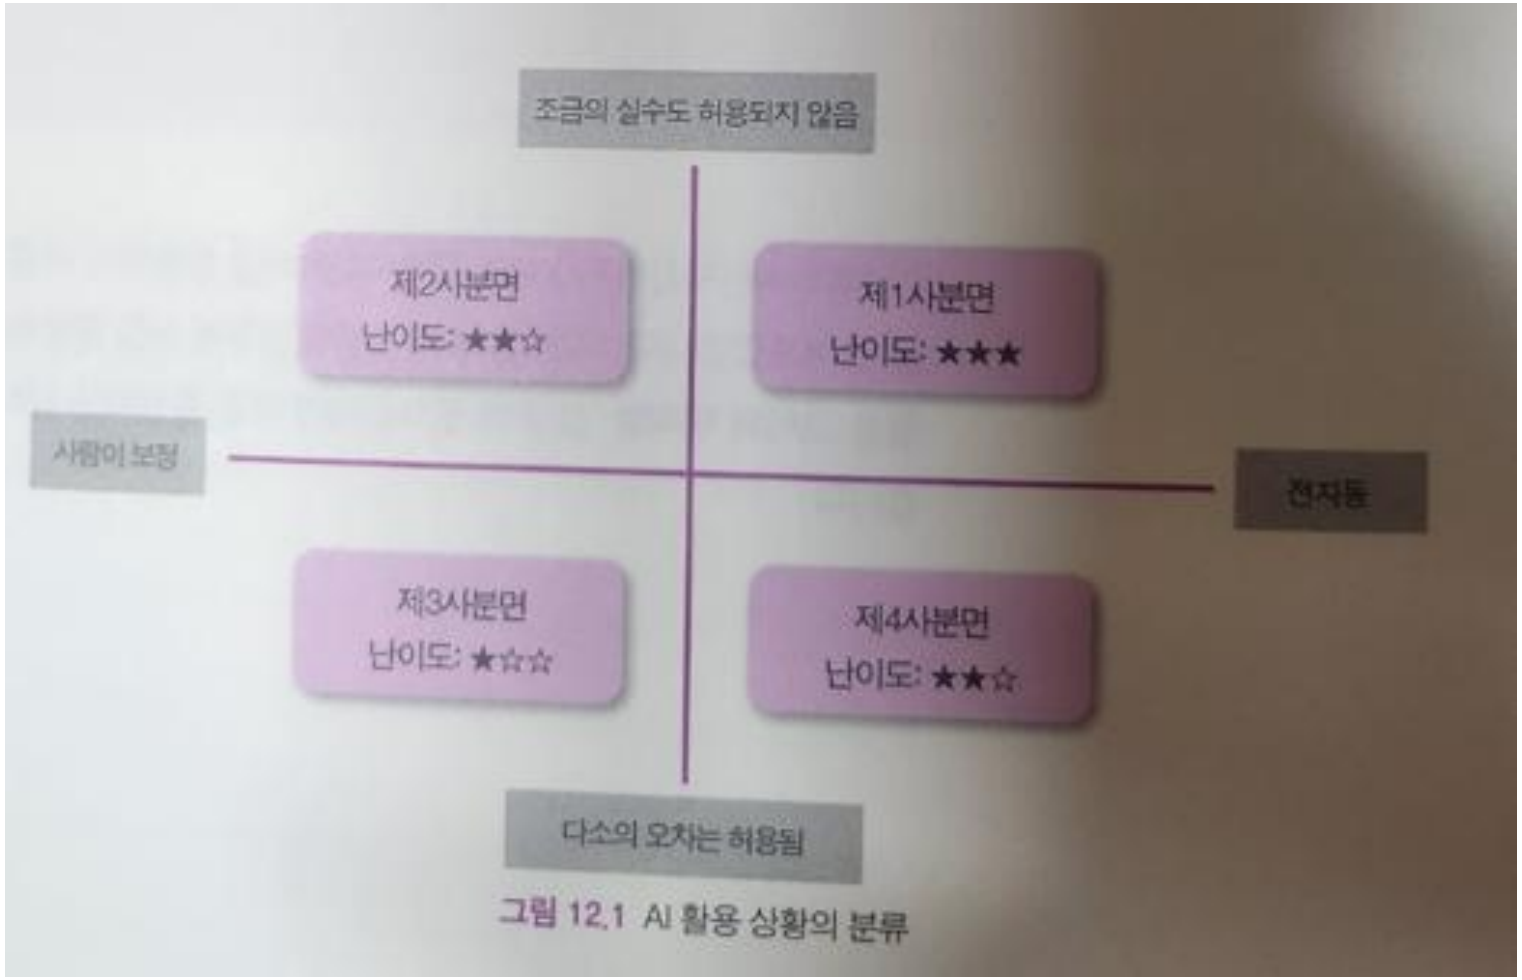


그림 12.1 AI 활용 상황의 분류

업무에서 필요한 설명 능력

비즈니스상의 설명

- AI활용 상황
- 1. 레벨 0: 비자율 주행
- 2. 레벨 1: 주행 지원
- 3. 레벨 2 : 부분 주행 자동화
- 4. 레벨 3 : 조건부 주행 자동화
- 5. 레벨 4 : 고속 주행 자동화
- 6. 레벨 5 : 완전 주행 자동화

레벨	명칭	주체
0	비자율주행	운전자
1	주행 지원	운전자
2	부분 주행 자동화	운전자
3	조건부 주행 자동화	자동차(자율 주행 시스템)
4	고속 주행 자동화	자동차(자율 주행 시스템)
5	완전 주행 자동화	자동차(자율 주행 시스템)

업무에서 필요한 설명 능력

비즈니스상의 설명

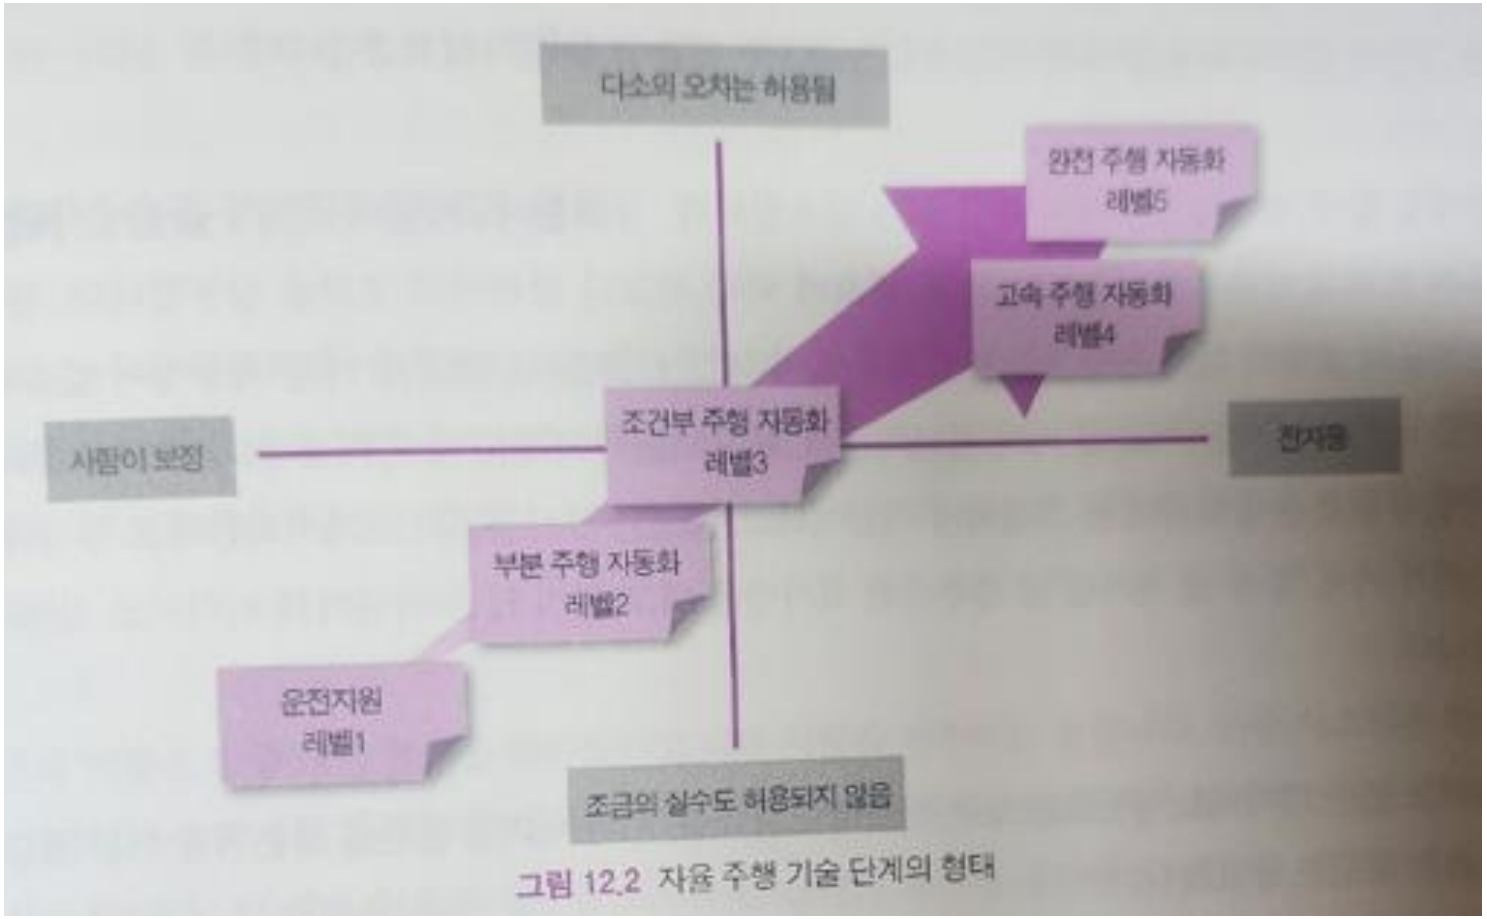


그림 12.2 자율 주행 기술 단계의 형태

업무에서 필요한 설명 능력

설명이 필요한 비즈니스 상황

- 법적 소송을 가정한 설명과 설득
- 중대한 의사결정을 할때의 설명과 설득
- 클러스터링에 의한 카테고리 라벨의 설명과 설득
- 처음부터 정형화된 설명 내용으로 결정할 때 설명과 설득

업무에서 필요한 설명 능력

비즈니스상 필요한 설명 분류

누구를 위해?(대상자)	무엇을 위해?(목적)	어떻게?(주요 방법)
모델 개발자	모델의 동작을 알고 개선함	XAI
모델을 사용하는 사람 (최종 사용자)	모델이 정확히 동작함을 설명	XAI 실험, 정밀도 리포트 제시
모델을 활용하는 사람	시책 입안 및 관련 힌트	XAI 사람의 판단이나 모델 밖에서의 구축
모델을 활용하는 사람	의사결정을 위한 증가	과거의 판단과 비교 모델 밖에서의 검증(시뮬레이션)
최종 사용자 사회	설명 책임	실험, 정밀도 리포트 제시 최초 상정 내용과 문제 발생시 차이를 제시

정밀도와 설명 능력의 Trade Off

복잡한 사상의 설명은 근본적으로 복잡하다

XAI에 과도한 기대는 금물

설득력 키우기

필요한 것은 이해가 아닌 설득?

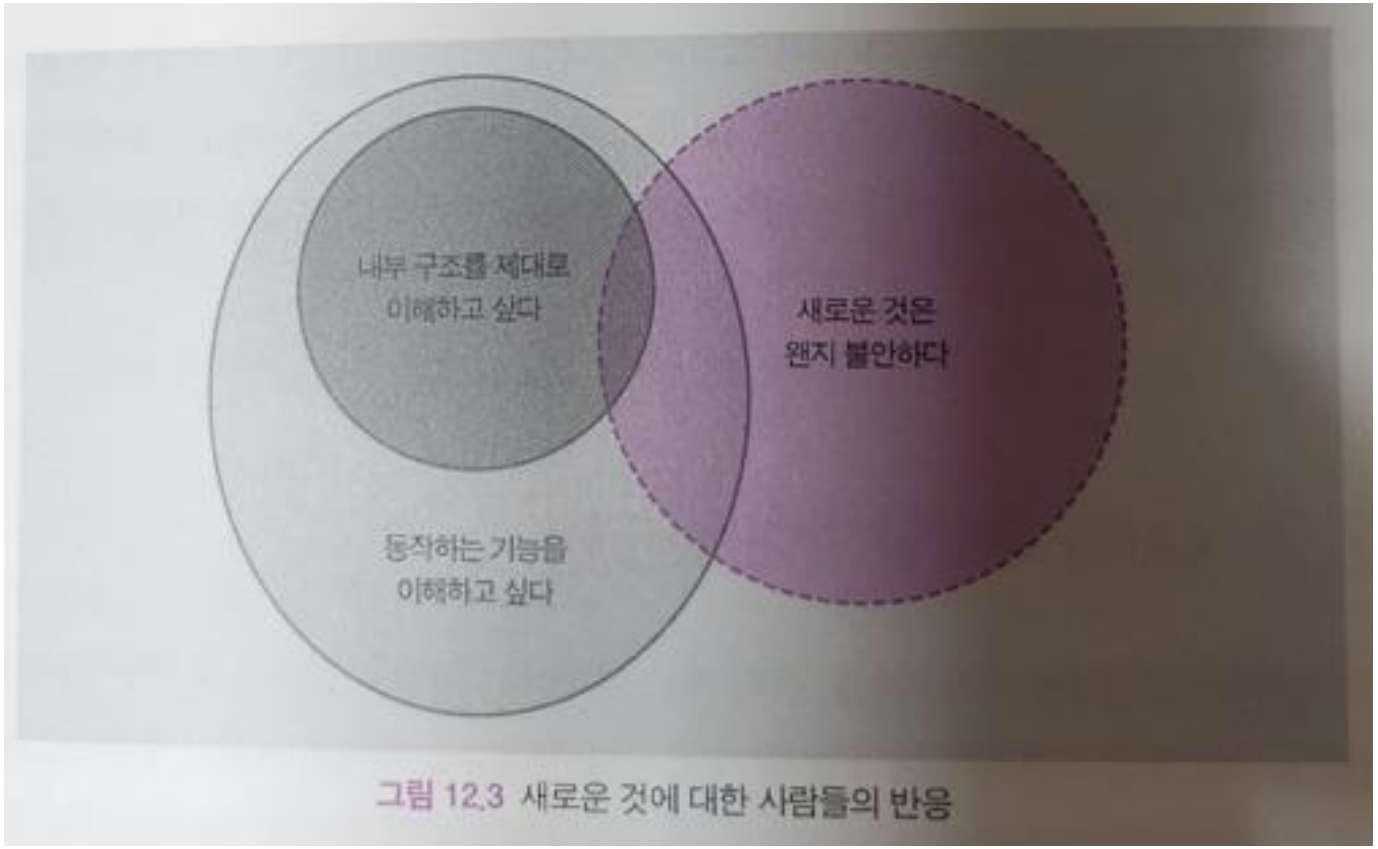


그림 12.3 새로운 것에 대한 사람들의 반응

설득력 키우기

필요한 것은 이해가 아닌 설득?

	mRNA 백신	AI 모델
1. 내부 구조까지 제대로 알고 싶은 사람을 위한 방안	백신 메커니즘 설명	모델 학습 및 예측 알고리즘 동작의 설명
2. 기능이나 효과를 이해하고 싶은 사람을 위한 설명	백신 접종 효과, 부작용 발생률의 정량 싶은 사람을 위한 설명 적 평가 공유, 상정된 최악의 경우 공유	예측 정밀도의 정량적 평가 공유 상정된 최악의 경우 공유
3. 그 이외의 사람을 위한 방안 실적을 쌓음	저명한 인사나 의사를 초대 실적을 쌓음 접종이 당연하다는 분위기를 조성	실무에서 실적 쌓기 매스미디어, 보드 등에서 소개

설득력 키우기

필요한 것은 이해가 아닌 설득?

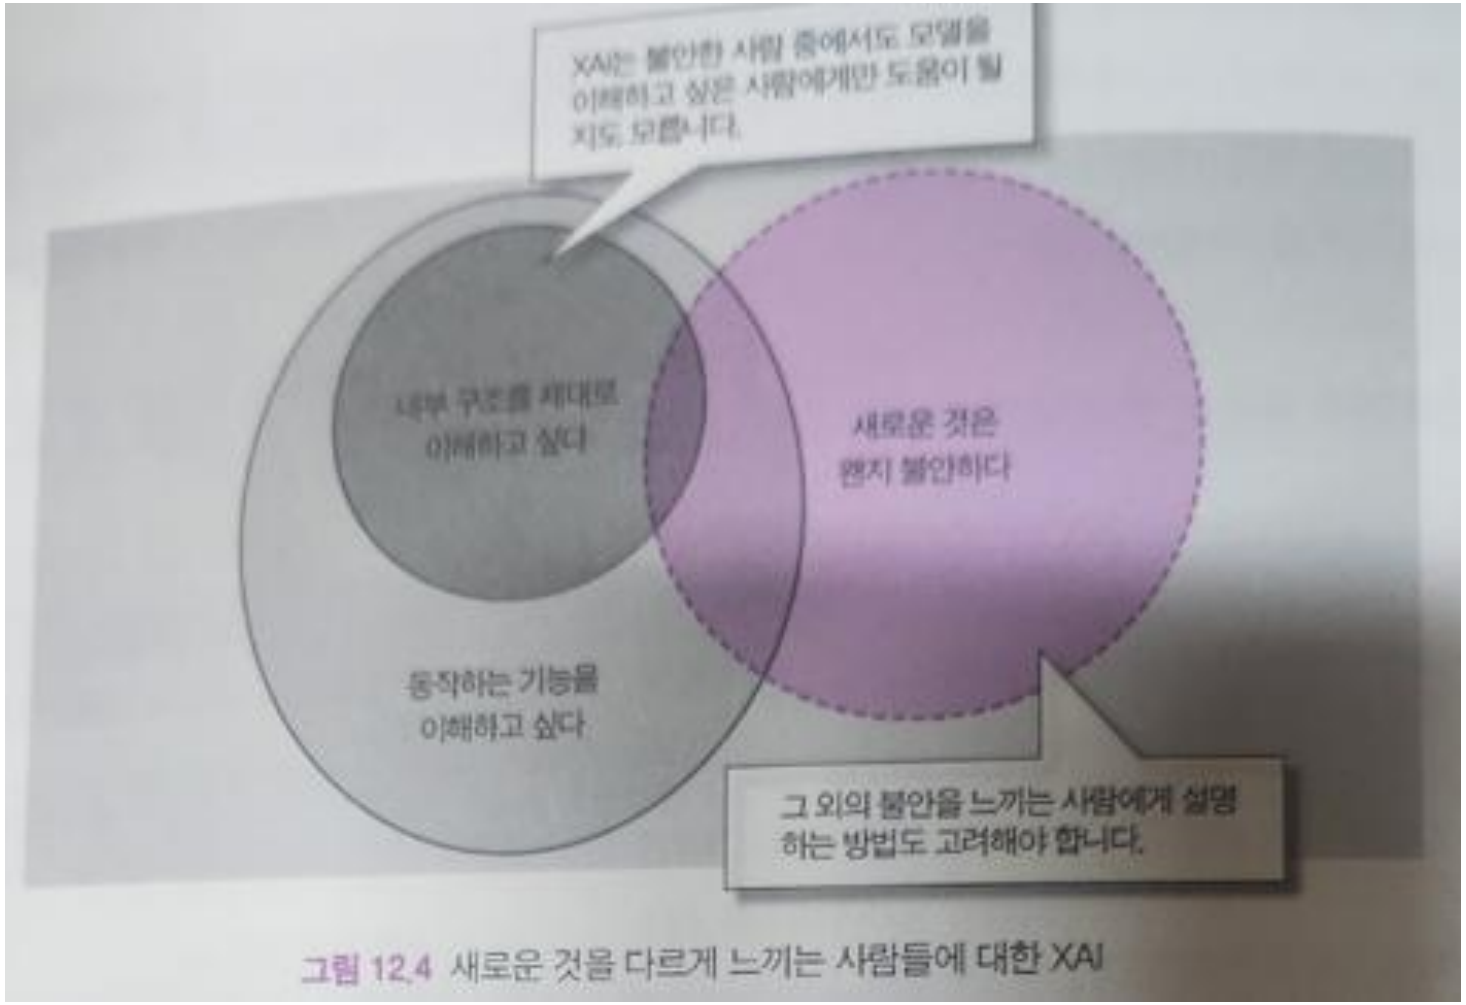


그림 12.4 새로운 것을 다르게 느끼는 사람들에 대한 XAI

설득력 키우기

왜 XAI 의 설득에 선형회귀가 사용되는가?

XAI 를 사용해 설득할 수 있는가?

감사합니다