기계학습특론

CHAPTER 9-1

군집화

비지도학습의 기초 · k-평균의 이론과 수렴 · 계층/밀도/확률/그래프 기반 군집화 · 평가 지표 · 딥러닝 시대의 군집화
(2026년 9월 개정판)



성명 : 최승호
이메일 : jcn99250@naver.com

기존 자료(31장)의 k-평균 중심 구성을 유지하면서 대학원 수준의 이론 · 최신 알고리즘 · 실무 이슈를 보강함

학습 목표

01

비지도학습과 군집화의 개념

라벨 없는 데이터에서 유사도 기반으로 구조를 찾는 문제를 정의하고, 거리·유사도 측도의 선택이 결과를 어떻게 바꾸는지 설명할 수 있다.

02

k-평균 군집화의 절차와 이론

Lloyd 알고리즘의 4단계를 수행하고, 목적함수(SSE)가 단조 비증가하여 수렴함을 증명하며, k-means++ 초기화의 근사 보장을 이해한다.

03

다양한 군집화 알고리즘

계층적 군집화, DBSCAN/HDBSCAN, 가우시안 혼합모델(EM), 스펙트럴 군집화의 원리와 적용 조건을 비교할 수 있다.

04

군집화 결과의 평가

내부 지표(실루엣, DB, CH)와 외부 지표(ARI, NMI), 안정성 평가로 k와 알고리즘을 선택할 수 있다.

05

실무·최신 동향과 실습

고차원·스케일링·범주형 처리, 딥 클러스터링·파운데이션 모델 임베딩 기반 군집화를 이해하고 scikit-learn 1.7+로 구현할 수 있다.

강의 로드맵

Part 1
비지도학습 · 군집화 · 유사도

Part 2
k-평균: 절차 · 수렴 · 초기화 · k 선택

Part 3
계층 · 밀도 · GMM · 스펙트럴

Part 4
평가 지표 · 안정성

Part 5
실무 이슈 · 최신 동향 · 실습

기존 자료에서 유지한 부분

- 비지도학습 → 군집화 → 유사도 측정의 흐름
- k-평균 4단계 절차와 단계별 그림 예시
- 초기 중심점에 따른 결과 차이 (예시 2)
- 성능 측도 SSE와 종료 조건

2026 개정에서 보강한 부분

- k-평균의 수렴 증명 · NP-난해성 · k-means++ 근사 보장
- GMM/EM, HDBSCAN, 스펙트럴 군집화, 딥 클러스터링
- 실루엣·ARI·NMI·안정성 평가, 고차원·스케일링 함정
- LLM 임베딩 기반 군집화, 의료 표현형 분석 응용
- 실습: scikit-learn 1.7+ API (n_init='auto', HDBSCAN 내장)

비지도학습 (Unsupervised Learning)

지도학습 (Supervised)

- 입력 x와 정답 라벨 y의 쌍 (x, y)으로 학습
- 목표: p(y | x) 또는 결정 함수 f(x) 학습
- 예: 분류, 회귀 (3~7주차)

비지도학습 (Unsupervised)

- 라벨 없이 특징 벡터 x 만으로 학습
- 목표: 데이터의 구조 · 패턴 · 분포 p(x) 파악
- 군집화 · 차원 축소 · 이상치 탐지 · 밀도 추정 · 표현 학습

왜 중요한가

- 라벨링은 비싸다 — 의료 데이터의 전문가 주석, 대규모 텍스트·이미지의 수작업 라벨은 병목
- 현대 딥러닝의 사전학습(자기지도학습, LLM)은 사실상 대규모 비지도학습이며, 군집화는 그 기저에서 가짜 라벨(pseudo-label)을 만드는 핵심 도구
- 탐색적 데이터 분석(EDA): 환자 하위집단, 고객 세그먼트, 문서 주제 등 '가설 생성'의 출발점
- *예시: 키·몸무게 데이터 — 라벨은 없지만 '체형이 비슷한 사람들'끼리 자연스럽게 모이는 구조가 존재*

군집화 (Clustering)

정의

- 라벨이 없는 관측치들의 특징 벡터 간 유사성을 측정하여 다수의 군집(그룹)으로 나누는 방법
- 군집(cluster): 유사도가 높은 관측치들이 서로 가깝게 모여 형성된 집합 — 군집 내 유사도는 높게, 군집 간 유사도는 낮게

응용 예시

- 고객 시장 세분화, 문서·뉴스 주제 정리, 이미지 색상 양자화, 유전자 발현 패턴 분석
- 의료: 환자 표현형(phenotype) 발굴 — 패혈증 4개 아형(Seymour et al., JAMA 2019), 외상 환자의 손상 패턴 군집 등

주의: 군집화 결과에는 '정답'이 없다

- 같은 데이터라도 유사도 측도 · 알고리즘 · k 에 따라 결과가 달라짐 → 목적과 도메인 지식으로 타당성을 판단해야 함

형식적 정의

데이터 $X = \{x_1,\ldots,x_n\}$, $x_i \in \mathbb{R}^d$

분할 군집화: X를 서로소인 k개 부분집합 $C_1,\ldots,C_k$로 나누는 함수 $\pi : X \to \{1,\ldots,k\}$

목적: 군집 내 응집도(cohesion) 최대, 군집 간 분리도(separation) 최대

군집화 유형

- 분할형 (k-means) — 경성 할당
- 계층형 — 덴드로그램
- 밀도 기반 (DBSCAN)
- 모델 기반 (GMM) — 연성 할당
- 그래프 기반 (스펙트럴, Louvain/Leiden)
- 딥 클러스터링 (임베딩 + 위 방법)

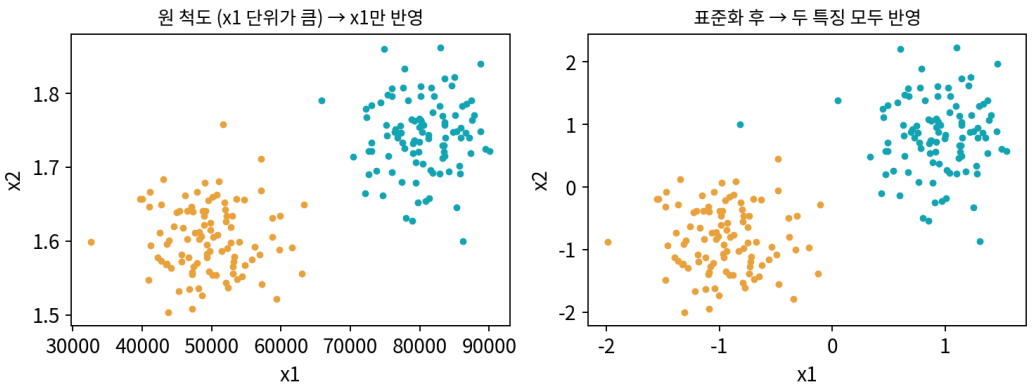
유사도 · 거리 측도 (1/2)

측도	정의	특징 · 적합한 데이터
유클리드 (L2)	$\|x-y\|_2 = \sqrt{\Sigma(x_i-y_i)^2}$	가장 일반적. k-means의 기본. 스케일에 민감
맨해튼 (L1)	$\Sigma\|x_i-y_i\|$	이상치에 덜 민감. k-medians와 짝
민코프스키 (Lp)	$(\Sigma\|x_i-y_i\|^p)^{(1/p)}$	p=1: L1, p=2: L2, p→∞: 체비셰프
코사인 유사도	$x\cdot y / (\|x\|\|y\|)$	방향만 비교. 텍스트·임베딩 벡터 (구형 k-means)
마할라노비스	$\sqrt{((x-y)^T\Sigma^{-1}(x-y))}$	특징 간 상관과 분산을 보정. GMM과 연결
상관 거리	$1 - \mathrm{corr}(x, y)$	시계열·유전자 발현 패턴 (형태 유사성)
해밍 / 자카드	불일치 비율 / $1 - \|A\cap B\|/\|A\cup B\|$	범주형·이진 특징. k-modes
DTW	시간 왜곡을 허용한 정렬 거리	길이·속도가 다른 시계열

군집화 결과는 '무엇을 가깝다고 보는가'의 정의에 그대로 종속된다 — 측도 선택이 알고리즘 선택보다 먼저다.

예: 유클리드 거리에서 같은 군집 관측치 간 거리는 작고(유사도 높음), 다른 군집 관측치 간 거리는 큼(유사도 낮음). 코사인 유사도는 크기 차이를 무시하므로 문서 길이가 다른 텍스트 벡터 비교에 유리하다.

유사도 · 거리 측도 (2/2) — 스케일링은 필수



왼쪽 그림

- x_1(예: 소득, 단위 원)의 분산이 x_2(예: 키, m)보다 10^{10}배가량 큼 → 거리가 x_1에 의해 결정되어 x_2 정보는 사실상 무시됨

오른쪽 그림

- 표준화(z-score) 후 두 특징이 동등하게 반영되어 의도한 군집이 드러남

StandardScaler

- $(x-\mu)/\sigma$
- 대부분의 경우 기본 선택
- 이상치가 많으면 RobustScaler

MinMaxScaler

- [0,1] 구간으로 선형 변환
- 경계값이 의미 있을 때
- 이상치에 취약

특징 가중치

- 스케일링 = 모든 특징에 동일 가중치
- 도메인 지식으로 가중치 w_j 를 둔 가중 유클리드 거리도 가능
- 특징 선택·PCA 후 군집화 (고차원 슬라이드 참고)

군집화 알고리즘의 분류

계열	대표 알고리즘	핵심 아이디어	장점	단점
분할형	k-means, k-medoids	k개 중심으로 SSE 최소화	단순·빠름 O(nkd)	k 사전 지정, 구형 군집 가정, 초기값 민감
계층형	응집형(Ward, single, ...)	가까운 군집부터 병합	k 불필요, 덴드로그램	$O(n^2)$~$O(n^3)$, 되돌릴 수 없음
밀도 기반	DBSCAN, HDBSCAN, OPTICS	밀집 영역 = 군집, 나머지 = 잡음	임의 형태, 잡음 처리, k 불필요	밀도 차이·고차원에 취약
모델 기반	GMM (EM)	혼합 분포의 최대우도	연성 할당, 타원형 군집, BIC로 k	국소 최적, 공분산 수 증가
그래프 기반	스펙트럴, Louvain/Leiden	유사도 그래프 절단	비볼록 군집, 매니폴드	그래프 구성 비용, 파라미터
딥 클러스터링	DEC, DeepCluster, SwAV	표현 학습과 군집을 동시에	고차원 원시 데이터(이미지·텍스트)	학습 비용, 평가 어려움

이 표의 순서로 Part 2 ~ Part 5 를 진행한다. 실무에서는 k-means → HDBSCAN/GMM 순으로 시도하고 실루엣·안정성으로 비교하는 것이 일반적인 출발점이다.

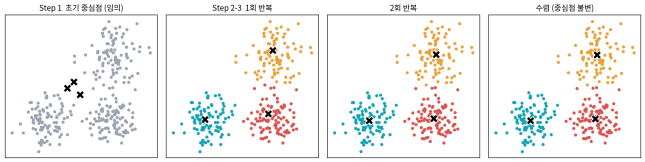
k-평균 군집화 (k-means) — 특성

핵심 가정과 성질

- 초매개변수 k에 맞는 군집 수로 군집화를 수행하며, 각 군집은 하나의 중심점(centroid)을 가짐
  - 중심점: 군집에 속한 관측치 특징 벡터의 평균 벡터 $\mu_k = (1/|C_k|) \Sigma_{x \in C_k} x$
- 모든 관측치는 k개 군집 중 정확히 하나에 속함 (경성 할당, hard assignment) — 군집 간 중복 없음
- 각 관측치는 가장 가까운(유클리드 거리) 중심점의 군집으로 할당됨 → 군집 경계는 중심점들의 보로노이(Voronoi) 다이어그램

함의

- 군집은 볼록(convex)·구형(spherical)이며 비슷한 크기·분산이라고 가정하는 셈 — 이 가정이 깨지면 실패 (뒤 슬라이드)
- 장점: 절차가 단순·직관적, 대규모 데이터에 확장 가능, 다른 방법의 초기화나 벡터 양자화(FAISS IVF/PQ)에 널리 사용
- 단점: k를 미리 정해야 함, 초기 중심점에 민감, 이상치에 민감(평균 사용)



목적함수 (SSE / WCSS / inertia)

$$J(\pi, \mu) = \Sigma_k \Sigma_{x \in C_k} \|x - \mu_k\|^2$$

= 군집별로 중심점과 관측치 차이를 제곱하여 모두 더한 값

SSE가 작을수록 관측치가 중심점 가까이 모여 있음 → k-means는 J를 π(할당)와 μ(중심)에 대해 최소화하는 문제

정확히 최소화하는 것은 NP-난해 → Lloyd 알고리즘은 휴리스틱

k-평균 군집화 수행 절차 (Lloyd 알고리즘)

Step 1
k개의 중심점을 초기화 (임의 또는 k-means++)

Step 2 할당
모든 관측치를 가장 가까운 중심점의 군집으로 할당

Step 3 갱신
각 군집의 평균 벡터로 중심점을 새로 정의

Step 4 반복
종료 조건까지 Step 2–3 반복

```
입력: X = {x₁,…,xₙ}, k,  최대 반복 T,  허용오차 tol
μ₁,…,μₖ ← 초기화(X, k)                          # Step 1
for t = 1 … T:
    for i = 1 … n:  cᵢ ← argmin_j ‖xᵢ − μⱼ‖²      # Step 2: 할당 (n·k·d 연산)
    for j = 1 … k:  μⱼ ← mean{ xᵢ : cᵢ = j }     # Step 3: 갱신 (빈 군집이면 재초기화)
    if 중심점 이동량 < tol  or  J 변화 없음: break   # Step 4: 종료 조건
출력: 할당 c, 중심점 μ, SSE J
```

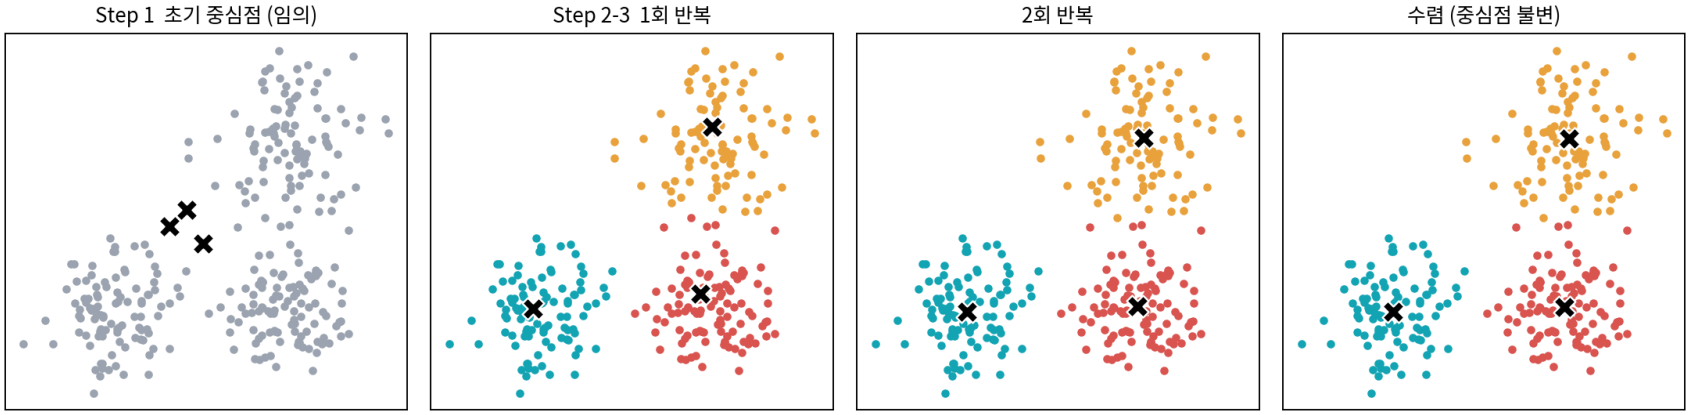
종료 조건 (택일 또는 병용)

- 지정 횟수만큼 반복 · 중심점이 더 이상 변하지 않음 · SSE 변화량이 임계값 미만 (scikit-learn: max_iter=300, tol=1e-4)

계산 복잡도

- 반복당 O(n·k·d); 실제 반복 횟수는 보통 수십 회. 최악의 경우 반복 횟수는 지수적(exponential)이지만(Vattani 2011), 평활화 분석(smoothed analysis)에서는 다항 시간(Arthur, Manthey & Röglin 2011)

k-평균 수행 예시 (k = 3)



Step 1

- 3개의 중심점(×)을 임의로 생성 — 아직 모든 점이 회색(미할당)

Step 2–3 (1회)

- 각 점을 가장 가까운 ×에 할당
- 군집별 평균으로 × 이동

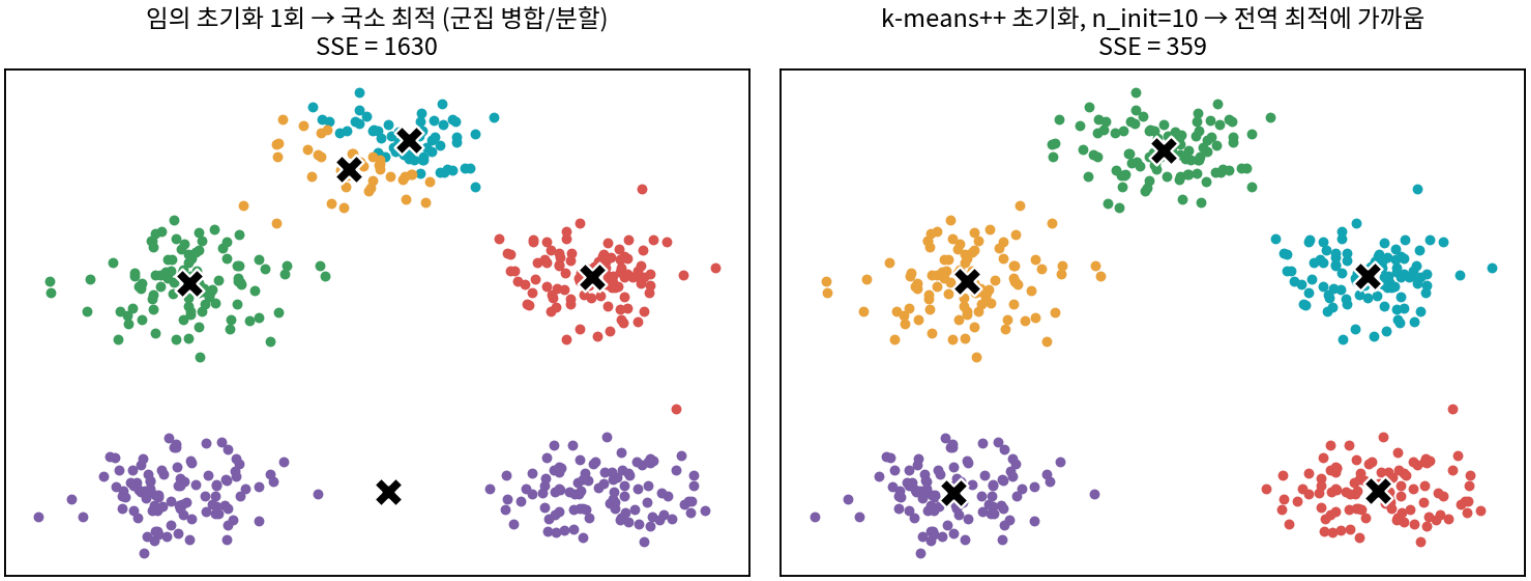
2회 반복

- 경계 근처 점들의 소속이 바뀌며 ×가 군집 중앙으로 이동

수렴

- ×가 더 이상 움직이지 않음 → 종료
- SSE가 국소 최솟값에 도달

초기 중심점에 따른 결과 차이 (예시 2)



- 동일한 데이터·동일한 k=5 — 왼쪽은 위쪽 군집 하나에 중심점 2개가 몰리고 아래 두 군집을 중심점 하나가 떠맡음 (SSE 1630)
- 오른쪽은 k-means++ 초기화 + n_init=10(10회 실행 중 SSE 최소 선택) → 의도한 5개 군집 (SSE 359)
- 관측치 수가 많고 분산이 클수록, 그리고 k가 클수록 초기값의 영향이 커짐 → 어떤 결과가 좋은가는 SSE(성능 측도)로 비교
- **실무 규칙: 항상 여러 번 초기화(n_init ≥ 10)하고 SSE가 가장 작은 해를 채택한다. scikit-learn ≥ 1.4의 기본값 n_init='auto'는 k-means++ 1회, 'random' 10회.**

성능 측도 — 오차제곱합 (SSE)

$$\mathrm{SSE} = J = \Sigma_\{k=1\}^\{K\} \Sigma_\{x_i \in C_k\} \|x_i - \mu_k\|^2 \quad \text{(scikit-learn: model.inertia_)}$$

- 군집별로 중심점과 군집 내 관측치 특징 벡터의 차이를 제곱하여 모두 더함 — 중심점과 유사한 관측치가 많을수록 값이 작음
- 예시 2의 두 결과 중 SSE가 작은 쪽(오른쪽, k-means++ + n_init=10, SSE 359)이 더 좋은 군집화로 평가됨
- 제곱 연산 때문에 오차가 커질수록 SSE가 급격히 커짐 → 이상치 하나가 중심점을 끌어당길 수 있음 (k-medoids/k-medians는 이에 강건)

종료 조건으로 사용

- SSE가 특정 값보다 작아지면 종료 · SSE가 더 이상 변하지 않으면 종료

한계

- SSE는 k가 커질수록 단조 감소 (k = n이면 0) → k 선택에는 SSE 자체가 아니라 엘보·실루엣·gap 등을 사용
- 다른 k, 다른 스케일링 간 SSE 비교는 무의미 — 같은 설정 내에서 초기화 간 비교에만 사용

SSE의 다른 이름

- WCSS (within-cluster sum of squares)
- inertia (scikit-learn)
- distortion (벡터 양자화)
- k-means 목적함수 J

총 제곱합 분해: TSS = WCSS + BCSS (군집 내 + 군집 간) — Calinski-Harabasz 지수의 기초

이론 (1) — Lloyd 알고리즘은 왜 수렴하는가

정리

Lloyd 알고리즘의 각 반복에서 목적함수 $J(\pi, \mu)$는 증가하지 않으며, 알고리즘은 유한 번의 반복 후에 종료한다 (단, 도달하는 해는 국소 최적일 수 있다).

증명 스케치

- 할당 단계 (μ 고정): 각 x_i에 대해 $c_i \leftarrow \text{argmin}_j \|x_i - \mu_j\|^2$ 이므로, 항마다 값이 비증가 $\Rightarrow J(\pi', \mu) \le J(\pi, \mu)$
- 갱신 단계 (π 고정): 군집 C_k에 대해 $f(\mu) = \Sigma_{x \in C_k} \|x - \mu\|^2$ 는 볼록 함수이며 $\nabla f = -2\Sigma(x - \mu) = 0 \Leftrightarrow \mu =$ 평균 $\Rightarrow$ 평균이 유일한 최소점, $J(\pi', \mu') \le J(\pi', \mu)$
- 따라서 J는 반복마다 단조 비증가하고 아래로 유계($J \ge 0$). 가능한 분할 π의 수는 유한($\le k^n$)하고, J가 엄격히 감소하는 동안 같은 분할이 반복될 수 없으므로 유한 단계에 종료. ■

함의

- 수렴은 보장되나 전역 최적은 보장되지 않음 — 좌표 하강(coordinate descent)의 전형적 성질. 초기화·다중 실행이 필요한 이유
- '왜 평균인가': 제곱 유클리드 거리에 대한 최소화자가 평균이기 때문. 거리를 L1으로 바꾸면 중앙값(k-medians), 실제 관측치로 제한하면 k-medoids

이론 (2) — NP-난해성과 k-means++ 근사 보장

k-means 문제의 난이도

- 차원 d가 입력의 일부인 일반 차원에서는 k = 2 이어도 NP-난해 (Aloise et al. 2009; Dasgupta 2008)
- 평면(d = 2)에서 일반 k 에 대해서도 NP-난해 (Mahajan et al. 2012)
- 따라서 실용 알고리즘은 근사·휴리스틱. 좋은 초기화가 품질을 좌우

k-means++ 초기화 (Arthur & Vassilvitskii 2007)

- 첫 중심 μ_1 을 데이터에서 균등하게 뽑음
- 각 x에 대해 D(x) = 이미 뽑힌 중심까지의 최소 거리 계산
- 다음 중심을 확률 $D(x)^2 / \Sigma D(x')^2$ 로 선택 (멀리 있는 점이 뽑힐 확률↑)
- k개가 될 때까지 반복 후 Lloyd 실행

$$E[\, J(\text{k-means++ 초기화}) \,] \le 8\,(\ln k + 2) \cdot J_OPT$$

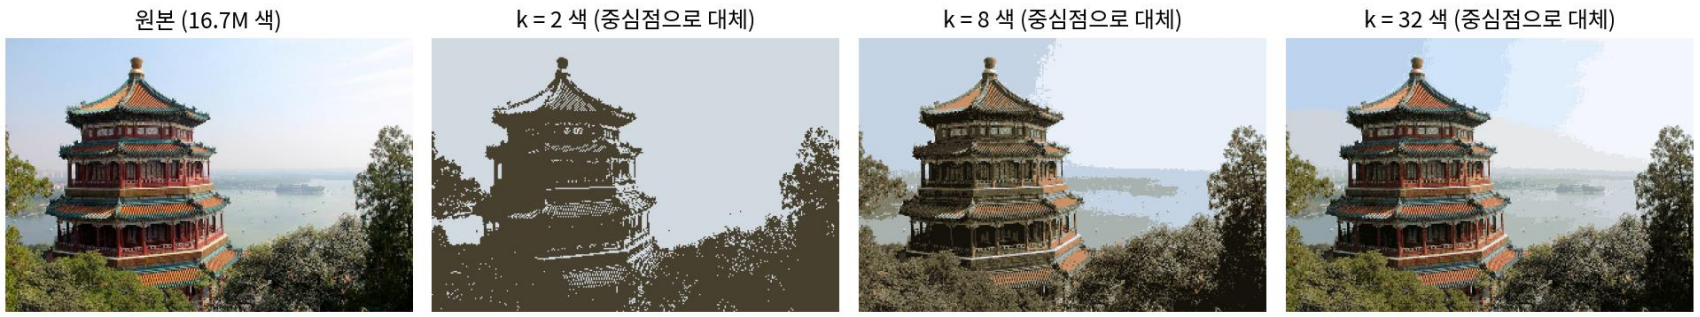
- 초기화 직후의 기대 비용이 최적해의 O(log k) 배 이내 — Lloyd 반복은 이를 더 줄일 뿐이므로 최종 해도 같은 보장을 가짐
- 실용적 효과: 수렴이 빨라지고 국소 최적에 빠질 확률이 크게 감소. scikit-learn KMeans의 기본 init='k-means++'
- 대규모 데이터: k-means‖ (Bahmani et al. 2012)는 병렬로 여러 점을 동시에 뽑아 k-means++ 의 순차성을 완화 (Spark MLlib 기본)
- 이론적 후속: 지역 탐색(local search)으로 상수 근사 (Kanungo et al. 2004), 특정 조건에서 PTAS 존재

k-평균의 변형들

알고리즘	중심 정의 / 거리	해결하려는 문제	scikit-learn / 라이브러리
k-medoids (PAM)	실제 관측치(medoid), 임의 거리	이상치 강건, 비유클리드 거리(문자열·그래프)	kmedoids 패키지 (scikit-learn-extra는 유지보수 중단·NumPy 2 미지원); PAM은 $O(k(n-k)^2)$
k-medians	좌표별 중앙값, L1	이상치 강건	직접 구현 간단
구형 k-means	정규화 벡터, 코사인	텍스트·임베딩 벡터의 방향 군집	정규화 후 KMeans (동치)
Mini-batch k-means	미니배치 확률적 갱신	n이 수백만 이상일 때 메모리·속도 (Sculley 2010)	MiniBatchKMeans
Bisecting k-means	2-분할을 반복해 계층 생성	초기값 민감도 완화, 계층 구조	BisectingKMeans (≥1.1)
k-modes / k-prototypes	최빈값 / 혼합 거리	범주형·혼합형 데이터	kmodes 패키지
Fuzzy c-means	소속도 $u_{ik} \in [0,1]$	연성 할당 (GMM의 비확률적 사촌)	scikit-fuzzy
Elkan k-means	삼각부등식으로 거리 계산 생략	같은 결과를 더 빠르게	KMeans(algorithm='elkan')

공통 구조: '할당 → 대표점 갱신'의 교대 최적화. 대표점의 정의(평균/중앙값/메도이드/최빈값)를 거리의 최소화자로 맞추면 수렴 증명이 그대로 성립한다.

k-평균의 응용 — 벡터 양자화와 이미지 색 압축



벡터 양자화 (Vector Quantization)

- 각 픽셀(3차원 RGB 벡터)을 k개 중심점(코드북) 중 가장 가까운 것으로 대체 → 픽셀당 24비트 대신 $\log_2 k$ 비트로 저장. k-means의 SSE 는 곧 양자화 왜곡(distortion)
- 같은 원리가 음성 코딩, 임베딩 압축(Product Quantization: 부분공간별 k-means 256 중심 → 1바이트), 근사 최근접 탐색(FAISS IVF) 에 쓰임

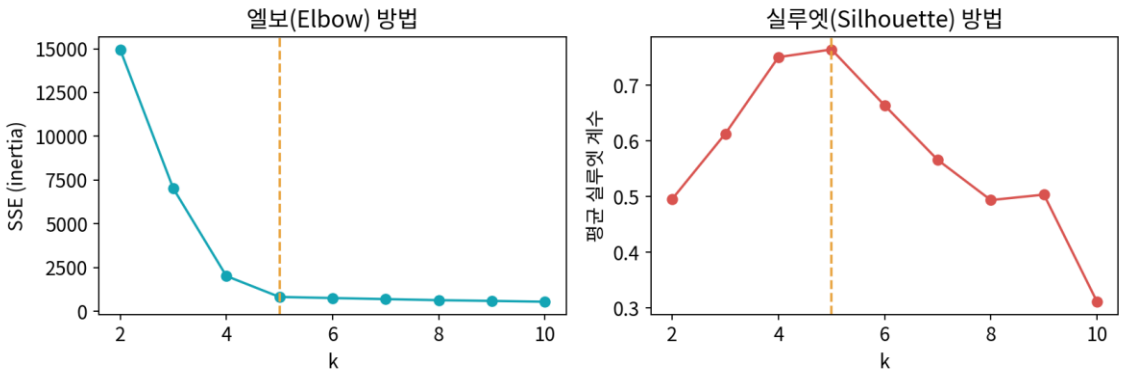
구현 팁

- 픽셀이 수십만 개이므로 무작위 표본 2만 개로 fit 한 뒤 전체에 predict — 중심점 품질은 거의 같고 속도는 수십 배
- 코드: km = KMeans(k).fit(sample); img_q = km.cluster_centers_[km.predict(pixels)].reshape(h, w, 3)

연결

- k 가 커질수록 SSE 는 줄지만 비트 수가 늘어남 — 율-왜곡(rate–distortion) 트레이드오프. '적절한 k' 는 목적(압축률 vs 화질)이 결정한다는 점을 보여주는 좋은 예

k 의 선택 — 엘보 · 실루엣 · Gap 통계량



Gap 통계량 (Tibshirani 2001)

Gap(k) = E*[log W_k] − log W_k

균등 참조분포에서의 기대 SSE와 비교. Gap(k) ≥ Gap(k+1) − s_{k+1} 인 최소 k 선택

엘보(Elbow)

- k에 따른 SSE 곡선에서 감소율이 꺾이는 지점. 직관적이나 주관적이며 꺾임이 불분명한 경우가 많음 (kneed 패키지의 Kneedle로 자동화 가능)

실루엣(Silhouette)

- s(i) = (b − a) / max(a, b), a = 같은 군집 내 평균 거리, b = 가장 가까운 다른 군집까지의 평균 거리. 평균 실루엣이 최대인 k 선택 (계산 $O(n^2)$ — 대규모에서는 표본 사용)

확률 모델 기반

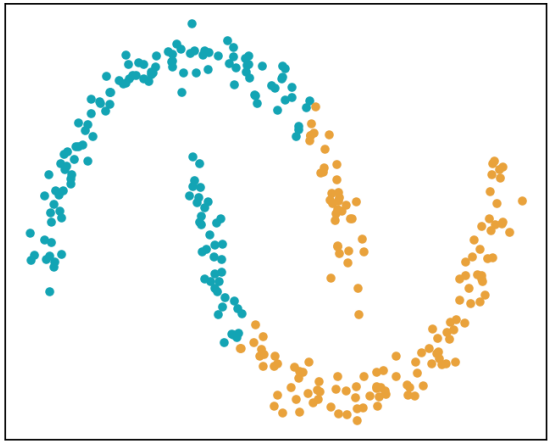
- GMM에서는 BIC/AIC로 k 선택 (Part 3). X-means는 BIC로 군집을 재귀 분할

실무 조언

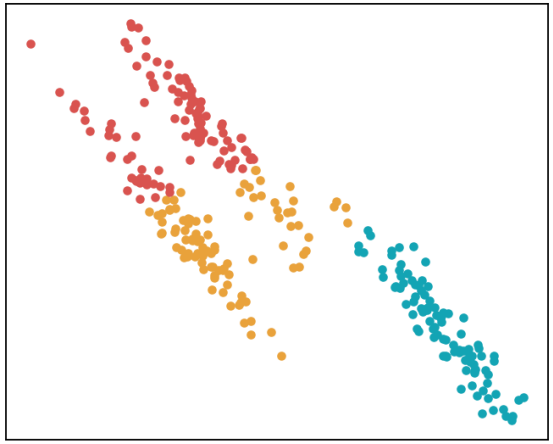
- 지표들이 서로 다른 k를 가리키는 일이 흔함 → 해석 가능성·안정성(부트스트랩)·도메인 목적(예: 임상적으로 구분되는 아형 수)을 함께 고려

k-평균이 실패하는 경우

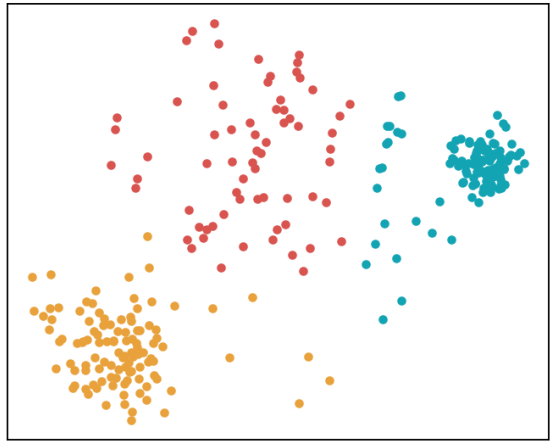
k-means 실패: 비볼록(초승달) 군집



k-means 실패: 비등방(늘어진) 군집



k-means 실패: 분산이 다른 군집



비볼록 군집

- 초승달·고리 형태는 보로노이 셀(볼록)로 표현 불가
- → DBSCAN, 스펙트럴, 계층(single linkage)

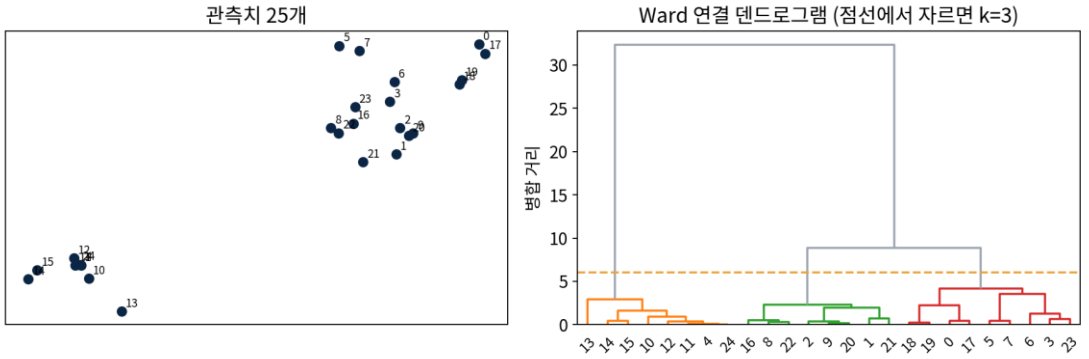
비등방 · 상관된 군집

- 등방 유클리드 거리는 길게 늘어진 군집을 잘라버림
- → GMM(full covariance), 마할라노비스 거리, 화이트닝

크기·밀도가 다른 군집

- 큰 군집의 점을 작은 군집이 빼앗음 (SSE 균등화 경향)
- → GMM(혼합 가중치 π_k), 밀도 기반

계층적 군집화 (Hierarchical Clustering)



연결 기준	군집 간 거리 d(A, B)	성질
단일(single)	min 쌍 거리	긴 사슬(chaining) 현상, 비볼록 군집 가능
완전(complete)	max 쌍 거리	조밀한 구형 군집, 이상치에 민감
평균(average, UPGMA)	모든 쌍의 평균 거리	절충안, 생물정보학 계통수
Ward	병합 시 SSE 증가량 최소	k-means와 같은 목적 → 크기 비슷한 구형 군집 (기본 권장)

응집형(agglomerative)

- 각 관측치를 하나의 군집으로 시작 → 가장 가까운 두 군집을 병합 → 하나가 될 때까지 반복

분할형(divisive)

- 전체를 하나로 시작해 재귀적으로 분할 (Bisecting k-means, DIANA)

장점

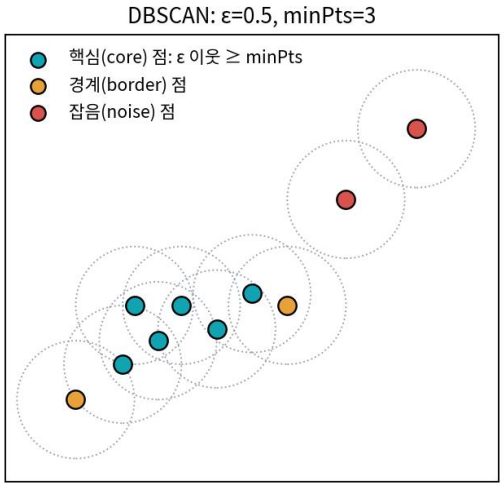
- k 지정 불필요, 덴드로그램으로 다중 해상도 구조 시각화, 결정적(초기값 없음)

단점

- 모든 쌍의 유사도를 계산·저장 → $O(n^2)$ 메모리, $O(n^2 \log n)$~$O(n^3)$ 시간. 병합은 되돌릴 수 없음(탐욕적)

Lance–Williams 갱신 공식으로 모든 연결 기준을 하나의 재귀식으로 표현 가능. scikit-learn: AgglomerativeClustering(linkage='ward', distance_threshold=...) — n_clusters 대신 거리 임계값으로 자를 수 있음.

밀도 기반 군집화 — DBSCAN

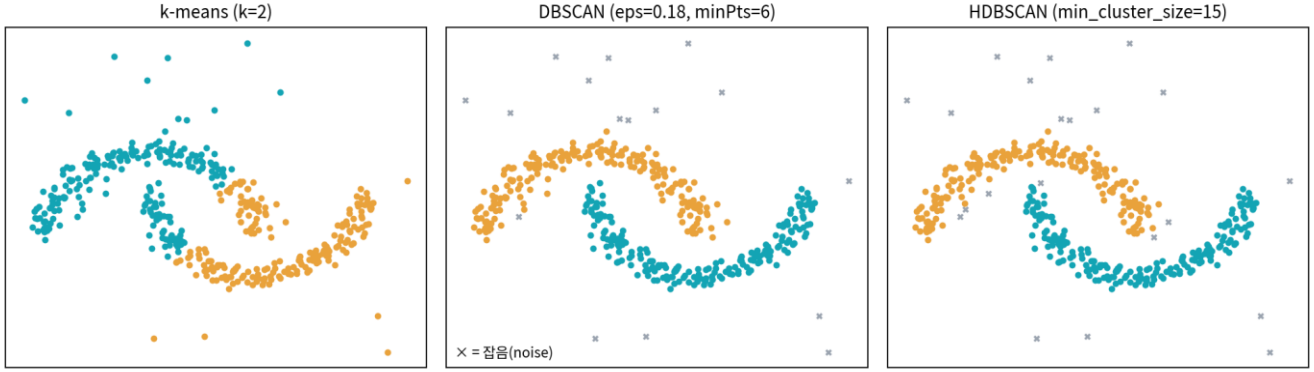


정의 (Ester et al. 1996)

- ε-이웃: $N_\varepsilon(x) = \{ y : d(x, y) \le \varepsilon \}$
- 핵심(core) 점: $|N_\varepsilon(x)| \ge$ minPts. 경계(border) 점: 핵심점의 이웃이나 스스로는 핵심이 아님. 잡음(noise): 둘 다 아님
- 군집 = 밀도-연결(density-connected)된 핵심점들과 그 경계점들의 최대 집합

알고리즘

- 미방문 핵심점에서 시작해 이웃을 BFS로 확장(밀도-도달 가능). 잡음은 라벨 −1. kd-tree/ball-tree 사용 시 평균 O(n log n)



장점: k 불필요, 임의 형태(초승달 등), 잡음 처리. 단점: 밀도가 다른 군집을 동시에 잡기 어렵고(하나의 ε), 고차원에서는 ε-이웃이 무의미해짐. ε는 k-거리 그래프(minPts번째 이웃 거리)의 꺾임에서 정한다.

HDBSCAN · OPTICS — 밀도 차이를 다루는 방법

HDBSCAN (Campello et al. 2013; McInnes 2017)

- ε를 고정하지 않고 모든 ε에 대한 계층(덴드로그램)을 만든 뒤, '안정성(stability)'이 가장 큰 군집들을 선택
- 상호 도달 거리 d_mreach(a,b) = max{core_k(a), core_k(b), d(a,b)} 로 최소 신장 트리 구성 → 단일 연결 계층
- 파라미터는 사실상 min_cluster_size 하나 → 밀도가 다른 군집을 동시에 발견, 잡음도 처리
- scikit-learn 1.3+ 에 sklearn.cluster.HDBSCAN 내장

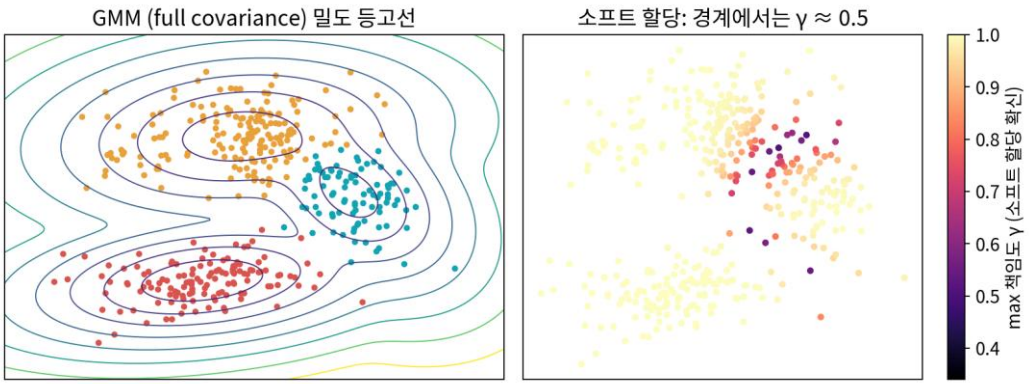
OPTICS (Ankerst et al. 1999)

- 점들을 밀도 순서로 정렬하고 각 점의 '도달 거리'를 그래프로 표현 (reachability plot)
- 골짜기 = 군집. 여러 ε에 해당하는 군집을 사후에 추출 가능
- DBSCAN보다 느리지만(O(n log n)~O(n²)) 밀도 변화에 강건
- scikit-learn: OPTICS(min_samples, xi)

언제 무엇을 쓰는가

- 군집 수를 모르고 잡음이 있으며 형태가 불규칙 → HDBSCAN이 현재 가장 널리 쓰이는 기본 선택 (BERTopic, 단일세포 분석 파이프라인 등)
- 고차원 원시 데이터에는 UMAP/PCA로 차원 축소 후 적용 — 단, 축소가 밀도 구조를 왜곡할 수 있음을 인지 (Part 5)
- soft clustering 확장(HDBSCAN의 membership vector), 예측 함수(approximate_predict)로 새 데이터 할당 가능(hdbscan 패키지)

가우시안 혼합 모델 (GMM) — 확률적 군집화



모델

$p(x) = \Sigma_k \pi_k \mathcal{N}(x \mid \mu_k, \Sigma_k), \quad \Sigma_k \pi_k = 1$

잠재변수 $z \in \{1..K\}$: $p(z=k)=\pi_k$, $p(x|z=k)=\mathcal{N}(\mu_k,\Sigma_k)$

군집 = 혼합 성분. 할당 = 사후확률(책임도) $\gamma_{ik} = p(z=k \mid x_i)$

k-means와의 차이

- 연성 할당(soft): 각 점이 각 군집에 속할 확률을 줌 → 경계의 불확실성을 정량화 (임상 아형 판정에 유용)
- 공분산 Σ_k로 타원형·회전된 군집 표현 (covariance_type = 'full' / 'tied' / 'diag' / 'spherical'), 혼합 가중치 π_k로 크기가 다른 군집 표현
- 생성 모델이므로 새 데이터의 우도, 이상치 점수(낮은 밀도), 샘플링 가능

한계

- 가우시안 가정, 국소 최적(EM), 파라미터 수 $O(K\,d^2)$ — 고차원에서는 'diag' 또는 정규화(reg_covar) 필요, 특이 공분산(singularity) 문제

EM 알고리즘과 k-means의 관계

E-step (기대): 책임도 계산

$\gamma_{ik} = \pi_k \mathcal{N}(x_i|\mu_k,\Sigma_k) / \Sigma_j \pi_j \mathcal{N}(x_i|\mu_j,\Sigma_j)$

현재 파라미터에서 각 점이 각 성분에서 나왔을 사후확률

k-means의 '할당 단계'에 해당 (경성 0/1 대신 확률)

M-step (최대화): 파라미터 갱신

$N_k = \Sigma_i \gamma_{ik}, \quad \pi_k = N_k / n, \quad \mu_k = (1/N_k) \Sigma_i \gamma_{ik} x_i$

$\Sigma_k = (1/N_k) \Sigma_i \gamma_{ik} (x_i-\mu_k)(x_i-\mu_k)^T$

가중 평균·가중 공분산 — k-means의 '갱신 단계'에 해당

수렴

- EM은 로그우도 log p(X|θ)를 단조 비감소시키며 정상점(stationary point)으로 수렴 (Dempster, Laird & Rubin 1977; Jensen 부등식으로 증명되는 ELBO의 좌표 상승)

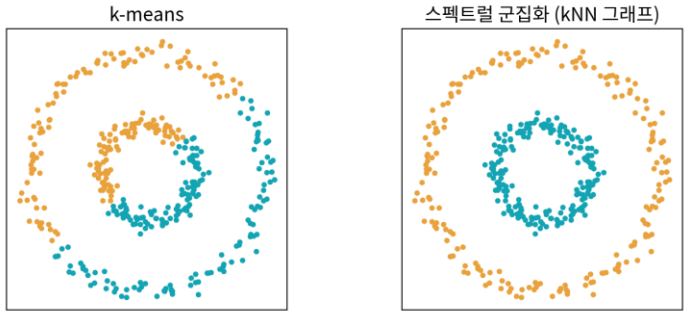
정리: k-means는 GMM의 극한

- 모든 성분이 $\Sigma_k = \varepsilon I$ (등방, 공통), $\pi_k = 1/K$ 이면 책임도는 $\gamma_{ik} \propto \exp(-\|x_i-\mu_k\|^2/2\varepsilon)$. $\varepsilon \to 0$ 에서 가장 가까운 중심의 $\gamma \to 1$, 나머지 $\to 0$ (경성 할당)이 되고, M-step은 단순 평균이 됨 ⇒ 정확히 Lloyd 알고리즘 (Bishop, PRML §9.3.2)

모델 선택

- BIC = −2 log L + p log n (p = 파라미터 수). K를 바꿔가며 BIC 최소인 모델 선택. 변분 베이즈 GMM(BayesianGaussianMixture)은 불필요한 성분의 $\pi_k \to 0$ 으로 K를 자동 조절

스펙트럴 군집화 (Spectral Clustering)



아이디어: 거리가 아니라 연결성

- ① 유사도 그래프 구성: kNN 그래프 또는 가우시안 커널 $W_{ij} = \exp(-\|x_i - x_j\|^2/2\sigma^2)$
- ② 그래프 라플라시안 L = D − W (D = 차수 행렬), 정규화 L_sym = I − D^{−1/2} W D^{−1/2}
- ③ 가장 작은 고유값 k개의 고유벡터로 n×k 행렬 U 구성 (행 정규화)
- ④ U의 행을 새 좌표로 k-means 수행 (Ng, Jordan & Weiss 2002)

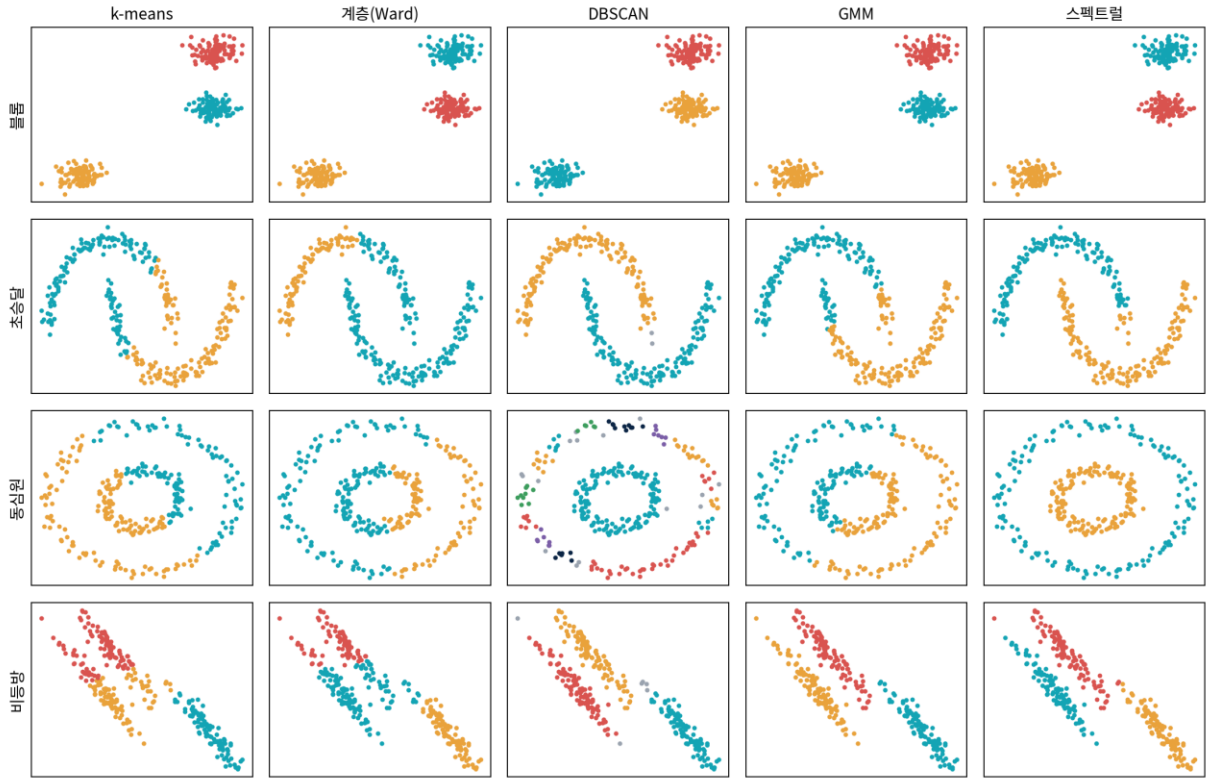
왜 되는가 — 이론

- L의 고유값 0의 중복도 = 그래프의 연결 성분 수. 성분이 k개면 첫 k 고유벡터가 성분 지시벡터를 생성
- 정규화 컷(NCut) 최소화의 완화(relaxation) 문제가 정확히 이 고유값 문제 (Shi & Malik 2000)
- 라플라스 고유맵(Belkin & Niyogi 2003)과 동일한 임베딩 → 매니폴드 위의 군집을 유클리드 공간으로 '펴서' 군집화

실무 · 확장

- 비용: 고유분해 $O(n^3)$ → 희소 kNN 그래프 + Lanczos/ARPACK으로 완화, Nyström 근사
- σ와 k(이웃 수)에 민감. 자기조정(self-tuning) σ_i 사용
- 그래프 커뮤니티 탐지(Louvain 2008, Leiden 2019)는 모듈러리티를 최적화 — 단일세포 RNA-seq(Scanpy/Seurat)의 표준 군집화
- 이미지 분할, 소셜 네트워크, 유사도만 정의된 데이터(비벡터)에 적합

알고리즘 비교 — 같은 데이터, 다른 결과



읽는 법

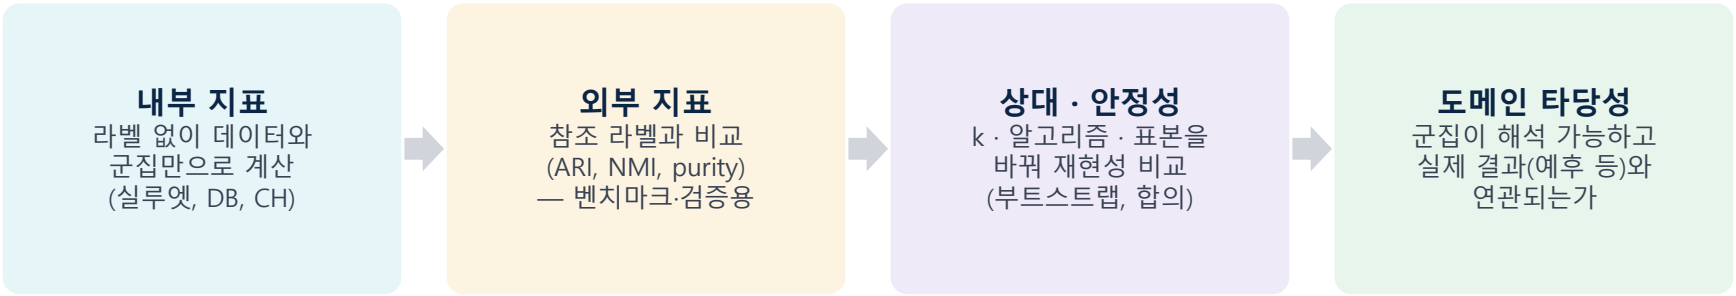
- 행 = 데이터 형태(블롭·초승달·동심원·비등방), 열 = 알고리즘
- 블롭: 모두 성공. 초승달: k-means·Ward·GMM 실패, DBSCAN·스펙트럴 성공. 동심원: 스펙트럴은 성공하지만 DBSCAN 은 고정된 ε 때문에 바깥 고리가 여러 조각과 잡음으로 쪼개짐
- 비등방: GMM(full)이 가장 자연스러움

교훈

- '최고의 알고리즘'은 없다 — 군집의 형태·밀도·잡음·규모·해석 목적에 따라 선택하고, 반드시 시각화·지표·안정성으로 검증

	k-means	계층(Ward)	DBSCAN/HDBSCAN	GMM	스펙트럴
k 필요	○	△(임계값)	×	○(BIC)	○
임의 형태	×	△	○	△	○
잡음 처리	×	×	○	△	×
확장성	매우 좋음	나쁨	좋음	보통	나쁨
확률 출력	×	×	△	○	×

군집화 결과의 평가 — 개요



왜 어려운가

- 정답이 없으므로 모든 내부 지표는 '어떤 군집이 좋은가'에 대한 가정을 내포함 — 실루엣·CH는 볼록·구형 군집을 선호해 DBSCAN 결과를 과소평가
- SSE·우도 등 학습 목적함수로 k를 고르면 항상 큰 k가 선택됨 → 복잡도 벌점(BIC) 또는 참조 분포(gap)가 필요
- 외부 지표는 라벨이 있을 때만 가능하고, 라벨이 '유일한 진실'이라는 보장도 없음 (다른 타당한 분할이 있을 수 있음)

권장 절차

- ① 여러 k·알고리즘으로 내부 지표 산출 → ② 부트스트랩 안정성으로 후보 축소 → ③ 시각화(PCA/UMAP)와 군집별 특징 요약 → ④ 외부 결과(예: 사망률, 치료 반응)와의 연관으로 임상적 타당성 확인

내부 평가 지표

실루엣 계수 (Rousseeuw 1987)

$s(i) = (b(i) - a(i)) / \max\{a(i), b(i)\} \in [-1, 1]$

- a(i): 같은 군집 내 다른 점들과의 평균 거리 (응집도)
- b(i): 가장 가까운 다른 군집 점들과의 평균 거리 (분리도)
- s ≈ 1 좋음, 0 경계, < 0 잘못 할당. 전체 평균 또는 실루엣 플롯으로 군집별 품질 확인

Davies–Bouldin 지수

$DB = (1/K) \Sigma_k \max_{j \neq k} (s_k + s_j) / d(\mu_k, \mu_j)$

- s_k: 군집 내 평균 산포, d: 중심 간 거리
- 작을수록 좋음 (0이 하한). 계산 O(n) — 대규모에 적합
- 구형·유사 크기 군집 가정

Calinski–Harabasz 지수 (분산비)

$CH = [BCSS/(K-1)] / [WCSS/(n-K)]$

- 군집 간 분산 / 군집 내 분산의 F-통계량 형태. 클수록 좋음
- 빠르고 k 선택에 자주 사용. 역시 볼록 군집 선호

밀도 기반 결과에는

- DBCV (Moulavi et al. 2014): 밀도 기반 군집 타당성 지수 — 임의 형태 군집과 잡음을 고려
- HDBSCAN의 relative_validity_ 속성으로 계산 가능

scikit-learn: silhouette_score, silhouette_samples, davies_bouldin_score, calinski_harabasz_score

외부 평가 지표 — 참조 라벨과의 일치도

조정 랜드 지수 (ARI)

RI = (같은/다른 군집으로 일치한 쌍의 수) / 전체 쌍의 수

ARI = (RI − E[RI]) / (max RI − E[RI])

- 우연 일치를 보정 → 무작위 할당이면 ≈ 0, 완전 일치 1, 음수 가능
- 군집 라벨 번호의 순열에 불변 (permutation invariant)

정규화 상호정보량 (NMI / AMI)

NMI = I(U; V) / mean{H(U), H(V)} ∈ [0, 1]

- 군집 U와 라벨 V 사이의 정보이론적 의존도 (분할표 기반)
- AMI는 우연 보정판 (Vinh et al. 2010). 군집 수가 다를 때 NMI는 k가 큰 쪽에 유리하므로 AMI 권장

지표	범위	우연 보정	특징
Purity	[0,1]	×	각 군집의 최다 라벨 비율. k가 커지면 항상 증가 (단독 사용 금지)
Homogeneity / Completeness / V-measure	[0,1]	×	각 군집이 한 라벨만 포함 / 각 라벨이 한 군집에 포함 / 둘의 조화평균 (NMI와 동치)
Fowlkes–Mallows	[0,1]	×	쌍 기반 정밀도·재현율의 기하평균
ARI / AMI	≤ 1	○	논문 보고의 표준. 두 개를 함께 보고

군집 라벨 번호는 임의이므로 정확도(accuracy)를 그대로 쓰면 안 된다 — 헝가리안 알고리즘으로 최적 매칭 후 계산하거나 위 지표를 사용한다.

안정성 · 재현성 평가

핵심 질문: 이 군집 구조는 '데이터의 성질'인가, '알고리즘의 산물'인가?

- 부트스트랩 안정성: 데이터를 재표본(또는 부분표본 80%)하여 군집화를 반복 → 원 결과와의 ARI/자카드 분포. 평균 자카드 ≥ 0.75 이면 안정 (Hennig 2007, fpc::clusterboot)
- 합의 군집화(consensus clustering, Monti et al. 2003): 수백 회 부분표본 군집화에서 두 점이 같은 군집에 속한 비율로 합의 행렬 구성 → CDF 곡선으로 k 선택. 임상 아형 연구의 표준 (예: 패혈증 표현형 JAMA 2019)
- 초기값 안정성: 다른 random_state로 반복해 결과 분산 확인 (k-means, GMM, 딥 클러스터링)
- 파라미터 민감도: ε·minPts·σ 격자에서 결과가 급변하는 구간을 피함

함정

- 합의 군집화는 구조가 없는(균등) 데이터에서도 그럴듯한 k를 보고할 수 있음 (Şenbabaoğlu et al. 2014) → 참조 귀무분포(PAC 점수, 무작위 회전 데이터)와 비교
- 차원 축소(UMAP/t-SNE) 그림에서 보이는 '덩어리'는 방법의 하이퍼파라미터가 만든 인공물일 수 있음 → 그림은 확인용, 군집화는 원 공간(또는 PCA 공간)에서

군집 결과의 해석 — 프로파일링

군집	n (%)	나이 (표준화 평균)	수축기혈압	젖산	GCS	사망률	임상적 해석(예시)
1	412 (41%)	−0.3	+0.4	−0.5	+0.6	5.2%	경증·생리적 안정
2	268 (27%)	+0.9	−0.2	+0.1	+0.2	12.8%	고령·동반질환
3	201 (20%)	−0.1	−1.1	+1.3	−0.4	31.5%	쇼크·관류 저하
4	119 (12%)	−0.6	+0.1	+0.3	−1.8	27.1%	두부손상 우세

가상의 예시 표 — 군집별 표준화 평균(z)과 외부 결과(사망률)를 나란히 제시하는 전형적 보고 형식

군집을 '설명'하는 방법

- 군집별 특징 요약표: 연속형은 표준화 평균(z) 또는 중앙값[IQR], 범주형은 비율. 히트맵으로 한눈에 비교
- 판별 특징 찾기: 군집 라벨을 y 로 놓고 얕은 의사결정나무(depth 2~3) 학습 → '젖산 > 4 이고 SBP < 90 이면 군집 3' 같은 규칙 (ExKMC, Moshkovitz et al. 2020 — 다음 강의 의사결정나무와 연결)
- 차원 축소 그림(PCA 1–2 성분)에 군집 색을 입혀 분리 정도 확인. 실루엣 플롯으로 군집별 품질 확인

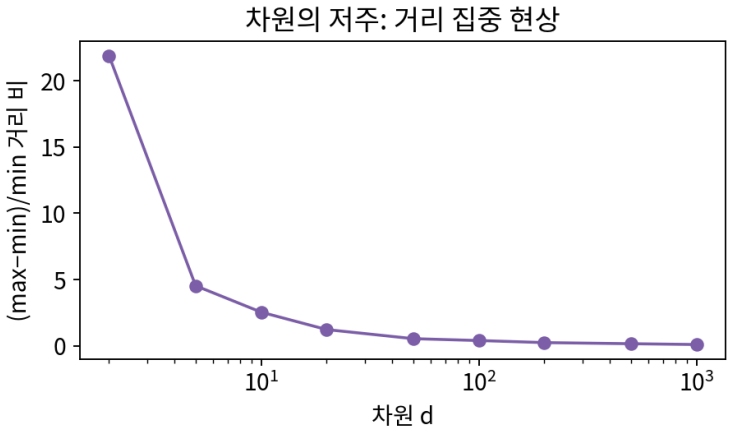
외부 타당성

- 군집과 예후(사망·재원일수)·치료 반응의 연관을 검정(χ^2, Kruskal–Wallis, 다중비교 보정). 군집이 기존 분류(예: ISS 중증도)와 무엇이 다른지를 보여야 새로운 가치가 있음

주의

- 군집 번호에 임상 이름을 붙이는 순간 과잉 해석 위험 — 아형 명칭은 관찰된 특징에 근거하고, 인과 주장은 피한다

고차원의 저주와 차원 축소 후 군집화



거리 집중 (distance concentration)

- 차원 d가 커지면 최근접·최원접 거리의 비 (max−min)/min → 0 (Beyer et al. 1999) — '가장 가까운 이웃'이 의미를 잃음
- 밀도 기반(ε-이웃)과 실루엣이 먼저 무너지고, k-means도 잡음 차원에 끌려감

대응

- 특징 선택 (분산·상관·도메인) → PCA (선형, 분산 보존) → UMAP/t-SNE (비선형, 시각화용)
- 부분공간 군집화(subspace clustering), 정규화된 k-means (sparse k-means, Witten & Tibshirani 2010)

PCA 후 k-means — 이론적 연결

- k-means 의 완화(relaxed) 해는 PCA 주성분 부분공간과 일치 (Ding & He 2004) → k−1 개 주성분 위에서 k-means 를 돌리는 것이 정당화됨
- 분산이 큰 방향이 군집 방향이라는 보장은 없음 — 스케일링과 함께 판단

UMAP / t-SNE 위에서 군집화할 때

- 국소 이웃 구조는 보존하나 군집 간 거리·크기·밀도는 왜곡 (t-SNE 특히)
- 그럼에도 HDBSCAN + UMAP 조합은 실무 표준(BERTopic, scRNA-seq) — n_neighbors, min_dist 를 고정하고 안정성 검증 필수
- 군집 결과는 원 공간의 특징 요약으로 해석

전처리 · 데이터 유형별 체크리스트

상황	문제	권장 처리
척도가 다른 연속형	큰 척도 특징이 거리를 지배	StandardScaler / RobustScaler. 로그 변환(왜도 큰 변수)
범주형 특징	원-핫 후 유클리드는 의미 왜곡	k-modes / k-prototypes, Gower 거리 + PAM·계층, 또는 임베딩 후 군집
혼합형 (연속+범주)	거리 정의 자체가 불명확	Gower 거리, FAMD(혼합형 데이터 요인분석) 후 군집, k-prototypes
결측치	대부분의 알고리즘이 NaN 불가	다중 대치(IterativeImputer/MICE), 결측 지시자 추가, 또는 결측 허용 모델 (GMM 확장)
이상치	k-means 중심을 끌어당김	IsolationForest/LOF로 사전 제거, k-medoids, DBSCAN(잡음 라벨)
매우 큰 n	$O(n^2)$ 방법 불가	MiniBatchKMeans, FAISS k-means(GPU), 코어셋(coreset) 표본 후 정밀 군집
시계열	길이·위상 차이	DTW + k-means(DBA, tslearn), 특징 추출(tsfresh) 후 일반 군집
텍스트 · 이미지	원시 픽셀/단어 거리 무의미	사전학습 임베딩(다음 슬라이드) → 코사인/유클리드 군집

군집화 파이프라인은 지도학습처럼 Pipeline(StandardScaler → PCA → KMeans)으로 묶어 재현성을 확보하고, 새 데이터에는 predict()/transform()으로 동일 처리를 적용한다.

준지도 · 제약 군집화 (Constrained Clustering)

상황

- 라벨이 전부 없는 것이 아니라 '조금' 있음 — 전문가가 확인한 소수 사례, 또는 '이 둘은 같은/다른 군집' 이라는 쌍 제약
- 완전 비지도 결과가 임상 지식과 어긋날 때 지식을 주입하는 방법

제약의 종류

- must-link (a, b): 같은 군집이어야 함
- cannot-link (a, b): 다른 군집이어야 함
- seed(부분 라벨): 일부 점의 군집이 알려짐
- 군집 크기·비율 제약(균형, 공정성)

방법	아이디어	비고
COP-k-means (Wagstaff 2001)	할당 단계에서 제약을 위반하는 할당을 금지	제약이 모순이면 실패할 수 있음
Seeded / Constrained k-means (Basu 2002)	라벨된 점으로 초기 중심 계산, 이후 고정 또는 갱신	초기화 민감도 해결에도 효과
PCK-means / MPCK-means	제약 위반에 벌점을 주는 목적함수 + 거리 학습	거리(metric)를 함께 학습
ClusterLLM (2023)	LLM 에 '두 문서가 같은 주제인가' 를 물어 제약 생성	라벨링 비용을 LLM 질의로 대체
딥 준지도 군집	소수 라벨 + 자기지도 손실 (예: SPICE)	이미지·텍스트

의료 데이터에서는 '전문가 검토를 거친 100 사례' 만으로도 군집의 임상적 일관성이 크게 개선된다 — 능동 학습(active learning)과 결합해 어떤 쌍을 물을지 선택하는 연구도 활발.

시계열 · 시공간 데이터의 군집화

시계열 군집화

- 유클리드 거리는 위상(phase) 이동에 취약 → DTW(동적 시간 왜곡) 거리 사용
- DTW 하에서 '평균' 은 DBA(DTW Barycenter Averaging) 로 정의 → DTW k-means (tslearn)
- 대안: 특징 추출(tsfresh, catch22) 후 일반 군집화, 또는 시계열 표현 학습(TS2Vec) 후 k-means
- 예: 환자 활력징후 궤적(trajectory) 군집 → 악화 패턴 아형

시공간 군집화

- ST-DBSCAN: 공간 ε_1 과 시간 ε_2 를 따로 두는 DBSCAN — 사고 다발 시간·장소 탐지
- Kulldorff 공간 스캔 통계: 원형 창 안팎의 발생률 비를 우도비로 검정 (SaTScan) — 질병 클러스터 감시의 표준
- Getis-Ord Gi*, Moran's I 로 핫스팟의 통계적 유의성 확인
- 예: 교통사고 사망 핫스팟, 감염병 발생 군집

궤적(trajectory) 군집 — 종단 데이터

- 잠재 성장 혼합모델(Growth Mixture Model; 가우시안 혼합모델의 종단 확장, LCGA/GBTM): 각 개체의 시간 곡선을 소수의 궤적 클래스로 요약 — 역학·정신건강 연구의 표준 도구
- k-means for longitudinal data (kml), DTW 기반, 또는 순환 신경망/Transformer 인코더로 궤적을 임베딩한 뒤 군집

주의

- 시계열 길이·표본 간격이 다르면 전처리(보간·정렬)가 결과를 좌우. 시공간 군집은 인구 밀도(기대 발생) 보정 없이는 단순히 '사람이 많은 곳' 을 찾게 됨

딥 클러스터링 — 표현 학습과 군집의 결합

① 2-단계
오토인코더/사전학습 임베딩
→ k-means / HDBSCAN

② 공동 최적화
DEC (2016): 임베딩과
군집 할당을 KL로 동시 학습

③ 자기지도
DeepCluster (2018): k-means
가짜 라벨로 CNN 학습 반복

④ 온라인 대조
SwAV (2020): 프로토타입에
온라인 할당 + 대조 학습

왜 필요한가

- 이미지·텍스트·신호의 원시 공간에서 유클리드 거리는 의미가 없음 → 의미를 담은 표현 $z = f_\theta(x)$ 를 먼저 학습해야 함

DEC (Xie, Girshick & Farhadi 2016)

- 소프트 할당 $q_{ik} \propto (1 + \|z_i - \mu_k\|^2)^{-1}$ (t-분포 커널), 목표 분포 $p_{ik} \propto q_{ik}^2 / \Sigma_i q_{ik}$ 로 '확신 강화' → KL(P‖Q) 최소화로 인코더와 중심을 함께 갱신

DeepCluster → SwAV → DINO

- 군집 할당을 가짜 라벨로 쓰는 자기지도학습 계열. 퇴화(모든 점이 한 군집) 방지를 위해 균등 할당 제약(Sinkhorn-Knopp) 사용. DINO/DINOv2 (2021–2024)의 특징은 k-means 만으로도 ImageNet 클래스 구조를 상당히 복원

주의

- 학습 목적함수가 '군집이 잘 되도록' 표현을 바꾸므로 평가가 순환적일 수 있음 → 외부 라벨(ARI/NMI)이나 다운스트림 과제로 검증. 재현성(시드)에 민감

파운데이션 모델 시대의 군집화 (2023–2026)

임베딩 → 군집화 파이프라인

- 텍스트: Sentence-BERT, E5, BGE, OpenAI/Gemini 임베딩 → 정규화 → k-means / HDBSCAN
- 이미지: CLIP, DINOv2 특징 → 군집 → 라벨 없는 데이터셋 정리·중복 제거·능동 학습 표본 선택
- 다중 모달: CLIP 공간에서 텍스트 프롬프트로 군집 이름 자동 부여

BERTopic (Grootendorst 2022)

- 문서 임베딩 → UMAP → HDBSCAN → 군집별 c-TF-IDF 로 주제 단어 추출
- LDA를 대체한 사실상 표준 토픽 모델링. LLM으로 주제 라벨 요약 가능
- 의료: 임상 노트·환자 리뷰·논문 초록의 주제 구조 분석

LLM 을 군집화에 활용하는 방식

- LLM 이 생성한 임베딩 사용 · LLM 으로 군집 요약/명명 · 소수의 '이 두 문서는 같은 주제인가' 질의(pairwise constraints)로 제약 군집화 개선 (Zhang et al. 2023 ClusterLLM)
- 제로샷 군집: 파운데이션 모델 표현 공간에서 라벨 없이 과제 특화 군집을 찾는 연구 (TURTLE, Gadetsky et al. ICML 2024)

벡터 검색과 양자화

- FAISS IVF: k-means 로 nlist 개 셀로 공간 분할 → 질의 시 가까운 셀만 탐색. PQ: 부분공간별 k-means(256 중심) 로 벡터를 바이트로 압축 — 군집화가 RAG·검색 인프라의 기반

연구 동향

- 군집화 가능성(clusterability) 검정, 공정성(fair clustering), 설명 가능한 군집(의사결정나무로 근사한 k-means, Moshkovitz et al. 2020), 차분 프라이버시 k-means

의료 · 보건 데이터 응용

환자 표현형(phenotype) 발굴

- 패혈증 4개 아형 α/β/γ/δ — 29개 임상변수, 합의 k-means, 아형별 사망률·치료 반응 차이 (Seymour et al., JAMA 2019)
- ARDS 아형(잠재 클래스 분석), 당뇨 5개 아형 (Ahlqvist et al., Lancet D&E 2018), 심부전(HFpEF) 표현형
- 핵심: 군집이 '예후·치료 반응과 연관'되어야 임상적 의미

외상 · 손상 데이터

- 손상 부위·중증도 벡터(AIS)의 군집 → 손상 패턴(injury pattern) 정의, 자원 배분
- 사고 기전·환자 특성 군집으로 예방 정책 타깃 설정
- 시공간 군집(ST-DBSCAN, Kulldorff 스캔 통계)으로 사고 다발 지역 탐지

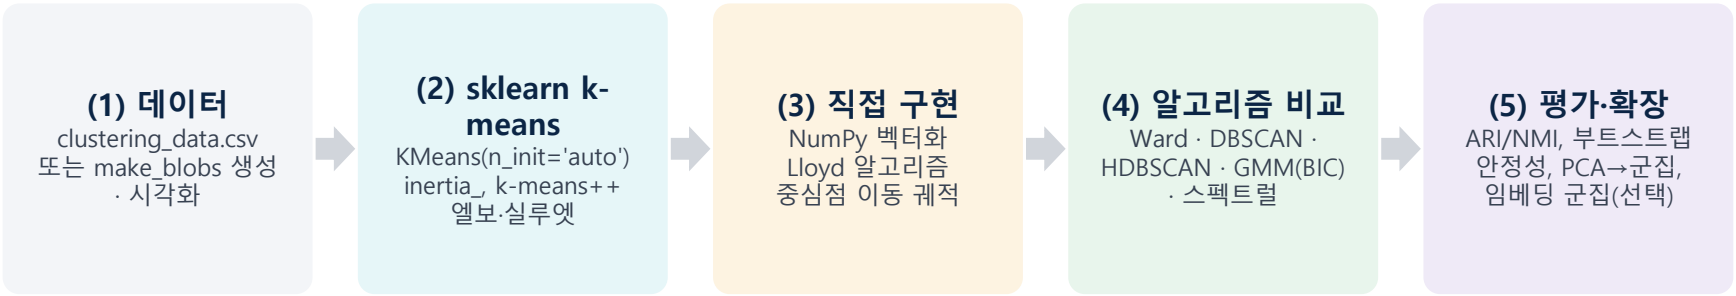
오믹스 · 영상

- scRNA-seq: PCA → kNN 그래프 → Leiden 커뮤니티 (Scanpy/Seurat 표준)
- 종양 아형(유전자 발현 합의 군집), 방사선 영상 radiomics 군집
- 의료 영상 분할에서 k-means/GMM 은 여전히 기본 baseline

보고 시 필수 항목 (재현성)

- 변수 선택·스케일링·결측 처리 방법
- 알고리즘·k·초기화·시드, k 선택 근거(지표 + 안정성)
- 군집별 특징 요약표와 외부 결과와의 연관 분석
- 외부 코호트에서의 재현(같은 중심점으로 할당) 여부

실습 개요 — 9주차_군집화_2026.ipynb



환경

- Python 3.11+, scikit-learn ≥ 1.7 (HDBSCAN 내장 1.3+, n_init='auto' 기본 1.4+), NumPy 2.x, matplotlib. Colab 에서 바로 실행 가능
- 기존 노트북과의 차이: KMeans(n_clusters=5) → KMeans(n_clusters=5, n_init='auto', random_state=0) 로 재현성 확보, 직접 구현은 for-루프를 브로드캐스팅으로 대체, 평가·비교·안정성 절이 추가됨

과제 제안 (대학원)

- ① k-means 수렴 증명을 노트북에서 SSE 궤적으로 실증 · ② GMM 의 ε→0 극한이 k-means 와 일치함을 수치로 확인 · ③ 본인 연구 데이터에 합의 군집화 + 안정성 평가 적용

코드 (1) — scikit-learn KMeans (1.7+ API)

```
import numpy as np, matplotlib.pyplot as plt
from sklearn.cluster import KMeans
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import silhouette_score

X = np.genfromtxt("clustering_data.csv", delimiter=",")        # (n, 2)
Xs = StandardScaler().fit_transform(X)                         # 스케일링 (필수 습관)

# n_init='auto': init='k-means++'이면 1회, 'random'이면 10회 (sklearn >= 1.4 기본값)
model = KMeans(n_clusters=5, init="k-means++", n_init=10, random_state=0)
labels = model.fit_predict(Xs)
print("SSE(inertia):", model.inertia_, " 반복 횟수:", model.n_iter_)
print("중심점:\n", model.cluster_centers_)

# k 선택: 엘보 + 실루엣
ks = range(2, 11)
sse = [KMeans(k, n_init=10, random_state=0).fit(Xs).inertia_ for k in ks]
sil = [silhouette_score(Xs, KMeans(k, n_init=10, random_state=0).fit_predict(Xs)) for k in ks]
fig, ax = plt.subplots(1, 2, figsize=(10, 3.5))
ax[0].plot(ks, sse, "-o"); ax[0].set(xlabel="k", ylabel="SSE", title="Elbow")
ax[1].plot(ks, sil, "-o"); ax[1].set(xlabel="k", ylabel="silhouette", title="Silhouette")
```

- predict(X_new) 로 새 데이터를 기존 중심점에 할당, transform(X) 은 각 중심점까지의 거리 행렬 반환
- algorithm='elkan' 은 삼각부등식으로 거리 계산을 생략해 저차원·큰 k에서 빠름 (결과 동일)

코드 (2) — k-means 직접 구현 (NumPy 벡터화)

```
def kmeans(X, k, n_iter=100, tol=1e-6, seed=0):
    rng = np.random.default_rng(seed)
    # k-means++ 초기화
    C = [X[rng.integers(len(X))]]
    for _ in range(1, k):
        d2 = np.min(((X[:, None, :] - np.array(C)[None]) ** 2).sum(-1), axis=1)   # D(x)^2
        C.append(X[rng.choice(len(X), p=d2 / d2.sum())])
    C = np.array(C); history = [C.copy()]; sse_hist = []
    for it in range(n_iter):
        D2 = ((X[:, None, :] - C[None, :, :]) ** 2).sum(-1)     # (n, k) 거리 제곱 — 브로드캐스팅
        lab = D2.argmin(1)                                      # Step 2: 할당
        sse_hist.append(D2[np.arange(len(X)), lab].sum())       # 현재 SSE
        C_new = np.array([X[lab == j].mean(0) if np.any(lab == j) else C[j] for j in range(k)])  # Step 3
        history.append(C_new.copy())
        if np.linalg.norm(C_new - C) < tol: C = C_new; break    # Step 4: 종료
        C = C_new
    return lab, C, np.array(history), np.array(sse_hist)

lab, C, hist, sse_hist = kmeans(Xs, 5)
assert np.all(np.diff(sse_hist) <= 1e-9)     # 이론 (1): SSE 단조 비증가 실증
plt.plot(sse_hist, "-o"); plt.xlabel("iteration"); plt.ylabel("SSE")
```

- X[:, None, :] − C[None, :, :] 는 (n,1,d) − (1,k,d) → (n,k,d): 이중 for-루프 없이 모든 쌍의 거리를 한 번에 계산
- hist 로 중심점 이동 경로를 그리면 기존 실습의 plot_centroid 와 동일한 그림을 얻을 수 있음

코드 (3) — 알고리즘 비교와 평가

```
from sklearn.cluster import AgglomerativeClustering, DBSCAN, HDBSCAN, SpectralClustering
from sklearn.mixture import GaussianMixture
from sklearn.metrics import adjusted_rand_score, normalized_mutual_info_score, davies_bouldin_score

algos = {
  "kmeans":   KMeans(5, n_init=10, random_state=0),
  "ward":     AgglomerativeClustering(n_clusters=5, linkage="ward"),
  "dbscan":   DBSCAN(eps=0.3, min_samples=5),
  "hdbscan":  HDBSCAN(min_cluster_size=15),                       # sklearn >= 1.3
  "gmm":      GaussianMixture(5, covariance_type="full", random_state=0),
  "spectral": SpectralClustering(5, affinity="nearest_neighbors", random_state=0),
}
results = {}
for name, m in algos.items():
    lab = m.fit_predict(Xs)
    mask = lab != -1                                  # DBSCAN 잡음(-1) 제외하고 내부 지표 계산
    results[name] = dict(k=len(set(lab[mask])),
        silhouette=silhouette_score(Xs[mask], lab[mask]) if len(set(lab[mask])) > 1 else np.nan,
        db=davies_bouldin_score(Xs[mask], lab[mask]) if len(set(lab[mask])) > 1 else np.nan)
    if "y_true" in globals():                          # 참조 라벨이 있을 때만
        results[name].update(ARI=adjusted_rand_score(y_true, lab), NMI=normalized_mutual_info_score(y_true, lab))
import pandas as pd; print(pd.DataFrame(results).T.round(3))

# GMM 에서 k 선택 (BIC)
bics = [GaussianMixture(k, random_state=0).fit(Xs).bic(Xs) for k in range(1, 11)]
print("BIC 최소 k =", int(np.argmin(bics)) + 1)
```

*부트스트랩 안정성: rng.choice(n, int(0.8*n)) 로 부분표본 → 군집화 → 원 라벨과 ARI 를 100회 반복해 분포를 본다 (노트북 (5)절).*

코드 (4) — 임베딩 기반 텍스트 군집화 (선택)

```
# pip install sentence-transformers umap-learn   (Colab 에서 1~2분)
from sentence_transformers import SentenceTransformer
docs = ["흉부 CT에서 폐렴 소견", "교통사고 다발성 골절 환자", "혈당 조절 불량 당뇨", ...]   # 임상 노트 예시
emb = SentenceTransformer("intfloat/multilingual-e5-small").encode(docs, normalize_embeddings=True)

# (a) 구형 k-means: 정규화된 벡터에 KMeans == 코사인 유사도 기준 군집
km = KMeans(n_clusters=3, n_init=10, random_state=0).fit(emb)

# (b) HDBSCAN + UMAP (BERTopic 방식): 군집 수를 데이터가 결정, 잡음 문서 분리
import umap
Z = umap.UMAP(n_neighbors=15, n_components=5, min_dist=0.0, random_state=0).fit_transform(emb)
hb = HDBSCAN(min_cluster_size=5).fit(Z)

for c in sorted(set(hb.labels_)):
    print(c, [docs[i][:20] for i in np.where(hb.labels_ == c)[0][:3]])   # 군집별 대표 문서 확인
```

- normalize_embeddings=True 로 단위 벡터를 만들면 유클리드 거리² = 2(1 − 코사인) 이므로 KMeans 가 곧 구형 k-means 가 됨
- 군집 이름은 c-TF-IDF 상위 단어 또는 LLM 요약으로 부여. 민감한 임상 텍스트는 외부 API 대신 로컬 모델 사용
- 실습 과제: 본인 연구 분야의 논문 초록 200편을 군집화하고 주제 지도를 만들어 볼 것

흔한 실수와 체크리스트

자주 하는 실수

- 스케일링 없이 k-means → 큰 척도 변수만 반영
- n_init=1 로 한 번만 실행하고 결과를 믿음
- SSE 가 작다고 k 를 키움 (k=n 이면 0)
- t-SNE 그림의 덩어리 수를 k 로 채택
- 범주형 원-핫에 유클리드 거리 적용
- 실루엣으로 DBSCAN 결과를 평가하고 '나쁘다'고 결론
- 군집 라벨로 accuracy 계산 (라벨 순열 무시)
- 훈련 데이터로 중심을 만들고 테스트 데이터로 다시 fit (fit 대신 predict 사용해야)
- 군집 결과를 곧바로 인과적 하위집단으로 해석

제출 전 체크리스트

- □ 거리 측도와 스케일링 근거를 적었는가
- □ 여러 k·알고리즘·시드를 비교했는가
- □ 내부 지표 + 안정성(부트스트랩/합의)을 보고했는가
- □ 군집별 특징 요약표(평균·비율)를 제시했는가
- □ 외부 결과(예후 등)와의 연관을 검정했는가 (다중비교 보정)
- □ 시각화는 확인용이고 군집화는 원/PCA 공간에서 했는가
- □ 새 데이터 할당 방법(predict)과 코드·시드를 공개했는가
- □ 군집화의 한계(정답 없음, 가정)를 논의했는가

연구 동향 요약 (2023–2026)

주제	핵심 내용	대표 문헌·도구
파운데이션 모델 임베딩 군집	CLIP/DINOv2/LLM 임베딩 위 k-means·HDBSCAN 이 지도학습 없이 의미 군집 복원	DINOv2 (2024), TURTLE (ICML 2024), ClusterLLM (2023)
토픽 모델링의 세대교체	LDA → 임베딩+UMAP+HDBSCAN (BERTopic), LLM 기반 주제 명명	Grootendorst 2022; Top2Vec
밀도 기반의 표준화	HDBSCAN 의 scikit-learn 내장(1.3), GPU 가속(cuML), DBCV 평가	scikit-learn 1.3+; RAPIDS cuML
설명 가능한 군집화	군집을 얕은 의사결정나무로 근사 (IMM), 군집별 규칙 추출	Moshkovitz et al. ICML 2020; ExKMC
공정·프라이버시	보호 집단 비율을 유지하는 공정 군집화, 차분 프라이버시 k-means	Chierichetti et al. 2017 계열
임상 표현형의 재현성	다기관 외부 검증, 전향적 치료 효과 이질성(HTE) 연구로 확장	JAMA 2019 패혈증 아형 후속 연구들
대규모 벡터 양자화	RAG·검색을 위한 십억 규모 k-means (IVF/PQ), GPU k-means	FAISS, ScaNN, DiskANN

흐름: '어떤 알고리즘'보다 '어떤 표현 공간에서, 무엇을 가깝다고 볼 것인가'가 결과를 결정한다는 인식이 지배적이다. 군집화는 표현 학습·검색·해석의 기반 기술로 위치가 바뀌었다.

핵심 정리

개념

- 비지도학습: 라벨 없이 구조 학습
- 군집화 = 유사도 정의 + 최적화 + 검증
- 정답이 없다 → 가정과 목적을 명시
- 거리 측도·스케일링이 알고리즘보다 먼저

k-means 이론

- $J = \Sigma\|x-\mu\|^2$ 최소화, NP-난해
- Lloyd: 할당·갱신 교대, J 단조 비증가 → 유한 수렴 (국소 최적)
- k-means++: $E[J] \le 8(\ln k+2)\cdot OPT$
- GMM/EM 의 $\varepsilon \to 0$ 극한
- k 선택: 엘보·실루엣·gap·BIC + 안정성

알고리즘 · 실무

- 계층(Ward)·DBSCAN/HDBSCAN·GMM·스펙트럴의 적용 조건
- 평가: 실루엣/DB/CH, ARI/AMI, 부트스트랩·합의
- 고차원: PCA→군집, UMAP 은 확인용
- 딥 클러스터링·임베딩 군집·BERTopic
- 의료: 표현형 발굴은 예후 연관과 외부 재현이 핵심

참고문헌

- Lloyd, S. (1982). Least squares quantization in PCM. IEEE Trans. Inf. Theory. / MacQueen (1967). Some methods for classification and analysis of multivariate observations.
- Arthur, D. & Vassilvitskii, S. (2007). k-means++: The advantages of careful seeding. SODA. / Bahmani et al. (2012). Scalable k-means++. VLDB.
- Aloise et al. (2009). NP-hardness of Euclidean sum-of-squares clustering. Machine Learning. / Vattani (2011). k-means requires exponentially many iterations. DCG.
- Ester et al. (1996). DBSCAN. KDD. / Campello, Moulavi & Sander (2013). HDBSCAN. PAKDD. / McInnes et al. (2017). hdbscan. JOSS.
- Dempster, Laird & Rubin (1977). Maximum likelihood from incomplete data via the EM algorithm. JRSS-B. / Bishop (2006). PRML, Ch. 9.
- Shi & Malik (2000). Normalized cuts. TPAMI. / Ng, Jordan & Weiss (2002). On spectral clustering. NeurIPS. / von Luxburg (2007). A tutorial on spectral clustering.
- Rousseeuw (1987). Silhouettes. / Tibshirani et al. (2001). Gap statistic. / Hubert & Arabie (1985). Comparing partitions (ARI). / Vinh et al. (2010). AMI. JMLR.
- Monti et al. (2003). Consensus clustering. / Şenbabaoğlu et al. (2014). Critical limitations of consensus clustering. Sci. Rep.
- Xie, Girshick & Farhadi (2016). DEC. ICML. / Caron et al. (2018). DeepCluster. ECCV. / Caron et al. (2020). SwAV. NeurIPS. / Oquab et al. (2024). DINOv2. TMLR.
- Grootendorst (2022). BERTopic. arXiv. / Zhang et al. (2023). ClusterLLM. EMNLP. / Gadetsky et al. (2024). TURTLE. ICML.
- Seymour et al. (2019). Derivation, validation, and potential treatment implications of novel clinical phenotypes for sepsis. JAMA 321(20).
- scikit-learn 1.7 User Guide — 2.3 Clustering; Pedregosa et al. (2011). JMLR.

질문 및 정리

Q & A

오늘의 핵심 정리

- 군집화는 '유사도 정의 → 최적화 → 검증'의 3단계이며, 정답이 없으므로 가정과 목적을 명시해야 한다.
- k-means 는 SSE 를 좌표 하강으로 줄이는 Lloyd 알고리즘 — 단조 비증가로 수렴하지만 국소 최적이므로 k-means++ 와 다중 실행이 필수.
- 군집 형태·밀도·잡음에 따라 계층(Ward) · DBSCAN/HDBSCAN · GMM(EM) · 스펙트럴을 선택하고, 실루엣·ARI·안정성으로 검증한다.
- 고차원에서는 스케일링·PCA 가 먼저, UMAP/t-SNE 는 확인용. 딥 클러스터링과 파운데이션 모델 임베딩이 현대 군집화의 표준 입력이다.
- 실습: scikit-learn 1.7+ 로 k-means 직접 구현·비교·평가, 선택 과제로 임베딩 기반 텍스트 군집화.

성명 : 최승호 · 이메일 : jcn99250@naver.com