CHAPTER 1

군집화

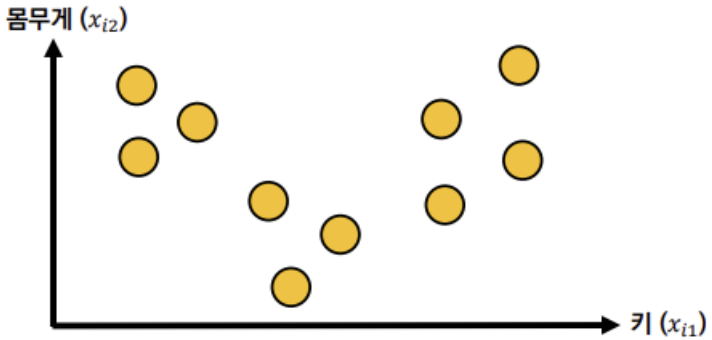
성명 : 최승호
이메일 : jcn99250@naver.com

학습 목표

- 군집화에 대해서 설명할 수 있습니다.

비지도 학습

- 비지도학습(Unsupervised learning)
  - 지도학습 데이터와 다르게 라벨 (실제 값, y) 이 없는 입력 데이터를 통해 학습하는 방법
    - 입력 데이터를 통해 데이터의 패턴이나 상관관계 등을 알아내는 방법
    - 라벨 없이 데이터의 특징 벡터(x)를 사용하여 학습을 진행
      - 군집화, 차원 축소, 이상치 탐지, 밀도 추정 등 다양한 분야에 응용



키 몸무게 데이터 (비지도 학습 데이터)

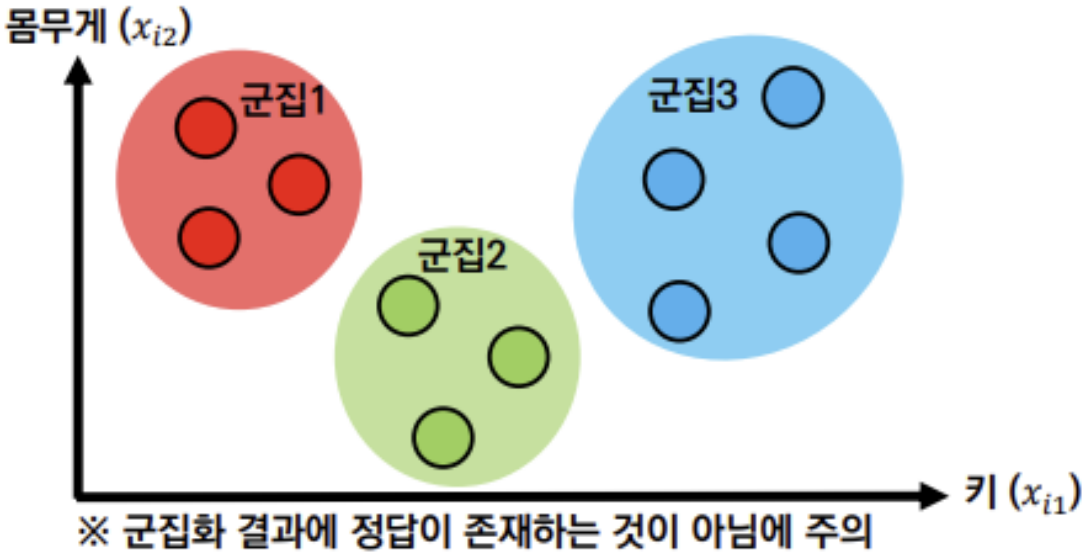
	키 (x_{i1})	몸무게 (x_{i2})
$\mathbf{x}_1$	170	75
$\mathbf{x}_2$	169	80
$\mathbf{x}_3$	172	78
$\mathbf{x}_4$	175	74
$\mathbf{x}_5$	176	70
$\mathbf{x}_6$	178	72
$\mathbf{x}_7$	180	78
$\mathbf{x}_8$	181	73
$\mathbf{x}_9$	183	85
$\mathbf{x}_{10}$	185	75

군집화

- 군집화(Clustering)
  - 라벨이 정해지지 않은 관측 값 특징 벡터 간 유사성을 측정하여 다수의 군집(그룹)으로 나누는 방법
    - 예시: 고객 시장 세분화, 신체 유형 그룹화, 관련 문서 정리등
  - 군집 (Cluster): 유사도가 높은 유한 개의 관측 치들이 서로 가깝게 모여 형성된 집합
    - 즉, 비슷한 특성 (특징 벡터)을 가진 관측치들의 집합을 의미

군집화

- 군집화(Clustering)
  - 유사도 측정 방법 : 유클리디안 거리, 맨하탄 거리, 코사인 유사도등



군집화 결과에 정답이 존재하는 것이 아님에 주의

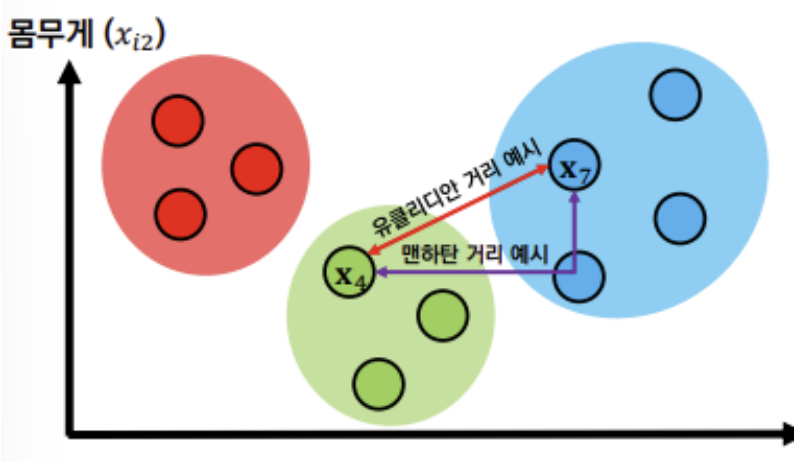
	키 (x_{i1})	몸무게 (x_{i2})
x_1	170	75
x_2	169	80
x_3	172	78
x_4	175	74
x_5	176	70
x_6	178	72
x_7	180	78
x_8	181	73
x_9	183	85
x_{10}	185	75

군집화

- 유사도 측정
  - 데이터 의 특성에 따라 적합한 유사도 측도를 사용하면 더 좋은 성능을 얻을 수 있음
  - 유클리디안 거리와 맨하탄 거리가 유사도 측도로 많이 사용됨
    - 같은 군집 관측 값 간 유사도는 높게 (유클리디안 거리의 값이 작음, 관측치 간 거리가 가까움)
    - 다른 군집 관측 값 간 유사도는 낮게 (유클리디안 거리의 값이 큼, 관측치 간 거리가 멀음)

군집화

- 유사도 측정



	키 (x_{i1})	몸무게 (x_{i2})
$\mathbf{x}_4$	175	74
$\mathbf{x}_7$	180	78

유클리디안 거리 예시 :

$$Euclidean(\mathbf{x}_4, \mathbf{x}_7) = \sqrt{\sum_{j=1}^{2}(x_{4j} - x_{7j})^2} = \sqrt{(175-180)^2 + (74-78)^2} = \sqrt{41}$$

맨하탄 거리 예시 :

$$Manhattan(\mathbf{x}_4, \mathbf{x}_7) = \sum_{}^{2} |x_{4j} - x_{7j}| = |175-180| + |74-78| = 9$$

군집화 유사도 측정 예시 (유클리디안 거리, 맨하탄 거리)

군집화

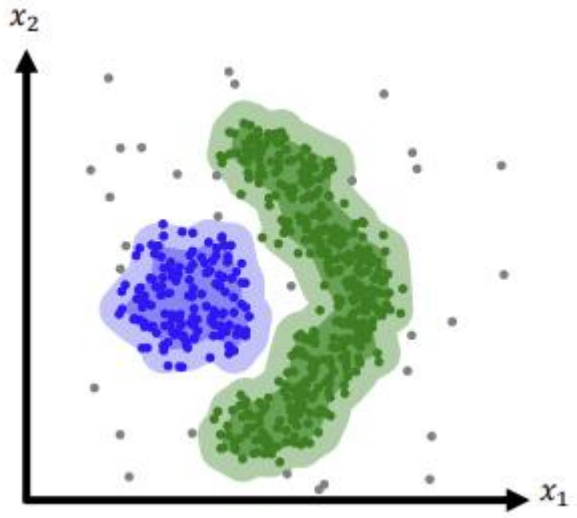
- 군집화 알고리즘의 종류
  - 어떤 군집화 알고리즘을 사용할 것인가?
    - K-평균 군집화 (k-means clustering)
      - 대표적인 분리형 군집화 알고리즘
        - 장점 : 절차가 단순하고 직관적임
        - 단점 : 사전에 군집의 수를 의미하는 초매개변수 k를 정해줘야 함
    - 계층적 군집화 (hierarchical clustering)
      - 개체들을 가까운 집단부터 차근차근 결합하는 알고리즘
        - 장점 : 군집 수 k값의 지정이 필요 없음, 군집화 결과를 트리 형태로 표현 (덴드로그램)하여 시각화 가능
        - 단점 : 모든 관측치 간 유사도를 연산하므로 관측치의 수가 많을 수록 연산량이 기하급수적으로 증가

군집화

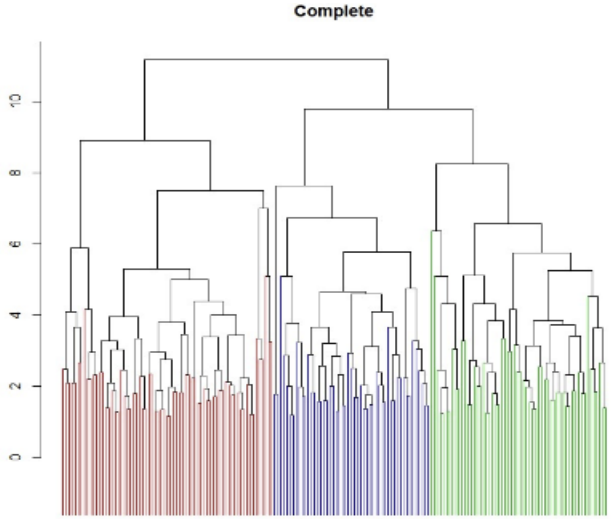
- 군집화 알고리즘의 종류
  - 어떤 군집화 알고리즘을 사용할 것인가?
    - 밀도기반 군집화 (Density-Based Spatial Clustering of Application with Noise, DBSCAN)
      - 데이터 밀도를 연산하여 군집을 결정하는 알고리즘
        - 장점 : 군집수 k 값의 지정이 필요 없음, 원뿔 모양등 특이한 관측치 분포에 대해 군집화 가능
        - 단점 : 관측 치 내 밀도가 다양하게 분포되어 있거나, 특징 벡터의 성분 수가 많으면 성능이 하락함

군집화

- 군집화 알고리즘의 종류
  - 밀도기반 군집화와 계층적 군집화 예시
    - 밀도기반 군집화 예시 : 밀도 기반 군집화 결과를 보여줌
    - 계층적 군집화 예시 : 덴드로그램을 통해 관측치 결합과정을 잘 보여줌



밀도기반 군집화 예시



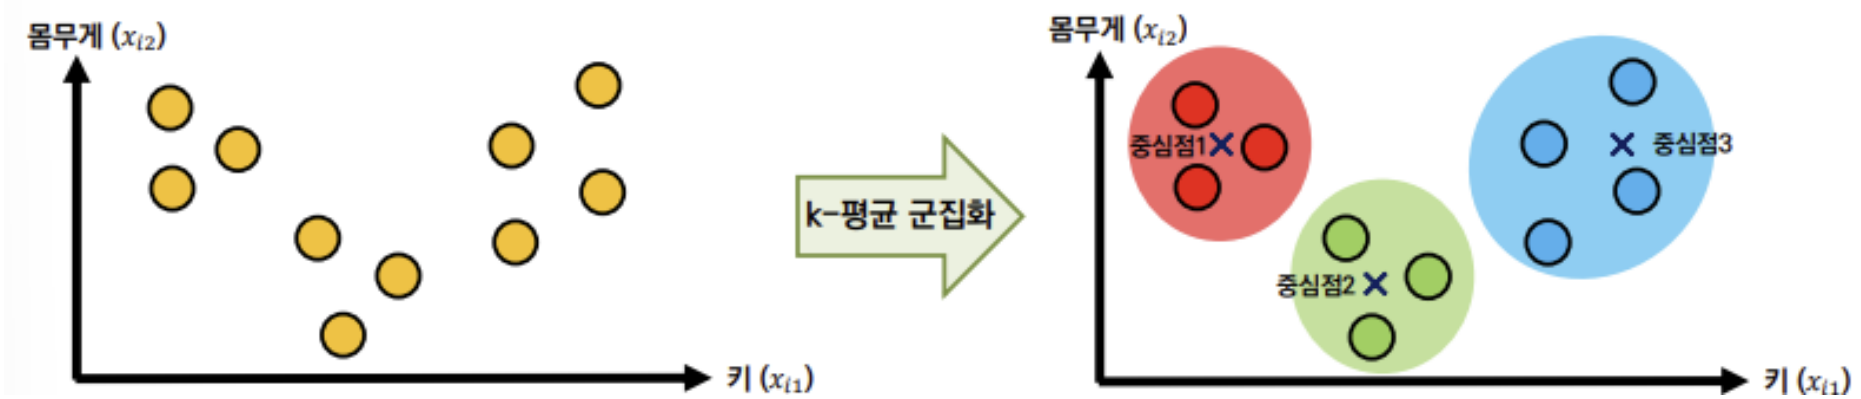
계층적 군집화 예시

군집화

- k- 평균 군집화
  - K-평균 군집화의 특성
    - 초 매개변수 k에 맞는 군집수로 군집화를 수행
      - 각 군집은 하나의 중심점(Centroid)을 가짐
        - 중심점(Centroid): 군집에 속하는 관측 값들을 대표하는 점 (관측 값 특징벡터 평균값이 성분인 벡터)
    - 모든 관측 값는 k개의 군집 중 적어도 하나에 속함
      - 각 관측값는 가장 유사한 중심점과 동일한 군집으로 할당됨
      - 같은 중심에 할당된 관측 값들이 모여 하나의 군집을 형성

군집화

- k- 평균 군집화
  - K-평균 군집화의 특성
    - 군집 간 중복되는 관측 값이 없음 (즉, 어떠한 관측치도 두 개 이상의 군집에 속하지 없음)



K- 평균 군집화 수행 예시 (k=3)

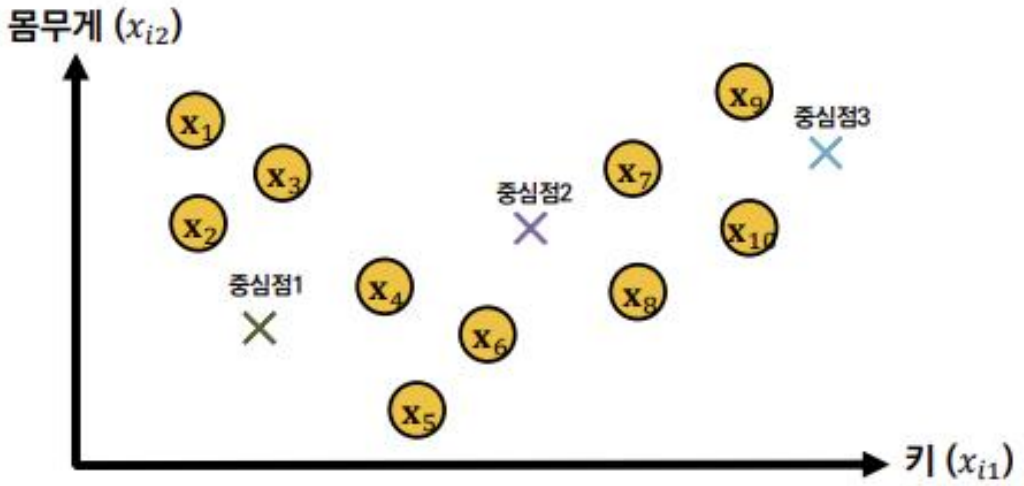
k-평균 군집화

- k- 평균 군집화 수행 절차
  - Step 1. k개의 중심점을 임의로 생성
    - 생성된 k개의 중심점을 초기 중심점이라고도 함
  - Step 2. k개의 중심점을 기준으로 모든 관측 값의 군집 할당
    - 모든 관측 값과 중심 점의 유사도를 측정
    - 가장 유사도가 큰 중심점이 속한 군집으로 할당 (유사도 측도 : 유클리디안 거리)
  - Step 3. 각 군집의 중심점을 새롭게 정의
    - 새로운 중심점은 각 군집 내의 관측 값 특징벡터의 평균 벡터를 연산하여 할당
  - Step 4. 종료 조건까지 Step2 ~ Step 3과정 반복 진행
    - 관측 값에 적합한 종료조건 설정 (지정된 횟수만큼 반복, 중심점이 변하지 않을 때까지 등)

k-평균 군집화 (예시 1)

c_j : 군집 j의 중심점(centroid)

- k- 평균 군집화 수행 예시 (k=3)
  - Step 1. 3개의 중심점을 임의로 생성
    - 생성된 중심점 1, 중심점 2, 중심점 3을 X로 표기



K 평균 군집화 Step 1

〈표1〉 관측값

	키 (x_{i1})	몸무게 (x_{i2})
x_1	170	75
x_2	169	80
x_3	172	78
x_4	175	74
x_5	176	70
x_6	178	72
x_7	180	78
x_8	181	73
x_9	183	85
x_{10}	185	75

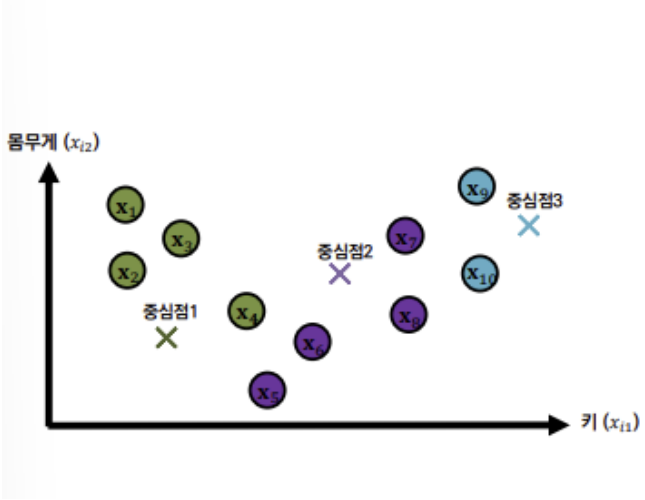
〈표2〉 중심점

	키 (c_{j1})	몸무게 (c_{j2})
c_1	171	73
c_2	179	75
c_3	187	79

k-평균 군집화 (예시 1)

c_j : 군집 j의 중심점(centroid)

- k- 평균 군집화 수행 예시 (k=3)
  - Step 2. 3개의 중심점을 기준으로 모든 관측 값의 군집 할당
    - 모든 관측 값와 중심점의 유사도를 측정
    - 가장 유사도가 큰 중심점이 속한 군집으로 할당 (유클리디안 거리)



K-평균 군집화 Step 2

〈표3〉 관측값 – 중심점 거리

	중심점1 (c_1)	중심점2 (c_2)	중심점3 (c_3)
x_1	2.23	9.0	17.46
x_2	7.28	11.18	18.02
x_3	5.09	7.61	15.03
x_4	4.12	4.12	13.0
x_5	5.83	4.12	14.21
x_6	7.07	5.83	11.40
x_7	10.29	3.16	7.07
x_8	10	2.82	8.48
x_9	16.97	10.77	7.21
x_{10}	14.14	6.0	4.47

〈표1〉 관측값

	키 (x_{i1})	몸무게 (x_{i2})
x_1	170	75
x_2	169	80
x_3	172	78
x_4	175	74
x_5	176	70
x_6	178	72
x_7	180	78
x_8	181	73
x_9	183	85
x_{10}	185	75

〈표2〉 중심점

	키 (c_{j1})	몸무게 (c_{j2})
c_1	171	73
c_2	179	75
c_3	187	79

k-평균 군집화 (예시 1)

* 수식참조
c_j : 군집 j의 중심점(centroid)
n_j는 군집 j 내 관측치의 수

- k- 평균 군집화 수행 예시 (k=3)
  - Step 3. 각 군집의 중심점을 새롭게 정의
    - 새로운 중심점은 각 군집 내 관측 값 특징벡터의 평균 벡터를 연산하여 할당

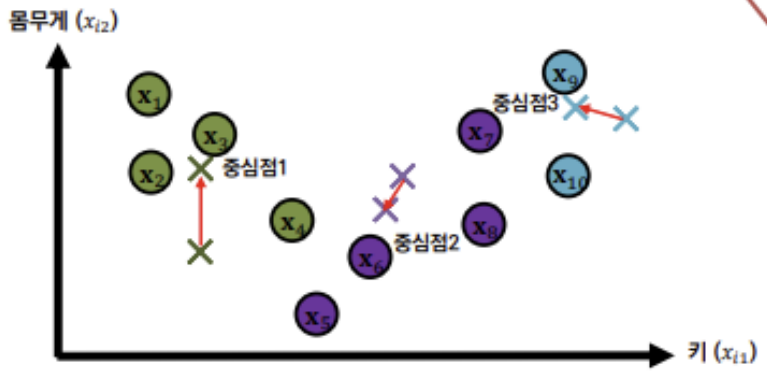
$$\text{군집}_1 \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix}, n_1 = 4 \quad \text{군집}_2 \begin{bmatrix} x_5 \\ x_6 \\ x_7 \\ x_8 \end{bmatrix}, n_2 = 4 \quad \text{군집}_3 \begin{bmatrix} x_9 \\ x_{10} \end{bmatrix}, n_3 = 2$$

군집 j 의 새로운 중심점 $\mathbf{c}_j = \left[\frac{1}{n_j}\sum_{i=1}^{n_j} x_{i1}, \frac{1}{n_j}\sum_{i=1}^{n_j} x_{i2}\right]$

군집 j 내에서 관측값의 인덱스를 새로 부여

* 연산 예시

$\mathbf{c}_1 = \left[\frac{1}{4}(170+169+172+175), \frac{1}{4}(170+169+172+175)\right] = [171.5, 76.75]$



K-평균 군집화 Step 3

〈표4〉 새로운 중심점 할당

	키 (c_{j1})	몸무게 (c_{j2})
$\mathbf{c}_1$	171	73
$\mathbf{c}_2$	179	75
$\mathbf{c}_3$	187	79

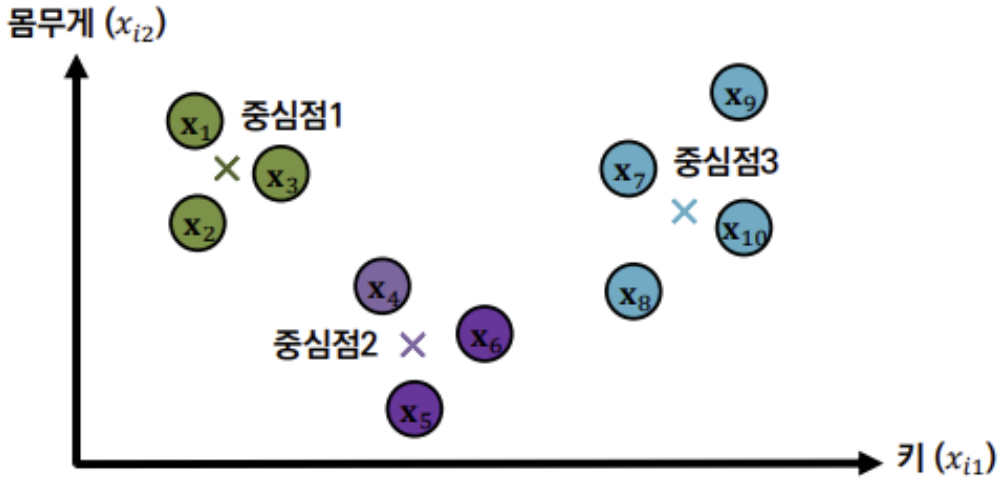
	키 (c_{j1})	몸무게 (c_{j2})
$\mathbf{c}_1$	171.5	76.75
$\mathbf{c}_2$	178.75	73.25
$\mathbf{c}_3$	184	80

〈표1〉 관측값

	키 (x_{i1})	몸무게 (x_{i2})
$\mathbf{x}_1$	170	75
$\mathbf{x}_2$	169	80
$\mathbf{x}_3$	172	78
$\mathbf{x}_4$	175	74
$\mathbf{x}_5$	176	70
$\mathbf{x}_6$	178	72
$\mathbf{x}_7$	180	78
$\mathbf{x}_8$	181	73
$\mathbf{x}_9$	183	85
$\mathbf{x}_{10}$	185	75

k-평균 군집화 (예시 1)

- k- 평균 군집화 수행 예시 (k=3)
  - Step 4. 종료조건까지 Step 2 ~ Step 3 과정 반복 진행
    - 관측 값에 적합한 종료조건 설정 (아래 예시는 중심점이 변하지 않을 때까지)



K-평균 군집화 Step 4

〈표1〉 관측값

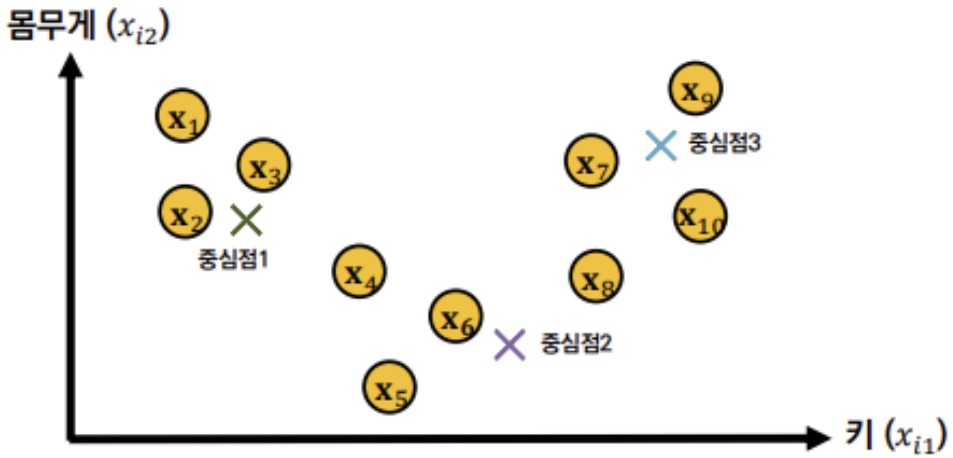
	키 (x_{i1})	몸무게 (x_{i2})
x_1	170	75
x_2	169	80
x_3	172	78
x_4	175	74
x_5	176	70
x_6	178	72
x_7	180	78
x_8	181	73
x_9	183	85
x_{10}	185	75

〈표5〉 최종 중심점

	키 (c_{j1})	몸무게 (c_{j2})
c_1	170.3	77.6
c_2	176.3	72
c_3	182.3	77.8

k-평균 군집화 (예시 2)

- 초기 중심점 설정
  - 초기 중심점을 임의의 값으로 설정하는 알고리즘 사용
    - 군집화 결과가 초기 중심점 설정에 따라서 다르게 나타나는 경우가 발생
    - 동일한 데이터에서 중심점이 다를 때 어떻게 군집화 결과가 나타나는지 확인



K-평균 군집화 (초기 중심점 변경)

〈표1〉 관측값

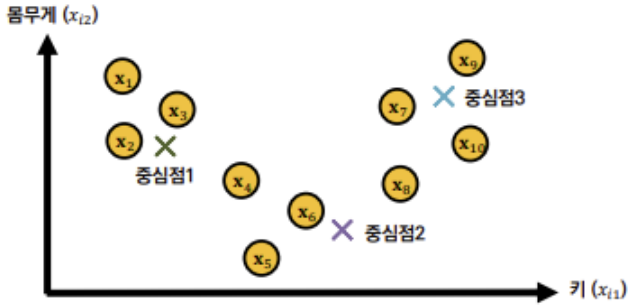
	키 (x_{i1})	몸무게 (x_{i2})
x_1	170	75
x_2	169	80
x_3	172	78
x_4	175	74
x_5	176	70
x_6	178	72
x_7	180	78
x_8	181	73
x_9	183	85
x_{10}	185	75

〈표6〉 중심점

	키 (c_{j1})	몸무게 (c_{j2})
c_1	171	74
c_2	179	71
c_3	182	80

k-평균 군집화 (예시 2)

- K-평균 군집화 (초기 중심점 변경)
  - Step 2. 3개의 중심점을 기준으로 모든 관측 관의 군집 할당
    - 모든 관측 값과 중심점의 유사도를 측정
    - 가장 유사도가 큰 중심점이 속한 군집으로 할당 (유클리디안 거리)



〈표7〉 관측값 – 중심점 거리

	중심점1 (c_1)	중심점2 (c_2)	중심점3 (c_3)
x_1			
x_2			
x_3			
x_4			
x_5			
x_6			
x_7			
x_8			
x_9			
x_{10}			

K-평균 군집화 Step 2 (초기 중심점 변경)

〈표1〉 관측값

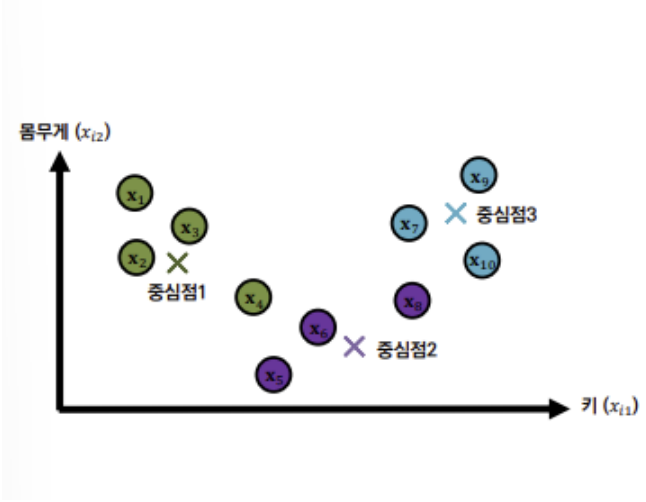
	키 (x_{i1})	몸무게 (x_{i2})
x_1	170	75
x_2	169	80
x_3	172	78
x_4	175	74
x_5	176	70
x_6	178	72
x_7	180	78
x_8	181	73
x_9	183	85
x_{10}	185	75

〈표6〉 중심점

	키 (c_{j1})	몸무게 (c_{j2})
c_1	171	74
c_2	179	71
c_3	182	80

k-평균 군집화 (예시 2)

- K-평균 군집화 (초기 중심점 변경)
  - Step 2. 3개의 중심점을 기준으로 모든 관측 관의 군집 할당
    - 모든 관측 값과 중심점의 유사도를 측정
    - 가장 유사도가 큰 중심점이 속한 군집으로 할당 (유클리디안 거리)



〈표7〉 관측값 – 중심점 거리

	중심점1 (c_1)	중심점2 (c_2)	중심점3 (c_3)
x_1	1.41	9.84	13
x_2	6.32	13.45	13
x_3	4.12	9.89	10.19
x_4	4	5	9.21
x_5	6.04	3.16	11.66
x_6	7.28	1.41	8.94
x_7	9.84	7.07	2.82
x_8	10.04	2.82	7.07
x_9	16.27	14.56	5.09
x_{10}	14.03	7.21	5.83

〈표1〉 관측값

	키 (x_{i1})	몸무게 (x_{i2})
x_1	170	75
x_2	169	80
x_3	172	78
x_4	175	74
x_5	176	70
x_6	178	72
x_7	180	78
x_8	181	73
x_9	183	85
x_{10}	185	75

〈표6〉 중심점

	키 (c_{j1})	몸무게 (c_{j2})
c_1	171	74
c_2	179	71
c_3	182	80

K-평균 군집화 Step 2 (초기 중심점 변경)

k-평균 군집화 (예시 2)

- K-평균 군집화 (초기 중심점 변경)
  - Step 3. 각 군집의 중심점을 새롭게 정의
    - 새로운 중심점은 각 군집 내 관측 값 특징벡터의 평균 벡터를 연산하여 할당

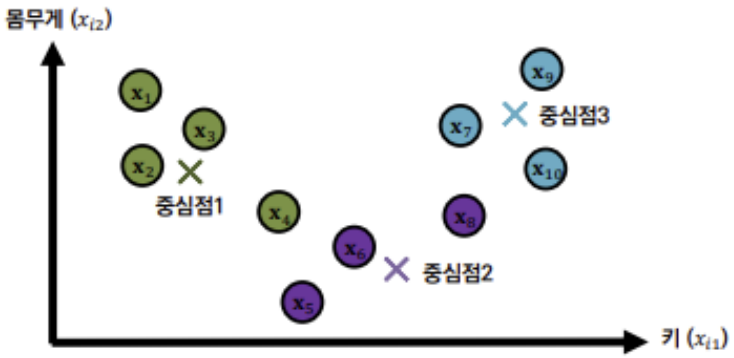
〈표1〉 관측치

	키 (x_{i1})	몸무게 (x_{i2})
$\mathbf{x}_1$	170	75
$\mathbf{x}_2$	169	80
$\mathbf{x}_3$	172	78
$\mathbf{x}_4$	175	74
$\mathbf{x}_5$	176	70
$\mathbf{x}_6$	178	72
$\mathbf{x}_7$	180	78
$\mathbf{x}_8$	181	73
$\mathbf{x}_9$	183	85
$\mathbf{x}_{10}$	185	75

〈표8〉 새로운 중심점 할당

	키 (c_{j1})	몸무게 (c_{j2})
$\mathbf{c}_1$	171	74
$\mathbf{c}_2$	179	71
$\mathbf{c}_3$	182	80

	키 (c_{j1})	몸무게 (c_{j2})
$\mathbf{c}_1$		
$\mathbf{c}_2$		
$\mathbf{c}_3$		



K-평균 군집화 Step 2 (초기 중심점 변경)

k-평균 군집화 (예시 2)

- K-평균 군집화 (초기 중심점 변경)
  - Step 3. 각 군집의 중심점을 새롭게 정의
    - 새로운 중심점은 각 군집 내 관측 값 특징벡터의 평균 벡터를 연산하여 할당

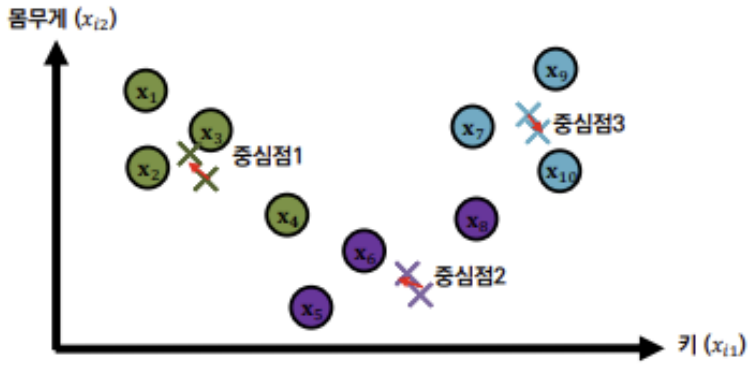
〈표1〉 관측값

	키 (x_{i1})	몸무게 (x_{i2})
$\mathbf{x}_1$	170	75
$\mathbf{x}_2$	169	80
$\mathbf{x}_3$	172	78
$\mathbf{x}_4$	175	74
$\mathbf{x}_5$	176	70
$\mathbf{x}_6$	178	72
$\mathbf{x}_7$	180	78
$\mathbf{x}_8$	181	73
$\mathbf{x}_9$	183	85
$\mathbf{x}_{10}$	185	75

〈표8〉 새로운 중심점 할당

	키 (c_{j1})	몸무게 (c_{j2})
$\mathbf{c}_1$	171	74
$\mathbf{c}_2$	179	71
$\mathbf{c}_3$	182	80

	키 (c_{j1})	몸무게 (c_{j2})
$\mathbf{c}_1$	171.5	76.75
$\mathbf{c}_2$	178.3	71.6
$\mathbf{c}_3$	182.6	79.3

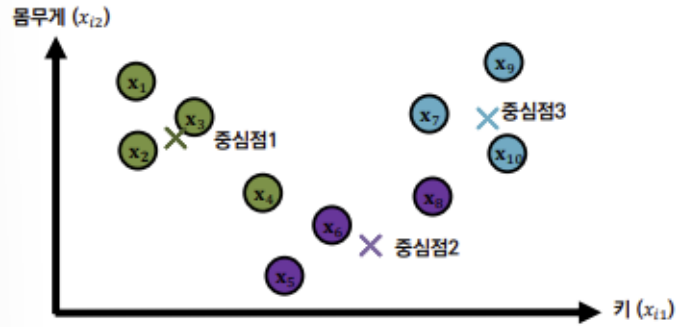


K-평균 군집화 Step 2 (초기 중심점 변경)

k-평균 군집화 (예시 2)

* 연습이므로 1회만 실시

- K-평균 군집화 (초기 중심점 변경)
  - Step 4. 종료조건까지 Step 2 ~ Step 3 과정 반복 진행
    - 관측 값에 적합한 종료 조건 설정 (아래 예시는 중심점이 변하지 않을 때 까지)



〈표9〉 관측값 – 중심점 거리

	중심점1 (c_1)	중심점2 (c_2)	중심점3 (c_3)
x_1			
x_2			
x_3			
x_4			
x_5			
x_6			
x_7			
x_8			
x_9			
x_{10}			

〈표1〉 관측값

	키 (x_{i1})	몸무게 (x_{i2})
x_1	170	75
x_2	169	80
x_3	172	78
x_4	175	74
x_5	176	70
x_6	178	72
x_7	180	78
x_8	181	73
x_9	183	85
x_{10}	185	75

〈표8〉 중심점

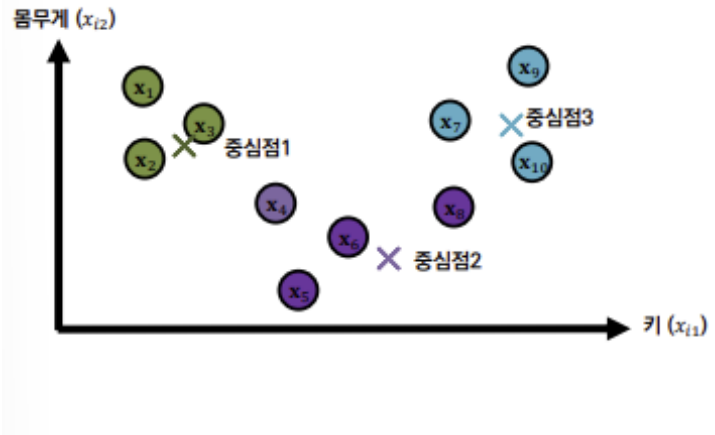
	키 (c_{j1})	몸무게 (c_{j2})
c_1	171.5	76.75
c_2	178.3	71.6
c_3	182.6	79.3

K-평균 군집화 Step 4 (초기 중심점 변경)

k-평균 군집화 (예시 2)

* 연습이므로 1회만 실시

- K-평균 군집화 (초기 중심점 변경)
  - Step 4. 종료조건까지 Step 2 ~ Step 3 과정 반복 진행
    - 관측 값에 적합한 종료 조건 설정 (아래 예시는 중심점이 변하지 않을 때 까지)



〈표9〉 관측값 – 중심점 거리

	중심점1 (c_1)	중심점2 (c_2)	중심점3 (c_3)
x_1	2.30	8.96	13.31
x_2	4.10	12.53	13.61
x_3	1.34	8.09	10.67
x_4	4.45	4.08	9.26
x_5	8.11	2.80	11.40
x_6	8.06	0.5	8.62
x_7	8.59	6.62	2.90
x_8	10.21	3.04	6.49
x_9	14.15	14.20	5.71
x_{10}	13.61	7.51	4.92

〈표1〉 관측값

	키 (x_{i1})	몸무게 (x_{i2})
x_1	170	75
x_2	169	80
x_3	172	78
x_4	175	74
x_5	176	70
x_6	178	72
x_7	180	78
x_8	181	73
x_9	183	85
x_{10}	185	75

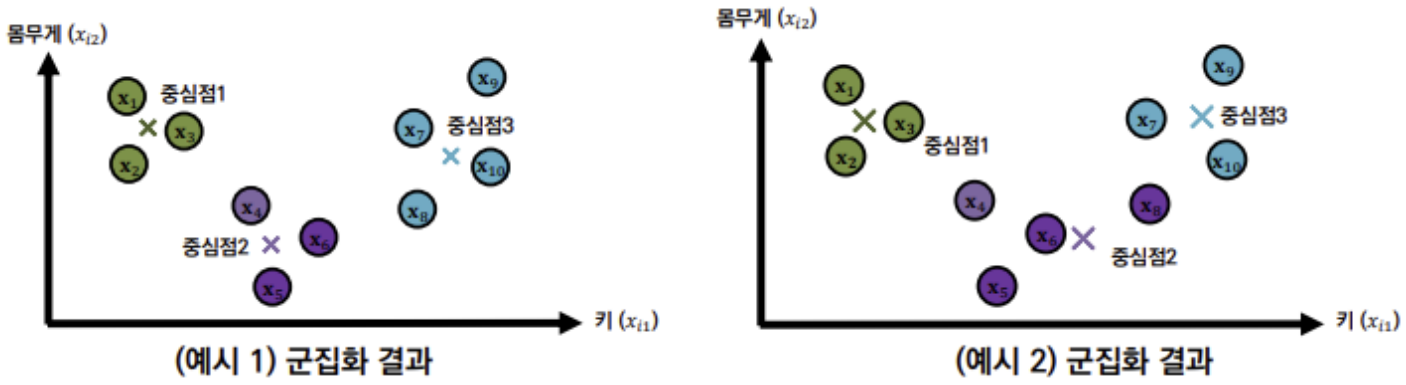
〈표8〉 중심점

	키 (c_{j1})	몸무게 (c_{j2})
c_1	171.5	76.75
c_2	178.3	71.6
c_3	182.6	79.3

K-평균 군집화 Step 4 (초기 중심점 변경)

k-평균 군집화

- K-평균 군집화 (초기 중심점 변경)
  - 초기 중심점에 따른 군집화 결과 비교
    - 관측 값의 수가 많고 분산이 큰 경우 초기 중심점의 영향을 더 많이 받음
    - 관측 값의 분포를 활용하여 초기 중심점 정하는 방법 등도 존재
      - 어떤 결과가 더 군집화를 잘 수행한 결과일까? 비지도 학습의 성능 측도 활용



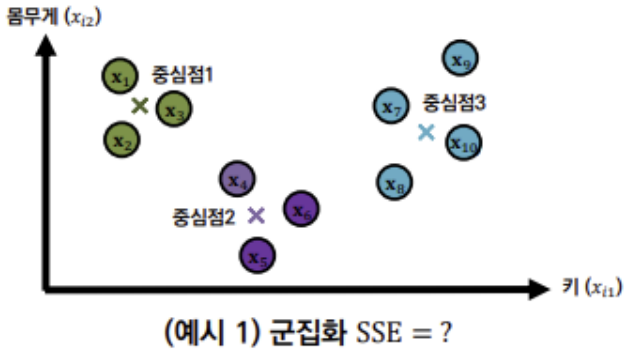
초기 중심점에 따른 k-평균 군집화 결과 비교

성능측도

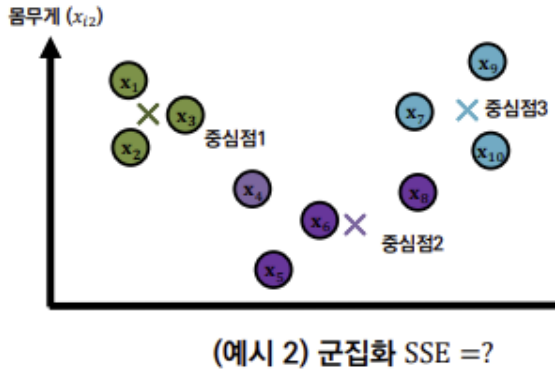
* 수식참조
c_j : 군집 j의 중심점(centroid)
n_j는 군집 j 내 관측치의 수
k 는 사전 정의한 군집의 수

- 오차제곱합(SSE, Sum Squared Error)
  - 군집별로 중심점과 군집 내 관측 값의 특징 벡터의 차이를 제곱하여 모두 더함
    - 즉, 중심점의 특징벡터 값과 유사한 관측 값이 많을 수록 더 좋은 성능으로 평가
    - SSE 값이 작을 수록 오차가 적은 군집화 결과

$$\mathrm{SSE} = \sum_{j=1}^{k} \sum_{i=1}^{n_j} (\mathbf{x}_i - \mathbf{c}_j)^2$$



(예시 1) 군집화 SSE = ?



(예시 2) 군집화 SSE =?

〈표1〉 관측값

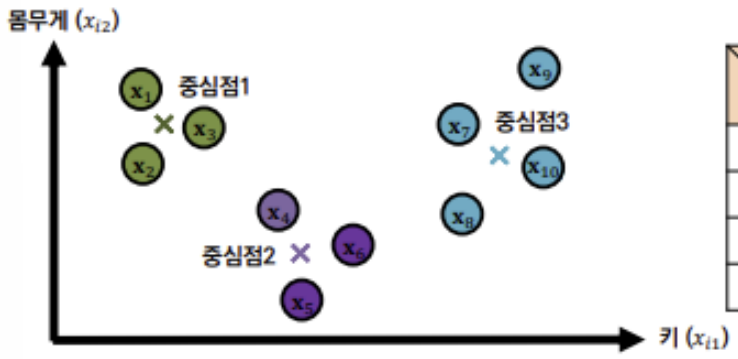
	키 (x_{i1})	몸무게 (x_{i2})
$\mathbf{x}_1$	170	75
$\mathbf{x}_2$	169	80
$\mathbf{x}_3$	172	78
$\mathbf{x}_4$	175	74
$\mathbf{x}_5$	176	70
$\mathbf{x}_6$	178	72
$\mathbf{x}_7$	180	78
$\mathbf{x}_8$	181	73
$\mathbf{x}_9$	183	85
$\mathbf{x}_{10}$	185	75

초기 중심점에 따른 k-평균 군집화 성능 비교

성능측도

- 오차제곱합(SSE, Sum Squared Error)

$$\mathrm{SSE} = \sum_{j=1}^{k} \sum_{i=1}^{n_j} (\mathbf{x}_i - \mathbf{c}_j)^2$$



(예시 1) 군집화 SSE = 31.46

〈표10〉 SSE 연산 과정

	중심점1 ($\mathbf{c}_1$)
$\mathbf{x}_1$	2.68
$\mathbf{x}_2$	2.68
$\mathbf{x}_3$	1.69
합산	7.05

	중심점2 ($\mathbf{c}_2$)
$\mathbf{x}_4$	2.40
$\mathbf{x}_5$	2.02
$\mathbf{x}_6$	1.66
합산	6.08

	중심점3 ($\mathbf{c}_3$)
$\mathbf{x}_7$	2.26
$\mathbf{x}_8$	4.91
$\mathbf{x}_9$	7.28
$\mathbf{x}_{10}$	3.88
합산	18.33

$SSE = 7.05 + 6.08 + 18.33 = 31.46$

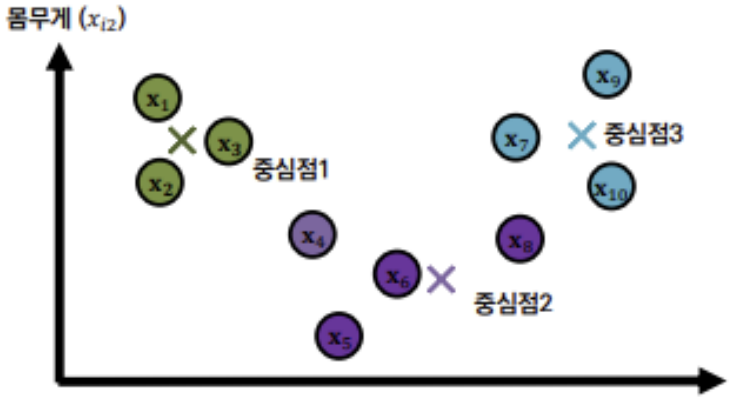
〈표1〉 관측값

	키 (x_{i1})	몸무게 (x_{i2})
$\mathbf{x}_1$	170	75
$\mathbf{x}_2$	169	80
$\mathbf{x}_3$	172	78
$\mathbf{x}_4$	175	74
$\mathbf{x}_5$	176	70
$\mathbf{x}_6$	178	72
$\mathbf{x}_7$	180	78
$\mathbf{x}_8$	181	73
$\mathbf{x}_9$	183	85
$\mathbf{x}_{10}$	185	75

성능측도

- 오차제곱합(SSE, Sum Squared Error)

$$\mathrm{SSE} = \sum_{j=1}^{k} \sum_{i=1}^{n_j} (\mathbf{x}_i - \mathbf{c}_j)^2$$



(예시 2) 군집화 SSE = 30.49

〈표11〉 SSE 연산 과정

	중심점1 ($\mathbf{c}_1$)
$\mathbf{x}_1$	2.68
$\mathbf{x}_2$	2.68
$\mathbf{x}_3$	1.69
합산	7.05

	중심점2 ($\mathbf{c}_2$)
$\mathbf{x}_7$	3.05
$\mathbf{x}_8$	2.70
$\mathbf{x}_9$	0.55
$\mathbf{x}_{10}$	3.57
합산	9.87

	중심점3 ($\mathbf{c}_3$)
$\mathbf{x}_4$	2.98
$\mathbf{x}_5$	5.67
$\mathbf{x}_6$	4.92
합산	13.57

$SSE = 7.05 + 9.87 + 13.57 = 30.49$

〈표1〉 관측값

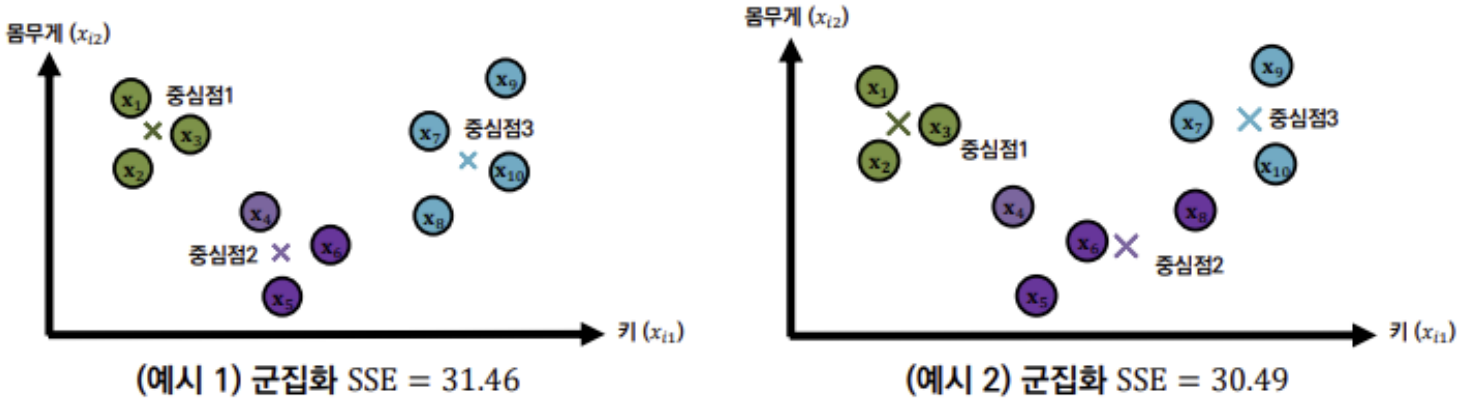
	키 (x_{i1})	몸무게 (x_{i2})
$\mathbf{x}_1$	170	75
$\mathbf{x}_2$	169	80
$\mathbf{x}_3$	172	78
$\mathbf{x}_4$	175	74
$\mathbf{x}_5$	176	70
$\mathbf{x}_6$	178	72
$\mathbf{x}_7$	180	78
$\mathbf{x}_8$	181	73
$\mathbf{x}_9$	183	85
$\mathbf{x}_{10}$	185	75

성능측도

- 오차제곱합(SSE, Sum Squared Error)
  - 두 예시 중 SSE 가 작은 (예시 2) 군집 결과가 더 좋은 성능으로 평가
    - k-평균 군집화의 종료조건으로도 설정 가능
      - SSE 값이 특정 값보다 작아지면 종료
      - SSE 값이 더 이상 변하지 않으면 종료

성능측도

- 오차제곱합(SSE, Sum Squared Error)
  - 두 예시 중 SSE 가 작은 (예시 2) 군집 결과가 더 좋은 성능으로 평가
    - 제곱 연산이 들어가기 때문에 오차가 커질 수록 SSE 값 기하급수적으로 커짐



초기 중심점에 따른 k-평균 군집화 성능 비교

질문 및 정리

