CHAPTER 1

의사결정나무

성명 : 최승호
이메일 : jcn99250@naver.com

학습 목표

- 의사결정트리에 대해서 이해합니다.

지도 학습 (분류 데이터)

타이타닉 생존자 예측 (Titanic: Survivior Prediction)

- 타이타닉 생존자를 예측을 위한 지도 학습 데이터
  - ✓ 실제 인공지능 전공 등에서 교육을 위해 많이 사용하는 데이터
  - ✓ 생존 여부, 객실 등급, 성별, 나이, 동반 부양인, 티켓 요금 등으로 구성
  - ✓ 아래 예시에서는 이름, 나이, 동반 형제, 성별, 생존 여부만 사용 (일부 변경)



KNN 혹은 MLP로 해결??

이름	나이 (x_{i1})	동반 형제 (x_{i2})	성별 (x_{i3})	생존 여부 (y_i)
안젤라	3	1	여성	생존
제임스	7	2	남성	생존
로날드	4	3	남성	사망
켈리	33	3	여성	생존
오스틴	35	0	남성	사망
앤써니	19	4	남성	사망
야니스	29	0	남성	사망
디카프리오	8	3	남성	???

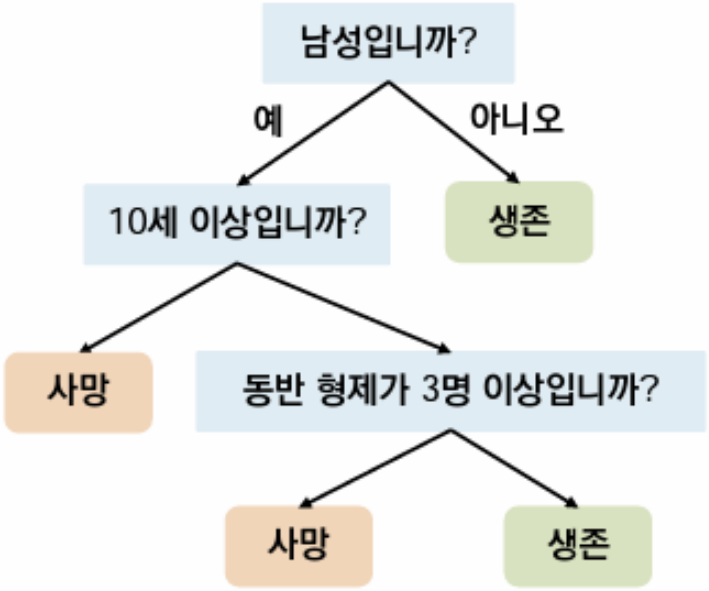
〈표1〉 타이타닉 생존 예측 데이터 (지도 학습)

지도 학습 (분류 데이터)

- 타이타닉 생존자 예측 (Titanic: Survivior Prediction)
  - KNN 혹은 MLP대신 의사결정나무를 사용해서도 분류가 가능하다.

이름	나이 (x_{i1})	동반 형제 (x_{i2})	성별 (x_{i3})	생존 여부 (y_i)
안젤라	3	1	여성	생존
제임스	7	2	남성	생존
로날드	4	3	남성	사망
켈리	33	3	여성	생존
오스틴	35	0	남성	사망
앤써니	19	4	남성	사망
야니스	29	0	남성	사망
디카프리오	8	3	남성	???

〈표1〉 타이타닉 생존 예측 데이터 (지도 학습)

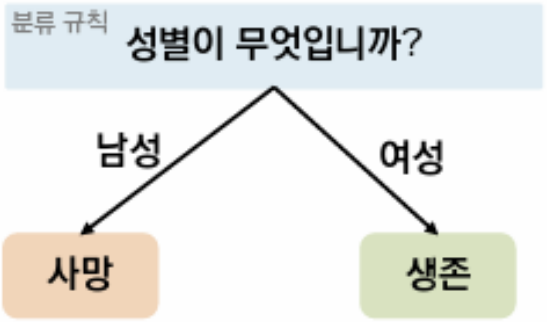


〈그림1〉 타이타닉 생존 예측 의사결정나무

의사결정나무란?

의사결정나무(Decision Tree)

- **의사결정나무란? :**
  의사결정나무는 데이터에 존재하는 속성들을 나누는 일련의 규칙(질문)들을 학습을 통해 찾아 트리 형태로 표현하는 방법
  - ✓ **규칙은 프로그래밍의 'If-else'문의 표현과 유사**
  - ✓ **트리는 일종의 분류 과정을 표현하는 것**
  - ✓ **트리의 마지막 노드에는 분류문제에서는 클래스가 회귀문제에서는 예측값이 들어감**



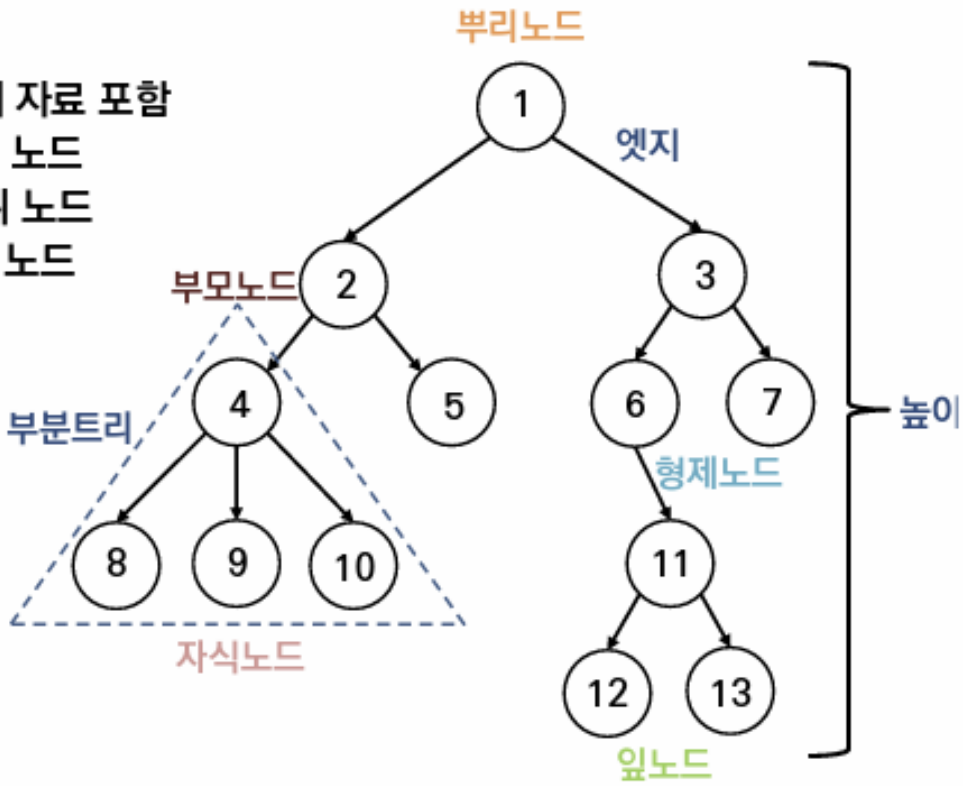


〈그림2〉 의사결정 나무 구조의 예시

트리 구조

트리(Tree)의 구조

- 노드(Node)
  - ✓ 뿌리노드(Root Node) : 시작되는 노드로 전체 자료 포함
  - ✓ 부모노드(Parent Node) : 주어진 노드의 상위 노드
  - ✓ 자식노드(Child Node) : 노드에서 분리된 하위 노드
  - ✓ 형제노드(Sibling Node) : 부모노드가 동일한 노드
  - ✓ 잎노드(Leaf Node) : 자식노드가 없는 노드
- 엣지(Edge) : 노드와 노드를 연결하는 간선
- 높이(Height) : 뿌리부터 잎노드까지의 깊이

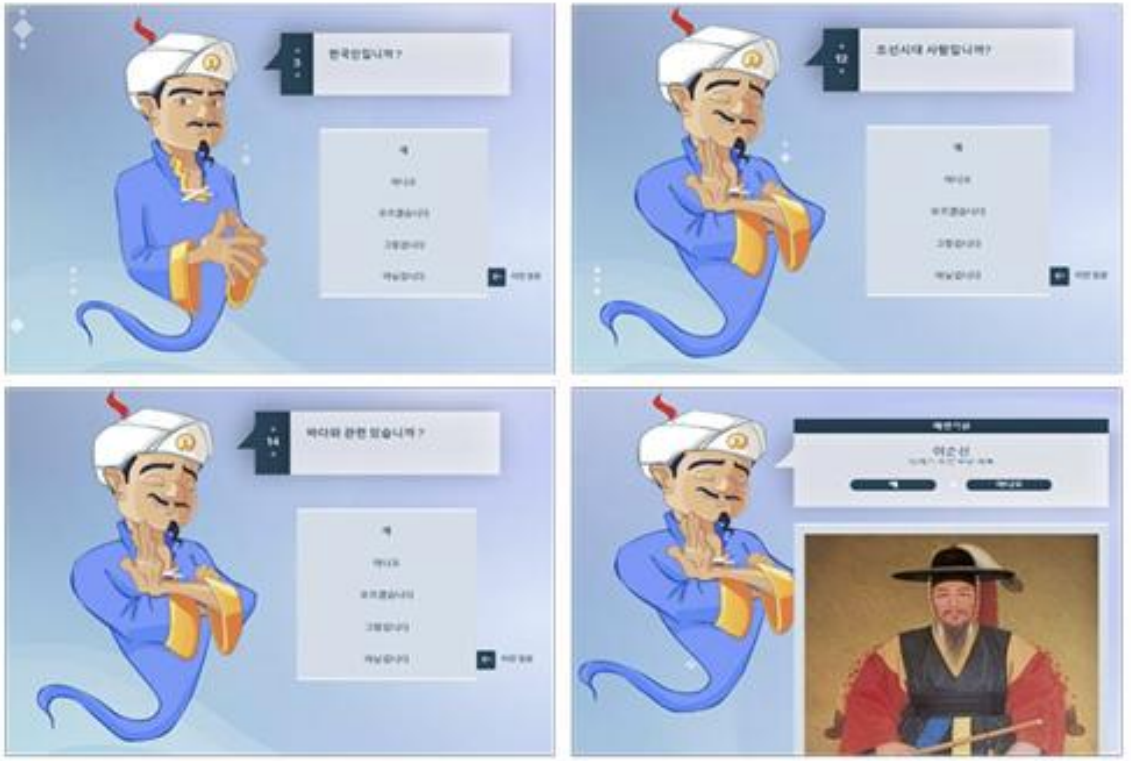


〈그림3〉 트리 구조의 예시

의사결정나무 예시

- 의사결정나무의 예시
  - 아키네이터(Akinator) 게임 : 스무고개 놀이와 유사



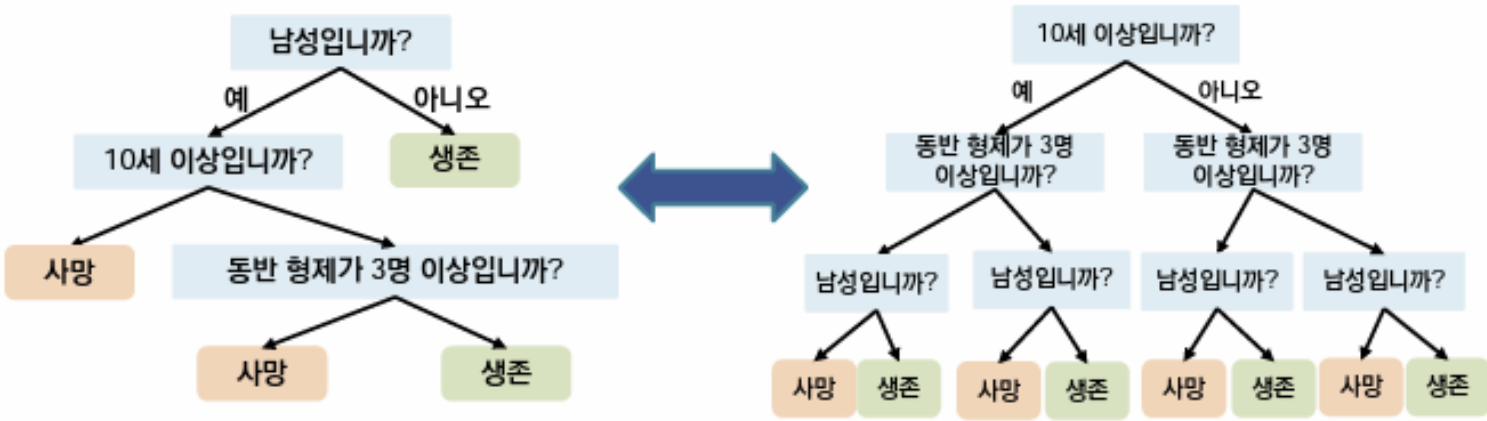


〈그림4〉 아키네이터 게임

https://kr.akinator.com/

의사결정나무를 통한 분류

- 의사결정나무 분류 규칙
  - 의사결정나무의 노드 구성(분류 규칙 결정)이 가장 중요
  - 마지막 노드에 클래스나 예측치를 기입하고 상위 부모 노드들에는 if-else의 조건 기입
  - 분할 속성(Splitting attributes) : 부모 노드에 들어가는 if-else 조건들
    - ✓ 어떤 분할 속성이 가장 모호성을 줄일 것인지 파악
      - ➢ 예시 : 1부터 100까지의 숫자 중 하나를 맞추는 '숫자 예측 게임'
    - ✓ 분할 속성을 잘 선택해야 연산적(비용적)으로 효율적인 의사결정나무를 만들 수 있음



〈그림5〉 분할 속성 선택에 따른 의사결정 나무 구성 예시

엔트로피의 이해

- **엔트로피의 이해**
  - **엔트로피 :**
    - ✓ 데이터 집합이 제공하는 각 사건이 일어날 확률을 통해 계산한 정보량을 의미함
    - ✓ 어떤 노드에서 분할 속성을 선택하였을 때 정보량을 계산하고, 해당 속성 값의 엔트로피를 최소화하는 방향으로 의사결정나무 구조를 만드는데 활용됨
      - ➢ 낮은 엔트로피 = 경우의 수가 적음 = 낮은 정보량 = 낮은 불확실성
      - ➢ 높은 엔트로피 = 경우의 수가 높음 = 높은 정보량 = 높은 불확실성
  - **엔트로피를 측정하는 방법 : 샤논(Shannon, Claude Elwood) 공식 사용**

$$h(\mathcal{D}) = -\sum_{k=1}^{m} p_k \log p_k$$

$\mathcal{D}$는 데이터 집합
m은 데이터 집합의 특정 속성의 라벨(클래스)의 개수
p_k는 라벨 k일 때의 확률

〈참조〉 log 의 밑이 2임에 주의

$$\log p_k = \log_2 p_k$$

〈수식1〉 엔트로피 계산 공식

엔트로피의 예시

- **엔트로피 예시**
  - 사람의 나이, 수입, 학생 여부, 신용 등급 고려하여 컴퓨터의 구매 여부를 의사결정
  - 전체 엔트로피의 연산
    - ✓ 컴퓨터를 구매할 확률 : 9/14
    - ✓ 컴퓨터를 구매하지 않을 확률 : 5/14

〈표2〉 컴퓨터 구매 여부 데이터 예시

번호	나이 (x_{i1})	수입 (x_{i2})	학생 여부 (x_{i3})	신용 등급 (x_{i4})	구매 여부 (y_i)
1	청소년	고소득층	아니오	좋음	미구매
2	청소년	고소득층	아니오	아주좋음	미구매
3	청년	고소득층	아니오	좋음	구매
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주좋음	미구매
7	청년	저소득층	예	아주좋음	구매
8	청소년	중소득층	아니오	좋음	미구매
9	청소년	저소득층	예	좋음	구매
10	중년	중소득층	예	좋음	구매
11	청소년	중소득층	예	아주좋음	구매
12	청년	중소득층	아니오	아주좋음	구매
13	청년	고소득층	예	좋음	구매
14	중년	중소득층	아니오	아주좋음	미구매

$$h(\mathcal{D}) = -\sum_{k=1}^{2} p_k \log p_k$$

$$h(\mathcal{D}) = \left(-\frac{9}{14}\log\frac{9}{14}\right) + \left(-\frac{5}{14}\log\frac{5}{14}\right) = 0.94$$

〈수식2〉 엔트로피 계산 예시

정보이득

- **정보이득**

$$h(\mathcal{D}) = -\sum_{k=1}^{m} p_k \log p_k$$ 〈참고〉 엔트로피 계산 공식

  - 정보이득(Information gain) :

    학습 데이터를 통해 각 노드의 분류 기준(속성)을 선정할 때, 각 속성의 효율성에 대한 측도

    * 각 노드별 정보이득을 최대화하는 특정 속성에 따라 데이터를 분류했을 경우, 가장 효율적인 분류 기준으로 구성된 트리 형태를 만들 수 있음.

    ✓ 각 속성을 기준으로 데이터를 분류했을 때의 엔트로피를 측정한다.

    ➢ 속성별 정보이득

    ❖ 정보이득이 클수록 속성 A를 기준으로 데이터를 분류했을 때 얻을 수 있는 정보량이 많다

    ❖ A를 기준으로 나눌 때 엔트로피가 작다면 해당 속성을 기준으로 데이터를 나누기 좋음 (분할 속성)

$$Gain(\mathcal{D}, A) = h(\mathcal{D}) - h_A(\mathcal{D})$$

    ➢ 속성별 엔트로피

    ❖ 속성 A로 분류했을 때 A의 모든 클래스의 각 엔트로피를 계산한 후, 데이터의 개수만큼 가중치 부여

$$h_A(\mathcal{D}) = \sum_{v \in Values(A)} \frac{|\mathcal{D}_v|}{|\mathcal{D}|} \times h(\mathcal{D}_v)$$

$Values(A)$: 속성 A가 가질 수 있는 값의 집합

$\mathcal{D}_v$: 속성 A의 값이 v인 데이터의 집합

의사결정나무의 성장

ID3 알고리즘을 활용한 의사결정나무의 성장

- 성장(grow) : 일반적으로 의사결정나무를 생성하는 방법을 성장이라고 부름
  각 노드에서 엔트로피가 최대로 감소하도록 하는 분할 속성을 결정하는 과정
  - ✓ ID3(Iterative Dichotomiser 3) : 반복적으로(iteratively) 데이터를 나누는(divides) 알고리즘
    - ➢ 탑다운 방식으로 정보이득을 최대화하는 탐욕적(greedy) 방식의 최적화 알고리즘
    - ➢ 각 노드마다 반복적으로 계산된 정보이득을 기반으로 노드별 데이터 분류 기준(속성)을 정함

$$\begin{cases} Gain(\mathcal{D}, age) = h(\mathcal{D}) - h_{age}(\mathcal{D}) \\ Gain(\mathcal{D}, income) = h(\mathcal{D}) - h_{income}(\mathcal{D}) \\ Gain(\mathcal{D}, student) = h(\mathcal{D}) - h_{student}(\mathcal{D}) \\ Gain(\mathcal{D}, credit) = h(\mathcal{D}) - h_{credit}(\mathcal{D}) \end{cases}$$

* 특정 노드에서 어떤 속성의 정보이득이 가장 높은지 탐색하여 해당 노드의 분류 기준으로 선정

〈수식3〉 컴퓨터 구매 여부 데이터 기반 정보 이득 연산 예시

의사결정나무의 성장

- **나이 기준의 정보이득**

$$Gain(\mathcal{D}, age) = h(\mathcal{D}) - h_{age}(\mathcal{D})$$

나이 속성에 부여 가능한 값은 청소년, 청년, 중년

$$h_{age}(\mathcal{D}) = \frac{5}{14} \times \left(-\frac{2}{5}\log\frac{2}{5} - \frac{3}{5}\log\frac{3}{5}\right) + \frac{4}{14} \times \left(-\frac{4}{4}\log\frac{4}{4}\right) + \frac{5}{14} \times \left(-\frac{3}{5}\log\frac{3}{5} - \frac{2}{5}\log\frac{2}{5}\right)$$

나이 기준 정보이득은 0.94 − 0.693 = 0.247

번호	나이 (x_{i1})	수입 (x_{i2})	학생 여부 (x_{i3})	신용 등급 (x_{i4})	구매 여부 (y_i)
1	청소년	고소득층	아니오	좋음	미구매
2	청소년	고소득층	아니오	아주좋음	미구매
3	청년	고소득층	아니오	좋음	구매
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주좋음	미구매
7	청년	저소득층	예	아주좋음	구매
8	청소년	중소득층	아니오	좋음	미구매
9	청소년	저소득층	예	좋음	구매
10	중년	중소득층	예	좋음	구매
11	청소년	중소득층	예	아주좋음	구매
12	청년	중소득층	아니오	아주좋음	구매
13	청년	고소득층	예	좋음	구매
14	중년	중소득층	아니오	아주좋음	미구매

〈표2〉 컴퓨터 구매 여부 데이터 예시

의사결정나무의 성장

- **수입 기준의 정보이득**

$Gain(\mathcal{D}, income) =$

수입 속성에 부여 가능한 값은 고소득층, 중소득층, 저소득층

$h_{income}(\mathcal{D}) =$ _____

_____

_____

수입 기준 정보이득은 – =

번호	나이 (x_{i1})	수입 (x_{i2})	학생 여부 (x_{i3})	신용 등급 (x_{i4})	구매 여부 (y_i)
1	청소년	고소득층	아니오	좋음	미구매
2	청소년	고소득층	아니오	아주좋음	미구매
3	청년	고소득층	아니오	좋음	구매
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주좋음	미구매
7	청년	저소득층	예	아주좋음	구매
8	청소년	중소득층	아니오	좋음	미구매
9	청소년	저소득층	예	좋음	구매
10	중년	중소득층	예	좋음	구매
11	청소년	중소득층	예	아주좋음	구매
12	청년	중소득층	아니오	아주좋음	구매
13	청년	고소득층	예	좋음	구매
14	중년	중소득층	아니오	아주좋음	미구매

〈표2〉 컴퓨터 구매 여부 데이터 예시

의사결정나무의 성장

- **수입 기준의 정보이득**

$$Gain(\mathcal{D}, income) = h(\mathcal{D}) - h_{income}(\mathcal{D})$$

수입 속성에 부여 가능한 값은 고소득층, 중소득층, 저소득층

$$h_{income}(\mathcal{D}) = \frac{4}{14} \times \left(-\frac{2}{4}\log\frac{2}{4} - \frac{2}{4}\log\frac{2}{4}\right) + \frac{6}{14} \times \left(-\frac{4}{6}\log\frac{4}{6} - \frac{2}{6}\log\frac{2}{6}\right) + \frac{4}{14} \times \left(-\frac{3}{4}\log\frac{3}{4} - \frac{1}{4}\log\frac{1}{4}\right)$$

수입 기준 정보이득은 0.94 − 0.911 = 0.029

번호	나이 (x_{i1})	수입 (x_{i2})	학생 여부 (x_{i3})	신용 등급 (x_{i4})	구매 여부 (y_i)
1	청소년	고소득층	아니오	좋음	미구매
2	청소년	고소득층	아니오	아주좋음	미구매
3	청년	고소득층	아니오	좋음	구매
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주좋음	미구매
7	청년	저소득층	예	아주좋음	구매
8	청소년	중소득층	아니오	좋음	미구매
9	청소년	저소득층	예	좋음	구매
10	중년	중소득층	예	좋음	구매
11	청소년	중소득층	예	아주좋음	구매
12	청년	중소득층	아니오	아주좋음	구매
13	청년	고소득층	예	좋음	구매
14	중년	중소득층	아니오	아주좋음	미구매

〈표2〉 컴퓨터 구매 여부 데이터 예시

의사결정나무의 성장

- **학생 여부 기준의 정보이득**

$Gain(\mathcal{D}, student) =$

학생 여부 속성에 부여 가능한 값은 예, 아니오

$h_{student}(\mathcal{D}) =$ _____

_____

학생 여부 기준 정보이득은 – =

번호	나이 (x_{i1})	수입 (x_{i2})	학생 여부 (x_{i3})	신용 등급 (x_{i4})	구매 여부 (y_i)
1	청소년	고소득층	아니오	좋음	미구매
2	청소년	고소득층	아니오	아주좋음	미구매
3	청년	고소득층	아니오	좋음	구매
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주좋음	미구매
7	청년	저소득층	예	아주좋음	구매
8	청소년	중소득층	아니오	좋음	미구매
9	청소년	저소득층	예	좋음	구매
10	중년	중소득층	예	좋음	구매
11	청소년	중소득층	예	아주좋음	구매
12	청년	중소득층	아니오	아주좋음	구매
13	청년	고소득층	예	좋음	구매
14	중년	중소득층	아니오	아주좋음	미구매

〈표2〉 컴퓨터 구매 여부 데이터 예시

의사결정나무의 성장

- **학생 여부 기준의 정보이득**

$$Gain(\mathcal{D}, student) = h(\mathcal{D}) - h_{student}(\mathcal{D})$$

학생 여부 속성에 부여 가능한 값은 예, 아니오

$$h_{student}(\mathcal{D}) = \frac{7}{14} \times \left(-\frac{6}{7}\log\frac{6}{7} - \frac{1}{7}\log\frac{1}{7}\right) + \frac{7}{14} \times \left(-\frac{3}{7}\log\frac{3}{7} - \frac{4}{7}\log\frac{4}{7}\right)$$

학생 여부 기준 정보이득은 0.94 − 0.789 = 0.151

번호	나이 (x_{i1})	수입 (x_{i2})	학생 여부 (x_{i3})	신용 등급 (x_{i4})	구매 여부 (y_i)
1	청소년	고소득층	아니오	좋음	미구매
2	청소년	고소득층	아니오	아주좋음	미구매
3	청년	고소득층	아니오	좋음	구매
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주좋음	미구매
7	청년	저소득층	예	아주좋음	구매
8	청소년	중소득층	아니오	좋음	미구매
9	청소년	저소득층	예	좋음	구매
10	중년	중소득층	예	좋음	구매
11	청소년	중소득층	예	아주좋음	구매
12	청년	중소득층	아니오	아주좋음	구매
13	청년	고소득층	예	좋음	구매
14	중년	중소득층	아니오	아주좋음	미구매

〈표2〉 컴퓨터 구매 여부 데이터 예시

의사결정나무의 성장

- **신용 등급 기준의 정보이득**

$Gain(\mathcal{D}, credit) =$

신용 등급 속성에 부여 가능한 값은 좋음, 아주좋음

$h_{credit}(\mathcal{D}) =$ _____

_____

신용 등급 기준 정보이득은 – =

번호	나이 (x_{i1})	수입 (x_{i2})	학생 여부 (x_{i3})	신용 등급 (x_{i4})	구매 여부 (y_i)
1	청소년	고소득층	아니오	좋음	미구매
2	청소년	고소득층	아니오	아주좋음	미구매
3	청년	고소득층	아니오	좋음	구매
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주좋음	미구매
7	청년	저소득층	예	아주좋음	구매
8	청소년	중소득층	아니오	좋음	미구매
9	청소년	저소득층	예	좋음	구매
10	중년	중소득층	예	좋음	구매
11	청소년	중소득층	예	아주좋음	구매
12	청년	중소득층	아니오	아주좋음	구매
13	청년	고소득층	예	좋음	구매
14	중년	중소득층	아니오	아주좋음	미구매

〈표2〉 컴퓨터 구매 여부 데이터 예시

의사결정나무의 성장

- **신용 등급 기준의 정보이득**

$$Gain(\mathcal{D}, credit) = h(\mathcal{D}) - h_{credit}(\mathcal{D})$$

신용 등급 속성에 부여 가능한 값은 좋음, 아주좋음

$$h_{credit}(\mathcal{D}) = \frac{8}{14} \times \left(-\frac{6}{8}\log\frac{6}{8} - \frac{2}{8}\log\frac{2}{8}\right) + \frac{6}{14} \times \left(-\frac{3}{6}\log\frac{3}{6} - \frac{3}{6}\log\frac{3}{6}\right)$$

신용 등급 기준 정보이득은 0.94 − 0.892 = 0.048

번호	나이 (x_{i1})	수입 (x_{i2})	학생 여부 (x_{i3})	신용 등급 (x_{i4})	구매 여부 (y_i)
1	청소년	고소득층	아니오	좋음	미구매
2	청소년	고소득층	아니오	아주좋음	미구매
3	청년	고소득층	아니오	좋음	구매
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주좋음	미구매
7	청년	저소득층	예	아주좋음	구매
8	청소년	중소득층	아니오	좋음	미구매
9	청소년	저소득층	예	좋음	구매
10	중년	중소득층	예	좋음	구매
11	청소년	중소득층	예	아주좋음	구매
12	청년	중소득층	아니오	아주좋음	구매
13	청년	고소득층	예	좋음	구매
14	중년	중소득층	아니오	아주좋음	미구매

〈표2〉 컴퓨터 구매 여부 데이터 예시

의사결정나무의 성장

- 다른 속성들의 정보이득과 가지 속성
  - ID3 알고리즘의 순서에 따라 정보 이득이 가장 큰 "나이" 속성이 첫 번째 분할 속성

$$Gain(\mathcal{D}, age) = h(\mathcal{D}) - h_{age}(\mathcal{D}) = 0.247$$
$$Gain(\mathcal{D}, income) = h(\mathcal{D}) - h_{income}(\mathcal{D}) = 0.029$$
$$Gain(\mathcal{D}, student) = h(\mathcal{D}) - h_{student}(\mathcal{D}) = 0.151$$
$$Gain(\mathcal{D}, credit) = h(\mathcal{D}) - h_{credit}(\mathcal{D}) = 0.048$$

  - 나이 속성 기준으로 데이터를 나누어 트리 생성

어떤 나이층에 속하나요?

청소년

번호	나이 (x_{i1})	수입 (x_{i2})	학생 여부 (x_{i3})	신용 등급 (x_{i4})	구매 여부 (y_i)
1	청소년	고소득층	아니오	좋음	미구매
2	청소년	고소득층	아니오	아주좋음	미구매
8	청소년	중소득층	아니오	좋음	미구매
9	청소년	저소득층	예	좋음	구매
11	청소년	중소득층	예	아주좋음	구매

청년

구매

중년

번호	나이 (x_{i1})	수입 (x_{i2})	학생 여부 (x_{i3})	신용 등급 (x_{i4})	구매 여부 (y_i)
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주좋음	미구매
10	중년	중소득층	예	좋음	구매
14	중년	중소득층	아니오	아주좋음	미구매

〈그림6〉 나이 기준 분할 속성으로 만든 트리

의사결정나무의 성장

- 두 번째 분할 속성을 정하기 위한 연산
  - "청소년"과 "중년" 데이터에 대한 정보 이득을 연산
  - "청년"의 경우 모두 컴퓨터를 구입한다는 데이터이므로 더 이상 데이터 분류 필요 X

번호	나이 (x_{i1})	수입 (x_{i2})	학생 여부 (x_{i3})	신용 등급 (x_{i4})	구매 여부 (y_i)
1	청소년	고소득층	아니오	좋음	미구매
2	청소년	고소득층	아니오	아주좋음	미구매
8	청소년	중소득층	아니오	좋음	미구매
9	청소년	저소득층	예	좋음	구매
11	청소년	중소득층	예	아주좋음	구매

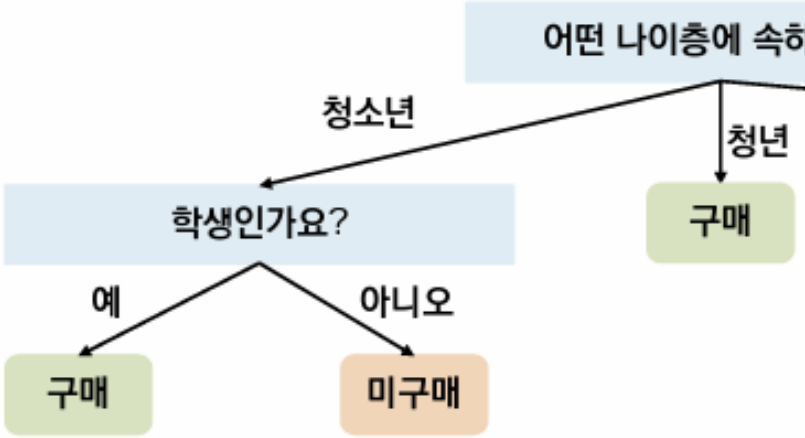
〈표3〉 나이 기준 분할 속성으로 만든 트리 (청소년 데이터)

  - 나이가 청소년으로 분류된 5개의 데이터에 대한 정보 이득

$$Gain(\mathcal{D}_{youth}, income) = h(\mathcal{D}_{youth}) - h_{income}(\mathcal{D}_{youth}) = 0.571$$
$$Gain(\mathcal{D}_{youth}, student) = h(\mathcal{D}_{youth}) - h_{student}(\mathcal{D}_{youth}) = 0.971$$
$$Gain(\mathcal{D}_{youth}, credit) = h(\mathcal{D}_{youth}) - h_{credit}(\mathcal{D}_{youth}) = 0.019$$

의사결정나무의 성장

- 두 번째 분할 속성을 정하기 위한 연산
  - 청소년 데이터를 학생 여부를 기준으로 분리했을 때 가장 정보이득이 큼



번호	나이 (x_{i1})	수입 (x_{i2})	학생 여부 (x_{i3})	신용 등급 (x_{i4})	구매 여부 (y_i)
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주좋음	미구매
10	중년	중소득층	예	좋음	구매
14	중년	중소득층	아니오	아주좋음	미구매

번호	나이 (x_{i1})	수입 (x_{i2})	학생 여부 (x_{i3})	신용 등급 (x_{i4})	구매 여부 (y_i)
1	청소년	고소득층	아니오	좋음	미구매
2	청소년	고소득층	아니오	아주좋음	미구매
8	청소년	중소득층	아니오	좋음	미구매
9	청소년	저소득층	예	좋음	구매
11	청소년	중소득층	예	아주좋음	구매

〈그림7〉 두 번째 분할 속성을 적용한 트리 (청소년)

의사결정나무의 성장

- 두 번째 분할 속성을 정하기 위한 연산
  - "중년" 데이터에 대한 정보이득을 연산

번호	나이 (x_{i1})	수입 (x_{i2})	학생 여부 (x_{i3})	신용 등급 (x_{i4})	구매 여부 (y_i)
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주좋음	미구매
10	중년	중소득층	예	좋음	구매
14	중년	중소득층	아니오	아주좋음	미구매

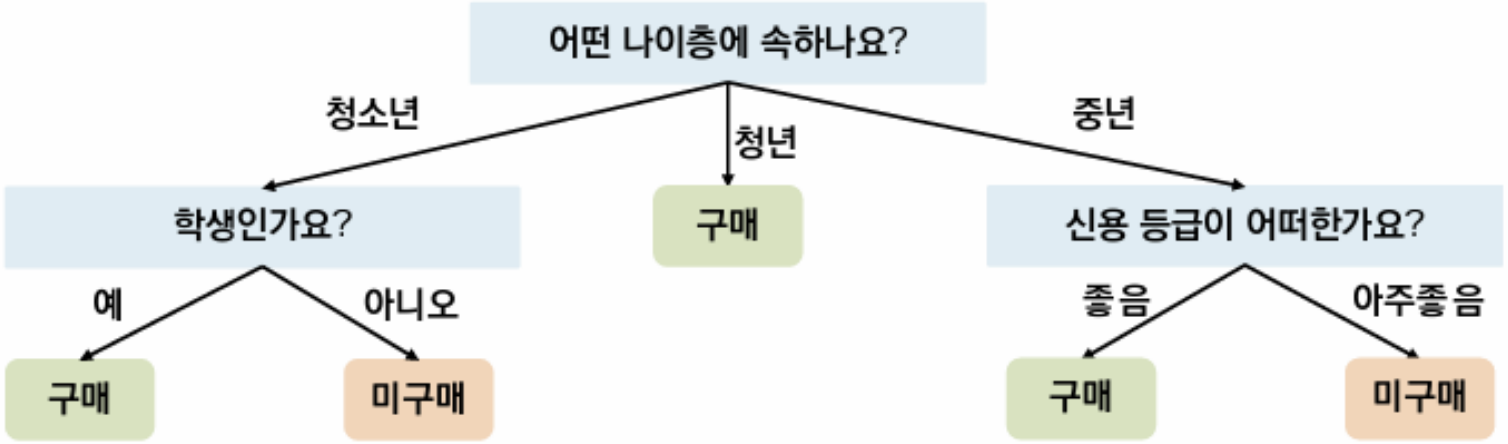
〈표4〉 나이 기준 분할 속성으로 만든 트리 (중년 데이터)

  - 나이가 중년으로 분류된 5개의 데이터에 대한 정보이득

$$Gain(\mathcal{D}_{senior}, income) = h(\mathcal{D}_{senior}) - h_{income}(\mathcal{D}_{senior}) = 0.019$$
$$Gain(\mathcal{D}_{senior}, student) = h(\mathcal{D}_{senior}) - h_{student}(\mathcal{D}_{senior}) = 0.019$$
$$Gain(\mathcal{D}_{senior}, credit) = h(\mathcal{D}_{senior}) - h_{credit}(\mathcal{D}_{senior}) = 0.971$$

의사결정나무의 성장

- 두 번째 분할 속성을 정하기 위한 연산
  - 중년 데이터를 신용 등급을 기준으로 분리했을 때 가장 정보이득이 큼

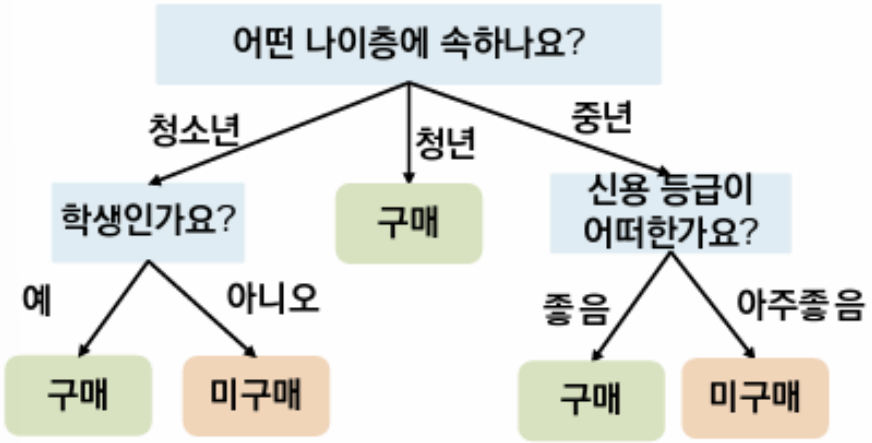


〈그림8〉 두 번째 분할 속성을 적용한 트리 (중년)

번호	나이 (x_{i1})	수입 (x_{i2})	학생 여부 (x_{i3})	신용 등급 (x_{i4})	구매 여부 (y_i)
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주좋음	미구매
10	중년	중소득층	예	좋음	구매
14	중년	중소득층	아니오	아주좋음	미구매

의사결정나무의 성장

- ID3 알고리즘을 이용한 의사결정나무



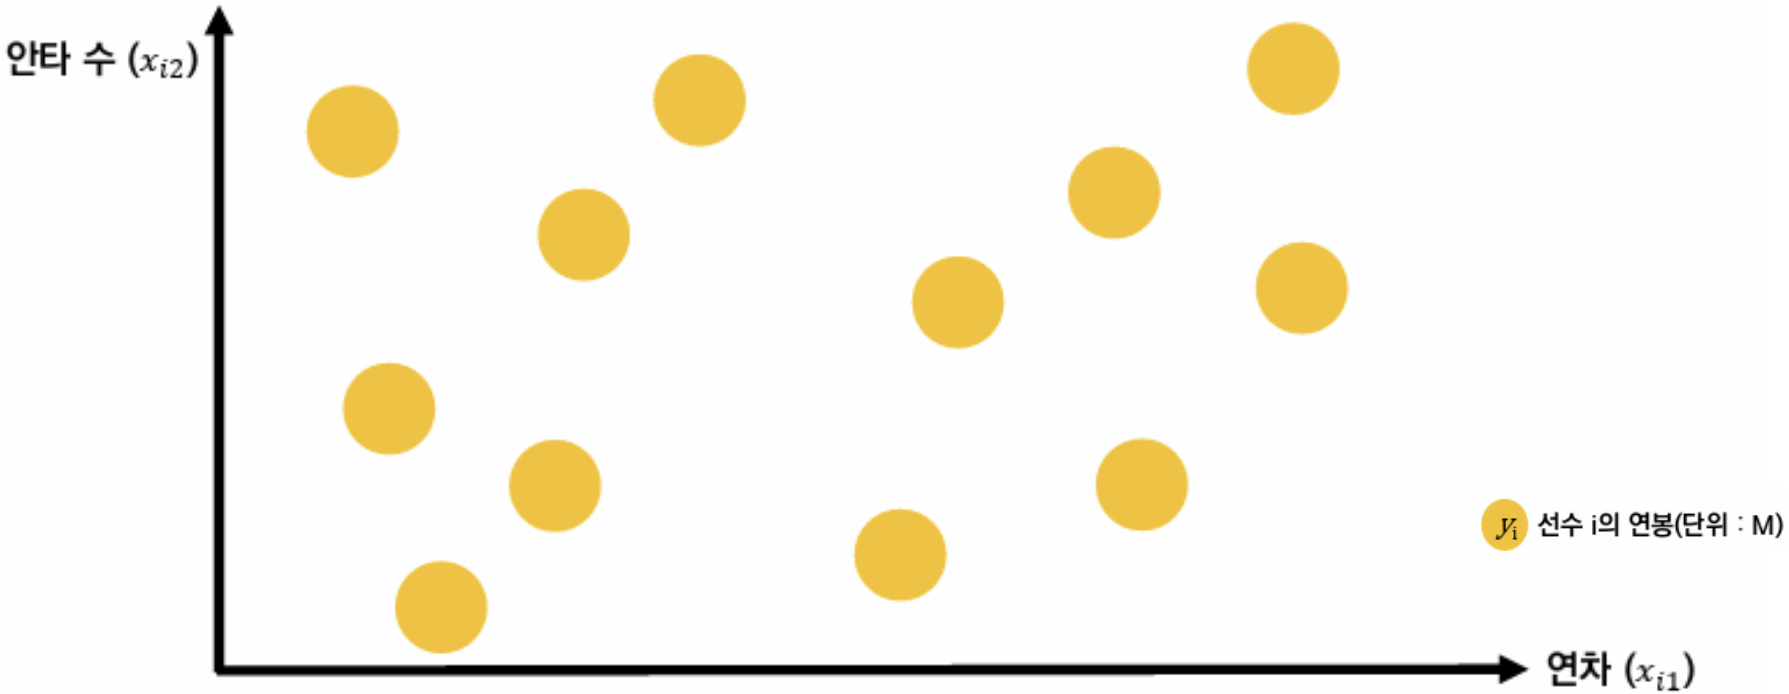
〈그림9〉 컴퓨터 구매 여부 데이터로 만든 의사결정 나무

번호	나이 (x_{i1})	수입 (x_{i2})	학생 여부 (x_{i3})	신용 등급 (x_{i4})	구매 여부 (y_i)
1	청소년	고소득층	아니오	좋음	미구매
2	청소년	고소득층	아니오	아주좋음	미구매
3	청년	고소득층	아니오	좋음	구매
4	중년	중소득층	아니오	좋음	구매
5	중년	저소득층	예	좋음	구매
6	중년	저소득층	예	아주좋음	미구매
7	청년	저소득층	예	아주좋음	구매
8	청소년	중소득층	아니오	좋음	미구매
9	청소년	저소득층	예	좋음	구매
10	중년	중소득층	예	좋음	구매
11	청소년	중소득층	예	아주좋음	구매
12	청년	중소득층	아니오	아주좋음	구매
13	청년	고소득층	예	좋음	구매
14	중년	중소득층	아니오	아주좋음	미구매

〈표2〉 컴퓨터 구매 여부 데이터 예시

회귀나무

- 회귀나무
  - 〈그림 10〉과 같이 회귀 데이터의 경우 잎노드가 회귀값인 회귀나무를 만들 수 있음
  - 아래 데이터를 회귀나무로 만드는 과정을 Step1~ Step3에 따라 알아보도록 하자



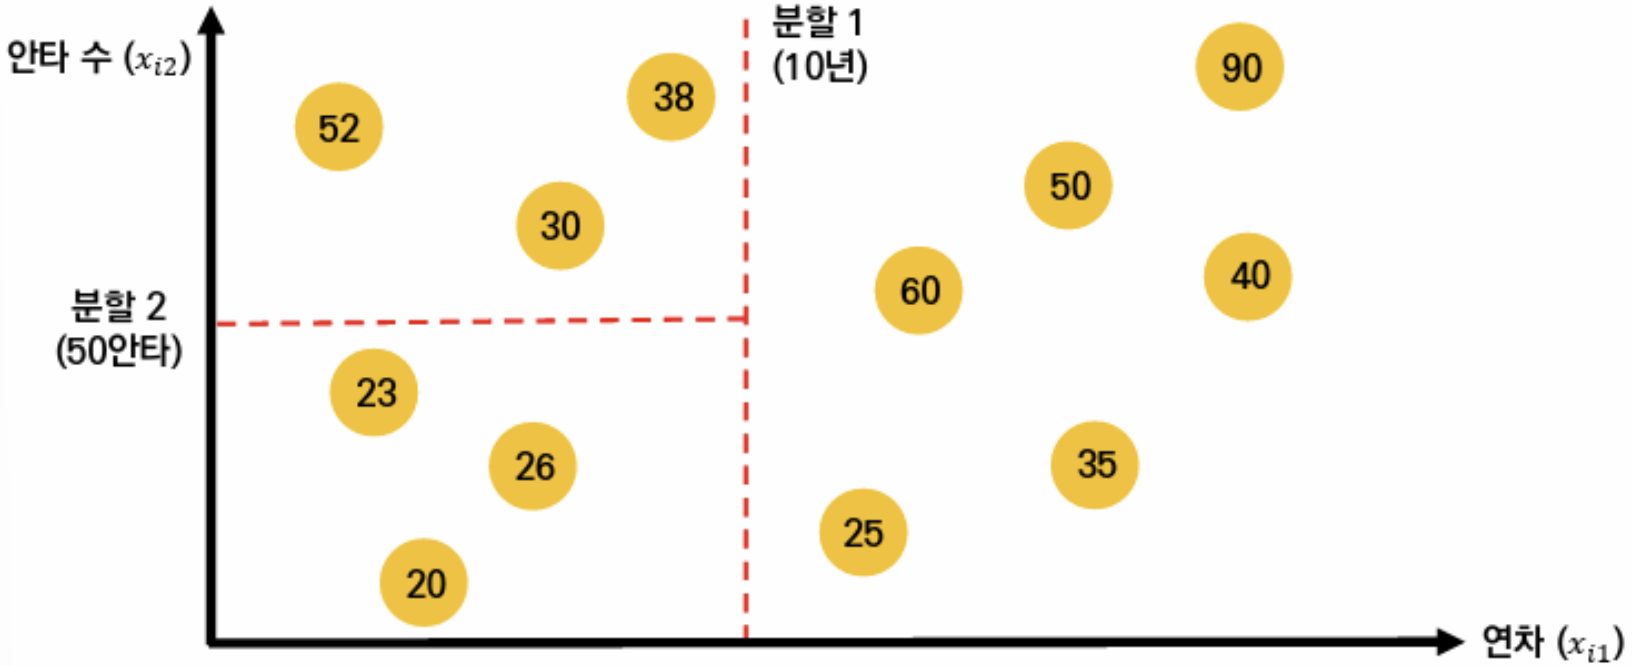
〈그림 10〉 연차와 안타 수에 따른 프로야구 선수의 연봉 (회귀 데이터)

회귀나무

- **회귀나무**

※속성별 분산을 구해 분할 기준을 정하는 방법 등이 존재

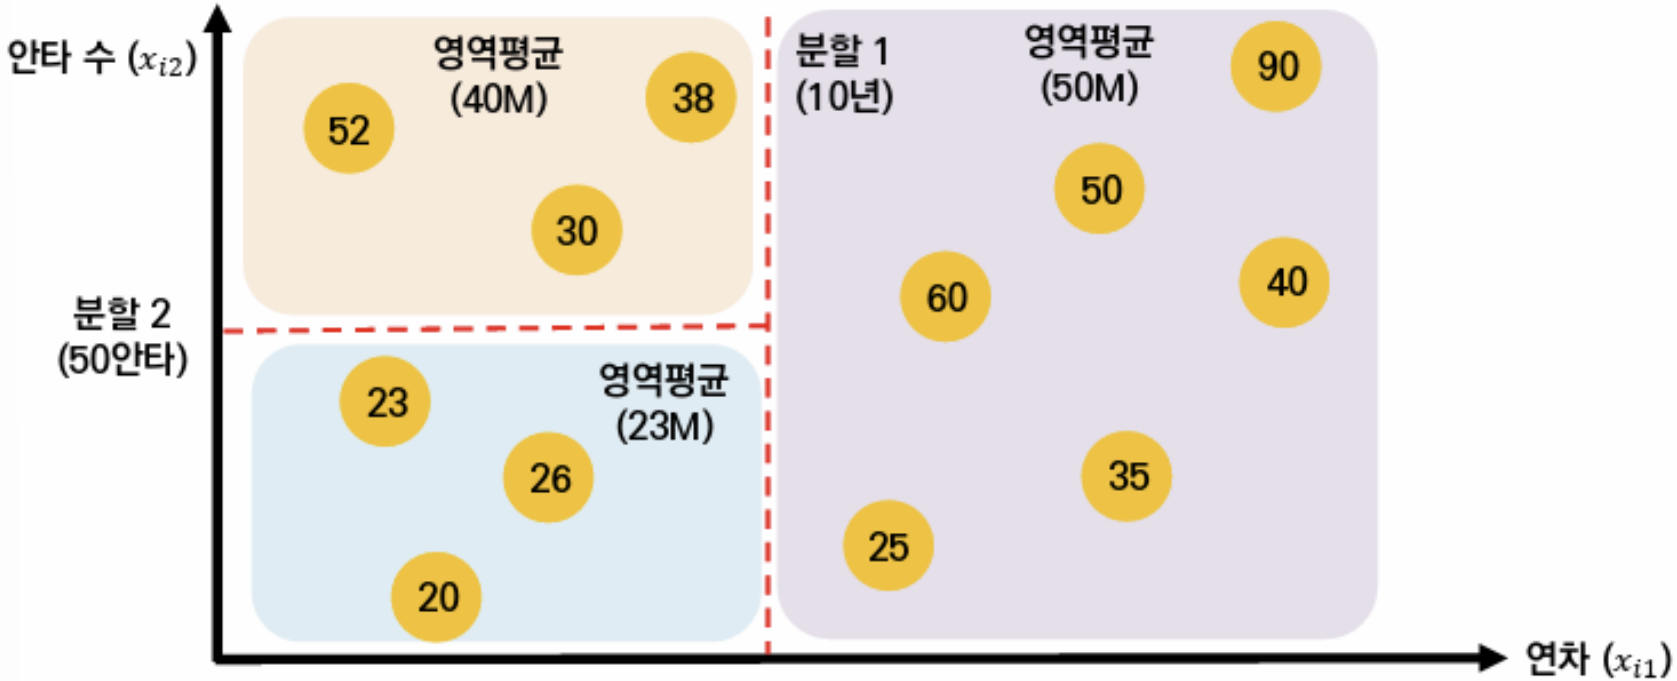
  - Step1. 데이터 분할
    - ✓ 영역을 나누고 분할 기준을 확인



〈그림 10〉 연차와 안타 수에 따른 프로야구 선수의 연봉 (회귀 데이터)

회귀나무

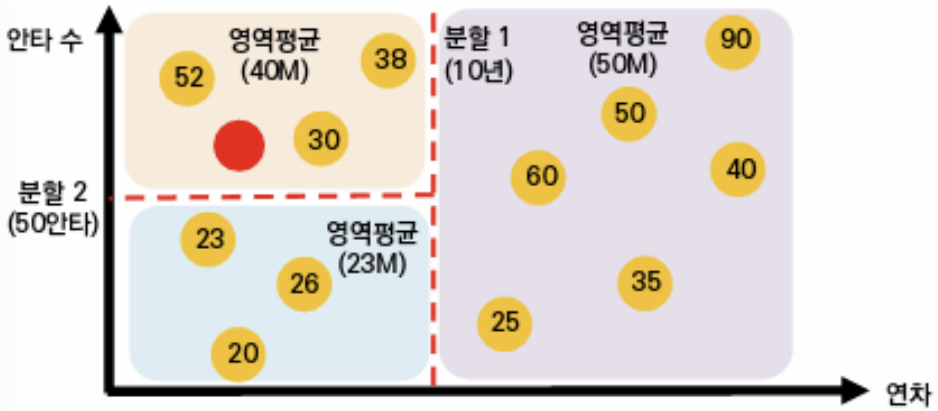
- 회귀나무
  - Step2. 영역별 평균 값 계산
    - ✓ 해당 영역별 평균 값을 회귀나무에서 잎노드의 값으로 설정



〈그림 10〉 연차와 안타 수에 따른 프로야구 선수의 연봉 (회귀 데이터)

회귀나무

- 회귀나무
  - Step3. 분할 기준과 영역 평균으로 회귀 나무 생성
    - ✓ 회귀값이 각 관측치 영역의 평균임
    - ✓ 새로운 관측치 ●의 예측 연봉은 얼마인가?



〈그림 10〉 프로야구 선수의 연봉



〈그림 11〉 프로야구 선수의 연봉(회귀나무)

질문 및 정리

