



CHAPTER 2

자연어처리를 위한 수학과 언어학의 기본 원리

자연어처리에 필요한 수학적·언어학적 기초는 무엇인가?


학습 목표

- 확률과 통계의 기초 (확률변수, 확률분포, 조건부확률, 베이즈 정리)
- MLE와 MAP (최대우도추정 · 최대사후확률추정과 스무딩)
- 정보이론과 엔트로피 (정보량, 교차엔트로피, KL-divergence, Perplexity)
- 자연어처리를 위한 선형대수 (벡터, 내적, 코사인 유사도, 행렬, SVD)
- 언어학 개요와 언어의 층위
- 형태론 : 음절, 형태소, 어절 그리고 품사
- 통사론 : 구구조와 의존구조
- 의미론과 화용론

이번 주차의 질문

- 자연어처리를 공부하는 데 왜 수학과 언어학이 필요한가?
- (수학) 언어는 불확실한 현상 → 확률로 모델링하고, 벡터·행렬로 계산한다
- (언어학) 무엇을 모델링할 것인가? → 언어의 구조와 단위를 알아야 한다

2주차 종합 : 수학과 언어학이 만나 자연어처리가 된다



2.1 확률의 기초

- 사람의 언어는 불확실한 현상으로 구성되어 있음
 - "사과"라는 단어 다음에 "맛있다"가 나올 가능성은 얼마나 되는가?
 - 같은 문장도 문맥에 따라 다르게 해석됨 → 많은 불확실성을 내포
- 확률(probability)이란 어떤 사건(event)이 발생할 가능성을 수치로 나타낸 것
 - 불확실한 자연어 현상을 정량적으로 분석 · 예측할 수 있게 해 주는 언어
- 현대 자연어처리의 거의 모든 모델은 확률 모델임
 - 언어모델 : 다음 단어의 확률분포를 예측 $P(\text{다음 단어} \mid \text{앞의 단어들})$
 - 분류 · 번역 · 요약 : 가장 확률이 높은 출력을 선택

$$P(A) = \frac{|A|}{|\Omega|}, \quad 0 \leq P(A) \leq 1, \quad \sum_{x \in \Omega} P(x) = 1$$

2.1 확률의 기초 : 표본공간과 사건


- 동전 두 개를 던지는 행위를 생각해보자
 - 앞면을 Heads(H), 뒷면을 Tails(T)라 하면 결과는 {HH, HT, TH, TT}
 - 일어날 수 있는 모든 경우의 집합을 표본공간(sample space) Ω 라고 함
 - 표본공간의 부분집합을 사건(event)이라고 함

동전 2개 던지기 : 표본공간 $\Omega = \{HH, HT, TH, TT\}$

동전1	동전2	사건	X (앞면 수)
H	H	HH	2
H	T	HT	1
T	H	TH	1
T	T	TT	0


2.1 확률의 기초 : 확률 변수

- 표본공간을 보고 $P(\{HH\}) = P(X=2) = 1/4$ 라고 답할 수 있음
- 여기서 X 를 확률 변수(random variable)라고 부름
 - 확률 변수는 표본공간의 각 표본점(결과)을 하나의 실수에 대응시키는 함수
- $X : \Omega \rightarrow \mathbb{R}$ (예 : $HH \rightarrow 2, HT \rightarrow 1, TH \rightarrow 1, TT \rightarrow 0$)
- 자연어처리에서의 확률 변수 : 다음에 올 단어, 문장의 감성 레이블, 품사 태그 등



2.1 확률의 기초 : 이산 / 연속 확률 변수

- 이산 확률 변수(discrete random variable)
 - X 가 취할 수 있는 값이 이산적으로 셀 수 있는 경우
 - 확률질량함수(PMF) $P(X=x)$ 로 분포를 표현 — 단어, 품사 등 대부분의 언어 단위
- 연속 확률 변수(continuous random variable)
 - 확률밀도함수(PDF) $f(x)$ 를 사용하며, 특정 한 점의 확률은 0
 - 구간의 확률 = 그 구간에서의 넓이(적분), 전체 넓이는 1 — 임베딩 값, 모델 파라미터 등



2.1 확률의 기초 : 결합 · 주변 · 조건부 확률

- 결합확률 $P(X, Y)$: 두 사건이 동시에 일어날 확률
- 주변확률 $P(X)$: 다른 변수를 모두 합해서 얻는 확률 (marginalization)
- 조건부확률 $P(Y|X)$: X 가 일어났다는 조건 아래 Y 가 일어날 확률

$$P(B | A) = \frac{P(A, B)}{P(A)} \quad \Rightarrow \quad P(A, B) = P(A) P(B | A)$$

결합확률 $P(X, Y)$ · 주변확률 · 조건부확률
 $P(Y=\text{긍정} | X=\text{포함}) = 0.30 / 0.35 = 0.857$


	Y = 긍정	Y = 부정	주변확률 P(X)
X : "좋다" 포함	0.30	0.05	0.35
X : "좋다" 미포함	0.25	0.40	0.65
주변확률 P(Y)	0.55	0.45	1.00

2.1 확률의 기초 : 연쇄법칙과 문장의 확률

- 조건부확률을 반복 적용하면 연쇄법칙(chain rule)을 얻을 수 있음
- 문장은 단어의 나열이므로 문장의 확률도 연쇄법칙으로 분해할 수 있음
- 그러나 앞 단어 전체를 조건으로 하면 경우의 수가 폭발 → 추정 불가능

$$P(w_1, w_2, \dots, w_n) = \prod_{i=1}^n P(w_i | w_1, \dots, w_{i-1})$$

문장의 확률을 어떻게 계산할 것인가?



$$\text{연쇄법칙 : } P(w_1, \dots, w_n) = \prod_i P(w_i | w_1^{i-1})$$

$$\text{마르코프 가정(bigram) : } P(w_i | w_1^{i-1}) \approx P(w_i | w_{i-1})$$

2.1 확률의 기초 : 독립과 마르코프 가정


- 두 사건이 독립(independent)이면 $P(A, B) = P(A) P(B)$
- 마르코프 가정 : 바로 앞의 $n-1$ 개 단어만 보면 충분하다고 가정함
 - $n=2$ 이면 bigram, $n=3$ 이면 trigram 모델
 - 현실을 단순화한 가정이지만 계산 가능한 모델을 만들어 줌
- 참고 : Transformer 기반 언어모델은 이 가정을 완화하여 긴 문맥을 직접 다룸

$$P(w_i | w_1^{i-1}) \approx P(w_i | w_{i-n+1}^{i-1})$$

2.1 확률의 기초 : 베이즈 정리

- 관측된 증거(E)를 이용해 가설(H)에 대한 믿음을 갱신하는 규칙
- 사전확률 $P(H)$ → (우도 $P(E|H)$ 반영) → 사후확률 $P(H|E)$

베이즈 정리 : 관측(E)을 통해 가설(H)에 대한 믿음을 갱신



$$P(H | E) = \frac{P(E | H) P(H)}{P(E)}$$

2.1 확률의 기초 : 베이즈 정리의 응용 (나이브 베이즈)

- 문서 분류 : 문서 d 가 주어졌을 때 가장 확률이 높은 클래스 c 를 선택
- $P(c|d) \propto P(c) P(d|c)$ 이고, 단어들이 조건부 독립이라고 "순진하게(naive)" 가정

$$\hat{c} = \arg \max_c P(c) \prod_{i=1}^n P(w_i | c)$$

나이브 베이즈 예제 : 메일 "무료 회의" 의 분류
→ $0.00160 > 0.00090$ 이므로 스팸으로 판정

	$P(c)$	$P(\text{"무료"} c)$	$P(\text{"회의"} c)$	$P(c) \cdot \prod P(w c)$
스팸 ($c=\text{spam}$)	0.40	0.20	0.02	$0.40 \times 0.20 \times 0.02 = 0.00160$
정상 ($c=\text{ham}$)	0.60	0.01	0.15	$0.60 \times 0.01 \times 0.15 = 0.00090$

2.1 확률의 기초 : 기댓값과 분산

- 기댓값(expectation)은 확률 변수의 평균과 같은 역할을 함
 - 주사위 한 개 : $E(X) = 1 \cdot 1/6 + 2 \cdot 1/6 + \dots + 6 \cdot 1/6 = 21/6 = 3.5$
 - 값과 그 값이 나올 확률의 가중평균(weighted average)
- 분산(variance)은 값들이 평균에서 얼마나 흩어져 있는지를 나타냄


$$E[X] = \sum_i x_i P(x_i) \qquad E[X] = \int_{-\infty}^{\infty} x f(x) dx$$

$$\text{Var}(X) = E[(X - \mu)^2] = E[X^2] - (E[X])^2$$

2.1 확률의 기초 : 이항분포와 다항분포

- 이항분포 $B(n, p)$: 확률 p 인 베르누이 시행을 n 번 반복할 때 성공 횟수의 분포
- 다항분포 $\text{Multi}(P)$: 이항분포의 일반화로 결과가 k 가지인 경우
- 평균 $E(x_i) = n p_i$, 분산 $\text{Var}(x_i) = n p_i(1-p_i)$
- 문서의 단어 빈도 벡터, 언어모델의 출력 분포가 대표적인 다항분포

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n - k}$$




2.1 확률의 기초 : 정규분포

- 연속 확률 분포 중 하나로 가우시안 분포(Gaussian distribution)라고도 함
- 평균 μ 와 표준편차 σ 두 개의 파라미터로 결정됨
- 신경망 가중치 초기화, 임베딩 값의 분포 등에서 널리 사용됨

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$



정규분포의 성질 : 평균 주변에 확률이 집중



참고 : 언어 데이터의 분포 — Zipf의 법칙

- 단어의 출현 빈도는 정규분포가 아니라 매우 치우친(long-tail) 분포를 따름
- 상위 소수 단어가 전체 출현의 대부분을 차지하고, 대부분의 단어는 매우 드물
- → 데이터 희소성(data sparsity) 문제의 근본 원인이며, 스무딩과 서브워드 분절의 배경


Zipf의 법칙 : 소수의 단어가 전체 출현의 대부분을 차지 ($f \propto 1/r$)



2.2 MLE와 MAP : 최대우도추정 (MLE)

- 모델의 파라미터 θ 를 데이터로부터 어떻게 정할 것인가?
- MLE : 관측된 데이터가 나타날 확률(우도)을 가장 크게 만드는 θ 를 선택
- 곱셈은 값이 작아지므로 보통 로그를 취한 로그우도를 최대화함

$$\hat{\theta}_{MLE} = \arg \max_{\theta} P(D|\theta) = \arg \max_{\theta} \sum_{i=1}^N \log P(x_i | \theta)$$



2.2 MLE와 MAP : MLE로 n-gram 확률 추정하기

- 코퍼스에서 세어본 빈도의 비율이 곧 MLE 추정값이 됨
 - 예 : $C(\text{"자연어 처리"}) = 30$, $C(\text{"자연어"}) = 50 \rightarrow P(\text{처리} \mid \text{자연어}) = 0.6$
- MLE의 한계 : 관측되지 않은 사건의 확률이 0이 되어 버림
 - 한 번도 못 본 bigram이 하나라도 있으면 문장 전체의 확률이 0이 됨

$$P_{MLE}(w_i \mid w_{i-1}) = \frac{C(w_{i-1}, w_i)}{C(w_{i-1})}$$


MLE의 0 확률 문제와 스무딩 (MAP의 실용적 형태)

bigram	빈도 c	MLE 추정	Add-1 (라플라스)
자연어 처리	30	$30/50 = 0.600$	$31/54 = 0.574$
자연어 분석	20	$20/50 = 0.400$	$21/54 = 0.389$
자연어 요리	0	$0/50 = 0.000$ (불가)	$1/54 = 0.019$ (해결)

2.2 MLE와 MAP : 최대사후확률추정 (MAP)

- MAP : 사전지식(prior)을 함께 고려하여 사후확률을 최대화하는 θ 를 선택
 - 데이터가 적을 때 사전분포가 추정값을 안정적인 쪽으로 끌어당겨 줌
 - 데이터가 많아지면 우도가 지배적이 되어 MLE와 거의 같아짐

$$\hat{\theta}_{MAP} = \arg \max_{\theta} P(\theta|D) = \arg \max_{\theta} P(D|\theta) P(\theta)$$



2.2 MLE와 MAP : 스무딩 (MAP의 실용적 형태)

- Add-k 스무딩 : 모든 사건에 가상의 빈도 k를 더해 줌 (k=1인 경우를 라플라스(add-one) 스무딩이라 함)
 - "모든 사건은 조금씩은 가능하다"는 사전 믿음을 반영한 것 → MAP 추정과 동치
 - 실무에서는 Kneser-Ney, Good-Turing 등 더 정교한 스무딩을 사용
- 딥러닝에서의 대응 개념 : 가중치 감쇠(weight decay), 라벨 스무딩 등의 정규화

$$P_{add-k}(w_i | w_{i-1}) = \frac{C(w_{i-1}, w_i) + k}{C(w_{i-1}) + k|V|}$$

2.2 MLE와 MAP : 비교


MLE vs MAP

구분	MLE (최대우도추정)	MAP (최대사후확률추정)
목적함수	$P(D \theta)$	$P(D \theta) P(\theta)$
사전지식	사용하지 않음	사전분포 $P(\theta)$ 로 반영
데이터가 많을 때	안정적, MAP와 수렴	MLE와 거의 동일해짐
데이터가 적을 때	과적합 · 0 확률 문제	사전분포가 보정 → 안정적
NLP에서의 예	n-gram 빈도 비율	Add-k 스무딩, 정규화

2.3 정보이론과 엔트로피 : 정보량

- 정보이론은 Shannon이 제안한 이론으로, 데이터의 압축률과 전송률을 최대화하는 수학적 모델에서 출발함
- 정보량(self-information) : 잘 일어나지 않는 사건일수록 정보량이 큼
- "오늘 해가 떴다" → 정보량 낮음 / "오늘 눈이 왔다(7월)" → 정보량 높음


$$I(x) = -\log_2 P(x) \quad (\text{bits})$$



2.3 정보이론과 엔트로피 : 엔트로피

- 엔트로피는 확률변수가 갖는 정보량의 평균적인 기댓값
- 어떤 정보의 불확실성이 높은지 낮은지 평가하는 지표로 사용됨
- 엔트로피 값이 높을수록 불확실성이 높다고 판단할 수 있음

$$H(X) = - \sum_{x \in \mathcal{X}} P(x) \log_2 P(x) = E[-\log_2 P(X)]$$



2.3 정보이론과 엔트로피 : 계산 예제

- 분포가 균등할수록(예측하기 어려울수록) 엔트로피가 커짐


$$\text{엔트로피 계산 예제 : } H(X) = -\sum P(x) \log_2 P(x)$$

상황	확률분포	엔트로피 H	해석
앞뒤 같은 동전	(0.5, 0.5)	1.00 bits	가장 불확실
편향된 동전	(0.9, 0.1)	0.47 bits	비교적 예측 가능
거의 확정된 동전	(0.99, 0.01)	0.08 bits	거의 확실
공정한 주사위	(1/6 × 6)	2.58 bits	선택지가 많을수록 큼

2.3 정보이론과 엔트로피 : 결합 · 조건부 엔트로피

- 결합 엔트로피 $H(X,Y)$: 두 확률 변수를 함께 볼 때의 불확실성
- 조건부 엔트로피 $H(Y|X)$: X 를 알고 난 뒤에도 남아 있는 Y 의 불확실성

$$H(X,Y) = -\sum_x \sum_y P(x,y) \log_2 P(x,y), \quad H(Y|X) = H(X,Y) - H(X)$$



2.3 정보이론과 엔트로피 : 상호정보량과 PMI

- 상호정보량 $I(X;Y)$: X를 알게 되어 줄어드는 Y의 불확실성 = 두 변수의 의존성
- PMI(점별 상호정보량) : 두 단어가 우연보다 얼마나 자주 함께 나타나는가
 - 연어(collocation) 추출, 단어 벡터(PPMI 행렬) 구성에 사용됨
 - 예 : "미역"- "국"의 PMI는 높고, "미역"- "컴퓨터"의 PMI는 낮음

$$I(X; Y) = \sum_{x, y} P(x, y) \log_2 \frac{P(x, y)}{P(x)P(y)}, \quad PMI(x, y) = \log_2 \frac{P(x, y)}{P(x)P(y)}$$

2.3 정보이론과 엔트로피 : 교차 엔트로피


- 교차 엔트로피 $H(P, Q)$: 참 분포 P 를 모델 분포 Q 로 표현할 때 필요한 평균 비트 수
- $H(P, Q) = H(P) + KL(P \parallel Q)$ 이므로, P 는 데이터가 정해 주는 고정 분포라 $H(P)$ 가 상수이므로, 교차 엔트로피를 줄이는 것과 KL 을 줄이는 것이 같음
- 딥러닝 분류 · 언어모델 학습의 표준 손실함수가 바로 교차 엔트로피임

$$H(P, Q) = - \sum_x P(x) \log_2 Q(x) = H(P) + D_{KL}(P \parallel Q)$$

2.3 정보이론과 엔트로피 : KL-divergence

- 두 분포 P와 Q가 서로 얼마나 다른지 측정하는 수단
- 값이 낮을수록 두 분포가 일치하는 정도가 높음 (항상 0 이상)
- 비대칭이므로 거리(distance)가 아니라 발산(divergence)이라고 부름
- 지식 증류, 강화학습(PPO)의 정책 제약 등에서 널리 사용됨

$$D_{KL}(P \parallel Q) = \sum_x P(x) \log_2 \frac{P(x)}{Q(x)} \geq 0$$



2.3 정보이론과 엔트로피 : Perplexity

- 언어모델의 표준 평가 지표로, 교차 엔트로피를 지수로 되돌린 값
- 직관 : "모델이 다음 단어를 고를 때 평균 몇 개의 후보 사이에서 헛갈리는가"
- 값이 낮을수록 좋은 모델

$$PPL(W) = P(w_1, \dots, w_N)^{-\frac{1}{N}} = 2^{H(P, Q)}$$

Perplexity = 2^H : 낮을수록 좋은 언어모델 (수치는 예시)

언어모델	교차엔트로피 (bits)	Perplexity	해석
Unigram	6.8	111.4	다음 단어 후보가 약 111개
Bigram	5.1	34.3	약 34개
Trigram	4.3	19.7	약 20개
신경망 LM	3.2	9.2	약 9개 → 가장 우수

2.4 자연어처리를 위한 선형대수 : 왜 벡터인가

- 컴퓨터는 문자열을 그대로 계산할 수 없음 → 단어와 문장을 수치 벡터로 바꿔야 함
- 원-핫 표현은 단순하지만 차원이 크고 의미 정보를 담지 못함
- 분산 표현(임베딩)은 조밀한 저차원 벡터로 의미의 유사성을 기하 구조로 표현함

	원-핫 표현 (One-hot)	분산 표현 (Dense embedding)
사과	[1, 0, 0, 0, ... , 0]	사과 [0.62, -0.11, 0.87, ...]
배	[0, 1, 0, 0, ... , 0]	배 [0.58, -0.09, 0.91, ...]
컴퓨터	[0, 0, 1, 0, ... , 0]	컴퓨터 [-0.42, 0.77, -0.15, ...]

· 차원 = $|V|$ (수십만)
· 모든 단어쌍의 유사도가 0
· 의미 정보 없음

· 차원 = 100~1024 (조밀)
· $\cos(\text{사과}, \text{배})$ 가 큼
· 의미가 기하 구조로 표현

2.4 선형대수 : 벡터, 노름, 내적


- 벡터 : 크기와 방향을 갖는 수의 나열 — 단어 하나가 하나의 벡터
- 노름(norm) : 벡터의 길이. 문서가 길수록 빈도 벡터의 노름이 커짐
- 내적(dot product) : 두 벡터의 크기와 방향의 일치 정도를 함께 반영하는 스칼라 값 (방향만 보려면 노름으로 나눈 코사인 유사도를 쓴다)

$$\|\mathbf{a}\|_2 = \sqrt{\sum_i a_i^2}, \quad \mathbf{a} \cdot \mathbf{b} = \sum_i a_i b_i = \|\mathbf{a}\| \|\mathbf{b}\| \cos \theta$$

2.4 선형대수 : 코사인 유사도

- 내적을 두 벡터의 노름으로 나누면 각도만 남음 → 길이의 영향을 제거
- 문서 길이나 단어 빈도의 크기와 무관하게 "의미의 방향"만 비교할 수 있음
- 검색, 문서 유사도, 임베딩 기반 추천 등에서 가장 널리 쓰이는 유사도

$$\text{sim}_{\cos}(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|} \in [-1, 1]$$



$$\cos(\theta) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|}$$

$\cos(\text{왕, 여왕}) = 0.995 \rightarrow$ 의미가 유사
 $\cos(\text{왕, 사과}) = 0.545 \rightarrow$ 의미가 다름

벡터의 "방향"이 의미의 유사도를 나타낸다

2.4 선형대수 : 행렬과 선형변환

- 행렬은 여러 벡터를 한꺼번에 다루거나, 벡터를 다른 공간으로 옮기는 변환
 - 임베딩 조회(lookup) : 원-핫 벡터에 임베딩 행렬을 곱하면 해당 행이 선택됨
 - 신경망의 한 층 = 행렬 곱 + 편향 + 비선형 함수
 - 배치 처리 : 여러 문장을 행렬로 쌓아 GPU에서 한 번에 계산

$$\mathbf{h} = \mathbf{W}\mathbf{x} + \mathbf{b}, \quad \mathbf{W} \in \mathbb{R}^{d \times |V|}, \quad \mathbf{x} \in \mathbb{R}^{|V|}$$

2.4 선형대수 : 단어-문서 행렬과 TF-IDF

- 문서 집합을 단어 × 문서 행렬로 표현하면 텍스트가 선형대수의 대상이 됨
- TF-IDF : 자주 나오지만 모든 문서에 흔한 단어의 가중치를 낮춤

$$tfidf(t, d) = tf(t, d) \times \log \frac{N}{df(t)}$$


단어-문서 행렬 (Term-Document Matrix) : 텍스트를 행렬로

자연어	3	4	0	0
처리	5	3	0	1
확률	2	3	0	0
축구	0	0	5	4
경기	0	1	3	5
선수	0	0	4	3
	문서1 (NLP)	문서2 (NLP)	문서3 (스포츠)	문서4 (스포츠)

2.4 선형대수 : 차원 축소와 특이값 분해(SVD)

- 단어-문서 행렬은 매우 크고 희소함 → 핵심 의미 구조만 남기고 압축
- SVD로 상위 k개의 특이값만 남기면 잠재 의미 분석(LSA)이 됨
- 문맥이 비슷한 단어가 같은 축으로 모이므로 (동의어뿐 아니라 반의어도 함께 모이는 것이 한계) 표면 형태가 달라도 유사도를 잡아낼 수 있음

$$\mathbf{A}_{m \times n} \approx \mathbf{U}_{m \times k} \mathbf{\Sigma}_{k \times k} \mathbf{V}_{k \times n}^T$$



m × n (희소, 고차원) 특이값 분해(SVD) : k개 특이값 k개만 남겨 핵심 의미 구조를 추출


참고 : 확률 · 선형대수가 만나는 지점 (소프트맥스)

- 벡터 내적으로 계산한 점수를 확률분포로 바꾸는 함수가 소프트맥스
 - 분자 : 문맥 벡터와 단어 벡터의 내적 → 선형대수
 - 분모 : 전체 어휘에 대한 정규화 → 확률의 합이 1
- 즉 언어모델 = 선형대수로 점수를 만들고, 확률로 해석하고, 교차 엔트로피로 학습

$$P(w_i | c) = \frac{\exp(\mathbf{u}_{w_i}^\top \mathbf{v}_c)}{\sum_{j \in V} \exp(\mathbf{u}_j^\top \mathbf{v}_c)}$$


2.5 언어학 개요

- 자연어처리를 연구하려면 자연어 자체의 원리를 이해할 필요가 있음
- 언어는 소리에서 맥락까지 여러 층위로 이루어져 있음
 - 각 층위마다 대응되는 자연어처리 과제가 존재함



2.6 음절, 형태소, 어절 그리고 품사 : 음절

- 음절(syllable) : 언어를 말하고 들을 때 하나의 덩어리로 여겨지는 최소 발화 단위
 - 한국어의 음절은 초성 · 중성 · 종성으로 이루어지는 것이 기본
 - 초성과 종성은 자음(C), 중성은 모음(V) — 모음 단독 음절도 가능
 - 자연어처리에서는 "음", "절", "은" 같은 한 글자 단위를 음절이라고 함



유니코드 : 코드포인트 = 0xAC00 + (초성 index × 588) + (중성 index × 28) + 종성 index

2.6 음절, 형태소, 어절 그리고 품사 : 형태소

- 형태소(morpheme) : 의미를 가지는 가장 작은 단위
 - 더 쪼개면 기능이나 의미를 갖지 않게 됨
- 실질 형태소(어휘 형태소) : 실질적인 의미를 갖는 형태소 (명사·대명사·수사·관형사·부사·감탄사, 그리고 용언의 어간)
- 형식 형태소(문법 형태소) : 문법적 기능을 하는 형태소 (조사·어미·접사)
- 자립성 기준으로는 자립 형태소와 의존 형태소로도 나눔
 - 이형태 : 하나의 형태소가 환경에 따라 다른 모습으로 나타나는 것 (이/가, 을/를)

2.6 음절, 형태소, 어절 그리고 품사 : 형태소 분석

- 한국어는 교착어이므로 어절 하나에 여러 형태소가 결합됨
- 따라서 단순 띄어쓰기 분리만으로는 의미 단위를 얻을 수 없음

"철수가 학교에 갔다" → 형태소 분석

철수	가	학교	에	가	았	다
NNP	JKS	NNG	JKB	W	EP	EF
명사(실질)	주격조사(형식)	명사(실질)	부사격조사(형식)	동사 어간(실질)	선어말어미(형식)	종결어미(형식)

파란색 : 실질(어휘) 형태소

주황색 : 형식(문법) 형태소

2.6 음절, 형태소, 어절 그리고 품사 : 어절

- 어절 : 한 개 이상의 형태소가 모여 구성된 단위
 - 발화할 때 끊어서 말하는 단위이며, 글에서는 띄어쓰기 단위와 거의 일치함
- 교착어인 한국어의 특징
 - "학교" + "에서" + "는" 처럼 조사가 계속 붙어 어절의 종류가 폭발적으로 많아짐
 - 어절을 그대로 어휘로 쓰면 미등록어(OOV)가 급증 → 형태소 분석 또는 서브워드 분절 필요
- 영어는 굴절어이지만 굴절이 약화되어 분석적(analytic) 성격이 강하므로, 기능어가 독립 단어로 분리되어 공백 토큰화만으로도 상당 부분 처리 가능 (언어별 차이)

2.6 음절, 형태소, 어절 그리고 품사 : 품사

- 품사(Part-of-Speech) : 단어를 문법적 성질에 따라 분류한 갈래
- 기능에 따라 체언 · 수식언 · 관계언 · 독립언 · 용언의 5언
- 의미에 따라 명사 · 대명사 · 수사 · 관형사 · 부사 · 조사 · 감탄사 · 동사 · 형용사의 9품사
- 형태에 따라 가변어와 불변어

한국어 품사 체계 : 기능(5언) × 의미(9품사) × 형태(가변/불변)

5언 (기능)	9품사 (의미)	형태	예시
체언	명사 · 대명사 · 수사	불변어	사과, 나, 하나
수식언	관형사 · 부사	불변어	새(옷), 매우
관계언	조사	불변어(서술격조사 제외)	이/가, 을/를, 은/는
독립언	감탄사	불변어	아이고, 글썄요
용언	동사 · 형용사	가변어 (활용)	먹다, 예쁘다

관계언 : 주로 체언 뒤에 붙지만 부사·어미·다른 조사 뒤에도 붙어 문법적 관계나 의미를 더하는 의존 형태소 = 조사

- 체언 : 문장에서 주체가 되는 자리에 쓰임 (명사 · 대명사 · 수사)
- 수식언 : 다른 말을 꾸며 주는 단어
 - 관형사는 체언 앞에서 체언을 꾸밈 (성상 · 지시 · 수 관형사)
 - 부사는 주로 용언이나 문장 전체를 꾸밈 (성상 · 지시 · 부정 · 양태 · 접속 부사)
- 관계언 : 자립 형태소에 붙어 문법적 관계를 나타내는 의존 형태소 = 조사
 - 격조사(주격 · 목적격 · 관형격 · 부사격 · 호격 · 보격 · 서술격), 접속조사, 보조사
- 독립언 : 다른 성분과 관계없이 독립적으로 쓰이는 감탄사

2.6 품사 : 용언과 활용

- 용언 : 어미를 활용하여 서술어 기능을 하는 말 (동사 · 형용사)
- 용언은 어간(변하지 않는 부분)과 어미(변하는 부분)로 이루어짐
 - 어말 어미 : 종결 어미 · 연결 어미 · 전성 어미
 - 선어말 어미 : 시제 선어말 어미(-았/었-, -겠-), 높임 선어말 어미(-시-)
- 동사의 분류 : 자동사/타동사, 능동사/피동사, 주동사/사동사, 본동사/보조동사, 규칙/불규칙
- 활용 때문에 한국어는 표면형의 종류가 매우 많음 → 형태소 분석기의 원형 복원 단계가 이를 처리함 (영어의 lemmatization 에 대응)

2.6 품사 : 품사 태깅과 중의성


- 품사 태깅(POS tagging) : 문맥을 보고 각 형태소에 올바른 품사를 부여하는 과제
 - 표기가 같아도 문맥에 따라 분석 결과가 달라짐 → 자동 분석이 필요한 이유
 - 대표 태그셋 : 세종 태그셋(Komoran · Mecab-ko 가 이를 따름)과 자체 태그셋을 쓰는 Okt

같은 표기, 다른 분석 — 품사 태깅이 필요한 이유

"나는 학생이다"	나 / NP + 는 / JX	대명사 + 보조사
"새가 하늘을 나는다"	날 / VV + 는 / ETM	동사 어간 + 관형형어미

2.7 구구조와 의존구조 : 구구조

- 구구조(phrase structure) : 문장 요소들이 서로 결합하여 이루는 계층적 구조
 - 구성 요소들은 선행 관계와 지배 관계를 맺고 있음
 - 수형도(tree) 또는 괄호 표기로 나타냄
 - 단어 배열이 비교적 고정된 영어와 같은 언어 분석에 많이 쓰임



구구조(Phrase Structure) : 문장을 구(phrase) 단위로 계층적으로 분해

2.7 구구조와 의존구조 : 문맥자유문법(CFG)

- 구구조는 다시 쓰기 규칙(rewriting rule)의 집합으로 형식화할 수 있음
- 유한한 규칙으로 무한한 문장을 생성할 수 있음 (생성 문법)

문맥자유문법 (CFG) 규칙

```
S → NP VP
VP → V NP
VP → V NP PP
NP → Det N
NP → NP PP
PP → P NP
```

어휘 규칙 (Lexicon)


```
Det → the | a
N → man | glasses
V → saw
P → with
```

규칙의 조합으로 무한한 문장을 생성 (생성 문법)


2.7 구구조와 의존구조 : 구조적 중의성

- 하나의 문장이 둘 이상의 구구조를 가질 수 있음
- "I saw the man with glasses" → 안경을 낀 남자를 보았다 / 안경을 끼고 남자를 보았다

구조적 중의성 : "I saw the man with glasses"



해석 1 : PP가 NP에 결합
→ "안경을 낀 남자를 보았다"




해석 2 : PP가 VP에 결합
→ "안경을 끼고 남자를 보았다"

2.7 구구조와 의존구조 : 의존 구조

- 의존구조 : 문장에 포함된 단어들이 서로 의존 관계를 이루어 구문을 형성한다고 봄
- 각 단어는 지배소(head)와 의존소(dependent)의 관계로 연결됨
- 한국어는 어순이 비교적 자유롭기 때문에 구구조보다 의존 구문 분석이 주로 이용됨

의존구조 : 단어 사이의 지배소(head) - 의존소(dependent) 관계



2.7 구구조와 의존구조 : 의존 구문 분석 방법


- 그래프 기반과 전이 기반의 두 가지 대표적 접근이 있음

의존 구문 분석의 두 가지 접근

구분	그래프 기반 (Graph-based)	전이 기반 (Transition-based)
탐색 방식	모든 후보 트리 중 최고 점수 트리 선택 (전역)	Shift / Reduce 행동을 순차적으로 결정 (지역)
정확도	전역 최적 → 긴 문장에 유리	오류 전파 가능성 있음
속도	$O(n^2) \sim O(n^3)$ · 느림	$O(n)$ · 빠름
대표 알고리즘	Eisner, MST (Chu-Liu-Edmonds)	Arc-standard, Arc-eager

2.8 의미론과 화용론 : 의미론

- 의미론 : 단어 · 문장 · 발화가 실제로 가리키는 의미와 그 관계를 다룸
 - 문법적으로 옳아도 의미가 어색하면 자연스러운 언어라 할 수 없음
 - 예 : "사료가 개를 먹었습니다"는 문법적으로 완벽하지만 의미적으로 부자연스러움
- 어휘 의미 관계 : 동의 · 반의 · 상하위 · 부분 관계 (WordNet, KorLex 등의 자원)



2.8 의미론과 화용론 : 의미역

- 의미역(semantic role) : 서술어에 대해 각 명사구가 담당하는 의미적 역할
 - 행위자 · 대상 · 수혜자 · 장소 · 도구 등
 - 의미역 결정(SRL)은 "누가 누구에게 무엇을 하였는가"를 밝히는 과제

의미역 결정 : "철수가 도서관에서 영희에게 책을 주었다"

문장 성분	의미역 (Semantic Role)	설명
철수가	행위자 (Agent)	동작을 수행하는 주체
영희에게	수혜자 (Beneficiary)	동작의 대상이 되는 사람
책을	대상 (Theme)	동작의 영향을 받는 사물
도서관에서	장소 (Location)	사건이 일어난 곳

2.8 의미론과 화용론 : 중의성 해소와 분포 가설

- 어휘 중의성 : 같은 단어가 문맥에 따라 다른 의미를 가짐 ("배" : 과일/신체/선박)
- 단어 의미 중의성 해소(WSD)는 문맥을 이용해 올바른 의미를 고르는 과제
- 분포 가설은 이 문제를 통계적으로 다루는 출발점이자 임베딩의 이론적 근거

분포 가설 (Distributional Hypothesis)

"단어의 의미는 그 주변에 나타나는 단어들로 결정된다" (Firth, 1957)

나는 어제 [] 를 마셨다.

따뜻한 [] 한 잔이 생각난다.

[] 에는 카페인이 들어 있다.



커피 / 차
(유사한 문맥 → 유사한 벡터)

→ 공기(co-occurrence) 통계 → 벡터 공간 → Word2Vec · BERT 임베딩의 출발점

2.8 의미론과 화용론 : 화용론

- 화용론 : 언어 사용자와 발화 맥락을 고려하는 연구
 - 말하는 이, 듣는 이, 시간, 장소로 구성되는 맥락 속에서 언어의 사용을 다룸
 - 대화 시스템 · 챗봇에서 특히 중요 (의도 파악, 문맥 유지, 공손성)

화용론 : 맥락 속에서의 언어 사용

개념	정의	예시
화행 (Speech Act)	발화를 통해 수행되는 행위	"창문 좀 열어 줄래?" → 요청
함축 (Implicature)	문자 그대로가 아닌 함의	"방이 좀 덥네" → 에어컨을 켜 달라
직시 (Deixis)	맥락 없이는 지시 대상 불명	"저는 내일 여기서 뵙겠습니다"
전제 (Presupposition)	참으로 가정되는 배경 정보	"철수가 담배를 끊었다" → 이전엔 피웠다

요약

- 확률의 기초 : 확률변수, 확률분포, 조건부확률과 연쇄법칙, 베이즈 정리를 살펴봄
- MLE와 MAP : 데이터로부터 파라미터를 추정하는 두 가지 원리와 스무딩을 살펴봄
- 정보이론 : 정보량 · 엔트로피 · 교차엔트로피 · KL-divergence · Perplexity를 살펴봄
- 선형대수 : 벡터 · 내적 · 코사인 유사도 · 행렬 · SVD와 텍스트 표현을 살펴봄
- 언어학 개요 : 음운 · 형태 · 통사 · 의미 · 화용의 층위를 살펴봄
- 음절, 형태소, 어절 그리고 품사에 대해서 살펴봄
- 구구조와 의존구조에 대해서 살펴봄
- 의미론과 화용론에 대해서 살펴봄

참고서적

- 임희석, 자연어처리 바이블 : 핵심이론 · 응용시스템 · 딥러닝, 휴먼사이언스
- 전창욱 외, 텐서플로 2와 머신러닝으로 시작하는 자연어 처리, 위키북스
- 홉슨 레인 외, 파이썬으로 배우는 자연어 처리 인 액션, 제이펍
- Jurafsky & Martin, Speech and Language Processing (3rd ed. draft)
- Manning & Schütze, Foundations of Statistical Natural Language Processing, MIT Press
- Goodfellow, Bengio & Courville, Deep Learning, MIT Press (Ch.2 선형대수, Ch.3 확률)

Q & A

이번 주차 내용에 대해 궁금한 점을 자유롭게 질문해 주세요