CHAPTER 7

개체명 인식, 언어 모델, 그리고 정보 추출

문장에서 유용한 정보를 어떻게 추출하는가?

학습 목표

- 개체명 인식
  - 개체명의 정의와 태그셋을 이해하고, BIO 태깅 기법으로 문장을 표현할 수 있음
  - 정밀도·재현율·F1으로 NER 시스템을 평가할 수 있음
- 언어 모델
  - 조건부 확률과 마르코프 가정으로부터 N-gram 언어 모델을 유도할 수 있음
  - 스무딩·보간법·백오프의 원리를 설명하고 퍼플렉서티로 모델을 평가할 수 있음
- 정보 추출
  - 비정형 텍스트로부터 (개체1, 관계, 개체2) 튜플을 추출하는 과정을 설명할 수 있음

목차

- 7.1 개체명 인식 (Named Entity Recognition)
- 7.2 언어 모델 (Language Model)
- 7.3 정보추출 (Information Extraction)
- 요약

7.1 개체명 인식

- 개체명 인식 구성
  - 개체명 인식 소개
  - 개체명 인식이란
  - 개체명 유형과 태그셋
  - NER 시스템
  - NER 평가 척도
  - BIO Tagging Scheme
  - 학습 코퍼스
  - 한국어 개체명 인식의 특수성

7.1 개체명 인식

- 개체명 인식 소개:
  - 텍스트에서 고유한 의미를 가지는 개체(Entity)를 자동으로 찾아내고 그 유형을 분류하는 개체명 인식(Named Entity Recognition, NER)에 대해 학습하고자 함
  - 개체명 인식이 무엇인지 예시를 통해 이해하고, 개체명 유형, NER 시스템, 평가 척도, 태깅 기법, 학습 코퍼스의 순서로 하나씩 살펴봄
  - 개체명 인식은 질의응답(Question Answering), 정보 검색(Information Retrieval), 관계 추출(Relation Extraction) 등을 위한 자연어처리 시스템의 핵심 구성요소임
  - 즉 NER은 그 자체가 최종 목적이라기보다, 상위 응용을 위한 전처리 또는 중간 표현을 만들어 주는 기반 기술의 성격을 가짐

7.1 개체명 인식

- 개체명 인식 소개:
  - 초기 NER 시스템은 사람이 직접 설계한 사전과 규칙에 의존하였기 때문에, 도메인이 바뀌면 규칙을 다시 만들어야 하는 부담이 있었음
  - 이후 통계 기반 기계학습(HMM, MEMM, CRF)이 도입되면서 주석된 학습 데이터로부터 규칙을 자동으로 학습하는 방향으로 전환됨
  - 신경망 기반 NER 시스템은 일반적으로 어휘집이나 온톨로지와 같은 특정 도메인 리소스를 필요로 하지 않기 때문에 매우 매력적이며, 최근에는 사전학습 언어모델 기반의 NER 시스템이 표준적으로 사용되고 있음
  - 본 장에서는 딥러닝 이전의 개념적 토대에 해당하는 정의, 태깅 기법, 평가 방법을 중심으로 다룸

7.1 개체명 인식

- 개체명 인식이란:
  - 사람(Person), 장소(Location), 기관(Organization), 날짜(Date) 이외에도 분야에 따라 약물, 임상 소견, 시술, 생물학적 단백질 등과 같이 명명된(named) 개체를 텍스트에서 식별하는 작업임
  - NER 시스템은 종종 질의응답, 정보 검색, 상호참조 해결, 토픽 모델링 등의 첫 번째 단계로 사용됨
  - 예를 들어 하나의 문서 내에서 주요 인물, 조직 및 장소에 대한 정보를 추출하고자 할 때, 미리 정의된 개체명 정의에 따라 해당 정보를 추출할 수 있음
  - 다음 장의 예시를 통해 개체명 인식에 대해서 좀 더 이해해 보고자 함

7.1 개체명 인식

- 개체명 인식이란:
  - 문장 1
    - 춘향아, 9월 15일에 강남에서 홍길동과 약속이 있으니까, 늦지 말고 오도록 해!
    - [사람] : 춘향, 홍길동
    - [날짜] : 9월 15일
    - [장소] : 강남
    - 태그를 문장에 직접 표시하여 시각화하면 다음과 같음
    - 춘향[PS]아, 9월 15일[DT]에 강남[LC]에서 홍길동[PS]과 약속이 있으니까, 늦지 말고 오도록 해!

7.1 개체명 인식

- 개체명 인식이란:
  - 문장 2
    - 명량 대첩은 1597년 음력 9월 16일 정유재란 때 이순신이 지휘하는 조선 수군 13척이 명량에서 일본 수군 130척 이상을 격퇴한 해전이었다.
    - 위 예시 문장에서 인식할 수 있는 정보는 다음과 같음
    - [사람] : 이순신 / [날짜] : 1597년, 음력 9월 16일 / [장소] : 명량 / [사건] : 명량 대첩, 정유재란
    - 태그를 표시하여 시각화하면 다음과 같음
    - 명량 대첩[EV]은 1597년[DT] 음력 9월 16일[DT] 정유재란[EV] 때 이순신[PS]이 지휘하는 조선 수군 13척이 명량[LC]에서 일본 수군 130척 이상을 격퇴한 해전이었다.

7.1 개체명 인식

- 개체명 인식이란:
  - 문장 1, 2의 결과 정리
    - 개체명 인식을 통해 특정 명사구에 해당하는 태그를 붙임으로써 [춘향, 홍길동, 이순신 - 사람], [강남, 명량 - 장소], [9월 15일, 1597년, 9월 16일 - 날짜]와 같이 개체명을 인식하여 분류할 수 있음
  - 경계(boundary) 문제와 유형(type) 문제
    - '정유재란'은 날짜로 볼 수도 있고 하나의 사건(Event)으로 볼 수도 있으므로, 태그셋을 어떻게 정의하느냐에 따라 정답이 달라짐
    - '조선 수군'을 기관으로 볼 것인지, '명량 대첩'을 하나의 개체로 볼 것인지도 주석 지침(annotation guideline)에 의존함
    - 따라서 NER에서는 태그셋 정의와 주석 지침이 모델 성능만큼이나 중요함

7.1 개체명 인식

- 개체명 유형과 태그셋:
  - 가장 널리 쓰이는 4종 태그셋 (CoNLL 계열)
    - PER(사람), LOC(장소), ORG(기관), MISC(기타)
  - 확장 태그셋 (OntoNotes 계열, 18종)
    - PERSON, NORP(국적/종교/정치집단), FAC(시설), ORG, GPE(행정구역), LOC, PRODUCT, EVENT, WORK_OF_ART, LAW, LANGUAGE, DATE, TIME, PERCENT, MONEY, QUANTITY, ORDINAL, CARDINAL
  - 한국어 태그셋 (TTA 표준 및 국립국어원 계열)
    - PS(사람), LC(장소), OG(기관), DT(날짜), TI(시간), QT(수량) 등 6종을 기본으로 하며, 세부 유형으로 확장하기도 함

7.1 개체명 인식

- NER 시스템:
  - 규칙 기반 시스템
    - 정규표현식, 사전(gazetteer), 문맥 단서 어휘 등을 사람이 직접 설계하여 개체명을 인식함
    - 예: '(주)', '㈜', '대학교', '병원'으로 끝나는 어절은 기관명일 가능성이 높음
    - 정밀도(precision)는 높지만 규칙이 다루지 못하는 표현에 대해 재현율(recall)이 낮고, 유지보수 비용이 큼
  - 지식 기반 시스템
    - 어휘 자원 및 도메인별 지식(온톨로지, 시소러스)에 의존하기 때문에 주석이 달린 학습 데이터를 필요로 하지 않음
    - 사전 정보가 철저할 때는 효과적이지만, 사전에 없는 신조어·신약명 등에서는 실패함

7.1 개체명 인식

- NER 시스템:
  - 지식 기반 시스템 (계속)
    - 어휘의 개방성 때문에 사전에는 존재하지 않는 표현이 계속 생성됨
    - 지식 기반 NER 시스템의 정밀도는 일반적으로 높을 수 있지만, 도메인 및 언어별 규칙과 사전의 불완전성으로 인해 재현율 값이 낮음
    - 또 다른 단점으로 지식 자원을 구성하고 유지하기 위한 도메인 전문가의 지속적인 개입이 필요하다는 점이 있음
  - 비지도 및 부트스트랩 시스템
    - 몇몇 초기 시스템들은 최소한의 학습 데이터만을 요구하였음
    - Collins & Singer (1999) 는 개체명이 포함된 단어, 문맥 등 소수의 자질만을 사용하여 시드(seed)로부터 개체를 분류·확장함
    - Nadeau et al. (2006) 은 자동 추출된 지명사전과 공개 지명사전을 결합하여 지명, 사람, 조직 개체에 대해 인식을 수행함

7.1 개체명 인식

- NER 시스템:
  - 지도학습 기반 시스템
    - 지도 방식의 기계학습 모델은 주석된 학습 데이터로부터 예측 함수를 학습하며, 사람이 만든 규칙을 대체하는 데 사용할 수 있음
    - NER은 각 토큰에 태그를 붙이는 문제이므로 전형적인 순차 레이블링(sequence labeling) 과제로 정식화됨
    - 대표 모델: 은닉 마르코프 모델(HMM), 최대 엔트로피 마르코프 모델(MEMM), 조건부 확률장(CRF)
    - 주요 자질: 단어 자체, 접두·접미사, 대소문자 패턴, 품사, 사전 일치 여부, 주변 문맥 단어
  - 신경망 기반 시스템
    - BiLSTM-CRF, 그리고 최근의 사전학습 언어모델(BERT 계열) + CRF 구조가 표준으로 사용됨
    - 자질 공학 없이도 문맥 표현을 학습하므로 도메인 이식성이 높음

7.1 개체명 인식

- NER 평가 척도:
  - NER에서는 예측된 레이블이 올바른지, 그리고 개체의 경계가 올바른지를 함께 평가해야 함
  - 정밀도(precision)는 시스템이 올바르게 예측한 개체 수를 시스템이 예측한 전체 개체 수로 나눈 값
    - Precision = TP / (TP + FP)
  - 재현율(recall)은 시스템이 올바르게 예측한 개체 수를 사람이 주석한 정답 개체 수로 나눈 값
    - Recall = TP / (TP + FN)
  - F1-Score는 정밀도와 재현율의 조화평균으로 정의함
    - F1 = 2 x Precision x Recall / (Precision + Recall)

7.1 개체명 인식

- NER 평가 척도:
  - 정확도(accuracy)를 쓰지 않는 이유
    - 실제 코퍼스에서 대부분의 토큰은 개체명이 아닌 O 태그이므로, 모든 토큰을 O로 예측해도 토큰 정확도가 90%를 넘김
    - 따라서 개체 단위의 정밀도·재현율·F1을 사용하는 것이 표준임
  - CoNLL 방식의 엄격한(strict) 평가
    - 예측한 개체의 시작 위치, 끝 위치, 유형이 모두 정답과 정확히 일치할 때에만 정답으로 인정함
    - CoNLL은 이러한 정확 일치 기준의 정밀도와 재현율의 조화평균인 F1-Score를 사용함

7.1 개체명 인식

- NER 평가 척도:
  - 완화된(relaxed) 평가
    - 개체 경계의 일부만 겹쳐도(부분 일치) 유형이 맞으면 정답으로 인정하는 방식
    - 예: 정답이 '서울 특별시'(LC)인데 '서울'(LC)만 인식한 경우, strict 기준에서는 오답이지만 relaxed 기준에서는 정답으로 인정될 수 있음
    - 의료·생명과학 분야의 shared task에서는 완화된 기준이 자주 사용됨
  - 평가 시 유의사항
    - strict와 relaxed 결과는 수 %p 이상 차이가 날 수 있으므로, 논문이나 보고서에서는 반드시 평가 기준을 명시해야 함
    - 클래스별 F1과 전체 micro/macro 평균을 함께 보고하는 것이 바람직함

7.1 개체명 인식

- NER 평가 척도:
  - 계산 예시
    - 정답 개체 8개, 시스템이 예측한 개체 10개, 그 중 정확히 일치한 개체 6개인 경우
    - Precision = 6 / 10 = 0.60
    - Recall = 6 / 8 = 0.75
    - F1 = 2 x 0.60 x 0.75 / (0.60 + 0.75) = 0.90 / 1.35 = 0.667
    - 즉 예측을 많이 할수록 재현율은 오르지만 정밀도가 떨어지므로, 두 지표의 균형을 나타내는 F1을 주 지표로 사용함

7.1 개체명 인식

- BIO Tagging Scheme:
  - BIO 태깅 기법이란 개체명을 텍스트로부터 인식시키기 위한 표현 기법 중 하나임
  - 개체명 인식을 비롯한 정보 추출 작업에서 자주 이용되는 태깅 기법
  - B는 Begin의 약자로 개체명의 시작을 나타내는 단어에 태그함
  - I는 Inside의 약자로 B 혹은 I 뒤에 이어지는 같은 개체명의 단어에 태그함
  - O는 Outside의 약자로 개체명이 아닌 나머지 단어에 태그함
  - 예를 들어 New York의 경우 (New, B-LOC), (York, I-LOC)로 태그할 수 있음
  - 이러한 표현을 사용하면 여러 토큰에 걸친 개체와 연속된 두 개체의 경계를 구분할 수 있음

7.1 개체명 인식

- BIO Tagging Scheme:
  - 영어 예시
    - Jim / bought / 300 / shares / of / Acme / Corp. / in / 2006 .
    - B-PER / O / O / O / O / B-ORG / I-ORG / O / B-DATE
      (OntoNotes 계열 DATE 태그를 함께 사용)
  - 한국어 예시 (어절 단위)
    - 춘향아 / 9월 / 15일에 / 강남에서 / 홍길동과 / 약속이 / 있으니까
    - B-PS / B-DT / I-DT / B-LC / B-PS / O / O
  - 태그 개수는 개체 유형이 N종일 때 2N + 1개가 됨 (4종이면 9개 태그)

7.1 개체명 인식

- BIO Tagging Scheme:
  - 확장된 표현 기법
    - IOB2 : 모든 개체의 첫 토큰에 항상 B를 붙임 (오늘날의 표준이며 본 실습의 BIO가 이 방식)
    - IOB1 : 기본은 I로 시작하고, 같은 유형의 개체가 바로 인접할 때만 두 번째 개체에 B를 붙임
    - BIOES(BILOU) : B(시작), I(중간), E(끝), S(단일 토큰 개체), O(비개체)로 세분화함
    - BIOES는 태그 수가 늘어나지만 개체 경계 정보를 명시적으로 학습할 수 있어 성능이 개선되는 경우가 많음
  - 디코딩 시 제약
    - I-LOC이 B-LOC 없이 등장하는 것과 같은 불법 태그열이 나올 수 있으므로, CRF나 후처리로 제약을 적용함

7.1 개체명 인식

- 학습 코퍼스:
  - NER에 대한 초기 연구 이후, NER 관련 많은 shared task 및 말뭉치가 만들어짐
  - MUC-6(1995)에서 Named Entity Task가 처음 정의되면서 NER이라는 용어가 정착됨
  - CoNLL-2002와 CoNLL-2003은 뉴스와이어 기사로부터 작성된 4가지 언어(스페인어, 네덜란드어, 영어, 독일어)에 대해 사람 PER, 장소 LOC, 조직 ORG, 기타 MISC에 해당하는 4가지 개체명으로 태그된 말뭉치임
  - OntoNotes 5.0은 뉴스, 방송, 대화, 웹 텍스트 등 다양한 장르에 대해 18종 개체명을 주석한 대규모 말뭉치임

7.1 개체명 인식

- 학습 코퍼스:
  - NER shared task에는 인도어, 아랍어, 독일어 및 슬라브어 등 다양한 언어에 대한 연구가 진행되는 작업 또한 존재함
  - 개체명 인식의 유형 체계는 말뭉치와 해당 언어·도메인의 성격에 따라 크게 달라짐
    - 동남아 언어 데이터에서는 사람, 명칭, 시간 표현, 약어, 객체 번호, 브랜드 등이 포함됨
    - 독일어 위키백과 및 온라인 뉴스 기반 데이터는 개체를 별도의 유형 체계로 지정함
    - 슬라브어 shared task는 7개 언어를 포함하고, 사람·장소·조직·기타에 대한 개체를 개체명 종류로 포함하고 있음

7.1 개체명 인식

- 학습 코퍼스:
  - 도메인 특화 말뭉치
    - 2007년에는 익명화 대상 개인 환자 정보를 찾는 임상 노트 비식별화(de-identification) 관련 task가 제안되었고, 이후에는 임상 문제, 검사 및 치료와 같은 개체명에 중점을 두기도 함
    - Drug NER shared task에서는 의약품, 브랜드명 및 신약과 같은 의약품 개체명을 중점으로 진행됨
    - 생명과학 분야의 GENIA, BC5CDR 등은 유전자·단백질·질병·화학물질 개체를 주석함
  - 한국어 말뭉치
    - 국립국어원 모두의 말뭉치(개체명 분석 말뭉치), KLUE-NER, 네이버 x 창원대 NER 데이터셋 등이 공개되어 있음

7.1 개체명 인식

- 한국어 개체명 인식의 특수성:
  - 한국어는 교착어이므로 개체명 뒤에 조사가 결합함
    - '강남에서'에서 개체명은 '강남'이고 '에서'는 조사이므로, 어절 단위 태깅은 경계를 부정확하게 만듦
    - 따라서 형태소 단위 또는 음절 단위 태깅이 널리 사용됨
  - 띄어쓰기가 불규칙하고, 한자어 기반 동형이의어가 많아 문맥 의존성이 큼
    - '배'는 문맥에 따라 과일, 선박, 신체 부위가 되며, 개체명 여부 자체가 문맥으로 결정됨
  - 최근에는 음절 단위 입력을 쓰는 사전학습 언어모델이 조사 결합 문제를 자연스럽게 완화함

7.2 언어 모델

- 언어 모델 구성
  - 언어 모델이란
  - 통계적 언어 모델과 조건부 확률
  - N-gram 언어 모델
  - 로그 확률
  - 희소성 문제와 일반화 (스무딩, 보간법, 백오프)
  - 모델 평가와 퍼플렉서티(Perplexity)

7.2 언어 모델

- 언어 모델이란:
  - 언어를 이루는 구성요소(글자, 형태소, 단어, 단어열인 문장·문단)에 확률 값을 부여하고, 이를 바탕으로 다음 구성요소를 예측하거나 생성하는 모델을 말함
  - 언어 모델은 크게 확률에 기초한 통계적 언어 모델과 인공 신경망에 기초한 딥러닝 언어 모델로 나뉨
  - 기본적으로 언어 모델은 주어진 단어를 바탕으로 다음 단어 혹은 단어들의 조합을 예측하는 일을 하며, 이를 바탕으로 문장 생성, 기계 번역, 음성 인식, 문서 요약과 같은 다양한 자연어처리 문제를 해결할 수 있음
  - 여기서는 통계적 언어 모델, 그중에서도 N-gram 언어 모델을 중심으로 설명하고자 함

7.2 언어 모델

- 언어 모델이란:
  - 언어 모델이 하는 두 가지 일
    - 확률 할당 : 주어진 단어열 W = w1 w2 … wn 에 대해 P(W)를 계산함
    - 다음 단어 예측 : 앞선 단어들이 주어졌을 때 P(w_n | w_1 … w_{n-1})을 계산함
  - 활용 예
    - 음성 인식 : '나는 밥을 먹었다'와 '나는 밥을 머것다' 중 더 그럴듯한 문장을 선택함
    - 기계 번역 : 후보 번역문 중 목표 언어에서 자연스러운 문장을 고름
    - 오타 교정, 자동 완성, 문장 생성 등

7.2 언어 모델

- 통계적 언어 모델:
  - 통계적 언어 모델(Statistical Language Model, SLM)은 단어열이 가지는 확률 분포를 기반으로 각 단어의 조합을 예측하는 전통적인 언어 모델임
  - 모델의 목표는 실제로 사람이 많이 사용하는 단어열의 분포를 정확하게 근사하는 데 있음
  - 확률을 기반으로 단어의 조합을 예측한다는 것은, 주어진 단어를 통해 다음에 올 확률이 가장 높은 단어를 예측하는 일련의 과정을 의미함
  - 이를 바탕으로 문장을 생성할 수도 있는데, 일상에서 흔히 접할 수 있는 스마트폰의 '자동 완성' 기능을 생각하면 쉽게 이해할 수 있음

7.2 언어 모델

- 통계적 언어 모델:
  - 조건부 확률과 언어 모델
    - 문장은 여러 단어의 조합으로 구성됨
    - 그렇다면 여러 단어의 조합을 어떻게 예측해서 생성할 수 있을까?
    - 조건부 확률의 연쇄 법칙(chain rule)을 이용하면 단어들의 결합 확률을 구할 수 있음
    - 문장의 확률은 각 단어가 이전 단어들이 주어졌을 때 다음 단어로 등장할 확률의 곱으로 나타낼 수 있음
    - $P(w1, w2, ..., wn) = P(w1) \times P(w2|w1) \times P(w3|w1,w2) \times ... \times P(wn|w1,...,w(n-1))$

7.2 언어 모델

- 통계적 언어 모델:
  - 조건부 확률과 언어 모델
    - 예를 들어 '나는 사과를 먹는다'라는 문장의 확률은 다음과 같이 표현할 수 있음
    - P(나는, 사과를, 먹는다) = P(나는) x P(사과를 | 나는) x P(먹는다 | 나는, 사과를)
    - 위 식은 단어를 기준으로 작성되었지만, 같은 방식으로 글자나 형태소의 결합 확률을 구할 수 있음
    - 문장의 시작과 끝을 표시하기 위해 <s>, </s>와 같은 경계 기호를 추가하기도 함
    - P(<s>, 나는, 사과를, 먹는다, </s>) 형태로 확장하면 문장 길이에 대한 확률도 모델링할 수 있음

7.2 언어 모델

- 통계적 언어 모델:
  - 조건부 확률의 계산 방법
    - '자동 완성'과 같은 통계적 언어 모델은 이 확률을 어떻게 계산할까?
    - 모델은 학습 시 주어지는 데이터, 즉 코퍼스(corpus) 내에서 각 단어 조합이 나오는 횟수를 세고 이에 기반하여 확률을 계산함
    - 즉 '나는 사과를' 다음에 '먹는다'가 나올 확률 P(먹는다 | 나는, 사과를)를 계산하려면, 코퍼스에서 '나는 사과를'이 나오는 횟수와 '나는 사과를 먹는다'가 나오는 횟수를 세어 나누어 주어야 함
    - P(먹는다 | 나는, 사과를) = count(나는 사과를 먹는다) / count(나는 사과를)
    - 이러한 추정 방식을 최대 우도 추정(Maximum Likelihood Estimation, MLE)이라고 함

7.2 언어 모델

- 통계적 언어 모델:
  - 연쇄 법칙만으로 계산할 때의 문제
    - 모든 단어 조합의 경우의 수를 다 세어야 하므로 계산 복잡도가 높아질 뿐만 아니라, 그만큼 방대한 양의 코퍼스가 필요함
    - 인간의 언어는 창조적으로 무한히 생성될 수 있는 특징을 가지고 있음
    - 이러한 특징을 고려하면 만들어질 수 있는 단어 조합은 사실상 무한함
    - 만약 코퍼스 내에 '나는 사과를'이라는 표현이 한 번도 등장하지 않으면 확률이 0 또는 정의 불가가 되어 버림
    - 결국 모든 단어 조합의 경우의 수를 세어 확률로 나타내는 것은 불가능에 가깝다는 것을 알 수 있음

7.2 언어 모델

- 통계적 언어 모델:
  - N-gram 언어 모델
    - 앞의 문제를 해결하기 위해, 특정 단어의 등장 확률이 바로 앞의 몇 개 단어에만 의존한다고 가정하여 조건부를 짧게 줄임
    - 다만 어떤 단어의 등장 확률이 바로 앞 한 단어하고만 연관된다고 가정하면, 문장 내 단어가 멀리 떨어진 단어와도 의존 관계를 가진다는 언어의 특성(장기 의존성)이 간과되어 예측 정확도가 떨어질 수 있음
    - 예를 들어 'The computer which I had just put into the machine room on the fifth floor crashed'라는 문장에서 'crashed'는 바로 앞의 'floor'보다 'computer'와 훨씬 강하게 연관됨

7.2 언어 모델

- 통계적 언어 모델:
  - N-gram 언어 모델
    - 문장 내 단어는 주변의 여러 단어와 연관되는 경우가 많기 때문에, 계산의 정확도를 위해 특정 단어가 주변에 있는 몇 개의 단어와 연관된다고 가정하는 것이 더 보편적임
    - 이때 주변 몇 개의 단어를 볼 것인지 정하는 임의의 숫자를 N이라 하며, N개의 연속된 단어열을 N-gram이라 함
    - N-gram 언어 모델은 조건부 확률을 다음과 같이 근사함
    - P(wn | w1, ..., w(n-1)) 를 P(wn | w(n-N+1), ..., w(n-1)) 로 근사

7.2 언어 모델

- 통계적 언어 모델:
  - N-gram 언어 모델
    - 예를 들어 'The boy is looking at a pretty girl'이라는 문장이 있을 때, 각 N에 대한 N-gram을 구해 보면 다음과 같음
    - 1-gram(유니그램) : The / boy / is / looking / at / a / pretty / girl
    - 2-gram(바이그램) : The boy / boy is / is looking / looking at / at a / a pretty / pretty girl
    - 3-gram(트라이그램) : The boy is / boy is looking / is looking at / looking at a / at a pretty / a pretty girl
    - 길이 L인 문장에서 N-gram의 개수는 L - N + 1개가 됨

7.2 언어 모델

- 통계적 언어 모델:
  - N-gram 언어 모델과 마르코프 가정
    - N-gram 언어 모델에서는 특정 단어가 등장하는 확률을 계산할 때 이전 N-1개 단어만을 고려함
    - 이러한 가정을 'N-1차 마르코프 가정(Markov assumption)'이라고 함
    - 1-gram 모델에서는 이전 0개의 단어를 고려하므로 모든 단어가 독립적이라고 봄
    - 2-gram 모델에서는 특정 단어의 등장 확률을 계산할 때 이전 1개의 단어를 조건부로 고려함
    - 3-gram 모델에서는 이전 2개, 4-gram 모델에서는 이전 3개의 단어를 조건부로 고려함

7.2 언어 모델

- 통계적 언어 모델:
  - 바이그램 확률 계산 예시
    - 학습 코퍼스 : <s> I am Sam </s> / <s> Sam I am </s> / <s> I do not like green eggs and ham </s>
    - P(I | <s>) = count(<s> I) / count(<s>) = 2 / 3 = 0.67
    - P(Sam | <s>) = 1 / 3 = 0.33
    - P(am | I) = count(I am) / count(I) = 2 / 3 = 0.67
    - P(</s> | Sam) = count(Sam </s>) / count(Sam) = 1 / 2 = 0.5
    - P(<s> I am Sam </s>) = (2/3) x (2/3) x (1/2) x (1/2) = 1/9 ≈ 0.111

7.2 언어 모델

- 통계적 언어 모델:
  - N-gram 확률 계산에 대한 해석
    - 여기서 확률 값은 절대적인 값이 아니며, 모델에 주어진 코퍼스에 따라 크게 달라짐
    - 보다 방대한 양의 코퍼스를 사용하면 추정값이 안정적으로 변함
    - 코퍼스의 장르(뉴스, 대화, 소설)와 언어에 따라서도 결과가 크게 달라질 수 있음
    - 따라서 언어 모델을 사용할 때는 학습 코퍼스와 적용 대상 도메인이 일치하는지 확인해야 함

7.2 언어 모델

- 통계적 언어 모델:
  - 한국어에서의 N-gram
    - 한국어는 교착어이기 때문에 영어와 같이 띄어쓰기만으로 단어를 구분할 수 없음
    - 접사와 조사가 붙어 단어의 의미와 기능을 결정하기 때문에, 하나의 어근에서 수많은 어절이 파생될 수 있음
    - 어절 단위로 N-gram을 만들면 어휘 수가 폭발적으로 늘어나 희소성 문제가 심각해짐
    - 따라서 한국어로 언어 모델을 제작할 때는 목적에 따라 형태소 분석 및 토큰화 등의 전처리를 우선적으로 진행할 필요가 있음
    - 최근에는 서브워드(subword) 토크나이저를 사용하여 미등록어 문제를 완화함

7.2 언어 모델

- 통계적 언어 모델:
  - N-gram 모델을 이용한 문장 생성
    - 학습된 N-gram 확률 분포에서 다음 단어를 반복적으로 샘플링하면 문장을 생성할 수 있음
    - 셰익스피어 (Jurafsky & Martin, SLP 3rd ed. N-gram 장 인용) 작품을 학습한 N-gram 모델의 생성 결과 예시
    - 1-gram : 'To him swallowed confess hear both. Which. Of save on ...'
    - 2-gram : 'What means, sir. I confess she? then all sorts, he is trim ...'
    - 4-gram : 'It cannot be but so. Will you not tell me who I am?'

7.2 언어 모델

- 통계적 언어 모델:
  - 생성 결과 분석
    - 4-gram 모델로 생성한 문장은 1-gram이나 2-gram 모델에 비해 훨씬 자연스럽지만, 코퍼스에 존재하는 텍스트에 가깝게 생성되기 때문에 새로운 문장이라고 보기 어려움
    - 반면 1-gram 모델은 완전히 새로운 단어열을 생성하지만 매우 부자연스러움
    - 이처럼 N-gram 언어 모델에서는 N 값에 따라 결과가 크게 좌우되므로, 데이터셋과 과제 목표에 따라 적절한 N을 선택하는 것이 중요함
    - N 값은 계산량 및 필요한 코퍼스 규모와도 직결됨

7.2 언어 모델

- 통계적 언어 모델:
  - N 값 선택의 트레이드오프
    - N을 늘리면 단어의 등장 확률을 예측하는 정확도가 올라가고 문장의 형태가 좀 더 자연스러워짐
    - 그러나 생성된 문장이 훈련에 사용된 코퍼스와 지나치게 유사해진다는 치명적인 단점이 나타남
    - 이는 코퍼스 내 빈도 카운트를 기반으로 훈련되는 통계적 언어 모델의 근본적 한계이기도 함
    - 어휘 크기가 V일 때 N-gram의 이론적 경우의 수는 V^N 이므로, N이 커질수록 대부분의 N-gram은 코퍼스에 한 번도 나타나지 않음
    - 실무에서는 보통 3-gram 또는 4-gram이 사용됨

7.2 언어 모델

- 통계적 언어 모델:
  - 로그 확률
    - 실제 언어 모델의 계산은 대수(logarithm) 공간에서 이루어짐
    - 즉 언어 모델에서 확률을 계산할 때는 원래의 확률 값에 로그를 취한 로그 확률을 사용하는 것이 보편적임
    - 로그 확률을 사용하는 주된 이유는 언더플로(underflow)를 피하기 위함임
    - 언더플로란 부동 소수점 연산에서 컴퓨터가 표현할 수 있는 것보다 작은 값이 발생하여 계산 결과를 정확히 표시할 수 없는 상태를 의미함
    - N-gram 모델의 확률을 계산하려면 0보다 크고 1보다 작은 확률 값을 여러 차례 곱해야 하므로, 문장이 길어지면 값이 급격히 0에 가까워짐

7.2 언어 모델

- 통계적 언어 모델:
  - 로그 확률
    - 1보다 작은 확률을 계속 곱하면 결과값이 0에 매우 가까워져 언더플로가 발생할 수 있음
    - 이를 로그 공간에서 계산하면 곱셈이 덧셈이 되어 언더플로를 피하고 수치적으로 안정적으로 계산할 수 있음
    - log P(w1...wn) = log P(w1) + log P(w2|w1) + ... + log P(wn|w1...w(n-1))
    - 필요할 때는 exp를 취해 원래 확률로 복원할 수 있음
    - 그러므로 언어 모델에서 확률을 계산할 때는 로그 공간에서 계산하는 것이 일반적임

7.2 언어 모델

- 일반화 (Generalization):
  - 통계적 언어 모델은 코퍼스 내 단어 출현 빈도(카운트)에 기반하여 언어를 예측하기 때문에 희소성(sparsity) 문제가 발생할 수 있음
  - 희소성 문제는 모델의 예측 정확도를 낮추는 주요 요인이 됨
  - N-gram 언어 모델에서는 마르코프 가정을 적용하여 어느 정도 일반화를 진행했지만, 여전히 희소성 문제는 존재함
  - 또한 N-gram 모델은 테스트 데이터셋이 훈련 데이터셋과 유사해야만 예측 성능이 좋다는 한계가 있음
  - N이 크면 자연스러운 문장이 완성되지만 훈련 데이터셋과 거의 똑같은 문장이 만들어짐

7.2 언어 모델

- 일반화 (Generalization):
  - 희소성 문제의 두 가지 형태
    - 미등록어(OOV, Out-Of-Vocabulary) : 테스트 시점에 학습 어휘에 없는 단어가 등장하여 확률을 정의할 수 없음
    - 미관측 N-gram : 각 단어는 어휘에 있지만 그 조합이 코퍼스에 없어 카운트가 0이 되고, 곱셈에 의해 문장 전체 확률이 0이 됨
  - 이러한 모델은 이전에 보지 못한 새로운 데이터셋에 대해서는 제대로 된 예측을 하지 못함
  - 모든 언어의 조합을 포함하는 코퍼스를 만드는 것은 현실적으로 불가능하므로 좋은 해결책이 아님
  - 이에 한정된 코퍼스 내에서 모델의 일반화 능력을 향상시키기 위한 다양한 기법이 제시되었으며, 대표적으로 스무딩, 보간법, 백오프가 있음

7.2 언어 모델

- 일반화 (Generalization):
  - 스무딩(Smoothing)
    - 코퍼스 내에 존재하지 않는 단어 조합, 즉 모델이 한 번도 본 적 없는 조합(unseen n-gram)에 대해 일정한 값을 부여하여 확률 분포에 약간의 변화를 주는 방법임
    - 라플라스 스무딩(add-1) : 모든 N-gram 카운트에 1을 더함
    - P_Laplace(wn | w(n-1)) = (count(w(n-1) wn) + 1) / (count(w(n-1)) + V)
    - add-k 스무딩 : P = (count(w(n-1) wn) + k) / (count(w(n-1)) + kV), k > 0 (보통 0 < k ≤ 1). 분모의 kV를 빠뜨리면 확률의 합이 1이 되지 않음
    - 그러면 모든 단어열이 0보다 큰 확률을 가지게 되므로, 코퍼스에 없는 단어열 때문에 전체 문장의 확률이 0이 되는 문제를 방지할 수 있음

7.2 언어 모델

- 일반화 (Generalization):
  - 스무딩의 한계
    - 라플라스 스무딩은 관측되지 않은 조합이 압도적으로 많은 상황에서 확률 질량을 과도하게 이동시킴
    - 결과적으로 실제로 관측된 N-gram의 확률이 지나치게 낮아져 성능이 떨어질 수 있음
    - 따라서 언어 모델에서는 단순 add-1보다 보간법, 백오프, Kneser-Ney 스무딩 등이 선호됨
  - Kneser-Ney 스무딩
    - 단어가 얼마나 자주 나왔는가가 아니라, 얼마나 다양한 문맥에서 나왔는가(continuation probability)를 이용함
    - N-gram 언어 모델에서 가장 성능이 좋은 표준적인 스무딩 기법으로 알려져 있음

7.2 언어 모델

- 일반화 (Generalization):
  - 보간법(Interpolation)
    - 특정 N-gram 확률을 더 낮은 차수 N-gram의 확률과 섞음으로써 일반화를 꾀함
    - 예컨대 3-gram 모델이라면 특정 단어의 확률을 구할 때 이전 2개 단어만 보는 것이 아니라, 2-gram(이전 1개 단어), 1-gram(단어 자체) 모델의 확률까지 모두 구하고 일정한 가중치를 각각 곱한 후 모두 합함
    - $P(wn|w(n-2),w(n-1)) = L1 \times P3 + L2 \times P2 + L3 \times P1$, 단 $L1 + L2 + L3 = 1$
    - 보간법을 사용하면 카운트가 0인 N-gram에도 하위 N-gram 정보에 따라 서로 다른 확률을 부여할 수 있음
    - 이때 가중치는 검증(held-out) 코퍼스에서 확률을 최대화하도록 학습함

7.2 언어 모델

- 일반화 (Generalization):
  - 백오프(Back-off)
    - 보간법과 유사하게 여러 차수의 N-gram을 고려하지만, 모두 합하지 않는다는 점에서 차이가 있음
    - 3-gram의 빈도가 0보다 크면 3-gram 확률을 쓰고, 3-gram 빈도가 0이지만 2-gram 빈도가 0보다 크면 2-gram을, 그마저도 없으면 1-gram 모델의 확률을 사용하는 방식임
    - 백오프 기법을 사용하면 특정 N-gram보다 낮은 차수의 단어열 정보를 활용할 수 있으므로 보다 나은 일반화가 가능함
    - 확률의 총합이 1이 되도록 상위 차수에서 일부 확률 질량을 떼어 내는 할인(discounting)이 필요하며, 이를 반영한 것이 Katz 백오프임
    - 대규모 코퍼스에서는 정규화를 생략한 Stupid Backoff가 실용적으로 쓰이기도 함

7.2 언어 모델

- 모델 평가와 퍼플렉서티(Perplexity):
  - 모델의 성능이 좋은지 나쁜지를 평가하는 단계가 필요함
  - 외부 평가(extrinsic evaluation)
    - 언어 모델을 실제 응용(기계 번역, 음성 인식)에 넣어 최종 성능이 얼마나 좋아지는지로 평가함
    - 가장 신뢰할 수 있지만 비용과 시간이 많이 소요됨
  - 내부 평가(intrinsic evaluation)
    - 응용과 무관하게 언어 모델 자체의 품질을 측정하며, 대표적인 지표가 퍼플렉서티(Perplexity, PPL)임

7.2 언어 모델

- 모델 평가와 퍼플렉서티(Perplexity):
  - 퍼플렉서티는 주어진 확률 모델이 샘플을 얼마나 잘 예측하는가에 대한 측정 지표임
  - 모델이 테스트 데이터셋에 대하여 확률 분포를 얼마나 확실하게 예측할 수 있는지를 나타낸다고 할 수 있음
  - 정의 : 테스트 문장 W = w1 ... wN 에 대해
    - PPL(W) = P(w1 w2 ... wN)^(-1/N)
    - = exp(- (1/N) x SUM log P(wi | 이전 단어들))
  - 퍼플렉서티 점수가 낮을수록(헷갈리는 경우가 적을수록) 좋은 모델이라고 할 수 있음

7.2 언어 모델

- 모델 평가와 퍼플렉서티(Perplexity):
  - 퍼플렉서티의 직관적 의미 : 분기 계수(branching factor)
    - PPL이 100이라면, 모델이 다음 단어를 고를 때 평균적으로 100개의 후보 중 하나를 고르는 정도로 헷갈리고 있다는 뜻임
    - 어휘 크기 V인 균등 분포 모델의 퍼플렉서티는 정확히 V가 됨
  - 주의사항
    - 어휘 집합과 토큰화 방식이 다르면 퍼플렉서티를 직접 비교할 수 없음
    - 미등록어 처리 방식(<unk> 비율)에 따라 값이 크게 달라짐
    - 퍼플렉서티가 낮다고 해서 반드시 응용 성능이 좋은 것은 아니므로, 외부 평가와 함께 보는 것이 바람직함

7.2 언어 모델

- 모델 평가와 퍼플렉서티(Perplexity):
  - N-gram 언어 모델의 한계 정리
    - 장기 의존성을 포착하지 못함 (N개 이전까지만 기억)
    - 단어를 이산적 기호로 다루므로 '사과'와 '배'가 비슷한 단어라는 정보를 활용할 수 없음
    - N이 커지면 경우의 수가 V^N 으로 기하급수적으로 증가해 모델 크기·희소성 문제가 악화됨
  - 신경망 언어 모델로의 전환
    - 단어를 밀집 벡터(임베딩)로 표현하여 유사한 단어가 유사한 확률 분포를 공유하게 함
    - RNN·LSTM을 거쳐 Transformer 기반 모델로 발전하였으며, 이후 주차에서 다룰 예정임

7.3 정보추출 (Information Extraction)

- 정보추출 구성
  - 정보추출이란
  - 정보추출의 하위 작업과 파이프라인
  - 관계 추출
  - 정보추출(관계 추출)의 접근법
  - 정보추출의 평가와 활용

7.3 정보추출 (Information Extraction)

- 정보추출이란:
  - 실세계의 대부분의 정보는 비정형(비구조화) 텍스트로 존재함
  - 비정형 텍스트로부터 유용한 정보를 자동으로 추출하기 위해서는 정보 추출(Information Extraction, IE) 작업이 필요함
  - 예를 들어 온라인 뉴스, 정부 문서, 진료 기록 등을 포함한 텍스트 정보의 상당 부분이 비정형 텍스트로 이루어져 있음
  - 이러한 대량의 비정형 텍스트에서 중요 정보를 사람이 직접 찾기에는 시간과 비용이 많이 소요되기 때문에 정보추출이 필요함
  - 자연어처리에서는 비정형 텍스트로부터 정보를 추출하기 위해, 개체 간의 의미적 관계를 포함하는 구조화된 데이터 표현이 필요함

7.3 정보추출 (Information Extraction)

- 정보추출이란:
  - 관계형 튜플(relational tuple) 표현
    - 개체 간의 의미적 관계는 (개체1, 관계, 개체2) 형태의 관계형 튜플로 표현할 수 있음
    - 예 : '이순신은 조선의 장군이다' -> (이순신, 직책, 장군)
    - 예 : '삼성전자는 수원에 본사를 두고 있다' -> (삼성전자, 본사_위치, 수원)
    - 예 : 'Steve Jobs founded Apple in 1976' -> (Steve Jobs, founded, Apple)
    - 이렇게 추출된 튜플을 모으면 지식 그래프(knowledge graph)나 데이터베이스를 구축할 수 있음

7.3 정보추출 (Information Extraction)

- 정보추출이란:
  - 정보 추출의 목적은 문서 내 개체 간의 대상 관계를 파악하여 의미적 관계를 추출하고, 이를 바탕으로 질의에 응답하는 것에 중점을 둠
  - 그러므로 추출된 부분 정보를 구조적으로 정확하게 수집하려면 도메인 지식을 필요로 하는 문제점이 있음
  - 이를 위해 수작업으로 추출한 패턴이나 정보를 바탕으로 데이터를 구축함
  - 결과적으로 새로운 도메인에 정보추출을 적용하기 위해서는, 사용자가 해당 도메인에서 목표로 하는 관계들의 이름을 지정할 뿐만 아니라 수동으로 새로운 규칙을 적용하여 데이터에 주석을 달아야 함
  - 최근에는 적은 수의 태깅 데이터로도 학습이 가능한 준지도·원격지도 방법이 활발히 연구되고 있음

7.3 정보추출 (Information Extraction)

- 정보추출의 하위 작업:
  - 정보 추출의 주요 하위 작업
    - NER(Named Entity Recognition) : 인명, 지명, 시간 표현 및 특정 유형의 수치 표현 등 특정 유형의 개체에 대한 참조를 식별함
    - 상호참조 해결(Coreference Resolution) : 이전 단계에서 추출된 개체들 사이의 상호 참조 관계를 찾아, '그', '이 회사'와 같은 표현이 어떤 개체를 가리키는지 연결함
    - 개체 연결(Entity Linking) : 추출된 개체를 위키피디아·지식베이스의 고유 항목에 연결함
    - 관계 추출(Relation Extraction) : 텍스트에서 개체 간의 관계를 식별하고 구조화된 정보로 나타내기 때문에 가장 중요한 하위 작업임
    - 사건 추출(Event Extraction) : 사건과 그 참여자·시간·장소를 함께 추출함

7.3 정보추출 (Information Extraction)

- 정보추출의 파이프라인:
  - 정보추출은 비정형 텍스트에서 중요 정보를 추출하여 구조화된 데이터로 변환하는 것을 목표로 함
  - 정보추출 시스템을 위한 대표적인 처리 순서
    - 원시 텍스트 -> 문장 분리 -> 토큰화 -> 품사 태깅
    - -> 개체명 인식 -> 상호참조 해결 -> 관계 추출
    - -> (개체1, 관계, 개체2) 튜플 목록 -> 데이터베이스 / 지식 그래프 저장
  - 정보 추출 시스템 구조를 이용하면 문서의 비정형 텍스트를 입력으로 사용하고, 출력으로 관계형 튜플 목록을 생성함
  - 각 단계의 오류가 다음 단계로 전파되는 오류 전파(error propagation) 문제가 존재하며, 이를 완화하기 위해 종단간(end-to-end) 학습 방식도 연구됨

7.3 정보추출 (Information Extraction)

- 관계 추출:
  - 정보추출은 개체와 개체 간의 관계를 식별하고 추출하는 것을 목표로 하며, 하위 작업 중에서 NER과 관계 추출을 중심으로 연구가 진행됨
  - 비정형 텍스트에서 추출된 개체 간의 관계를 추출한 예시
    - 입력 : '홍길동은 2020년부터 한국대학교 컴퓨터공학과 교수로 재직 중이다.'
    - 개체 : 홍길동[PS], 2020년[DT], 한국대학교 컴퓨터공학과[OG]
    - 관계 튜플 : (홍길동, 소속, 한국대학교 컴퓨터공학과), (홍길동, 직책, 교수), (홍길동, 재직_시작, 2020년)

7.3 정보추출 (Information Extraction)

- 관계 추출:
  - 대표적인 관계 유형 (ACE, TACRED 기준)
    - 소속(per:employee_of), 출생지(per:city_of_birth), 설립자(org:founded_by), 본사 위치(org:city_of_headquarters), 부분-전체(part-whole), 상하위(is-a) 등
  - 관계 추출 과제의 정식화
    - 문장과 두 개체(entity mention) 쌍이 주어졌을 때, 사전에 정의된 관계 집합 중 어느 것에 해당하는지(또는 관계 없음) 분류하는 문제
    - 즉 다중 클래스 분류 문제로 환원되며, 'no_relation' 클래스가 대부분을 차지하는 불균형 문제가 존재함

7.3 정보추출 (Information Extraction)

- 정보추출(관계 추출)의 접근법:
  - 관계 추출에 따라 정보 추출은 개체, 관계 및 사건의 인스턴스를 식별하고 이들 사이의 관계를 추출하는 것임
  - 정보 추출 시스템의 두 가지 목표
    - 첫 번째 목표는 비정형 텍스트에서 구조화된 정보를 추출하기 위해 모든 언급(mention)을 식별하는 것임
    - 두 번째 목표는 구조화된 개체와 관계를 데이터베이스에 저장하는 것임
  - 이러한 목표를 달성하기 위한 정보추출의 접근 방식은 크게 규칙 기반 접근법과 기계학습 기반 접근법으로 나뉨

7.3 정보추출 (Information Extraction)

- 정보추출(관계 추출)의 접근법:
  - 규칙 기반 접근법
    - 컴퓨터 시스템에 지식을 통합하기 위해, 수작업으로 필요한 전문지식을 획득하고 규칙을 생성하는 지식 기반·규칙 기반 접근법임
    - 사람이 직접 규칙을 생성하며, 비정형 텍스트에 대한 언어학적 분석을 통해 관계 튜플의 패턴을 정의하고, 정의된 규칙을 사용하여 텍스트로부터 관계 튜플을 추출함
    - 대표적으로 Hearst 패턴이 있음 : 'NP such as NP, NP, and NP' -> 상하위 관계(is-a)
    - 예 : '과일, 예를 들어 사과, 배, 감' -> (사과, is-a, 과일), (배, is-a, 과일)

7.3 정보추출 (Information Extraction)

- 정보추출(관계 추출)의 접근법:
  - 규칙 기반 접근법의 절차
    - 규칙 획득 : 초기 규칙은 학습 말뭉치의 특징과 개념을 기반으로 도메인 전문가에 의해 공식화됨
    - 규칙 재정의 : 주어진 규칙을 실제 데이터에 적용하며 점차적으로 조정하고 세분화함, 이러한 방식을 통해 말뭉치의 확장 및 변경 사항도 쉽게 반영할 수 있음
    - 규칙 적용 : 지식 획득 단계 이후 추출된 규칙을 적용하여 구조화된 데이터를 생성할 수 있음, 출력은 도메인별로 다르지만 일반적으로 속성-값 쌍이 출력됨
    - 구조화된 데이터 생성 : 이 단계에서는 속성-값 쌍이 최종 데이터베이스에 기록됨

7.3 정보추출 (Information Extraction)

- 정보추출(관계 추출)의 접근법:
  - 규칙 기반 접근법의 장단점
    - 장점 : 정밀도가 높고, 왜 그런 결과가 나왔는지 해석이 명확하며, 학습 데이터가 없어도 즉시 적용 가능함
    - 단점 : 재현율이 낮고, 규칙 작성에 많은 인력과 시간이 필요하며, 새로운 도메인마다 규칙을 다시 만들어야 함
  - 기계학습 기반 접근법
    - 기계학습 알고리즘을 적용한 결과로 규칙을 자동으로 추출하기 때문에 자동학습 기반 접근법이라고도 함
    - 비정형 텍스트로부터 기계학습 알고리즘을 적용하여 패턴을 직접 발견하여 학습함
    - 많은 데이터를 분석할 수 있기 때문에 다양한 패턴을 수집할 수 있다는 장점이 있음

7.3 정보추출 (Information Extraction)

- 정보추출(관계 추출)의 접근법:
  - 지도학습 기반 관계 추출
    - 관계가 주석된 학습 데이터로부터 분류기를 학습함
    - 주요 자질 : 두 개체의 유형, 두 개체 사이의 단어들, 의존 구문 경로, 개체 앞뒤의 문맥 단어
    - 장점 : 성능이 높고 평가가 명확함 / 단점 : 주석 데이터 구축 비용이 매우 큼
  - 준지도(부트스트래핑) 방식
    - 소수의 시드 튜플에서 출발하여 패턴을 찾고, 그 패턴으로 새 튜플을 찾아 다시 패턴을 확장하는 반복 절차를 수행함
    - 의미 표류(semantic drift)로 인해 반복이 진행될수록 잘못된 패턴이 유입될 수 있음

7.3 정보추출 (Information Extraction)

- 정보추출(관계 추출)의 접근법:
  - 원격 지도(Distant Supervision)
    - 기존 지식베이스(예: Freebase, DBpedia)에 있는 관계 튜플을 이용하여 학습 데이터를 자동으로 만드는 방법
    - 가정 : 두 개체가 지식베이스에서 어떤 관계를 가진다면, 두 개체가 함께 등장하는 문장은 그 관계를 표현할 가능성이 높음
    - 대량의 학습 데이터를 저비용으로 얻을 수 있지만, 가정이 성립하지 않는 문장에서 잡음 레이블이 발생함
  - 개방형 정보 추출(Open IE)
    - 관계 집합을 미리 정의하지 않고, 텍스트에 나타난 술어 표현 자체를 관계로 추출함
    - 대규모 웹 텍스트에 확장 적용할 수 있으나, 동일한 관계가 서로 다른 표현으로 추출되어 정규화가 필요함

7.3 정보추출 (Information Extraction)

- 정보추출의 평가와 활용:
  - 평가
    - 관계 추출도 NER과 동일하게 정밀도, 재현율, F1로 평가함
    - 'no_relation'을 제외한 관계들에 대한 micro-F1을 주 지표로 사용하는 경우가 많음
    - 대표 벤치마크 : ACE 2005, SemEval-2010 Task 8, TACRED, 한국어의 KLUE-RE
  - 활용 사례
    - 지식 그래프 구축 및 검색 엔진의 정보 카드
    - 금융 공시·뉴스에서 기업 이벤트 자동 추출
    - 의료 기록에서 질병-약물-부작용 관계 추출
    - 이력서·계약서 등 문서 자동 구조화

요약

- 7.1 개체명 인식
  - 개체명 인식 소개, 개체명 인식이란, 개체명 유형과 태그셋, NER 시스템, NER 평가 척도, BIO Tagging Scheme, 학습 코퍼스, 한국어 NER의 특수성에 대해서 살펴봄
- 7.2 언어 모델
  - 언어 모델이란, 통계적 언어 모델과 조건부 확률, N-gram 언어 모델, 로그 확률, 일반화(스무딩·보간법·백오프), 모델 평가와 퍼플렉서티에 대해서 살펴봄
- 7.3 정보추출
  - 정보추출이란, 정보추출의 하위 작업과 파이프라인, 관계 추출, 정보추출(관계 추출)의 접근법, 평가와 활용에 대해서 살펴봄

핵심 정리

- 기억해야 할 핵심 개념
  - NER은 개체의 경계와 유형을 함께 맞혀야 하므로 BIO 표현과 개체 단위 F1이 표준임
  - 언어 모델은 단어열에 확률을 부여하며, 연쇄 법칙 + 마르코프 가정으로 N-gram 모델이 유도됨
  - N-gram의 최대 약점은 희소성이며, 스무딩·보간법·백오프로 완화하고 퍼플렉서티로 평가함
  - 정보추출은 NER 결과 위에서 개체 간 관계를 (개체1, 관계, 개체2) 튜플로 구조화하는 작업임
  - 세 주제는 독립적이지 않고, NER -> 관계 추출 -> 지식 그래프로 이어지는 하나의 흐름을 이룸

질문 및 정리

- 확인 질문
  - BIO 태깅에서 태그의 총 개수가 2N+1개가 되는 이유는 무엇인가?
  - NER 평가에 정확도(accuracy) 대신 F1을 사용하는 이유는 무엇인가?
  - 3-gram 모델이 2-gram 모델보다 항상 좋은 것은 아닌 이유는 무엇인가?
  - 라플라스 스무딩이 실제 언어 모델에서 잘 사용되지 않는 이유는 무엇인가?
  - 퍼플렉서티가 낮은 모델이 반드시 좋은 모델이라고 할 수 없는 이유는 무엇인가?
  - 원격 지도 방식이 만들어 내는 잡음 레이블의 예를 들어 보시오.