CHAPTER 8

중간 정리

1주차 ~ 7주차 핵심 요약과 중간고사 대비

학습 목표

- 무엇을 하는 시간인가
  - 1~7주차에서 배운 개념을 하나의 흐름으로 다시 연결한다
  - 주차별 핵심 용어·수식·평가지표를 표로 정리해 암기 지점을 명확히 한다
  - 예상 문제와 자가 점검 체크리스트로 중간고사를 대비한다
- 가장 중요한 한 문장
  - 1~7주차는 결국 “텍스트를 어떻게 숫자로 바꾸고, 그 숫자로 무엇을 예측할 것인가”이다
- 복습 우선순위
  - ① 전처리 파이프라인 순서 ② TF-IDF·유사도 계산 ③ N-gram 언어모델과 스무딩
  - ④ 품사 태깅(HMM)과 BIO 태깅 ⑤ 정밀도·재현율·F1·퍼플렉서티

1~7주차 전체 지도

아래로 갈수록 추상도가 높아진다

- 1주차 자연어처리란 무엇인가 — 정의·역사·난점·응용·파이프라인
- 2주차 수학과 언어학의 기초 — 확률·정보이론·선형대수 / 형태론·통사론·의미론
- 3주차 전처리 — 토큰화·품사 태깅·불용어 제거·정규화
- 4주차 전처리·어휘·구문·의미 분석 — 유니코드 정규화·띄어쓰기/맞춤법 교정·서브워드 토큰화, 형태소 분석, 구구조/의존 구문, 중의성 해소
- 5주차 단어 표현·텍스트 분류·텍스트 유사도 — 원핫·BoW·TF-IDF, 분류 평가
- 6주차 텍스트 요약·생성·벡터 표현 — TextRank, 마르코프 체인, 임베딩
- 7주차 개체명 인식·언어 모델·정보 추출 — BIO, N-gram LM, 관계 추출

관통하는 축

- 문자열 → 토큰 → 벡터 → 확률 → 예측

PART 1 1~2주차 · 개요와 기초

자연어처리는 무엇이고, 왜 확률과 언어학이 필요한가

1주차 · 자연어처리 개요

정의와 범위

- 자연어처리(NLP) = 자연어 이해(NLU) + 자연어 생성(NLG)

역사 4단계

- 규칙 기반(1960~80년대) → 통계 기반(1990~2000년대) → 신경망(2013~2017) → 사전학습·LLM(2017~)
- ELIZA(1966), IBM 통계 번역(1990년대), Word2Vec(2013), Transformer(2017), BERT(2018)

자연어처리가 어려운 이유

- 중의성 — 어휘적('배'), 구조적·구문적(수식 범위), 화용적 (4주차 4.4절 기준 3유형)
- 규칙의 예외, 언어의 유연성·확장성(신조어), 관용 표현
- 한국어의 난점 — 교착어, 자유로운 어순, 띄어쓰기 불규칙, 조사·어미의 다양성

파이프라인

- 전처리 → 토큰화 → 벡터화 → 모델 → 후처리

2주차 · 확률 · 정보이론 · 선형대수

확률의 기초

- 조건부확률 $P(A|B) = P(A \cap B) / P(B)$
- 베이즈 정리 $P(A|B) = P(B|A) \cdot P(A) / P(B)$ — 사후 ∝ 우도 × 사전
- MLE(최대우도) vs MAP(최대사후) — MAP는 사전분포를 더해 스무딩 효과를 준다

정보이론

- 엔트로피 $H_2(P) = -\Sigma\, P(x) \log_2 P(x)$ — 불확실성의 크기
- 교차엔트로피 $H(P,Q) = H(P) + KL(P \| Q)$ — 그래서 $H(P,Q) \geq H(P)$
- KL divergence 는 비음수이지만 비대칭이다 (거리가 아니다)
- 퍼플렉서티 PPL = 2^H — 균등분포이면 PPL = V

선형대수

- 내적·노름·코사인 유사도, 행렬 곱, SVD(차원 축소의 기반)

2주차 · 언어학의 층위

언어의 5개 층위

- 음운론 → 형태론 → 통사론 → 의미론 → 화용론 (작은 단위에서 큰 맥락으로)

형태론

- 형태소 = 의미를 가진 최소 단위 / 어절 = 띄어쓰기 단위
- 한국어 9품사 — 명사·대명사·수사·동사·형용사·관형사·부사·조사·감탄사
- 관형사는 형태 변화 없이 체언만 수식하는 별도 품사이며, 영어의 형용사와 구분해야 한다

통사론

- 구구조 문법(구성 성분의 계층) vs 의존 문법(단어 간 지배-의존 관계)

의미론 · 화용론

- 의미론 = 문장 자체의 의미 / 화용론 = 맥락에 따라 달라지는 의미

언어 유형론

- 영어는 굴절어이나 굴절이 약화되어 분석적 성격이 강하므로(고립어와는 구분) 공백 토큰화가 비교적 잘 통한다
- 한국어는 교착어라 형태소 단위 분석이 필요하다

PART 2 3~4주차 · 전처리와 언어 분석

원시 텍스트를 어떻게 다듬고, 구조와 의미를 어떻게 읽어내는가

3주차 · 전처리 파이프라인

표준 순서 (시험 빈출)

- 정제(HTML·URL·이메일·특수문자) → 정규화 → 토큰화 → 품사 태깅 → 불용어 제거 → 표제어 추출
- 품사 정보를 쓰는 단계는 반드시 품사 태깅 뒤에 와야 한다 (오류 전파 방지)

토큰화

- 단어 / n-그램 / 서브워드(BPE·WordPiece) / 한국어 형태소 단위

불용어 제거의 함정

- NLTK 영어 불용어는 179개이며 'one'은 포함되지 않는다
- 감성 분석에서 'not/no/never'를 지우면 의미가 정반대가 된다
- 사전학습 모델(BERT 등)에서는 일반적으로 제거하지 않는다

어간 추출 vs 표제어 추출

- Porter Stemmer — 규칙 기반, 비단어 생성 가능 ('battling → battl')
- Lemmatizer — 사전 기반, 품사를 함께 주어야 정확 ('was' + v → 'be')

4주차 (1) · 편집 거리 계산 예제

Levenshtein distance

- 한 문자열을 다른 문자열로 바꾸는 데 필요한 최소 편집 횟수
- 허용 연산: 삽입(insert) · 삭제(delete) · 대체(substitute)
- 각 연산의 비용을 1로 두고 최소 비용을 계산

kitten → sitting

kitten
↓ k → s 대체 1회
sitten
↓ e → i 대체 1회
sittin
↓ g 삽입 삽입 1회
sitting

편집 거리 = 3

Damerau-Levenshtein

- Levenshtein의 3가지 연산에 인접 문자 전치(transposition)를 추가
- 예: teh → the는 e와 h의 전치 1회 → 거리 1

시험 포인트: 주어진 두 문자열을 같게 만드는 최소 삽입·삭제·대체 횟수를 계산할 수 있어야 한다.

4주차 (1) · 텍스트 전처리

전처리 파이프라인 (4.1)

- 텍스트 추출 → 정제(Cleaning) → 정규화 → 교정 → 토큰화
- 정제는 정규표현식으로 HTML·URL·특수문자 등 노이즈를 제거한다

정규화

- 유니코드 NFC / NFD / NFKC — len('한글') 은 NFC 2, NFD 6
- 대소문자 통일, 반복 문자 축약, 동의어·표기 변형 통일

한국어 띄어쓰기 교정 — 세 가지 접근

- ① 규칙 기반 ② 통계·확률 기반(음절 n-gram) ③ 딥러닝 기반(음절 단위 이진 분류)

맞춤법 교정

- 오류 4유형 — 삽입 · 생략 · 대체 · 전치
- 삽입·생략·대체만 허용하면 Levenshtein, 전치까지 허용하면 Damerau-Levenshtein 거리
- 잡음 채널 모형 $\hat{c} = \text{argmax } P(w|c)\cdot P(c)$ (오타 모델 × 언어 모델)

서브워드 토큰화

- BPE / WordPiece / SentencePiece — 고정된 사전 크기로 OOV를 원천 제거

4주차 (2) · 어휘 · 구문 · 의미 분석

어휘 분석

- HMM 품사 태깅 $\text{argmax}_t \prod P(w|t) \cdot P(t|t_{-1})$ — Viterbi 로 $O(n \cdot |T|^2)$
- 형태소는 자립/의존 · 실질/형식으로 분류. 한국어는 교착어라 어절 ≠ 단어
- 한국어 형태소 분석기 — KoNLPy(Okt·Komoran·Hannanum·Kkma·Mecab)와 별도 패키지 Kiwi

구문 분석

- 구구조 파싱(Chomsky, 1957) vs 의존 파싱 — 의존 에지는 지배소 → 의존소 방향
- 구문 중의성 유형 — 부착 중의성, 등위 접속 중의성, 명사구 경계 중의성
- 단어 n개의 이진 트리 수는 카탈란 수 $C(n-1)$ 로 폭발한다
- 의존 파싱 — 전이 기반 $O(n)$ vs 그래프 기반 MST(전역 최적)

의미 분석

- 어휘 중의성 해소(WSD) — Lesk, WordNet, 문맥 임베딩
- 의미역 결정(SRL) — PropBank ARG0(행위자)·ARG1(대상)·ARG2 …
- 분포 가설(Firth, 1957) — "단어는 함께 나타나는 단어들로 규정된다"

PART 3 5~6주차 · 표현과 생성

텍스트를 벡터로 바꾸고, 요약하고, 새로 만들어내기

5주차 · 단어 표현 방법 비교

방법	핵심 아이디어	장점	한계
원-핫	어휘 크기 V 차원 중 한 자리만 1	단순·명확	차원 폭발, 모든 단어가 직교 → 유사도 0
BoW	단어 등장 횟수를 세어 벡터화	구현 간단, 빠름	어순 무시, 흔한 단어가 과대평가
N-gram	연속한 n개 토큰을 하나의 자질로	국소적 어순 반영	n이 커질수록 희소성 급증
TF-IDF	빈도 × 희귀도 가중	변별력 있는 단어 강조	의미·유의어 관계는 여전히 못 잡음
분산 표현	예측/공기 통계로 밀집 벡터 학습	의미적 유사도 계산 가능	다의어를 한 벡터로 뭉갬(정적 임베딩)

5주차 · TF-IDF 와 텍스트 유사도

TF-IDF

- TF(t,d) = 문서 d 에서 t 의 등장 빈도
- IDF(t) = log((1+N) / (1+DF(t))) + 1 ← scikit-learn 기본(smooth_idf=True)
- DF ≤ N 이므로 IDF는 음수가 될 수 없다. 끝의 +1 이 없으면 DF = N 인 단어의 IDF가 0이 되어 TF-IDF가 통째로 사라지므로, +1 로 최솟값을 1로 유지한다

네 가지 유사도

- 자카드 $|A \cap B| / |A \cup B|$ — 집합 기반, 빈도 무시
- 코사인 $(A \cdot B) / (\|A\| \|B\|)$ — 방향만 비교, 문서 길이에 강건 (가장 널리 쓰임)
- 유클리디언 $\sqrt{\Sigma(a_i - b_i)^2}$ · 맨해튼 $\Sigma|a_i - b_i|$ — 거리이므로 작을수록 유사
- 거리 지표는 벡터를 L1 정규화(각 행의 성분 합 = 1)한 뒤 비교해야 공정하다

계산 예

- A 17개, B 13개, 교집합 5개 → 합집합 25개 → 자카드 = 5/25 = 0.20

5주차 · 분류 성능 평가 지표

지표	수식	언제 보는가
정확도 Accuracy	(TP+TN) / 전체	클래스가 균형일 때만 신뢰할 수 있다
정밀도 Precision	TP / (TP+FP)	오탐 비용이 클 때 (스팸 오분류 등)
재현율 Recall	TP / (TP+FN)	누락 비용이 클 때 (질병·위험 탐지 등)
F1	2PR / (P+R)	정밀도와 재현율의 조화평균, 불균형 데이터의 기본 지표
매크로 / 마이크로 F1	클래스별 평균 / 전체 합산	다중 분류에서 소수 클래스 반영 여부

6주차 · 요약 · 생성 · 벡터 표현

텍스트 요약

- 추출적 요약 — 원문 문장을 골라 배열 (TextRank, 빈도·TF-IDF 기반)
- 생성적(추상적) 요약 — 새 문장을 만들어냄 (Seq2Seq·트랜스포머)
- TextRank(Mihalcea & Tarau, 2004) — 문장을 노드, 유사도를 에지로 두고 PageRank
- PageRank의 핵심은 링크 개수가 아니라 "중요한 노드가 가리키면 더 중요해진다"는 재귀성
- 선택한 문장은 점수 순이 아니라 원문 순서로 배열해야 읽을 수 있는 요약이 된다

요약 평가 — ROUGE

- ROUGE-N = n-gram 재현율, ROUGE-L = 최장 공통 부분수열(LCS) 기반
- BLEU 는 정밀도 중심(번역), ROUGE 는 재현율 중심(요약)

텍스트 생성

- 마르코프 체인 / n-gram 언어 모델로 다음 단어를 확률적으로 선택
- 디코딩 전략 — 그리디, temperature 조절, top-k 샘플링

6주차 · ROUGE-L 계산 예제

ROUGE-L

- 후보 요약과 참조 요약 사이의 **최장 공통 부분수열(LCS, Longest Common Subsequence)**을 이용
- 연속해서 붙어 있을 필요는 없지만 단어의 순서는 유지해야 함
- ROUGE-N과 달리 문장의 순서 정보를 어느 정도 반영

계산 예

Reference : the cat is on the mat
Candidate : the cat sat on mat

LCS : the cat on mat
LCS 길이 : 4

따라서

Recall = 4 / 6 = 0.667
Precision = 4 / 5 = 0.800

F1 = 2 × P × R / (P + R) ≈ 0.727

시험 포인트: 두 문장에서 LCS를 찾고, LCS 길이를 이용해 Precision · Recall · F1을 계산할 수 있어야 한다.

PART 4 7주차 · 개체명 인식과 언어 모델

문장에서 정보를 뽑아내고, 다음 단어를 예측하기

7주차 · 개체명 인식(NER)

개체명과 태그셋

- 사람(PS)·장소(LC)·기관(OG)·날짜(DT)·TI(시간) · QT(수량) 6종이 기본이고 확장 시 EV(사건) 등 고유 대상을 가리키는 표현
- CoNLL-2003 : PER·LOC·ORG·MISC / OntoNotes : 18종

BIO 태깅

- B-XXX = 개체의 시작, I-XXX = 개체의 내부, O = 개체가 아님
- `New/B-LOC  York/I-LOC  City/I-LOC  is/O  big/O`
- 태그 수 = 2N + 1 (N = 개체 범주 수)
- BIO를 쓰는 이유 — 여러 토큰에 걸친 개체와 연속된 두 개체의 경계를 구분하기 위해

평가

- 토큰 단위가 아니라 개체(스팬) 단위로 정밀도·재현율·F1을 계산한다

정보 추출

- (개체1, 관계, 개체2) 튜플 추출 / Hearst 패턴 — "X such as Y" → Y is-a X

7주차 · N-gram 언어 모델

정의

- 언어 모델 = 단어열의 확률 $P(w_1 \ldots w_n)$ 을 계산하는 모델
- 연쇄 법칙 + 마르코프 가정 → $P(w_i \mid w_1 \ldots w_{i-1}) \approx P(w_i \mid w_{i-n+1} \ldots w_{i-1})$
- 바이그램 $P(w_i|w_{i-1}) = C(w_{i-1},w_i) / C(w_{i-1})$

희소성 문제

- N이 커지면 경우의 수가 V^N 으로 기하급수적으로 늘어 대부분의 n-gram이 관측되지 않는다

스무딩 · 보간 · 백오프

- 라플라스(Add-1) : $(C+1) / (C(w_{-1})+V)$, Add-k : $(C+k) / (C(w_{-1})+kV)$
- 보간(interpolation) — 유니그램·바이그램·트라이그램을 λ 가중 평균
- 백오프(back-off) — 고차 n-gram이 없으면 저차로 내려간다

평가 — 퍼플렉서티

- PPL = $P(W)^{(-1/N)} = 2^{(}$교차엔트로피, 로그 밑 2 기준 — 7주차의 exp 형태는 자연로그 기준이며 두 표현은 동치) — 낮을수록 좋은 모델
- 미관측 n-gram이 하나라도 있으면 MLE의 PPL은 무한대가 된다

PART 5 중간고사 대비

핵심 수식 · 예상 문제 · 자가 점검

반드시 외워야 할 수식

주제	수식	주차
베이즈 정리	$P(A\|B) = P(B\|A)P(A) / P(B)$	2
엔트로피 / 퍼플렉서티	$H = -\Sigma P \log P$, $PPL = 2^H$	2·7
코사인 유사도	$(A \cdot B) / (\|\|A\|\| \|\|B\|\|)$	5
자카드 유사도	$\|A \cap B\| / \|A \cup B\|$	5
TF-IDF (5주차·sklearn)	TF(원시 빈도) × [log((1+N)/(1+DF)) + 1]	5
TF-IDF (6주차 판 - 비교용, 시험 출제는 5주차·sklearn 식)	TF(상대 빈도) × [log(N/(1+DF)) + 1]	6
F1 점수	$2 \cdot P \cdot R / (P+R)$	5·7
바이그램 확률	$C(w_{-1},w) / C(w_{-1})$	7
라플라스 스무딩	$(C+1) / (C(w_{-1}) + V)$	7
ROUGE-N	(참조와 겹치는 n-gram 수) / (참조의 n-gram 수)	6

예상 문제 (1) — 계산

문제 1 TF-IDF

- 문서 3개 중 단어 t 가 2개 문서에 등장한다. sklearn 기본식으로 IDF(t) 를 구하시오.
- 정답 : log(4/3) + 1 ≈ 1.288

문제 2 자카드 유사도

- |A| = 10, |B| = 8, |A∩B| = 4 일 때 자카드 유사도는?
- 정답 : 4 / (10+8−4) = 4/14 ≈ 0.286

문제 3 바이그램

- 코퍼스에서 C('나는') = 6, C('나는','밥을') = 3 일 때 P(밥을|나는) 은?
- 정답 : 3/6 = 0.5 (라플라스, V=100 이면 4/106 ≈ 0.038)

문제 4 F1

- TP = 30, FP = 10, FN = 20 일 때 정밀도·재현율·F1 을 구하시오.
- 정답 : P = 0.75, R = 0.60, F1 = 2(0.75)(0.6)/1.35 ≈ 0.667

예상 문제 (2) — 서술

문제 5

- 전처리 파이프라인에서 불용어 제거를 품사 태깅보다 먼저 수행하면 어떤 문제가 생기는지
- 구체적인 예를 들어 설명하시오. (오류 전파 개념 포함)

문제 6

- 원-핫 인코딩과 분산 표현의 차이를 '유사도 계산 가능 여부' 관점에서 설명하시오.

문제 7

- BIO 태깅 체계가 필요한 이유를 두 가지 이상 제시하고, 예문에 직접 태깅하시오.

문제 8

- N-gram 언어 모델에서 N을 키울 때의 장점과 단점을 희소성 관점에서 논하시오.

문제 9

- TextRank 가 단순 빈도 기반 요약보다 나은 점을 PageRank 의 재귀성으로 설명하시오.

문제 10

- 정밀도와 재현율이 상충하는 실제 사례를 하나 제시하고 어떤 지표를 우선할지 논하시오.

자가 점검 체크리스트

개념 — 설명할 수 있는가

- ☐ 자연어처리의 4단계 역사와 각 시대의 대표 기법
- ☐ 중의성의 세 가지 유형(어휘적·구조적·화용적)과 예시
- ☐ MLE 와 MAP 의 차이, 스무딩과의 관계
- ☐ 형태소·어절·품사의 정의와 한국어 9품사
- ☐ 구구조 문법과 의존 문법의 차이
- ☐ 분포 가설이 임베딩의 근거가 되는 이유

계산 — 손으로 풀 수 있는가

- ☐ TF-IDF 행렬 만들기 ☐ 자카드·코사인 유사도 ☐ 편집 거리(Levenshtein / Damerau-Levenshtein)
- ☐ 바이그램 확률과 라플라스 스무딩 ☐ 퍼플렉서티
- ☐ 혼동행렬에서 정밀도·재현율·F1 ☐ ROUGE-1 / ROUGE-L (공식과 예제는 6주차 참조)

구현 — 코드를 읽고 쓸 수 있는가

- ☐ 전처리 파이프라인 함수 ☐ TF-IDF 직접 구현 ☐ TextRank ☐ N-gram LM ☐ 규칙 기반 NER

자주 틀리는 지점 (1)

① IDF 공식

- 일반 교재의 IDF = log(N/DF) 와 scikit-learn 구현이 다르다. 본 강의(5주차)와 과제·시험은 모두 sklearn 기본식을 기준으로 한다
- IDF = log((1+N)/(1+DF)) + 1

② 자카드 합집합

- |A∪B| = |A| + |B| − |A∩B| — 교집합을 두 번 빼거나 아예 안 빼는 실수가 잦다

③ 불용어 목록을 맹신

- 'one' 은 NLTK 기본 목록(179개)에 없다. 도메인에 맞게 추가·제외 목록을 관리해야 한다

④ 전처리 순서

- 품사 태깅 전에 불용어를 지우면 태깅이 틀어지고 오류가 뒤 단계로 전파된다

자주 틀리는 지점 (2)

⑤ 의존 에지 방향

- 지배소(head) → 의존소(dependent) 방향으로 그린다

⑥ GloVe 의 분류

- Word2Vec·FastText 는 예측 기반, GloVe 는 전역 공기 행렬을 분해하는 카운트 기반이다

⑦ 어간 추출 결과

- Porter 는 규칙만 적용하므로 'battling → battl' 같은 비단어가 나온다
- 정확한 기본형이 필요하면 품사를 함께 준 표제어 추출을 써야 한다

⑧ 관용 표현과 복합어

- '미역국을 먹다'는 복합어가 아니라 관용구다

⑨ 영어의 형용사와 한국어의 관형사

- 관형사(이·그·새·헌)는 한국어 고유 품사이며, 영어 'old' 는 형용사의 한정적 용법이다

8주차 마무리

정리

- 1~7주차는 '텍스트 → 숫자' 로 가는 길을 단계별로 배운 시간이었다
- 전처리로 잡음을 줄이고, 표현으로 의미를 담고, 확률로 다음을 예측했다

9주차 이후 미리보기

- 9~10주차 질의응답·기계번역·대화 / 토픽 모델링·감성 분석·기계 독해
- 11~12주차 딥러닝 기초·Word2Vec·CNN / RNN·LSTM·Seq2Seq·어텐션
- 13~14주차 딥러닝 기반 형태소 분석·NER / 트랜스포머 기반 번역·생성
- 15주차 기말 정리 — 9~14주차 핵심 요약과 기말고사 대비
- 16주차 자연어처리의 미래와 연구 방향

복습 자료

- 각 주차 실습 노트북을 다시 실행해 보는 것이 가장 효과적인 복습이다