CHAPTER 9

질의 응답, 기계 번역, 그리고 대화 시스템

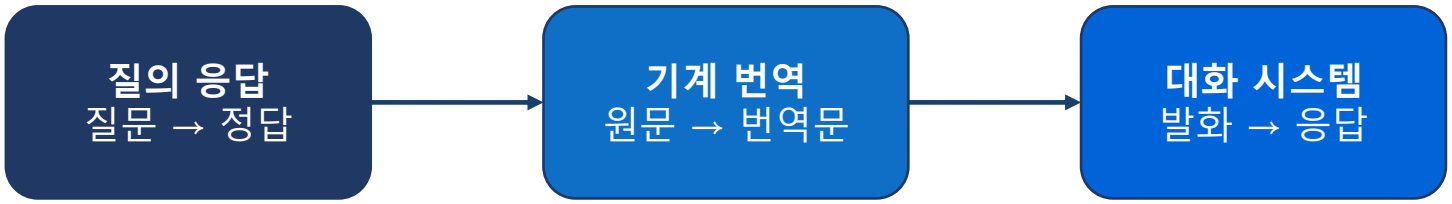
질문에 답하고 언어를 번역하는 시스템은 어떻게 만드는가?

학습 목표

- 질의 응답 (Question Answering)
  - 정보 검색 기반 질의응답의 3단계 처리 과정을 설명할 수 있다
  - Retriever–Reader 구조와 RAG 기반 질의응답의 원리를 이해한다
- 기계 번역 (Machine Translation)
  - 규칙 기반 · 통계 기반 · 신경망 기반 번역의 차이를 비교할 수 있다
  - 잡음 통로 모델과 BLEU 점수를 직접 계산할 수 있다
- 대화 시스템 (Dialogue System)
  - 대화 시스템의 5개 모듈 구성도와 슬롯 채우기를 이해한다
  - 기능대화와 일상대화의 차이 및 평가 방법을 설명할 수 있다

강의 개요: 세 가지 응용, 하나의 뼈대

입력 문장을 이해(NLU)하고 → 필요한 정보를 찾고(검색·정렬) → 자연어로 출력(NLG)한다



구분	9.1 질의 응답	9.2 기계 번역	9.3 대화 시스템
고전 기법	IR 기반 QA (질문·문서·정답 처리)	규칙 기반 / 통계 기반 (구 기반 번역)	FSA · Frame 기반 대화 관리
신경망 기법	BERT Reader DPR · RAG	seq2seq · 어텐션 Transformer	신경망 DST LLM 챗봇
평가 지표	EM · F1	BLEU · chrF · COMET	Slot Error Rate End-to-end 평가

9.1 질의 응답

Question Answering

- 질의응답이란
- 정보 검색 기반 질의응답
- 지식 기반 질의응답
- 신경망 기반 질의응답 (Reader · DPR · RAG)
- 질의응답의 평가

9.1 질의 응답 (Question Answering)

질의응답(Question Answering)이란:

- 사용자가 필요한 정보를 자연어 질문으로 입력하였을 때, 시스템이 질문에 부합하는 정답을 문서로부터 찾아 제시하는 기술
- 텍스트 콘텐츠의 폭증과 모바일·음성 환경의 도래가 질의응답 기술의 중요성을 부각시키고 있음
- 자연어처리 · 정보추출 · 정보검색 기술이 포괄적으로 적용되는 대표적 응용 기술임
- 최근에는 무인 상담 시스템, 자동 응답 챗봇, 검색 엔진의 답변 요약(AI Overview) 등으로 발전하고 있음

9.1 질의 응답 (Question Answering)

정보 검색과 질의응답의 차이:

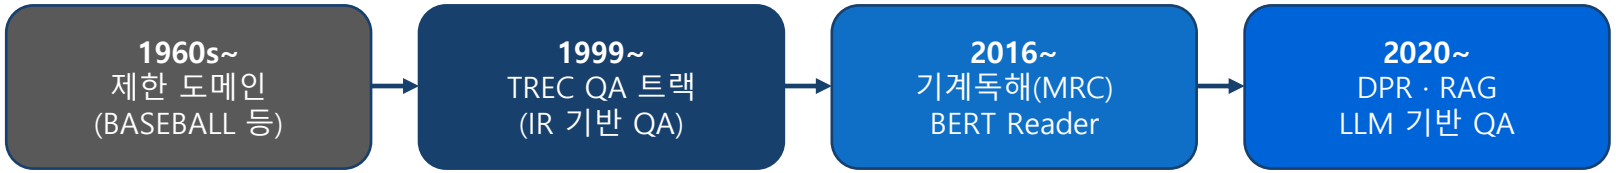
- 정보 검색은 관련 문서 목록을 반환하고, 사용자가 그 문서를 읽어 정답을 스스로 찾아야 함
- 질의응답은 시스템이 문서를 대신 읽고 정답 그 자체를 짧게 제시함

구분	정보 검색 (IR)	질의 응답 (QA)
입력	키워드 (예: 인도 독립 운동가)	자연어 질문 (예: 인도의 독립 운동을 이끈 사람은 ?)
출력	문서·웹페이지 순위 목록	정답 문자열 또는 문장 (예: 마하트마 간디)
필요 기술	색인, 유사도 계산, 순위화	IR + 질문 분석 + 정답 추출·검증
사용자 부담	문서를 직접 읽어야 함	정답을 바로 확인 (근거 확인은 필요)

9.1 질의 응답 (Question Answering)

질의응답 기술의 발전 과정:

- 초창기에는 기술 난이도로 인해 제한된 도메인·문서를 대상으로 연구가 수행됨
- TREC 질의응답 트랙의 등장으로 사실 기반(factoid) 질문 처리 기술이 발전함
- 이후 정보 추출·의미 분석 기술의 발전과 함께 오픈 도메인으로 확장됨
- 2016년 SQuAD 등 기계독해 데이터셋과 사전학습 모델로 성능이 급상승함



→ **정답을 '찾는' 문제에서, 근거 문서를 '읽고 생성하는' 문제로 확장**

9.1 질의 응답 (Question Answering)

질의응답 시스템의 분류:

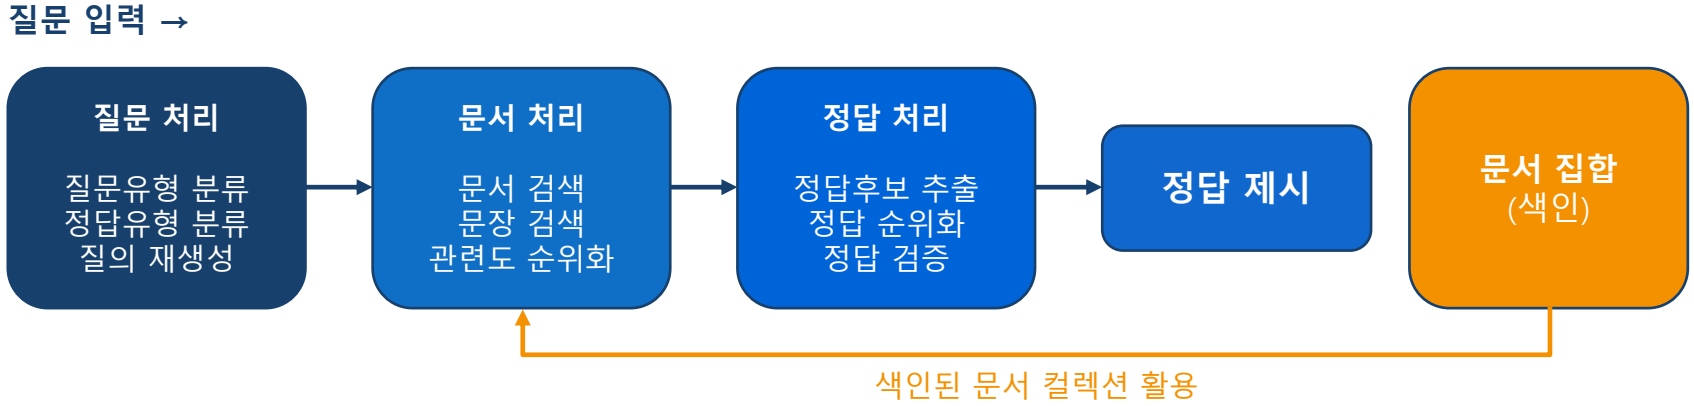
분류 기준	유형	설명 및 예시
정답 출처	정보 검색 기반 / 지식 기반 / 모델 내부 지식	문서에서 찾기 / 지식베이스 질의 / 매개변수에 저장된 지식으로 생성
질문 성격	Factoid / Non-factoid	'간디는 언제 태어났나?' / '간디는 왜 비폭력을 택했나?'
정답 생성 방식	추출형(Extractive) / 생성형(Abstractive)	문서의 구간을 그대로 추출 / 문서를 종합해 새 문장 생성
문서 범위	Closed-domain / Open-domain	의료·법률 등 특정 도메인 / 위키피디아 전체·웹

본 절에서는 ① 정보 검색 기반 → ② 지식 기반 → ③ 신경망·생성 기반 순으로 살펴본다

9.1 질의 응답 (Question Answering)

정보 검색 기반 질의응답:

- IR 기반 QA는 질문 처리 단계(question processing), 문서 처리 단계(document processing), 정답 처리 단계(answer processing)로 이루어짐



· 각 단계는 앞 단계의 결과를 단서로 사용하므로 오류가 뒤로 전파(error propagation)됨
· 예) 질문 처리에서 정답유형을 '인물'로 잘못 판단하면, 정답 처리에서 올바른 후보를 찾지 못함

9.1 질의 응답 (Question Answering)

정보 검색 기반 질의응답: 단계별 역할

- 질문 처리 단계는 질문 분석(question analysis)을 통해 질문 유형 분류와 정답 유형 분류를 수행함. 사용자의 질문을 이해하여 사용자가 요구하는 정보(정답)가 무엇인지 파악하는 것이 핵심임
- 문서 처리 단계는 문서 검색이라 불리며, 정답을 포함하고 있는 문서나 문장을 검색하는 것으로 정답과 관련성이 높은 문서를 찾아내는 것이 주요 목적임
- 정답 처리 단계는 정답 후보 추출 · 정답 순위화 · 정답 검증의 3단계로 구성됨
- 정답 순위화는 질문과 정답 후보 문장의 의미적 유사도, 정답 유형과 후보의 의미적 연관성, 키워드 중복성에 기반함

9.1 질의 응답 (Question Answering)

정보 검색 기반 질의응답: 질문 처리 단계

- 수많은 문서 안에서 알맞은 정답을 찾기 위해서는 먼저 '질문이 무엇을 묻는지' 이해하는 단계가 선행되어야 함
- 질문 처리 단계에서는 질문유형 분류와 정답유형 분류를 수행하며, 두 분류는 서로 상호의존적임
  - 질문 유형 분류: 사용자의 질문을 의문사에 기반하여 구분 (누가/언제/어디서/무엇을/왜/어떻게)
  - 정답 유형 분류: 의문사 정보와 개체명 태그, 형태소 분석 결과를 활용하여 기대되는 정답의 의미 범주를 결정
- 질문 유형은 정답 유형을 판단하기 위한 중요한 단서가 될 수 있음

9.1 질의 응답 (Question Answering)

질문 처리 단계: 의문사와 정답 유형 제약

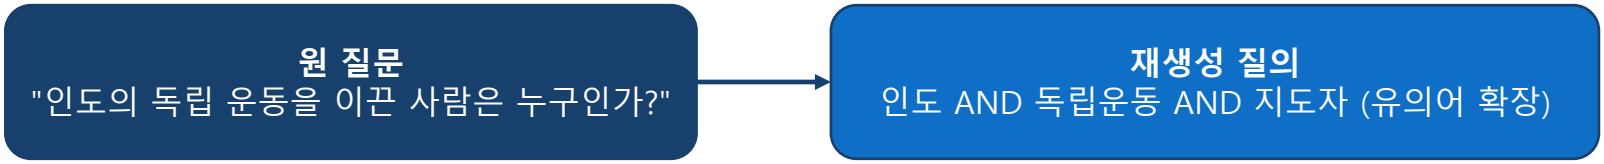
- 의문사는 정답유형을 결정할 때 중요한 단서이지만, 정답유형을 완전히 결정짓지는 못함. 다양한 정답유형에 대한 제약 정보로써 활용됨

의문사	정답 유형 제약	질문 예시
누가 / Who	인물, 기관, 단체	인도의 독립 운동을 이끈 사람은 누구인가?
언제 / When	날짜, 시간, 기간	간디가 태어난 해는 언제인가?
어디 / Where	장소, 지명, 국가	소금 행진이 시작된 곳은 어디인가?
무엇 / What	사물, 용어, 정의	비폭력 저항 운동을 무엇이라 하는가?
얼마 / How many	수량, 금액, 비율	인도의 인구는 얼마인가?
왜 / Why	이유, 원인 (서술형)	간디는 왜 비폭력 노선을 택했는가?

9.1 질의 응답 (Question Answering)

질문 처리 단계: 질의 재생성 (query reformulation)

- 질문은 단문 형태이므로 분류를 위한 단서가 부족하고, 문서 검색에 바로 쓰기에도 불리함
- 질의 재생성 단계에서는 질문 내 주요 키워드와 문장 패턴을 인식하여 검색용 질의를 새로 생성함
- 재생성된 질의는 문서 처리 단계에서 관련 문서를 검색할 때 이용됨



· 불용어 제거, 형태소 원형 복원, 유의어·상위어 확장, 개체명 가중치 부여 등을 적용
· 결론: 질문 처리 단계는 형태소 분석 결과, 개체명 인식 결과, 의문사 정보, 어절 정보, 어휘 의미 정보를 활용하여 질문유형·정답유형 분류를 진행함

9.1 질의 응답 (Question Answering)

정보 검색 기반 질의응답: 문서 처리 단계

- 문서 검색의 가장 기본적인 모델은 불리언(Boolean) 모델임
  - 질의의 각 단어가 각 문서에 출현했는지 여부를 Boolean 값으로 표시하는 방식
  - 질의어와 일치하거나 아니거나로만 나타나므로, 어떤 문서가 더 중요한지 순위를 측정할 수 없음
  - 결과 개수가 너무 많아 이를 줄이려면 질의를 다듬어 다시 물어야 하고, 이 과정에는 전문적인 능력이 필요함
- 따라서 실제 시스템에서는 단어의 가중치를 사용하는 벡터 공간 모델(TF-IDF)과 확률 모델(BM25)을 사용함

9.1 질의 응답 (Question Answering)

문서 처리 단계: 가중치 기반 검색 모델

- TF-IDF는 문서 내 단어 빈도(TF)와 전체 문서에서의 희귀성(IDF)을 곱해 단어의 중요도를 계산함

$$\text{tf-idf}(t, d) = \text{tf}(t, d) \times \log(N / \text{df}(t))$$

· 질의 벡터와 문서 벡터의 코사인 유사도로 문서를 순위화함
· BM25는 문서 길이와 빈도 포화(saturation)를 함께 고려한 개선된 확률 모델로, 현재도 강력한 기준선(baseline)임

$$\text{sim}(q, d) = \cos(vq, vd) = (vq \cdot vd) / (|vq| \, |vd|)$$

· 한계: 질의와 문서가 다른 단어를 쓰면 매칭에 실패하는 어휘 불일치(lexical gap) 문제
  예) 질의 '독립 운동가' ↔ 문서 '민족 해방 지도자' → 표면형이 달라 검색되지 않음
· 이 한계가 뒤에서 다룰 밀집 검색(dense retrieval, DPR)의 출발점이 됨

9.1 질의 응답 (Question Answering)

정보 검색 기반 질의응답: 정답 처리 단계

- 정답 처리 단계는 검색된 문서나 문장에서 정답후보에 해당하는 개체·어휘·구를 추출하는 것으로, 질문 처리 단계에서 분류된 정답유형이 중요한 단서가 됨
- 정답 유형에 따른 개체명을 기준으로 문서 처리 단계에서 얻은 관련 문서·문장을 탐색함
  - ① 정답 유형 확인 → ② 형태소 분석 · 개체명 태깅 → ③ 정답유형과 같은 범주의 후보 추출 → ④ 후보 순위화 → ⑤ 최종 정답 제시
- 정답후보는 하나가 아니라 여러 개일 수 있고, 단어가 아니라 구(phrase) 형태로도 존재할 수 있음

9.1 질의 응답 (Question Answering)

정답 처리 단계: 정답후보 추출 예시

- 질문: "인도의 독립 운동을 이끈 사람은 누구인가?" → 정답유형: 인물(PERSON)

검색된 문장: "인도의 독립 운동을 이끈 마하트마 간디는 비폭력 저항을 주장하였다. 현재 인도의 총리인 나렌드라 모디는 1950년에 태어났다."

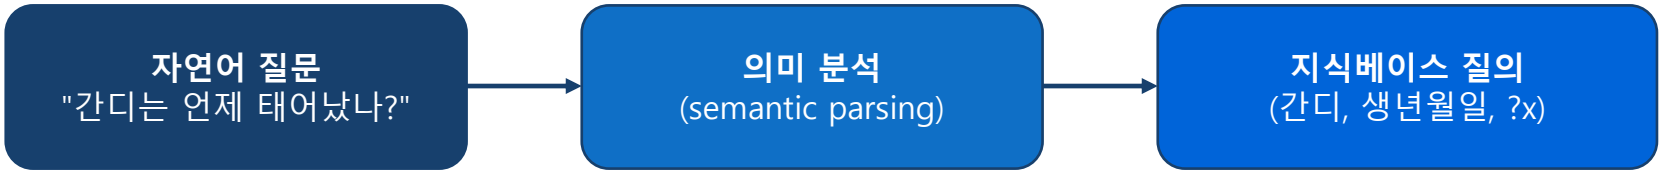
정답 후보	개체명 태그	정답유형 일치	질의 키워드 포함	최종 순위
마하트마 간디	PERSON	○	독립 운동, 인도	1
나렌드라 모디	PERSON	○	인도	2
1950년	DATE	×	-	제외
비폭력 저항	TERM	×	-	제외

순위화 기준: 정답유형 일치 여부, 질의 키워드 포함 여부, 재생성 질의와의 유사도

9.1 질의 응답 (Question Answering)

지식 기반 질의응답 (Knowledge-based QA):

- 문서 대신 구조화된 지식베이스(knowledge base)에서 정답을 찾는 방식
- 자연어 질문을 논리형(logical form) 또는 SPARQL 같은 질의어로 변환(semantic parsing)함

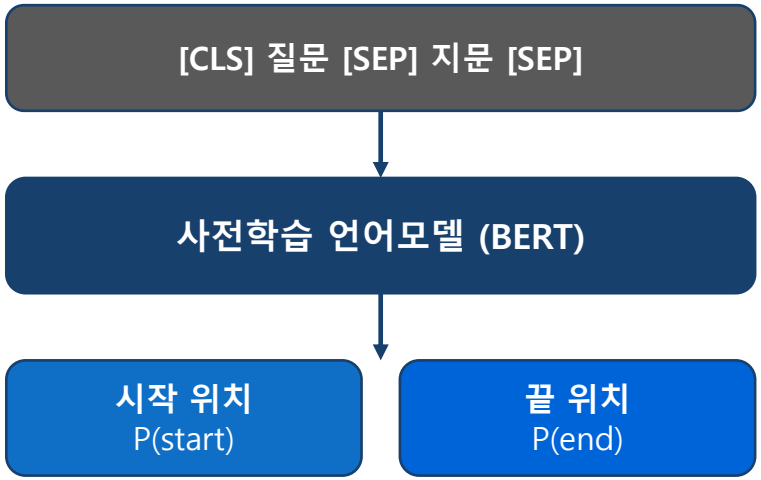


· 장점: 정답이 정확하고 근거 추적이 쉬움, 수치·날짜 등 사실형 질문에 강함
· 단점: 지식베이스 구축 비용이 크고, 지식베이스에 없는 질문에는 답할 수 없음(coverage 문제)
· 대표 자원: Freebase, DBpedia, Wikidata, 한국어 개체 지식베이스
· 최근에는 문서 기반 QA와 지식 기반 QA를 결합한 하이브리드 방식이 많이 사용됨

9.1 질의 응답 (Question Answering)

신경망 기반 질의응답 ①: 기계 독해 (MRC)

- 지문과 질문을 함께 입력해, 지문 안 정답 구간(span)의 시작·끝 위치를 예측함
- SQuAD·KorQuAD 데이터셋과 BERT 계열 모델의 결합으로 성능이 급상승함



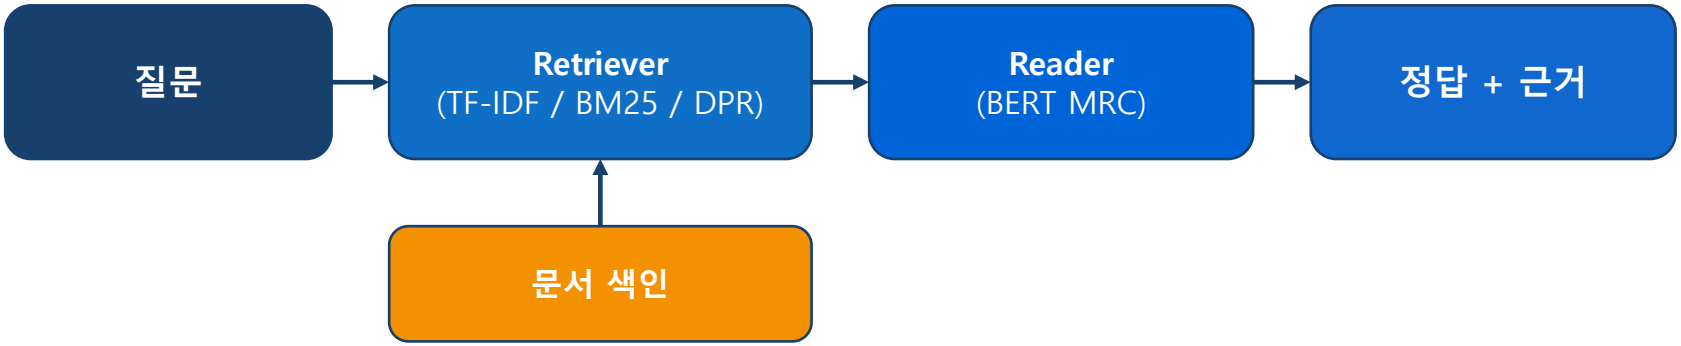
· 각 토큰의 은닉 벡터에 선형층을 붙여 start/end 확률을 계산
· 예측 구간 = argmax P(start=i)·P(end=j), 단 i ≤ j 이고 (i, j)는 지문 구간 내이며 j - i < 최대 정답 길이

· 장점: 정답 근거가 지문에 명시되어 검증이 가능함
· 한계: 정답이 지문 안에 문자열로 존재해야 함 (추론형 질문에 약함)

9.1 질의 응답 (Question Answering)

신경망 기반 질의응답 ②: Retriever–Reader 구조

- 오픈 도메인 QA는 '검색기(retriever)가 후보 문서를 좁히고, 독해기(reader)가 정답을 추출하는' 2단계로 구성됨

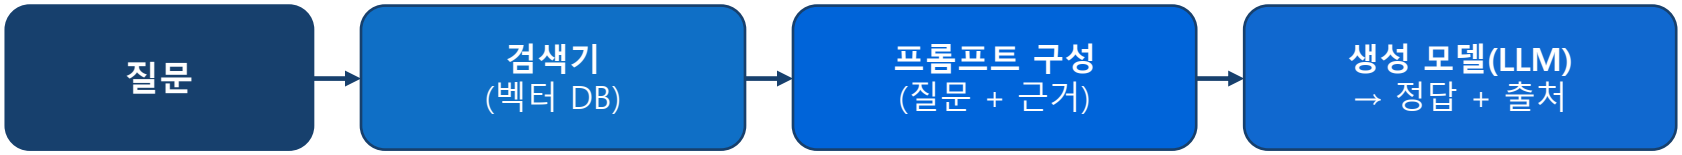


· 희소 검색(sparse): 단어 일치 기반, 빠르고 해석이 쉬움 (BM25)
· 밀집 검색(dense, DPR): 질문과 문서를 같은 임베딩 공간의 벡터로 만들고 내적으로 유사도를 계산
→ 표면형이 달라도 의미가 비슷하면 검색되므로 어휘 불일치 문제를 완화함
· 실제 시스템은 두 방식을 결합한 하이브리드 검색을 자주 사용함

9.1 질의 응답 (Question Answering)

신경망 기반 질의응답 ③: 검색 증강 생성 (RAG)

◦ RAG(Retrieval-Augmented Generation)는 검색한 문서를 생성 모델의 입력으로 넣어 정답 문장을 생성함



· 장점
  – 모델을 재학습하지 않고 최신 문서·사내 문서를 반영할 수 있음
  – 근거 문서를 함께 제시하므로 환각(hallucination)을 줄이고 출처 확인이 가능함
· 유의점
  – 검색 품질이 낮으면 생성 결과도 함께 나빠짐 (garbage in, garbage out)
  – 근거에 없는 내용을 생성하지 않도록 프롬프트와 검증 단계를 설계해야 함

9.1 질의 응답 (Question Answering)

질의응답의 평가:

◦ 추출형 QA는 정답 문자열과의 일치도로 평가함

EM = (완전히 일치한 질문 수) / (전체 질문 수)

F1 = 2 · (precision × recall) / (precision + recall) ← 토큰 단위 중첩 (KorQuAD 공식 평가는 문자 단위이므로 같은 예시가 0.50이 됨)

정답(gold)	예측(pred)	EM	토큰 F1
마하트마 간디	마하트마 간디	1	1.00
마하트마 간디	간디	0	0.67
마하트마 간디	나렌드라 모디	0	0.00

· 생성형 QA는 정답 표현이 다양하므로 EM/F1만으로는 부족 → ROUGE, BERTScore, 사람 평가, LLM 심사(LLM-as-a-judge) 병행
· 근거 제시 여부(attribution)도 중요한 평가 항목이 됨

9.1 질의 응답 (Question Answering)

9.1 정리:

- 질의응답은 자연어 질문에 대해 정답 자체를 제시하는 기술로, 정보검색·정보추출·자연어처리의 종합 응용임
- IR 기반 QA는 질문 처리 → 문서 처리 → 정답 처리의 3단계로 구성되며, 각 단계의 오류가 뒤로 전파됨
- 질문 처리는 질문유형·정답유형 분류와 질의 재생성을, 문서 처리는 불리언·TF-IDF·BM25 검색을, 정답 처리는 후보 추출과 순위화를 담당함
- 신경망 시대에는 BERT 기반 기계독해, DPR 밀집 검색, RAG 기반 생성형 QA로 발전하였으나, '질문 이해 → 근거 확보 → 정답 결정'이라는 뼈대는 동일함

9.2 기계 번역

Machine Translation

· 기계번역이란

· 규칙 기반 기계번역

· 통계 기반 기계번역 (잡음 통로 모델 · 정렬 · 구 기반)

· 신경망 기계번역 (seq2seq · 어텐션 · Transformer)

· 번역 품질의 평가 (BLEU)

9.2 기계 번역 (Machine Translation)

기계번역이란:

- 번역이란 하나의 언어로 쓰인 글을 같은 의미를 나타내는 다른 언어의 글로 변환하는 작업임
- 번역 전후 두 언어에 능숙한 사람의 수가 적고, 사람이 처리할 수 있는 번역 속도에도 한계가 있음
- 그래서 컴퓨터가 발전함에 따라 번역 작업을 컴퓨터에 맡기는 기계번역 연구가 시작됨
- 정확도가 완벽하지 않더라도, 텍스트가 매우 빠르게 생산되는 정보사회에서 지체 없이 바로 글을 읽을 수 있게 해주는 장점이 각광받아 활발히 연구되어 왔음

9.2 기계 번역 (Machine Translation)

기계번역이란: 서비스 현황

- 온라인 번역 서비스로 가장 잘 알려진 것은 구글 번역이며, 매우 많은 언어를 번역하고 입력 언어를 자동 감지하는 기능도 갖고 있음
- 일본어처럼 같은 한자에 여러 읽는 방법이 있는 언어에 대해서는 읽는 방법까지 제공하는 특징이 있음
- 최근 알려진 자연어처리의 다양한 활용 예는 딥러닝 기반 자연어처리의 활성화와 함께 시작된 것이 많음
  - 과거의 명령 인식형 대화 시스템은 정해진 입력 형식을 제공하는 것으로 충분했고, 자연어 생성도 고정된 문장 틀에 단어를 삽입하는 단순한 형태로 가능했음
  - 하지만 기계번역만큼은 시작부터 자연 언어를 그대로 입력받는 형태가 아니면 성립되지 않는 연구 분야였음

9.2 기계 번역 (Machine Translation)

기계번역이 어려운 이유:

난점	설명	예시 (한국어 ↔ 영어)
어순 차이	SOV vs SVO — 단어 순서대로 옮기면 문장이 성립하지 않음	나는 사과를 먹었다 → I ate an apple
어휘 중의성	한 단어가 여러 의미를 가져 문맥으로 판단해야 함	'배' → ship / pear / stomach
형태론 차이	한국어는 조사·어미가 결합하며 형태가 변함	먹었다 / 먹겠다 / 먹었더라면
대응 단위 불일치	한 단어가 여러 단어(구)로 번역되고 그 역도 성립	to the conference → 컨퍼런스에
문화·관용 표현	숙어·관용구는 한 번에 번역해야 자연스러움	쥐구멍에도 볕 들 날 있다

→ 이 난점들이 규칙 기반 → 통계 기반 → 신경망 기반으로 접근법이 발전한 이유가 된다

9.2 기계 번역 (Machine Translation)

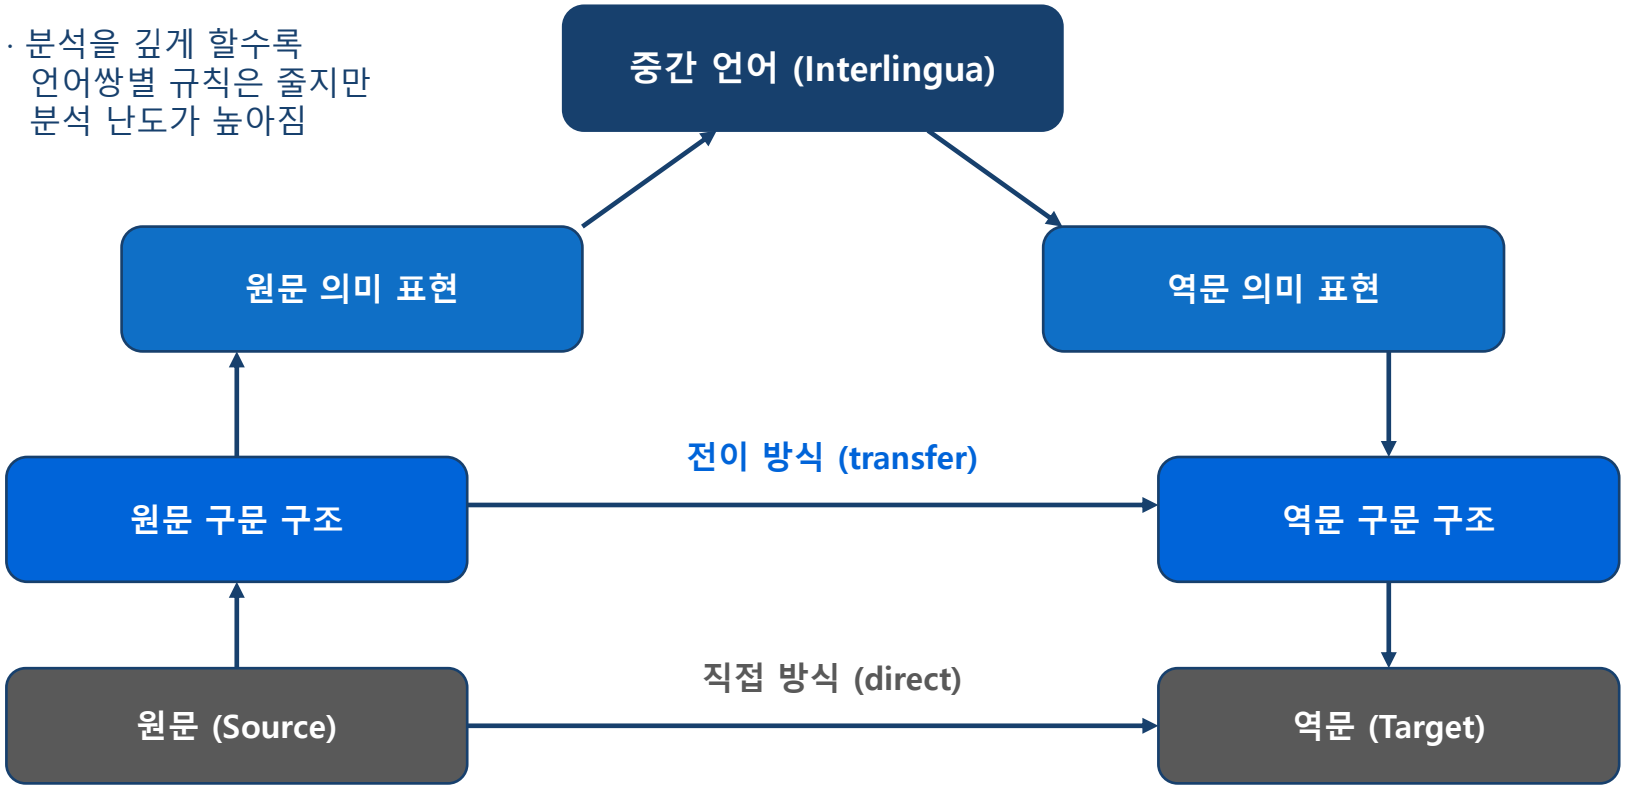
규칙 기반 기계번역 (RBMT):

- 언어학적·문법적인 규칙을 이용해 문장을 번역하는 방식
- 원본 문장을 형태소나 구문 등으로 분석하고, 핵심 단어들을 목표 언어로 번역한 후, 목표 언어의 문법 규칙에 맞게 문장을 다듬음
- 단순히 단어만 번역하는 것이 아니라 통사적·의미론적 구조를 함께 분석하고자 함
- 궁극적으로는 규칙에 기반하여 하나의 인공 통합 언어(중간 언어, interlingua)로 바꾼 후 다시 다른 언어로 규칙에 기반해 번역을 시도함

9.2 기계 번역 (Machine Translation)

규칙 기반 기계번역: 세 가지 전략 (Vauquois 삼각형)

· 분석을 깊게 할수록
  언어쌍별 규칙은 줄지만
  분석 난도가 높아짐



9.2 기계 번역 (Machine Translation)

규칙 기반 기계번역: 장점과 한계

- 장점: 문법적인 부분을 반드시 지키면서 모든 과정을 진행하므로 번역된 문장의 문법이 꽤 정확함
  - 한 언어의 규칙에 대응하는 다른 언어의 규칙을 적용하여 그대로 문장을 옮김
  - 규칙이 명시적이므로 오류의 원인을 추적하고 수정하기 쉬움
- 한계: 한국어는 형태소가 결합하면서 형태가 바뀌는 경우가 있어 분석이 어렵고, 잘못된 분석의 여파가 결과물까지 이어져 번역 내용이 쓸모 없어지는 경우가 잦았음
  - 언어쌍마다 방대한 규칙과 사전을 사람이 구축해야 하므로 확장성이 낮음
- 단어·형태소 분석기의 성능은 딥러닝의 발전과 함께 크게 개선되었고, 규칙 기반 번역이라는 핵심 요소의 가치 자체가 훼손된 것은 아니므로 딥러닝 기반 번역과 융합하려는 시도가 있음

9.2 기계 번역 (Machine Translation)

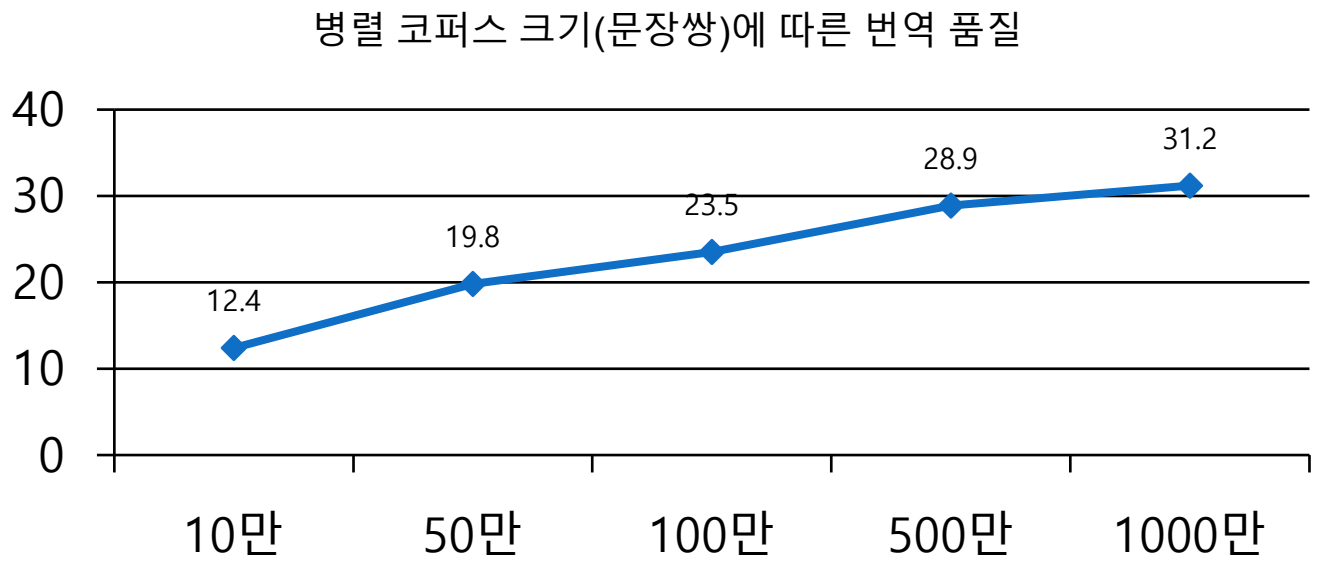
통계 기반 기계번역 (SMT):

- 대량의 예제 문장들을 바탕으로 두 언어 사이의 상관관계를 통계적으로 분석한 모델을 생성하고, 이 모델을 바탕으로 주어진 문장의 번역을 제시하는 방법
- 규칙 기반 기계번역과의 차이점
  - ① 대량의 문장을 모아둔 코퍼스를 필요로 함
  - ② 기계가 코퍼스를 통해 번역을 학습해야 하므로, 두 언어로 같은 내용을 뜻하는 문장이 서로 쌍으로 연결된 병렬 코퍼스(parallel corpus)가 필요함
- 사람이 규칙을 쓰는 대신, 데이터가 규칙을 대신하는 패러다임 전환

9.2 기계 번역 (Machine Translation)

통계 기반 기계번역: 코퍼스의 역할

- 코퍼스의 크기가 클수록 번역 품질 평가 점수가 높아지므로, 코퍼스는 통계 기반 기계번역에서 결정적으로 중요함



※ 개념 설명용 예시 수치 — 코퍼스가 커질수록 향상되지만 증가폭은 점차 둔화됨

9.2 기계 번역 (Machine Translation)

통계 기반 기계번역의 수학적 접근: 조건부 확률

- 영어 문장을 입력하면 프랑스어로 번역하는 시스템을 만든다고 가정함 (입력 E, 출력 F)
- 가장 단순한 방법은 병렬 코퍼스에서 두 문장이 쌍으로 연결된 경우를 찾는 것이며, 이는 조건부 확률로 계산할 수 있음

$$P(F \mid E) = count(E, F) / count(E)$$

$$F^* = \text{argmax}_F \; P(F \mid E)$$

입력 E는 고정되어 있으므로 count(E)는 F와 무관한 상수 → argmax는 count(E,F)만으로 결정됨

· 따라서 확률을 정의에 맞추어 풀어 쓰고 공통된 개수를 제거하면, 문장의 개수를 세는 것만으로 주어진 영어 문장에 대한 프랑스어 문장의 확률을 구할 수 있음

· 모든 프랑스어 문장에 대해 확률을 구한 뒤 가장 높은 문장을 선택하면 그것이 찾는 번역문임

9.2 기계 번역 (Machine Translation)

통계 기반 기계번역: 단순 조건부 확률의 한계

- 문장 단위 조건부 확률만으로는 기계번역을 수행할 수 없음 — 우리가 세상의 모든 문장을 알 수 없기 때문
  - 입력된 영어 문장이 코퍼스에 존재하지 않으면 확률을 구할 수조차 없음 (data sparsity)
  - 무작정 코퍼스를 키운다고 해결되지 않음 — 좋은 품질의 사람이 직접 번역한 문장쌍을 만들어야 하므로 시간과 비용이 매우 크게 소모됨
  - 언어가 무한하다는 특성 때문에 세상의 모든 문장을 담은 병렬 코퍼스는 절대 만들 수 없음
- 이를 해결하기 위해 '확률적으로 가장 높다고 추정되는 문장을 선택한다'는 핵심 개념은 유지하면서, 확률을 계산하는 방법을 달리 제시하는 다양한 방법이 도입됨 (단어·구 단위 분해)

9.2 기계 번역 (Machine Translation)

수학적으로 번역의 질을 지표화하기

- 변형된 조건부 확률로 그럴듯한 통계적 번역 방법이 제시되었으나, 궁극적으로 원하는 번역과는 거리가 있음
  - 첫째, 단어가 항상 한 가지 의미로만 번역되지는 않음 — 같은 글자라도 발음이나 의미가 여러 가지일 수 있고, 반대로 비슷한 의미의 여러 단어 중 어느 위치에 등장하는지에 따라 선택 기준이 달라짐
  - 둘째, 언어별로 단어의 변환(활용) 방법이 달라 단어를 직접 변환해도 자연스럽게 이어지지 않음
  - 셋째, 언어에 따라 어순이 다르므로 원본 언어의 단어 순서대로만 번역하면 자연스러운 번역이 나올 수 없음
- 위 문제는 번역 자체보다 '번역 후 문장의 상태'에 관한 것이므로, 문장 선택 시 번역 상태를 고려하는 변수를 추가하면 도움이 됨

9.2 기계 번역 (Machine Translation)

잡음 통로 모델 (Noisy Channel Model)

- 추가할 변수는 통계 기반 기계번역의 기초 수식에서 유도할 수 있으면 가장 좋으며, 그 방법 중 하나가 조건부 확률에 베이즈 정리를 이용하는 것임

$$F^* = \text{argmax}_F \, P(F \mid E) = \text{argmax}_F \, P(E \mid F) \cdot P(F) / P(E)$$

$$= \text{argmax}_F \, P(E \mid F) \cdot P(F)$$

번역 모델 P(E | F)
두 언어 단어·구의 대응 관계
(병렬 코퍼스에서 학습)

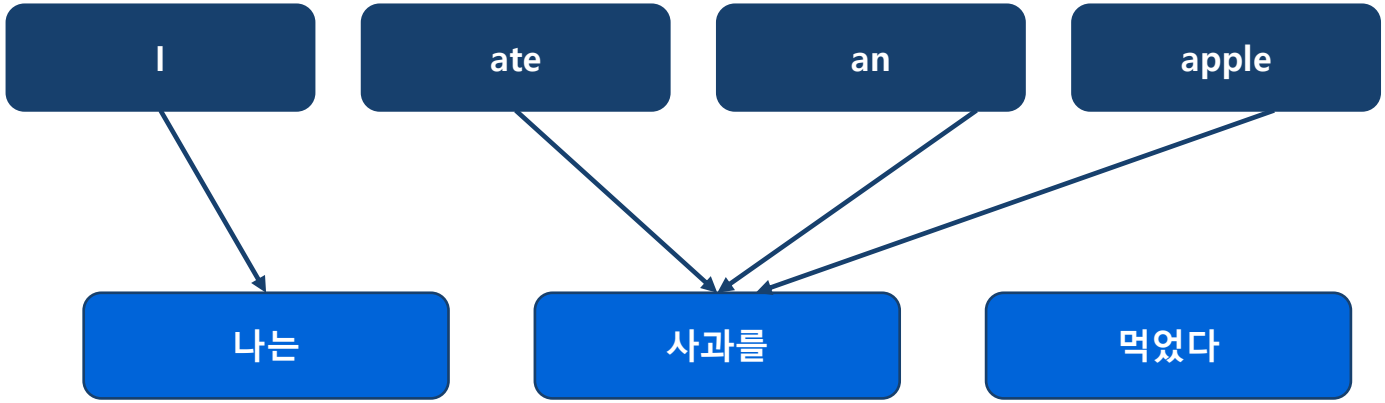
언어 모델 P(F)
목표 언어 문장의 자연스러움
(단일 언어 코퍼스에서 학습)

· P(E) 는 F 선택에 영향을 주지 않으므로 argmax 계산에서 제거됨
· 언어 모델이 어순·활용의 자연스러움을 담당하므로, 앞서 지적한 세 가지 문제를 크게 완화함

9.2 기계 번역 (Machine Translation)

단어 정렬 (word alignment)과 IBM Model

- 번역 모델을 학습하려면 문장쌍 안에서 어떤 단어가 어떤 단어에 대응하는지 알아야 함
- 정렬 정보는 사람이 표시해 주지 않으므로, EM 알고리즘으로 반복 추정함 (IBM Model 1~5)



· 정렬은 1:1이 아니라 1:다, 다:1, 교차(reordering)로 나타남 — 이것이 어순 차이를 모델링하는 방법
· 정렬 결과를 모아 '구 번역 표(phrase table)'를 만드는 것이 구 기반 번역의 출발점

9.2 기계 번역 (Machine Translation)

구 기반 번역 (Phrase-Based Model):

- 앞서 번역 과정을 설명할 때는 기본적으로 모든 분석과 번역을 단어 단위로 진행했음
- 하지만 언어에 따라 하나의 단어가 여러 개의 단어구로 번역되기도 하고, 입력/출력 언어가 바뀌면 그 반대도 충분히 가능함
- 또한 숙어나 관용구 등은 한 번에 번역되지 않으면 번역이 어색해짐
- 따라서 문장을 단어 단위로 번역하는 것이 아니라, 구(phrase)별 경계를 나눈 다음 이것을 바탕으로 작은 단위에서부터 번역을 시작하는 방법이 제시됨

9.2 기계 번역 (Machine Translation)

구 기반 번역: 예시

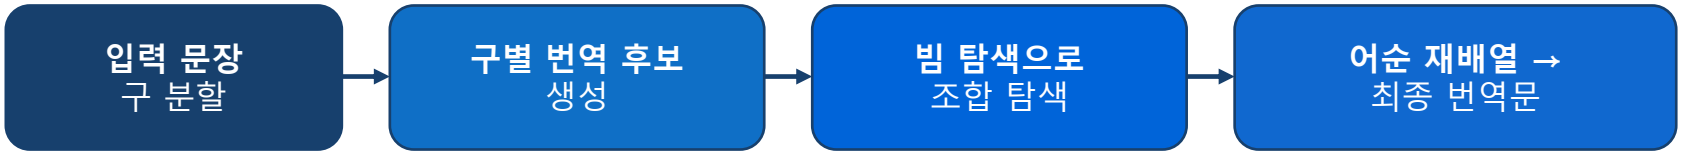
- "Tomorrow I will fly to the conference in France" 에서 to the conference 는 한국어로 "컨퍼런스에" 라는 하나의 어절로 번역됨
- 출력 언어에 맞는 순서 조절은 가장 마지막 단계에서 이루어짐 (구별로 묶기 → 번역 → 재배열)



9.2 기계 번역 (Machine Translation)

통계 모델을 이용한 실제 문장 번역 (디코딩)

- 번역 모델과 언어 모델을 조합해 통계적 모델을 만든 뒤, 입력 문장을 모델에 투입하여 번역을 수행함
- 언어 모델이 지금까지 들어온 단어를 바탕으로 다음 단어를 예측하듯이, 번역도 앞에서부터 차례로 수행한 후 점차 재조합함
- 즉, 입력 단어나 구 단위로 번역 후보군을 나열한 다음 확률이 가장 높은 순서대로 조합해 전체 문장을 번역하고, 어순에 맞추어 재조립함



· 가능한 조합의 수가 폭발적으로 늘어나므로 모든 경우를 계산하지 않고 빔 탐색(beam search)으로 상위 후보만 유지함
· 번역 모델 점수 · 언어 모델 점수 · 구 재배열 점수를 가중합한 값이 최종 점수가 됨

9.2 기계 번역 (Machine Translation)

번역 품질의 평가: BLEU

- 기계 번역문과 사람이 만든 참조 번역문의 n-gram 일치 비율(정밀도)을 기하평균한 뒤, 너무 짧은 번역에 벌점을 주는 지표

$$\text{BLEU} = \text{BP} \cdot \exp\left(\sum w_n \log p_n\right), \quad w_n = 1/N \ (\text{보통 } N = 4)$$

$$\text{BP} = \begin{cases} 1 & (c > r) \\ \exp(1 - r/c) & (c \le r) \end{cases}$$

· p_n : n-gram 정밀도 (같은 n-gram을 중복해 세지 않도록 clipping 적용)
· BP : 짧은 번역이 정밀도를 쉽게 높이는 것을 막는 길이 벌점 (c = 후보 길이, r = 참조 길이)
· 값의 범위는 0~1(또는 0~100), 값이 클수록 참조 번역과 유사함
· 한계: 어순 변화·동의어를 반영하지 못하고, 문장 단위 점수는 신뢰도가 낮음
· 보완 지표: chrF(문자 n-gram), METEOR(동의어), COMET·BERTScore(의미 임베딩 기반)

9.2 기계 번역 (Machine Translation)

BLEU 계산 예시

◦ 참조: the cat is on the mat / 후보: the cat is on mat

n	후보 n-gram 수	일치(clipped)	정밀도 p_n
1-gram	5	5	5/5 = 1.000
2-gram	4	3	3/4 = 0.750
3-gram	3	2	2/3 = 0.667
4-gram	2	1	1/2 = 0.500

BP = exp(1 − 6/5) = 0.819, BLEU = 0.819 × (1·0.75·0.667·0.5)^(1/4) ≈ 0.58

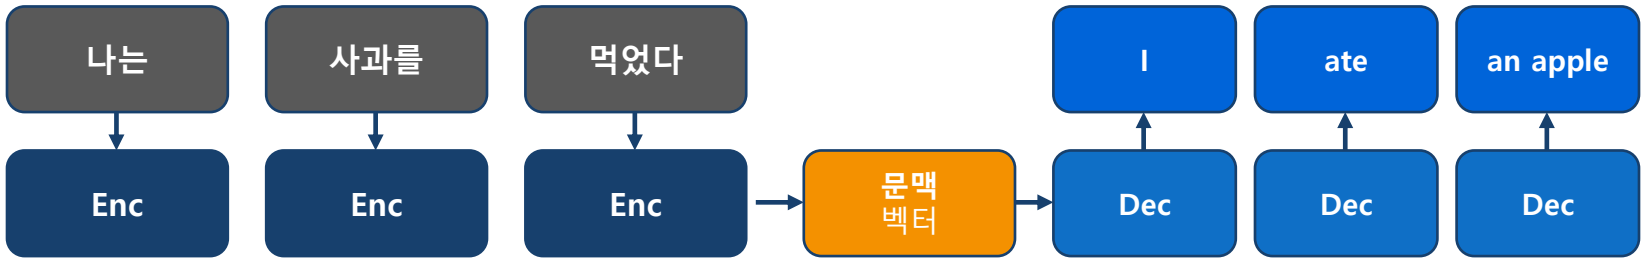
· 단어 하나(the)가 빠지면서 2~4-gram 정밀도가 함께 떨어지고 길이 벌점까지 받는 점을 확인할 것
· 실습에서 이 계산을 직접 구현하고 sacrebleu 결과와 비교한다

9.2 기계 번역 (Machine Translation)

신경망 기계번역 ①: seq2seq (인코더–디코더)

※ 은닉 상태와 RNN 의 정의는 12주차에서 자세히 다룬다 (여기서는 개념 소개)

- 인코더 RNN이 원문 전체를 하나의 문맥 벡터로 압축하고, 디코더 RNN이 그 벡터로부터 번역문을 한 단어씩 생성함



· 별도의 정렬·구 표·재배열 규칙 없이, 병렬 코퍼스만으로 종단간(end-to-end) 학습이 가능해짐
· 문제: 긴 문장의 정보를 고정 길이 벡터 하나에 담기 어려움 (information bottleneck)
· 해결: 디코더가 매 시점 원문의 어느 부분을 볼지 결정하는 어텐션(attention) 도입

9.2 기계 번역 (Machine Translation)

신경망 기계번역 ②: 어텐션 (Attention)

◦ 디코더가 단어를 생성할 때마다 인코더의 모든 은닉 상태에 가중치를 부여해 가중합(문맥 벡터)을 새로 계산함

score(s, h) = s·h, α = softmax(score), c = Σ α · h
※ score 에는 dot(Luong)·additive(Bahdanau) 등 변형이 있으며,
c(t)는 s(t)와 결합해 출력층에 넣는다

	나는	사과를	먹었다
I	0.82	0.10	0.08
ate	0.06	0.14	0.80
an apple	0.05	0.86	0.09

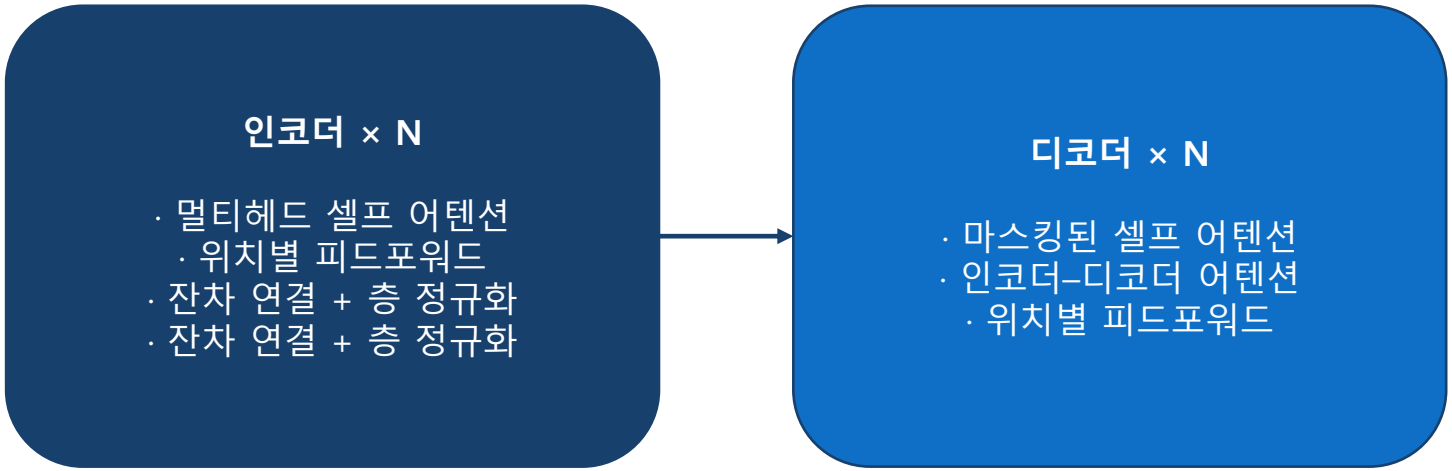
▲ 어텐션 가중치는 통계 기반 번역의 '단어 정렬'을 학습으로 대체한 것

· 교차 정렬(어순 차이)이 가중치 분포로 자연스럽게 표현되며, 번역 결과의 해석에도 활용됨

9.2 기계 번역 (Machine Translation)

신경망 기계번역 ③: Transformer

◦ RNN의 순차 계산을 제거하고 셀프 어텐션만으로 문맥을 표현
→ 병렬 학습이 가능해지고 장거리 의존 관계를 잘 포착함



· 순서 정보는 위치 인코딩(positional encoding)으로 주입
· 오늘날 상용 번역기와 대규모 언어모델의 공통 기반 구조

9.2 기계 번역 (Machine Translation)

신경망 기계번역의 실무 요소

- 서브워드 분절 (BPE, SentencePiece)
  - 어휘 사전을 유한하게 유지하면서 미등록어(OOV)를 처리 — 한국어의 교착어적 특성에도 효과적
- 역번역 (back-translation)
  - 단일 언어 코퍼스를 번역해 가짜 병렬 코퍼스를 만들어 학습 데이터를 증강함
- 다국어·제로샷 번역
  - 하나의 모델로 여러 언어쌍을 학습하면 학습 데이터가 적은 언어쌍의 성능도 향상됨
- LLM 기반 번역
  - 문맥·문체·용어집을 프롬프트로 지시할 수 있어 문서 단위 번역과 사후 교정(APE)에 강점

9.2 기계 번역 (Machine Translation)

9.2 정리:

- 규칙 기반 번역은 언어학적 규칙으로 문법 정확성을 얻지만, 규칙 구축 비용과 분석 오류 전파가 한계임
- 통계 기반 번역은 병렬 코퍼스에서 확률을 추정하며, 베이즈 정리로 번역 모델 P(E|F)과 언어 모델 P(F)로 분해함
- 단어 단위의 한계를 보완하기 위해 구 기반 번역이 제시되었고, 디코딩은 빔 탐색으로 후보를 조합함
- 신경망 번역은 seq2seq → 어텐션 → Transformer로 발전했으며, 어텐션은 통계 번역의 단어 정렬을 학습으로 대체한 것으로 볼 수 있음
- 번역 품질은 BLEU로 널리 측정하지만 의미·어순을 반영하지 못하므로 chrF·COMET 등과 함께 사용함

9.3 대화 시스템

Dialogue System

· 대화 시스템 개론

· 대화 시스템의 구현 (ASR · NLU · DM · NLG · TTS)

· 대화 관리 방식 (규칙 기반 · 데이터 기반)

· 대화 시스템의 평가

· 대화 시스템의 분류와 최신 동향

9.3 대화 시스템 (Dialogue System)

대화 시스템 개론: 대화 시스템이란

- 대화 시스템이란 자연어를 사용해 인간과 대화하는 시스템임
- 대화의 주도권에 따라 두 가지로 나눌 수 있음

사용자 주도 대화 시스템

사용자: 오늘 서울 날씨 알려줘
시스템: 맑고 최고 28도입니다
사용자: 내일은?
시스템: 흐리고 비가 옵니다

→ 사용자가 원하는 것을 자유롭게 질문
→ 유연하지만 이해 실패 위험이 큼

시스템 주도 대화 시스템

시스템: 몇 명 예약하시겠습니까?
사용자: 두 명이요
시스템: 언제 방문하시겠습니까?
사용자: 토요일 저녁 7시

→ 시스템이 필요한 정보를 차례로 질문
→ 안정적이지만 대화가 경직됨

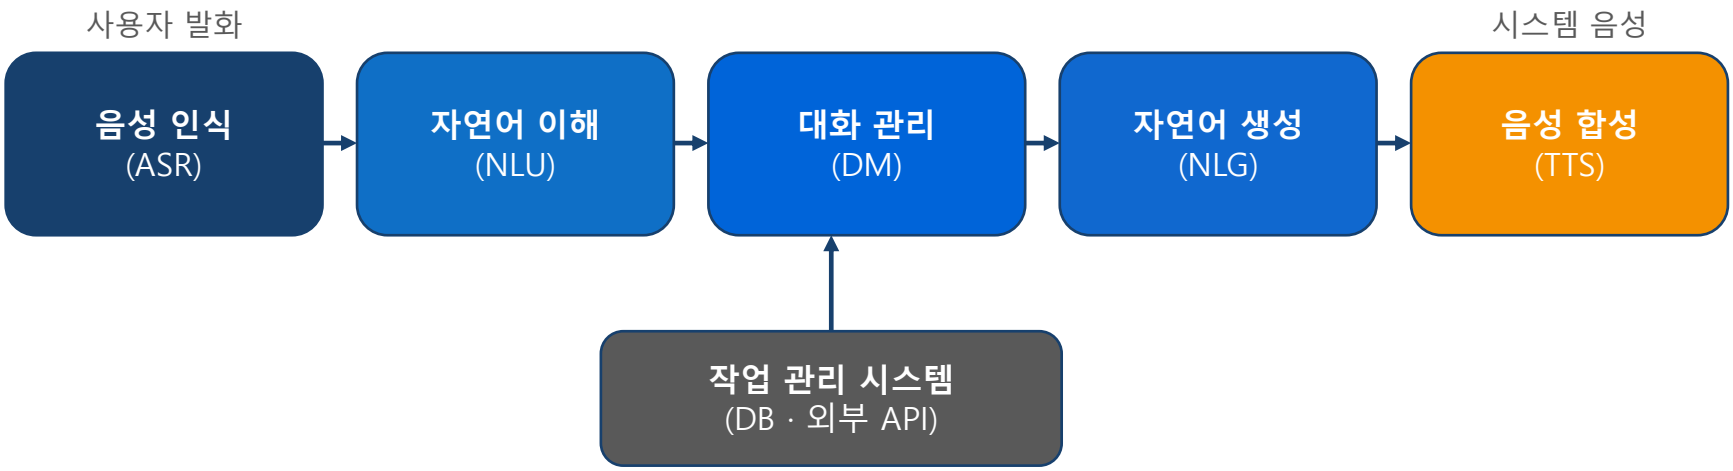
9.3 대화 시스템 (Dialogue System)

대화 시스템 개론: 대표적인 사례

- 스마트폰 음성 비서: 삼성 빅스비, 애플 시리, 구글 어시스턴트, 마이크로소프트 Cortana 등
- 인공지능 스피커 제품: 아마존 에코(Alexa), 구글 네스트, KT 기가지니, 네이버 Clova 등
- 고객 상담 챗봇: 은행·통신사·쇼핑몰의 상담 자동화, 사내 규정 문의 응답
- 최근에는 대규모 언어모델(LLM)을 기반으로 한 범용 대화 시스템이 등장하여, 특정 도메인에 한정되지 않는 자유 대화와 도구 호출(tool calling)까지 수행함

9.3 대화 시스템 (Dialogue System)

대화 시스템의 구현: 전체 구성도



모듈	입력 → 출력	핵심 과제
ASR	음성 신호 → 텍스트	잡음·발음 변이에 강한 인식
NLU	텍스트 → 의미 표현(의도+슬롯)	의도 분류, 슬롯 채우기
DM	의미 표현 → 시스템 행동	문맥 관리, 생략 복원, 예외 처리
NLG	시스템 행동 → 문장	자연스럽고 간결한 응답 생성
TTS	문장 → 음성	듣기 편한 운율·음색

9.3 대화 시스템 (Dialogue System)

대화 시스템의 구현: 처리 흐름 ①

- 먼저 사용자가 이야기를 하면 음성인식 시스템이 사용자의 음성 신호를 텍스트로 변환함. 이때 정확한 음성인식 성능이 전제되어야 함
- 텍스트로 변환된 발화는 의미 분석을 위해 자연어 이해 시스템으로 들어감
- 자연어 이해 시스템은 변환된 텍스트 문장을 의미 표현으로 변환함
  - 예: 영화 예매 발화에서 예매 장소, 상영 시간, 티켓 수, 성인/청소년 여부 등의 슬롯을 만들고 그 값을 채우는 형식으로 의미를 표현함 (이를 슬롯 채우기라고 함)

9.3 대화 시스템 (Dialogue System)

자연어 이해: 의도 분류와 슬롯 채우기

◦ 발화: "토요일 저녁 7시에 강남에서 아바타 성인 2장 예매해줘"

의도 (intent)	movie_booking
영화 (title)	아바타
장소 (location)	강남
날짜 (date)	토요일
시간 (time)	저녁 7시
인원 (count)	성인 2명

· 의도 분류: 문장 전체를 하나의 범주로 분류하는 문장 분류 문제

· 슬롯 채우기: 각 토큰에 BIO 태그를 붙이는 시퀀스 라벨링 문제 (개체명 인식과 동일한 틀)

· 두 과제를 하나의 신경망으로 함께 학습(joint learning)하면 성능이 향상됨

9.3 대화 시스템 (Dialogue System)

대화 시스템의 구현: 처리 흐름 ②

- 의미 분석이 끝나면 결과를 대화 관리 시스템으로 보냄
- 대화 관리 시스템은 작업 관리 시스템과 상호작용하면서 여러 과정을 거쳐 시스템 발화 정보를 생성함
  - 대화의 문맥, 흐름, 적용 도메인, 생략 복원, 중의성 해소, 예외 처리 등을 담당함
  - 대화의 문맥을 어떻게 저장하고 활용할지가 주로 고려되는 사항임
- 대화 관리 시스템은 문맥을 분석해 사용자가 무엇을 원하는지 파악한 뒤, 자연어 생성 시스템에서 목적에 따른 자연어를 생성함
- 생성된 문장은 음성 합성 시스템을 통해 사람과 유사하고 듣기 편한 음성으로 변환되어 사용자에게 전달됨

9.3 대화 시스템 (Dialogue System)

대화 관리 방식의 분류

- 실제 연구에서는 각 모듈의 성능을 개선하기 위해 연구자가 따로 존재할 정도로 대화 시스템 연구는 어려운 편임
- 대화 관리 시스템의 방식은 규칙 기반 접근 방법과 데이터 기반 방법으로 나누어짐

규칙 기반 접근

· 유한 상태 오토마타(FSA)
· Frame 기반

장점: 예측 가능, 소량 데이터
단점: 확장·유지보수 비용

데이터 기반 접근

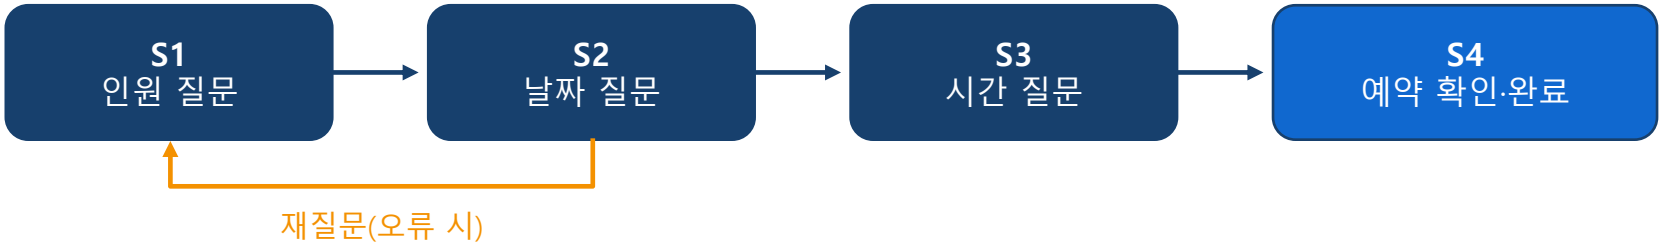
· 강화학습 (POMDP)
· 신경망 대화 상태 추적

장점: 유연·자동 개선
단점: 대량 데이터·불투명

9.3 대화 시스템 (Dialogue System)

규칙 기반 접근 ①: 유한 상태 오토마타 (FSA)

◦ 모든 경우의 수에 대해 규칙을 정해두고, 경우에 따라 대화의 문맥과 순서를 상태 전이로 표현함



· 시스템이 대화를 주도하므로 안정적이고 구현이 단순함
· 사용자가 순서를 벗어난 발화를 하면 처리하기 어려움 ("아, 날짜를 바꿀게요")
· 상태 수가 늘어나면 전이 규칙이 폭발적으로 증가함 → 대규모 서비스에는 부적합
· 실무에서는 여전히 간단한 ARS·주문 봇에 널리 사용됨

9.3 대화 시스템 (Dialogue System)

규칙 기반 접근 ②: Frame 기반 대화 관리

- Frame이라는 규칙과 규칙 간의 우선순위가 있고, 비어 있는 슬롯에 대해 사용자에게 질문하며 문맥을 이해하는 형식으로 구성됨
- 동작 방식은 사용자가 주도하여 정보를 요구하는 형식도 가능함 (mixed initiative)

슬롯	현재 값	시스템 행동
출발지	서울	채워짐 → 질문하지 않음
도착지	(비어 있음)	우선순위 1 → "어디로 가십니까?"
날짜	(비어 있음)	우선순위 2 → 도착지 확보 후 질문
인원	1명 (기본값)	기본값 사용, 필요 시 확인

→ 빈 슬롯이 모두 채워지면 작업 관리 시스템(예약 API)을 호출함

9.3 대화 시스템 (Dialogue System)

데이터 기반 접근: 강화학습 기반 대화 관리

- 데이터 기반 방법에서 대표적인 방법은 강화학습 방법임
- 대화를 '상태–행동–보상'의 순차 의사결정 문제로 보고, 목표 달성 시 보상을 주어 정책(policy)을 학습함



· 불확실한 음성 인식·이해 결과를 확률 분포로 다루는 POMDP 기반 대화 관리로 발전함
· 최근에는 신경망 기반 대화 상태 추적(DST)과 결합하고, 사용자 시뮬레이터로 학습 데이터를 확보함

9.3 대화 시스템 (Dialogue System)

대화 시스템의 평가

- 좋은 대화 시스템이란 무엇인가? 대화 시스템의 평가는 어떻게 이루어질까?
- 평가 방식은 크게 두 가지가 있음
  - ① Slot Error Rate: 문장의 슬롯 채우기를 얼마나 정확히 했는지 평가
  - ② End-to-end evaluation: 대화 전체가 목적을 달성했는지 평가 (예: 올바른 약속 정보가 달력에 잘 저장되었는지 확인)
- 이 외에 대화 턴 수, 작업 완료율, 사용자 만족도 설문 등이 함께 사용됨

9.3 대화 시스템 (Dialogue System)

대화 시스템의 평가: Slot Error Rate 예시

◦ 발화: "Make an appointment with Chris at 10:30 in Gates 104"

슬롯	정답 값	시스템이 채운 값	판정
PERSON	Chris	Chris	○
TIME	10:30	11:30	×
ROOM	Gates 104	Gates 104	○

Slot Error Rate = (치환 + 삽입 + 삭제) / 전체 참조 슬롯 수 = 1 / 3 ≈ 0.33

· 3개의 슬롯 값 중 두 개는 맞고 하나는 틀렸으므로 SER은 1/3이 됨
· SER이 낮아도 대화가 실패할 수 있으므로 End-to-end 평가를 함께 봐야 함
· 일상대화는 정답이 하나가 아니므로 perplexity, 사람 평가(적절성·일관성·안전성)로 평가함

9.3 대화 시스템 (Dialogue System)

대화 시스템의 분류: 기능대화 (Task-oriented dialogue)

- 대화 시스템은 크게 기능대화(Task-oriented dialogue)와 일상대화(Social conversation)로 나누어짐
- 기능대화는 대화의 목적이 분명함. 사용자는 원하는 목적이 분명하게 있고, 대화를 통해 어떤 목적이 결과로 나타나길 바람 (이를 Task-Completion이라 함)
- 대화의 목적은 고정되어 있지 않고 대화가 진행됨에 따라 다이나믹하게 변화함
  - 예: 식당 예약을 하다가 주차 공간을 물어보면 restaurant booking → parking 으로 바뀜

9.3 대화 시스템 (Dialogue System)

대화 시스템의 분류: 기능대화의 특징

- 기능대화는 목적이 분명하며, 이는 대화가 진행되며 수시로 바뀌는 성질을 가짐
- 기능대화는 Domain-specific한 특징을 갖고 있음
  - 비행기 티켓 예매와 영화 티켓 예매는 동일해 보이지만 도메인은 전혀 다르며, 이는 모델 학습에 중요한 영향을 미침
  - 도메인이 무작정 늘어나면 처리하기 어려우므로 최근에는 transfer learning 등을 활용한 domain adaptation 연구가 많이 진행됨
- 마지막으로 기능대화는 명확한 답이 존재함 — 사용자가 호텔을 예약하고 싶으면 결과는 반드시 호텔 예약이 되어야 함

9.3 대화 시스템 (Dialogue System)

대화 시스템의 분류: 일상대화 (Social conversation)

- 일상대화는 기능대화와 달리 대화 자체가 목적임
  - 카페에서 수다를 떠는 상황을 생각해 보면, 어떤 목적을 이루기 위해서가 아니라 말 그대로 대화를 나누기 위해 대화함
  - 인간은 사회성을 지닌 동물이고, 사회적 관계를 유지하기 위해 이러한 잡담(chit-chat)을 함
- 일상대화는 Domain-specific하지 않고 Open-domain으로 이루어짐 — 대화의 도메인이 정해져 있지 않음
- 또한 기능대화와 다르게 여러 개의 정답을 가짐
  - 예: "오늘 너무 춥다"라는 발화에는 공감·정보 제공·농담 등 다양한 반응이 모두 적절할 수 있음

9.3 대화 시스템 (Dialogue System)

기능대화와 일상대화의 특징 정리

구분	기능대화 (Task-oriented)	일상대화 (Social conversation)
대화의 목적	명확한 작업 완료 (Task-Completion)	대화 자체 (사회적 관계 유지)
도메인	Domain-specific (예약, 주문)	Open-domain (주제 제한 없음)
정답	명확한 하나의 정답	여러 개의 적절한 응답
구현 방식	슬롯 채우기 + 대화 관리 + API 호출	생성 모델 (seq2seq, LLM)
주요 평가	작업 완료율, Slot Error Rate, 턴 수	적절성·일관성·안전성 사람 평가
대표 예시	항공 예약 봇, 상담 챗봇	심심이, 페르소나 챗봇, 범용 AI 채팅

9.3 대화 시스템 (Dialogue System)

대화 시스템의 최신 동향

- 신경망 대화 상태 추적(DST): 매 턴 전체 대화 이력을 입력해 슬롯 값을 직접 생성하므로, 사전에 정의된 값 목록에 얽매이지 않음
- 종단간(end-to-end) 대화 모델: NLU–DM–NLG를 하나의 생성 모델로 통합함
- LLM 기반 대화 시스템: 프롬프트로 역할·정책을 지정하고, 함수 호출(tool calling)로 예약·검색 등 실제 작업을 수행함
- RAG 결합: 사내 문서·매뉴얼을 검색해 근거와 함께 답하도록 하여 환각을 줄임 (9.1의 RAG와 동일한 구조)
- 안전성·정책 준수: 개인정보 노출, 유해 발화, 근거 없는 단정에 대한 필터링과 사람 검토(HITL)가 실무의 핵심 과제

세 응용을 관통하는 하나의 구조

- 질의응답 · 기계번역 · 대화시스템은 모두 '이해 → 탐색·정렬 → 생성'의 파이프라인으로 볼 수 있음



응용	이해	탐색 · 정렬	생성
질의응답	질문유형·정답유형 분류	문서 검색 · 정답 후보 순위화	정답 문자열 / 근거 기반 답변
기계번역	형태소·구문 분석 / 인코딩	단어 정렬 · 어텐션 · 빔 탐색	목표 언어 문장
대화시스템	의도 분류 · 슬롯 채우기	대화 상태 추적 · 정책 결정	시스템 응답 발화

요약

- 질의응답에서는 질의응답의 정의, 정보 검색 기반 질의응답(질문 처리·문서 처리·정답 처리)과 지식 기반 질의응답, 그리고 BERT Reader·DPR·RAG 기반 최신 질의응답을 살펴봄
- 기계번역에서는 기계번역의 정의, 규칙 기반 기계번역, 통계 기반 기계번역(잡음 통로 모델·단어 정렬), 구 기반 번역, 통계 모델을 이용한 실제 문장 번역, 그리고 seq2seq·어텐션·Transformer 기반 신경망 번역과 BLEU 평가를 살펴봄
- 대화 시스템에서는 대화 시스템 개론, 5개 모듈의 구성도, 규칙 기반(FSA·Frame)과 데이터 기반(강화학습) 대화 관리, Slot Error Rate와 End-to-end 평가, 기능대화와 일상대화의 분류 및 LLM 기반 최신 동향을 살펴봄
- 세 응용은 모두 '이해 → 탐색·정렬 → 생성'이라는 공통 뼈대를 가지며, 규칙 → 통계 → 신경망으로 발전해 왔음

참고서적

- 전창욱, 최태균, 조중현, 신성진 지음, 텐서플로 2와 머신러닝으로 시작하는 자연어 처리, 위키북스
- 홉슨 레인, 하네스 막스 하프케, 콜 하워드, 파이썬으로 배우는 자연어 처리 인 액션, 제이펍
- 쇼햄 고시, 드와이트 거닝, 예제로 배우는 자연어 처리 기초, 에이콘
- 임희석, 자연어처리 바이블 — 핵심이론 응용 시스템 딥러닝, 휴먼싸이언스
- Jurafsky & Martin, Speech and Language Processing (3rd ed. draft), Ch. 14 Question Answering · Ch. 13 Machine Translation · Ch. 15 Chatbots & Dialogue Systems

질문 및 정리

1. IR 기반 질의응답의 3단계에서 오류가 전파되는 과정을 예로 설명해 보자

2. 잡음 통로 모델에서 언어 모델 P(F)가 필요한 이유는 무엇인가?

3. BLEU가 높아도 번역 품질이 나쁠 수 있는 경우는?

4. 기능대화와 일상대화의 평가 방법은 왜 달라야 하는가?