CHAPTER 10

토픽 모델링, 감성 분석, 그리고 기계 이해

문서의 주제와 감정을 어떻게 파악하는가?

학습 목표

- 토픽 모델링
- 감성 분석
- 기계 독해 (기계 이해)

10주차 개요

- 핵심 질문 :
  - 문서의 주제와 감성은 어떻게 파악하는가?
- 세 가지 관점에서 문서를 이해함
  - 무엇에 관한 글인가? → 토픽 모델링 (주제 발견)
  - 어떤 감정을 담고 있는가? → 감성 분석 (태도 판별)
  - 무엇을 묻고 답할 수 있는가? → 기계 독해 (내용 이해)
- 세 과제 모두 텍스트를 수치 표현으로 바꾸어 처리한다는 공통점을 가짐
  - 토픽 모델링은 비지도 학습, 감성 분석은 지도 학습, 기계 독해는 사전학습 모델의 미세 조정을 주로 사용함

10.1 토픽 모델링

- 학습 목표 :
  - 토픽 모델링과 토픽 모델링의 활용 분야를 설명함
  - 토픽 모델링 알고리즘을 설명함
  - LSA의 동작 원리에 대해서 설명함
  - LDA의 동작 원리에 대해서 설명함
- 다양한 토픽 모델링 알고리즘을 살펴보고, 그 알고리즘을 활용해 데이터셋에 토픽 모델링을 수행하는 방법에 대해서 알아보고자 함

10.1 토픽 모델링

- 소개 (1/2) :
  - 자연어 처리에서 인기 있는 개념인 토픽 모델링에 중점을 둠
  - 토픽 모델링은 문서 모음에서 의미를 포착하는 간단한 방법임
  - 여기서 문서란 의미상 하나로 묶이는 단어들의 집합으로, 프로젝트에 따라 트윗만큼 짧거나 기사만큼 길 수 있음
  - 토픽 모델은 일련의 텍스트에 포함된 개념들에 대한 정보를 포착함, 이러한 개념을 사용해 문서를 다양한 범주나 토픽으로 묶을 수 있음
  - 토픽 모델링은 대부분 자체적으로 토픽을 찾아내는 비지도 학습 알고리즘을 사용해 수행함

10.1 토픽 모델링

- 소개 (2/2) :
  - 토픽 모델링 알고리즘은 문서에서 단어나 토큰에 대한 통계 분석을 수행한 후 해당 통계를 사용해 토픽에 문서를 자동으로 할당함
  - 잠재 의미 분석(Latent Semantic Analysis, LSA)과 잠재 디리클레 할당(Latent Dirichlet Allocation, LDA) 같은 몇 가지 유명한 토픽 모델링 알고리즘을 살펴봄
  - 토픽 모델링 알고리즘은 지도 학습 알고리즘이 아니라 비지도 학습 알고리즘을 사용함
  - 이는, 훈련 중에 학습할 토픽이 지정된 예시를 제공하지 않아도 된다는 것을 의미함
  - 토픽 모델링은 흥미로운 토픽을 발견하는 데 도움을 줄 뿐만 아니라 토픽으로 텍스트에 레이블을 지정하는 데 드는 수작업의 노력을 줄여 줌

10.1 토픽 모델링

- 토픽 찾기 (1/2) :
  - 토픽 모델링의 주요 목표는 문서 집합을 분류하는 데 사용할 수 있는 일련의 토픽들을 찾는 것임
  - 어떤 토픽이 있는지 미리 알 수 없기 때문에 토픽은 잠재적(latent)임
    - 토픽은 이름을 갖고 있지 않음
    - 단지 몇몇 문서들이 서로 비슷하며 문서들의 토픽으로 정리할 수 있다고 추측할 뿐임
  - 따라서, 토픽은 항상 인간이 인지할 수 있는 토픽과 직접적으로 일치하지 않을 수도 있음
  - 토픽은 여러 문서가 공유하는 잠재 요인이므로 토픽 개수는 문서의 개수보다 훨씬 더 적어야 함

10.1 토픽 모델링

- 토픽 찾기 (2/2) :
  - 선택한 토픽 개수는 문서의 수와 프로젝트의 목적에 따라 달라짐
  - 문서가 많거나 문서가 상당히 다양할 경우에는 토픽 개수를 늘리고 싶을 수 있음, 반대로, 작은 문서 집합을 분석하는 경우에는 토픽 개수를 줄일 수도 있음
  - 만약, 문서 집합에 본질적으로 많은 수의 토픽이 포함되어 있다고 생각되는 경우, 유사한 개수의 토픽을 찾도록 알고리즘을 구성해야 함
  - 토픽 개수 K는 하이퍼파라미터이므로 정량 지표(응집도, 혼란도)와 정성 평가를 함께 사용해 결정함

10.1 토픽 모델링

- 토픽 모델링 적용 분야 :
  - 테마 찾기
  - 탐색적 데이터 분석
  - 문서 클러스터링
  - 차원 축소
  - 역사적 분석
  - 추천 및 검색 (의미 기반 문서 색인)

10.1 토픽 모델링

- 테마 찾기 :
  - 보통 텍스트 문서 모음을 확인할 때는 문서에 어떤 테마나 토픽이 포함되어 있는지 파악하고 싶어함
  - 그런 다음, 찾아낸 테마를 사용해 문서를 분류할 수 있으며, 추가적인 분석에 활용할 수도 있음
  - 예시 :
    - 많은 문서 조사가 필요한 법률 검색에서 문서들을 테마별로 분류하는 데 사용 가능
    - 온라인 텍스트 자원에서 테마를 발견하기 위해 토픽 모델링을 사용 가능
    - 고객 문의(VOC) 로그에서 반복적으로 제기되는 불만 유형을 발견 가능

10.1 토픽 모델링

- 탐색적 데이터 분석 :
  - 머신러닝 프로젝트를 수행하기 전에 탐색적 데이터 분석을 하는 것이 좋음
  - 왜냐하면 데이터를 이해하고 데이터 안에 있는 항목들의 확률 분포를 파악할 수 있도록 도와 주기 때문임
  - 이를 통해, 사용할 특정 알고리즘을 선택할 수 있는 더 좋은 위치에 있게 될 것임
  - 이때 탐색적 데이터 분석에 토픽 모델링을 사용한다면,
    - 토픽 모델링은 텍스트 데이터를 탐색하고 자연스럽게 텍스트 데이터를 그룹 지을 수 있는 좋은 방법임
    - 토픽 모델링은 데이터가 균일하게 분포하는지, 특정한 방식으로 한쪽에 치우쳐져 있는지 이해하는 데 도움이 됨

10.1 토픽 모델링

- 문서 클러스터링 :
  - 클러스터링은 유사한 항목을 함께 묶는 방식으로 일련의 항목들을 그룹화하는 것을 포함함
  - 클러스터링 프로젝트 결과는 자동으로 할당된 클러스터 ID와 그룹으로 묶인 데이터 항목들의 집합임
  - 문서를 BoW·TF-IDF로 표현하면 어휘 크기만큼 차원이 커져 거리 계산이 잘 동작하지 않음
  - 따라서, 토픽 분포를 먼저 구한 뒤 그 위에서 군집화를 수행하면 더 안정적인 결과를 얻을 수 있음

10.1 토픽 모델링

- 차원 축소 :
  - 머신러닝의 과제 중 하나는 고차원 데이터 처리임
  - 차원은 데이터가 변화하는 축임
  - 문서는 많은 다른 단어들을 포함하고 있기 때문에 본질적으로 차원이 매우 큼
  - 각 단어는 한 문서를 다른 문서와 구분할 수 있는 피처로 간주할 수 있음
  - 따라서, 토픽 모델링은 머신러닝 프로젝트에 대비해 차원 축소를 수행하는 한 가지 방법임
    - 예 : 어휘 수 20,000개의 문서 벡터 → 토픽 20개의 벡터로 축약

10.1 토픽 모델링

- 역사적 분석 :
  - 시기별로 문서를 나눈 뒤 각 시기의 토픽 분포를 비교하면 관심사의 변화를 추적할 수 있음
    - 예 : 연도별 신문 기사에 토픽 모델링을 적용해 사회적 이슈의 등장과 소멸을 관찰함
    - 예 : 학술 논문 초록을 분석해 연구 주제의 흐름 변화를 파악함
- 추천 및 검색 (의미 기반 문서 색인) :
  - 문서를 토픽 벡터로 표현하면 단어가 정확히 겹치지 않아도 의미가 비슷한 문서를 찾을 수 있음
  - 사용자가 읽은 문서의 토픽 분포와 가까운 문서를 추천하는 방식으로 활용함

10.1 토픽 모델링

- 단어 모음 (Bag of Words) :
  - 모델링 알고리즘이 무엇인지 알아보기 전에 몇 가지 간단한 가정을 수행해야 함
  - 첫째, 문서를 단어 모음(BoW)으로 취급하는데, 이는 문서의 구조와 문법을 무시하고 문서에 대한 패턴을 추론하기 위해 단지 문서 안에 있는 단어 개수를 사용한다는 것을 의미함
  - 구조, 순서, 문법을 무시할 수 있다면 추론을 위해 개수와 확률에 의존하는 특정한 알고리즘을 사용할 수 있음
  - 반면에 순서나 구조를 무시할 경우에는 약간의 정보를 잃어버림
  - 단어 모음은 각각의 고유 단어와 문서에서 출현하는 단어의 정수형 개수를 담고 있는 사전임

10.1 토픽 모델링

- 문서-단어 행렬과 가중치 :
  - 문서 모음 전체를 하나의 행렬로 표현한 것이 문서-단어 행렬(Document-Term Matrix)임
    - 행은 문서, 열은 어휘 사전의 단어, 원소는 출현 빈도임
  - 단순 빈도는 'the', '그리고'와 같이 자주 등장하지만 변별력이 없는 단어에 큰 값을 부여하는 문제가 있음
  - TF-IDF는 이 문제를 보정하는 가중치 방식임
    - TF(t, d) : 문서 d에서 단어 t가 등장한 빈도
    - IDF(t) = log(N / df(t)) : 단어 t가 등장한 문서 수가 적을수록 큰 값을 가짐
    - TF-IDF(t, d) = TF(t, d) × IDF(t)

10.1 토픽 모델링

- 토픽 모델링 알고리즘 :
  - 가정 :
    - 토픽에는 단어들의 집합이 포함되어 있음
    - 문서는 일련의 토픽들로 구성되어 있음
  - 토픽은 확인되지는 않지만 숨겨진 단어 생성기로 가정함
  - 이러한 가정 후, 여러 알고리즘들은 토픽을 발견하는 방법에 따라서 달라짐
  - 본 장에서는 LSA와 LDA를 이용한 토픽 모델링 알고리즘을 다룸

10.1 토픽 모델링

- 잠재 의미 분석 (LSA) (1/3) :
  - 개념 :
    - 특히 문서 색인의 의미 검색에 사용함
    - 목표는 문서와 단어의 기반이 되는 잠재적인 토픽을 발견하는 것임
    - 이러한 잠재적인 토픽은 문서에 있는 단어들의 분포를 주도한다고 가정함
  - LSA의 동작 방식 :
    - 문서 모음을 갖고 있는 것으로 가정하고, 위 문서들은 단어들로 구성함
    - 목표는 문서에서 잠재적인 토픽을 발견하기 위해 통계 분석을 수행하는 것임
    - 문서-단어 행렬로 나타낼 수 있는 문서 모음을 갖고 있다고 가정함

10.1 토픽 모델링

- 잠재 의미 분석 (LSA) (2/3) :
  - 특이값 분해 (Singular Value Decomposition, SVD) :
    - 앞서 정의한 문서-단어 행렬 A를 세 개의 행렬로 분해함
    - $A(N \times M) \approx U(N \times K) \times \Sigma(K \times K) \times V^T(K \times M)$ (N : 문서 수, M : 어휘 수, K : 토픽 수)
      - U : 문서-토픽 행렬 (각 문서가 어떤 토픽으로 구성되는지)
      - Σ : 토픽 중요도를 나타내는 대각 행렬 (특이값)
      - V^T : 토픽-단어 행렬 (각 단어가 어떤 토픽과 관련되는지)
      - 행렬을 전치하면 단어-문서 기준으로도 동일하게 전개할 수 있음
    - 상위 K개의 특이값만 남기는 절단된 SVD(Truncated SVD)를 사용해 차원을 축소함

10.1 토픽 모델링

- 잠재 의미 분석 (LSA) (3/3) :
  - 장점 :
    - 구현이 간단하고 계산이 빠르며, 동의어 문제를 어느 정도 완화함
    - 문서 간 의미적 유사도 계산에 바로 활용할 수 있음
  - 단점 :
    - 특이값 분해의 결과에 음수가 포함되어 토픽을 확률로 해석하기 어려움
    - 새 문서는 기존 분해 결과로 사영(fold-in)할 수 있으나, 어휘·잠재 공간을 갱신하려면 재분해가 필요함
    - 한 단어가 여러 의미를 갖는 다의어 문제를 제대로 다루지 못함
  - 실제 구현 : scikit-learn의 TruncatedSVD, gensim의 LsiModel

10.1 토픽 모델링

- 잠재 디리클레 할당 (LDA) (1/3) :
  - 개념 :
    - 문서가 만들어지는 과정을 확률적으로 가정한 생성 모형임
    - 각 문서는 여러 토픽의 혼합이며, 각 토픽은 여러 단어의 확률 분포임
  - 가정하는 문서 생성 과정 :
    - 1. 문서 d의 토픽 분포 θ를 디리클레 분포에서 뽑음
    - 2. 문서의 각 단어 위치마다 토픽 z를 θ에서 뽑음
    - 3. 선택된 토픽 z의 단어 분포 φ에서 실제 단어 w를 뽑음
  - 관측된 것은 단어 w뿐이므로, 역으로 θ와 φ를 추정하는 것이 학습 과정임

10.1 토픽 모델링

- 잠재 디리클레 할당 (LDA) (2/3) :
  - 하이퍼파라미터 :
    - α (알파) : 문서-토픽 분포의 사전 분포를 조절함
      - 값이 작으면 문서가 소수의 토픽에 집중되고, 크면 여러 토픽에 고르게 퍼짐
    - β (베타) : 토픽-단어 분포의 사전 분포를 조절함
      - 값이 작으면 토픽이 소수의 단어로 뚜렷해지고, 크면 많은 단어에 퍼짐
    - K : 토픽의 개수, 분석자가 직접 지정해야 하는 값임
  - 추론 방법 :
    - 깁스 샘플링(Gibbs Sampling)과 변분 추론(Variational Inference)이 주로 사용됨

10.1 토픽 모델링

- 잠재 디리클레 할당 (LDA) (3/3) :
  - 결과의 해석 :
    - 각 토픽은 확률이 높은 상위 단어 목록으로 제시되며, 토픽의 이름은 사람이 붙여야 함
    - 각 문서는 토픽에 대한 확률 분포로 표현되므로 합이 1이 됨
  - 장점 :
    - 결과가 확률로 표현되어 해석이 직관적임
    - 새로운 문서에 대해서도 학습된 모델로 토픽 분포를 추론할 수 있음
  - 단점 :
    - 토픽 개수 K를 미리 정해야 하고, 짧은 문서(트윗 등)에서는 성능이 떨어짐
    - 단어 순서를 무시하므로 문맥 정보를 활용하지 못함

10.1 토픽 모델링

- LSA와 LDA의 비교 :
  - 기반 이론 :
    - LSA는 선형대수의 특이값 분해, LDA는 베이지안 확률 모형에 기반함
  - 결과의 형태 :
    - LSA는 실수 값 (음수 포함), LDA는 확률 값 (0 이상, 합이 1)
  - 해석 가능성 :
    - LDA가 일반적으로 더 직관적이며 토픽의 의미를 파악하기 쉬움
  - 속도 :
    - LSA가 상대적으로 빠르며 대규모 문서 집합의 초기 탐색에 적합함

10.1 토픽 모델링

- 토픽 개수의 선택과 평가 :
  - 혼란도 (Perplexity) :
    - 모델이 새로운 문서를 얼마나 잘 예측하는지를 나타내는 지표로, 값이 낮을수록 좋음
    - 다만 혼란도가 낮다고 해서 사람이 보기에 좋은 토픽이라는 보장은 없음
  - 응집도 (Coherence) :
    - 한 토픽의 상위 단어들이 서로 얼마나 자주 함께 등장하는지를 측정함
    - 값이 높을수록 사람이 이해하기 좋은 토픽이며, gensim의 CoherenceModel로 계산함
  - 실무에서는 K를 바꿔가며 응집도 곡선을 그린 후, 응집도는 최댓값(상승이 멈추는 지점), 혼란도는 엘보를 기준으로 K를 선택함

10.1 토픽 모델링

- 실제 구현 :
  - scikit-learn :
    - CountVectorizer, TfidfVectorizer로 문서-단어 행렬을 생성함
    - TruncatedSVD(LSA), LatentDirichletAllocation(LDA) 클래스를 제공함
    - ※ LSA에는 TfidfVectorizer를, LDA에는 원시 빈도(CountVectorizer)를 넣어야 한다
  - gensim :
    - 토픽 모델링에 많이 사용되는 파이썬 라이브러리임
    - 두 가지 토픽 모델링 클래스인 LdaModel(LDA), LsiModel(LSI)을 제공함
    - 선택된 토픽의 정확도를 측정하는 데 사용하는 CoherenceModel도 있음
  - pyLDAvis : 토픽 모델링 결과를 대화형으로 시각화하는 도구임

10.1 토픽 모델링

- 한국어 토픽 모델링 시 유의 사항 :
  - 한국어는 교착어이므로 공백 단위 분리만으로는 같은 단어가 여러 형태로 흩어짐
    - 예 : '학교가', '학교를', '학교에' → 모두 '학교'로 정규화해야 함
  - 따라서 KoNLPy(Okt, Mecab 등) 같은 형태소 분석기로 명사를 추출하는 전처리가 필요함
  - 불용어 처리 :
    - '것', '수', '등', '때'와 같은 의존명사는 토픽 해석을 방해하므로 제거함
  - 한 글자 단어는 대부분 노이즈이므로 제외하는 것이 일반적임

10.2 감성 분석

- 학습 목표 :
  - 감성 분석과 그 응용 분야를 알아봄
  - 감성 분석에서 사용되는 다양한 도구들을 알아봄
  - TextBlob 라이브러리를 사용해 감성 분석을 해봄
  - 감성 분석에 필요한 데이터를 불러오는 방법을 알아봄
  - 감성 분석 모델 학습을 알아봄
- 감성 분석의 개념과 원리를 학습하고, 데이터에 담긴 다양한 감성을 찾아내는 방법을 배움

10.2 감성 분석

- 목차
  - 소개 및 감성 분석이 필요한 이유
  - 감성의 유형과 주요 용어
  - 감성 분석의 수준 (문서 / 문장 / 속성 기반)
  - 감성 분석의 응용 분야
  - 감성 분석에 사용되는 도구들
  - 감성 분석 데이터의 이해
  - 감성 모델 학습과 평가
  - 감성 분석이 어려운 이유

10.2 감성 분석

- 소개 :
  - 감성 분석은 작성된 콘텐츠나 처리한 오디오에 있는 감성을 찾아내기 위해 컴퓨터를 학습시키는 것이 포함된 NLP 분야임
  - 감성 분석에서는 사람의 감정을 찾아내는 모델을 만들려고 함
  - 이는, 어떤 종류의 감정을 찾아내고 싶은지를 결정하는 것으로 시작함
  - 애플리케이션은 인간의 감정 수준을 결정하려고 시도할 수 있음
  - 감정 수준은 대부분의 경우에 사람이 슬픈지 행복한지, 만족스러운지 불만족스러운지, 관심이 있는지 없는지를 의미할 수 있음

10.2 감성 분석

- 왜 감성 분석이 필요한가?
  - 머신러닝 프로젝트에서 어느 정도 인간과 비슷하게 동작하는 애플리케이션을 구축하려고 함
  - 애플리케이션이 인간 수준의 성능과 얼마나 가까운지 확인해서 부분적으로 성공 여부를 측정함
  - 따라서, 제품 리뷰에 대한 감성 분석을 수행한다고 가정함
  - 감성 분석 프로그램은 리뷰어가 어떻게 느끼는지 계속해서 찾아내야 함
  - 사람이 수천 건의 책이나 영화 리뷰를 읽는 것은 비현실적임
  - 바로 여기가 자동화된 감성 분석이 필요한 지점임

10.2 감성 분석

- 감성 분석의 성장 :
  - 몇 가지 주요 요인에 의해 좌우됨
    - 첫째, 기업이 사람들의 느낌을 이해하고 대응하는 데 사용하는 온라인 콘텐츠의 빠른 성장에 의해 주도됨
    - 둘째, 감성이 인간의 의사 결정을 주도하기 때문에 고객의 감성을 이해하는 기업은 구매 결정을 예측하고 구체화하는 데 큰 이점을 가짐
    - 셋째, 이 콘텐츠의 대부분은 소셜 미디어와 기타 온라인 서비스에서 제공되며, 이곳에 있는 사람들의 의견과 감성은 비즈니스 가치의 핵심 요소임
    - 마지막으로, NLP 기술이 발전함에 따라 감성 분석의 적용 범위가 확장됨

10.2 감성 분석

- 감성의 유형 (1/2) :
  - 언어 소스에서 찾아낼 수 있는 다양한 감성이 있음
  - 감정 :
    - 감성 분석은 종종 사람의 감정을 찾아내는 데 사용함
    - 감정은 사람이 행복한지 슬픈지, 또는 만족스러운지 불만족스러운지를 확인함
    - 기업은 종종 고객 만족도를 높이기 위해 이를 사용함
  - 능동성 혹은 수동성 :
    - 화자가 능동적인 태도를 보이는지 수동적인 태도를 보이는지를 판별하는 것임
    - 의견이 실제 행동(구매, 이탈 등)으로 이어질 가능성을 가늠하기 위해 수행함

10.2 감성 분석

- 감성의 유형 (2/2) :
  - 어조 :
    - 발화나 텍스트는 종종 사실적일 필요가 없고 완전히 감정적이지 않은 특정한 느낌을 전달하기 위해 사용함
    - 어조는 특정 상황에서 자주 사용되는 특정한 단어나 문구가 있을 수 있음
  - 주관성 혹은 객관성 :
    - 주관성은 주어진 텍스트 자원이 주관적인지 객관적인지를 찾아내는 것임
    - 문장이 개인이 의견을 내고 표현한 것인지, 문장이 사실에 가깝고 참이나 거짓으로 판단할 수 있는 것인지를 파악해야 할 수도 있음

10.2 감성 분석

- 주요 아이디어와 용어 (1/2) :
  - 분류 :
    - 텍스트 문서에 하나 이상의 클래스를 할당하는 NLP 기술임
    - 문서를 분리하고 정렬하는 데 도움이 됨
    - 감성 분석에 분류를 사용하는 경우에는 긍정, 부정, 중립과 같이 다양한 감성 클래스를 지정함
  - 지도 학습 :
    - 데이터와 레이블이 지정된 목적 변수를 학습 알고리즘에 제공하는 모델을 만듦
    - 데이터셋의 각 텍스트에 대해 감성이 긍정적이면 1을, 문장이 부정적이면 0을 할당함

10.2 감성 분석

- 주요 아이디어와 용어 (2/2) :
  - 극성 :
    - 주어진 언어 소스에서 감성이 얼마나 부정적이거나 긍정적인지를 평가할 것임
    - 극성은 간단하고 측정하기 쉬우며 간단한 숫자 스케일로 쉽게 변환할 수 있기 때문에 사용됨
    - TextBlob의 경우 -1에서 +1 사이의 범위를 사용함
      - +1에 가까울수록 긍정, -1에 가까울수록 부정, 0은 중립을 의미함
    - 분류 모델의 출력을 확률로 표현할 때는 0과 1 사이의 범위를 사용함
      - 1에 가까울수록 긍정, 0에 가까울수록 부정, 0.5 부근은 판단이 애매한 문서를 의미함
  - 강도 :
    - 강도 수준이 감성 점수에 포함되며 강도(intensity)는 극성 점수의 절댓값으로, 1 에 가까울수록 강하고 0 에 가까울수록 약함

10.2 감성 분석

- 감성 분석의 수준 :
  - 문서 수준 (Document-level) :
    - 리뷰 한 건 전체에 하나의 감성 레이블을 부여함
    - 가장 단순하지만, 한 문서 안에 긍정과 부정이 섞여 있으면 정보를 잃음
  - 문장 수준 (Sentence-level) :
    - 문장 단위로 감성을 판정하며, 주관적 문장과 객관적 문장을 먼저 구분하기도 함
  - 속성 기반 감성 분석 (Aspect-Based Sentiment Analysis, ABSA) :
    - '배터리는 좋은데 화면이 어둡다'처럼 대상 속성별로 감성을 분리해 판정함
    - 제품 개선 지점을 구체적으로 찾을 수 있어 실무 활용도가 높음

10.2 감성 분석

- 감성 분석의 응용 분야 (1/5) :
  - 금융 시장 감성 :
    - 금융 시장은 부분적으로 경제 원칙에 기반을 두고 있지만 인간의 감성에 의해 큰 영향을 받음
    - 상승 및 하락 추세가 있는 주식 시장 가격은 전체 시장이나 특정 유가 증권에 관한 뉴스 기사의 의견에 영향을 받음
    - 금융 시장 감성은 증권에 대한 투자자들의 전반적인 관점임
    - 시장 감성은 뉴스나 소셜 미디어 기사에서 찾아낼 수 있음
    - NLP 알고리즘을 사용해 시장 감성을 찾아내는 모델을 구축하고, 해당 모델을 사용해 미래 시장 가격을 예측할 수 있음

10.2 감성 분석

- 감성 분석의 응용 분야 (2/5) :
  - 제품 만족도 :
    - 감성 분석은 일반적으로 고객이 제품과 서비스를 어떻게 느끼는지 결정하는 데 사용함
    - 예를 들어, 아마존은 광범위한 제품 리뷰 데이터를 사용함
    - 이는 제품과 서비스를 개선하는 데 도움이 될 뿐만 아니라 감성 분석 서비스를 위한 학습 데이터로도 사용됨
    - 별점과 리뷰 텍스트의 불일치를 찾아내 신뢰할 수 없는 리뷰를 걸러내는 데도 활용됨

10.2 감성 분석

- 감성 분석의 응용 분야 (3/5) :
  - 소셜 미디어 감성 :
    - 감성 분석에 매우 유용한 핵심 영역 중 하나는 소셜 미디어 모니터링임
    - 소셜 미디어는 전 세계 대부분의 사람들이 매일 상호작용하는 주요 커뮤니케이션 매체임
    - 소셜 미디어에는 거대하고 점점 증가하는 인간 언어 데이터 소스가 있음
    - 무엇보다, 기업과 단체가 소셜 미디어에서 사람들이 언급하는 것을 처리하고 이해해야 할 필요성이 증가했다는 점이 중요함
    - 이는 감성 분석에 대한 수요가 증가함을 나타냄

10.2 감성 분석

- 감성 분석의 응용 분야 (4/5) :
  - 브랜드 모니터링 :
    - 회사는 브랜드 가치를 유지하기 위해 많은 시간과 노력과 비용을 소비함
    - 소셜 미디어가 성장함에 따라 기업은 이제 부정적인 소셜 미디어 대화로 인해 잠재적인 브랜드 위험에 노출됨
    - 반면에 소셜 미디어의 긍정적인 상호작용과 메시지로 인해 브랜드가 긍정적으로 성장할 가능성도 있음
    - 이러한 이유로 기업들은 사람들을 배치해 소셜 미디어에서 자신과 브랜드에 대한 의견을 모니터링함

10.2 감성 분석

- 감성 분석의 응용 분야 (5/5) :
  - 고객 상호작용 :
    - 조직은 종종 온라인 채팅이나 전화 통화를 통해 상호작용하는 동안 고객의 느낌을 알고 싶어함
    - 이러한 경우, 목표는 서비스나 제품에 대한 만족도를 찾아내는 것임
    - 기업은 감성 분석 도구를 사용해 고객과의 상호작용 중에 생성되는 대량의 텍스트와 음성 데이터를 처리할 수 있음
    - 고객과의 상호작용 데이터는 매우 유용하므로 기업이 고객 만족도에 대한 인사이트를 얻을 수 있다면 수익을 올릴 수 있음

10.2 감성 분석

- 감성 분석에 사용되는 도구들 (1/5) :
  - 주요 클라우드 제공업체의 NLP 서비스 :
    - 온라인 감성 분석은 주요 클라우드 서비스 제공업체에서 제공함
    - 장점 :
      - NLP 알고리즘이나 감성 분석에 대한 지식이 거의 필요하지 않음
      - 감성 분석 서비스는 자체 연산 기능을 제공해 연산 요구 사항이 줄어듦
      - 온라인 서비스는 일반 회사들이 직접 할 수 있는 것 이상으로 확장할 수 있음
      - 감성 분석 알고리즘과 데이터에 대한 자동적인 개선 및 업데이트의 이점을 얻을 수 있음
    - 단점 :
      - 온라인 서비스는 서비스에 분석할 문서를 제공해야 하므로 프라이버시 보호가 부족함

10.2 감성 분석

- 감성 분석에 사용되는 도구들 (2/5) :
  - 파이썬 NLP 라이브러리 :
    - 프로젝트에 포함시켜야 하는 몇 가지 NLP 라이브러리가 있음
    - 예시 : NLTK, spaCy, 젠심(gensim), TextBlob 등
    - 장점 :
      - 일반적으로 최신 연구가 위 라이브러리로 작성되며, 잘 선택된 데이터셋을 가지고 있음
    - 단점 :
      - 복잡한 비즈니스 사용 사례에 대해서는 전용 NLP 라이브러리가 충분히 유연하지 않을 수 있음
      - 프로젝트가 필요로 하는 형태로 감성 분석 결과를 반환하지 않을 수 있음

10.2 감성 분석

- 감성 분석에 사용되는 도구들 (3/5) :
  - 딥러닝 라이브러리 :
    - NLP뿐만 아니라 다양한 유형의 머신러닝 프로젝트에 사용됨
    - 솔루션 개발에 훨씬 더 많은 유연성을 제공하고 강력하고 복잡한 모델을 만드는 데 도움이 됨
    - 장점 :
      - 복잡한 비즈니스 요구를 충족시키기 위해 감성 분석 모델을 유연하게 개발할 수 있음
      - 방대한 텍스트 자원으로 학습된 모델을 사용해 프로젝트 요구 사항에 따라 학습을 미세 조정하는 전이 학습을 활용할 수 있음
    - 단점 :
      - 머신러닝과 딥러닝 같은 주제에 대한 지식이 필요하며, 많은 리소스와 데이터가 필요함

10.2 감성 분석

- 감성 분석에 사용되는 도구들 (4/5) :
  - TextBlob은 NLP를 위한 파이썬 라이브러리임
  - 간단한 API를 갖고 있으며 파이썬에서 감성 분석과 그 외 텍스트 분석을 하는 데 가장 쉬운 방법임
  - TextBlob 라이브러리를 사용한 기본적인 감성 분석 :
    - 1. 주피터 노트북을 염
    - 2. TextBlob 라이브러리의 TextBlob 클래스를 불러옴
      - from textblob import TextBlob
    - 3. sentence라는 변수를 생성하고 문자열을 할당함
      - sentence = "But you are late again!"

10.2 감성 분석

- 감성 분석에 사용되는 도구들 (5/5) :
  - TextBlob 라이브러리를 사용한 기본적인 감성 분석 (계속) :
    - 4. TextBlob 클래스 객체를 생성하고 TextBlob 컨테이너에 sentence를 파라미터로 추가함
      - blob = TextBlob(sentence)
    - 5. TextBlob 클래스의 sentiment 속성을 사용해 구현함
      - blob.sentiment
      - 결과 : Sentiment(polarity=-0.58, subjectivity=0.6)
      - 주어진 텍스트에 대한 polarity와 subjectivity 점수를 확인할 수 있음
  - VADER는 소셜 미디어 텍스트에 특화된 규칙 기반 도구로, 이모티콘과 강조 표현을 함께 고려함

10.2 감성 분석

- 감성 분석 데이터의 이해 :
  - 감성 분석은 텍스트 분류의 한 종류임
  - 감성 분석 모델은 지도 학습 데이터를 사용해 학습함
  - 지도 학습 데이터셋은 일반적으로 텍스트에 대한 감성 값이 적혀 있는 열인 목적 변수에 레이블이 지정되어 있는 데이터셋임
  - 사용 데이터셋 :
    - Amazon, Yelp, IMDb 리뷰 데이터셋 (Amazon·Yelp 각 1,000문장, IMDb 748문장, 긍정 1 / 부정 0)
    - 데이터 참조 :
      - https://archive.ics.uci.edu/ml/machine-learning-databases/00331/
    - 한국어 : NSMC (네이버 영화 리뷰) 데이터셋

10.2 감성 분석

- 감성 분석 데이터의 이해 (계속) :
  - 1. 라이브러리 불러오기 및 데이터 위치 지정
  - 2. IMDb 리뷰를 불러오기
    - imdb_reviews = pd.read_table(IMDB_DATA_FILE, names=COLUMN_NAMES)
  - 3. 부정적인 리뷰는 감성 점수 0을 갖고 긍정적인 리뷰는 감성 점수 1을 갖는 것을 확인
  - 4. 레이블별 문장 수를 확인하기 위해 value_counts() 함수를 사용
    - imdb_reviews.Sentiment.value_counts()
  - 5. 데이터 형태 지정
    - imdb_counts = imdb_reviews.Sentiment.value_counts().to_frame()
    - ※ value_counts()는 빈도 내림차순으로 정렬되므로, 인덱스 이름을 붙일 때 순서에 주의해야 함

10.2 감성 분석

- 감성 분석 데이터의 이해 (계속) :
  - 아마존 리뷰 불러오기
    - amazon_reviews = pd.read_table(AMAZON_DATA_FILE, names=COLUMN_NAMES)
    - amazon_reviews.head(10)
  - Yelp 리뷰 불러오기
    - yelp_reviews = pd.read_table(YELP_DATA_FILE, names=COLUMN_NAMES)
    - yelp_reviews.head(10)
  - 감성 분석 모델 학습에 필요한 데이터 로딩 완료
  - 추가적으로 리뷰 텍스트는 그대로 사용할 수 없음
  - 피처 벡터를 추출해 모델의 입력으로 전달할 수 있도록 처리해야 함

10.2 감성 분석

- 감성 모델 학습 :
  - 모델은 학습한 데이터들을 저장한 표현을 담고 있는 객체임
  - 모델은 이전에 보지 못한 텍스트의 감성 값을 예측 가능함
  - 모델을 개발하기 위한 과정
    - 1. 문서 데이터셋을 학습 데이터셋과 테스트 데이터셋으로 나눔, 테스트 데이터셋은 전체 데이터셋의 일부
    - 2. 필요 없는 문자와 불용어를 제거하고 그 외 일반적인 전처리 단계를 거쳐 텍스트를 전처리함
    - 3. 텍스트를 수치형 벡터 표현으로 변환해 피처를 추출함
    - 4. 모델 학습을 진행함, 위 과정은 사용할 알고리즘의 유형에 따라 다름
    - 5. 모델을 사용해 예전에 보지 못했던 문서의 감성을 예측함

10.2 감성 분석

- 피처 추출 방법 :
  - BoW (CountVectorizer) :
    - 단어의 등장 횟수를 그대로 사용하며, 구현이 가장 간단함
  - TF-IDF (TfidfVectorizer) :
    - 흔한 단어의 가중치를 낮춰 변별력 있는 단어를 강조함, 감성 분석에서 기본적으로 많이 사용됨
  - N-gram :
    - 'not good'처럼 두 단어가 붙어야 의미가 살아나는 경우를 포착하기 위해 사용함
    - ngram_range=(1, 2)로 설정하면 단어 하나와 두 단어 묶음을 함께 사용함
  - 워드 임베딩 / 사전학습 언어모델 : Word2Vec, BERT 등을 사용해 문맥을 반영한 표현을 얻음

10.2 감성 분석

- 감성 모델의 평가 :
  - 혼동 행렬 (Confusion Matrix)을 기준으로 지표를 계산함
    - 정확도 (Accuracy) = (TP + TN) / 전체
    - 정밀도 (Precision) = TP / (TP + FP), 긍정이라 예측한 것 중 실제 긍정의 비율
    - 재현율 (Recall) = TP / (TP + FN), 실제 긍정 중 찾아낸 비율
    - F1 점수 = 2 × (정밀도 × 재현율) / (정밀도 + 재현율)
  - 클래스가 불균형한 경우 정확도만 보면 잘못된 판단을 할 수 있으므로 F1 점수를 함께 확인해야 함

10.2 감성 분석

- 감성 분석이 어려운 이유 :
  - 부정 표현 : '이 영화는 좋지 않다'에서 '좋다'만 보면 긍정으로 오판함
  - 반어와 풍자 : '정말 훌륭한 서비스네요, 두 시간 기다렸습니다'
  - 도메인 의존성 : '예측 가능한'은 영화 리뷰에서는 부정, 자동차 리뷰에서는 긍정임
  - 비교 표현 : 'A보다는 낫다'는 A와 B 중 무엇에 대한 평가인지 판단해야 함
  - 이모티콘, 신조어, 초성체 등 정제되지 않은 표현이 많음
  - 이러한 이유로 규칙 기반 도구보다 문맥을 학습하는 사전학습 언어모델이 유리함

10.3 기계 독해

- 학습 목표 :
  - 기계 독해(Machine Reading Comprehension)의 개념과 필요성을 설명함
  - 기계 독해 과제의 유형을 구분함
  - 대표적인 기계 독해 데이터셋의 구조를 이해함
  - BERT 기반 질의응답 모델의 동작 원리를 설명함
  - EM과 F1 지표로 기계 독해 성능을 평가함
- 주어진 지문을 읽고 질문에 답하는 기계 독해 과제를 통해, 기계가 문서를 '이해'한다는 것의 의미를 알아보고자 함

10.3 기계 독해

- 소개 :
  - 기계 독해는 주어진 지문(context)을 읽고 그에 대한 질문(question)에 답하는 과제임
  - 토픽 모델링이 '무엇에 관한 글인가', 감성 분석이 '어떤 태도인가'를 다룬다면, 기계 독해는 '무엇이라고 말하고 있는가'를 다룸
  - 단어의 통계적 분포만으로는 풀 수 없고, 문장 사이의 관계와 문맥을 파악해야 함
  - 따라서 기계 독해는 언어 이해 능력을 측정하는 대표적인 벤치마크로 사용됨
  - 검색 엔진의 답변 요약, 챗봇, 문서 기반 질의응답 시스템의 핵심 기술임

10.3 기계 독해

- 왜 기계 독해인가?
  - 정보 접근 방식의 변화 :
    - 기존 검색은 관련 문서 목록을 반환하지만, 사용자는 문서가 아니라 답을 원함
    - 기계 독해는 문서에서 답이 되는 부분을 직접 찾아 제시함
  - 업무 자동화 :
    - 계약서, 매뉴얼, 사규 등 방대한 내부 문서에서 필요한 조항을 즉시 찾을 수 있음
  - 언어 이해 능력의 척도 :
    - 정답이 명확하게 정의되므로 모델의 이해 수준을 정량적으로 비교할 수 있음

10.3 기계 독해

- 기계 독해 과제의 유형 (1/2) :
  - 빈칸 채우기 (Cloze Style) :
    - 지문의 특정 단어를 가리고 무엇인지 맞히는 형태임
    - 대표 데이터셋 : CNN/Daily Mail, CBT
    - 자동으로 대량 생성할 수 있지만 실제 질의응답과는 거리가 있음
  - 객관식 (Multiple Choice) :
    - 주어진 보기 중 정답을 고르는 형태임
    - 대표 데이터셋 : RACE, MCTest
    - 평가가 간단하지만 보기가 주어져야만 동작함

10.3 기계 독해

- 기계 독해 과제의 유형 (2/2) :
  - 추출형 (Extractive / Span Prediction) :
    - 정답이 지문 안에 연속된 구간(span)으로 존재한다고 가정하고 그 시작과 끝 위치를 예측함
    - 대표 데이터셋 : SQuAD, KorQuAD, Natural Questions
    - 가장 널리 연구된 형태이며, 본 강의의 실습도 이 유형을 다룸
  - 추상형 (Abstractive / Generative) :
    - 지문에 없는 표현으로 답을 생성함
    - 대표 데이터셋 : MS MARCO, NarrativeQA
    - 자연스러운 답변이 가능하지만 사실과 다른 내용을 만들어내는 환각 문제가 발생할 수 있음

10.3 기계 독해

- 대표 데이터셋 :
  - SQuAD 1.1 (Stanford Question Answering Dataset) :
    - 위키피디아 문단 기반, 약 10만 개의 질문-답변 쌍으로 구성됨
    - 모든 질문에 반드시 답이 지문 안에 존재함
  - SQuAD 2.0 :
    - 답할 수 없는 질문 약 5만 개를 추가해, '답이 없다'고 판단하는 능력까지 평가함
    - 실제 서비스에서는 답이 없는 경우를 정확히 거절하는 것이 중요하기 때문임
  - KorQuAD 1.0 / 2.0 :
    - 한국어 위키피디아 기반의 기계 독해 데이터셋으로, SQuAD와 동일한 형식을 따름
    - 2.0은 표와 목록이 포함된 긴 문서 전체를 대상으로 함

10.3 기계 독해

- SQuAD 데이터 형식 :
  - JSON 형태의 계층 구조를 가짐
    - context : 지문 (문단 단위의 텍스트)
    - question : 지문에 대한 질문
    - answers : {'text': 정답 문자열, 'answer_start': 지문 내 시작 문자 위치}
  - 예시 :
    - context = "세종대왕은 1443년에 훈민정음을 창제하였다."
    - question = "훈민정음은 언제 창제되었는가?"
    - answers = {'text': '1443년', 'answer_start': 6}
  - 정답이 문자 위치로 주어지므로, 토크나이저를 거친 후 토큰 위치로 변환하는 전처리가 필요함

10.3 기계 독해

- 기계 독해 모델의 발전 (1/2) :
  - 전통적 파이프라인 방식 :
    - 형태소 분석, 개체명 인식, 구문 분석 등을 단계별로 수행한 후 규칙으로 답을 찾음
    - 단계마다 오류가 누적되고, 새로운 도메인에 적용하기 어려움
  - 신경망 기반 (2016~2018) :
    - BiDAF(Seo et al. 2017)는 질문→지문·지문→질문 양방향 어텐션 흐름을, DrQA(Chen et al. 2017)는 문서 검색기와 결합한 독해기를 제안했으며, 지문과 질문을 각각 LSTM으로 인코딩한 후 어텐션으로 상호작용시킴
    - 질문 → 지문, 지문 → 질문 양방향 어텐션으로 관련 부분을 찾음
    - 사람 수준에는 미치지 못했으나 종단간(end-to-end) 학습의 가능성을 보여 줌

10.3 기계 독해

- 기계 독해 모델의 발전 (2/2) :
  - 사전학습 언어모델 기반 (2018~) :
    - BERT는 대규모 말뭉치로 사전학습한 후, 기계 독해 데이터로 미세 조정(fine-tuning)함
    - SQuAD 1.1에서 단일 모델이 사람의 성능(F1 91.2)에 필적하고, 앙상블 모델은 F1 93.2로 사람을 넘어섬
  - 핵심 아이디어 :
    - 언어에 대한 일반 지식은 사전학습에서 얻고, 과제별 지식만 소량의 데이터로 학습함
    - 출력층으로 시작 위치와 끝 위치를 예측하는 출력 차원이 2인 선형 계층 하나(= 시작 벡터 S, 끝 벡터 E)만 추가하면 됨
  - 최근에는 대규모 언어모델(LLM)이 별도 미세 조정 없이도 기계 독해를 수행함

10.3 기계 독해

- BERT 기반 질의응답의 동작 원리 (1/2) :
  - 입력 구성 :
    - [CLS] 질문 토큰들 [SEP] 지문 토큰들 [SEP] 형태로 하나의 시퀀스를 만듦
    - 세그먼트 임베딩으로 질문 부분과 지문 부분을 구분함
  - 출력 계산 :
    - 각 토큰 i에 대해 최종 은닉 벡터 h_i를 얻음
    - 시작 로짓 : $s_i = S \cdot h_i$, 끝 로짓 : $e_i = E \cdot h_i$ (S, E는 학습되는 벡터)
    - 소프트맥스를 적용해 각 토큰이 정답의 시작/끝일 확률을 구함

10.3 기계 독해

- BERT 기반 질의응답의 동작 원리 (2/2) :
  - 예측 :
    - $s_i + e_j$ 를 최대로 만드는 (i, j) 쌍을 선택하되, $i \le j$ 조건을 만족해야 함
    - 선택된 토큰 구간을 원래 문자열 위치로 되돌려 정답 문자열을 출력함
  - 학습 :
    - 정답 시작 위치와 끝 위치에 대한 교차 엔트로피 손실의 평균을 최소화함
  - 긴 문서 처리 :
    - BERT의 최대 입력 길이(보통 512 토큰)를 넘는 문서는 겹치는 구간(stride)을 두고 잘라 여러 번 처리한 뒤 가장 점수가 높은 답을 선택함

10.3 기계 독해

- 평가 지표 :
  - EM (Exact Match) :
    - 예측한 답이 정답 문자열과 완전히 일치하는 비율임
    - 대소문자, 관사, 구두점을 제거하는 정규화를 거친 후 비교함
  - F1 :
    - 예측과 정답을 토큰 다중집합(Counter)으로 보고 겹치는 정도를 측정함
    - 정밀도 = 겹친 토큰 수 / 예측 토큰 수, 재현율 = 겹친 토큰 수 / 정답 토큰 수
    - 부분적으로 맞은 답에도 점수를 주므로 EM보다 관대한 지표임
  - 정답이 여러 개 제공된 경우, 각 정답에 대해 계산한 값 중 최대값을 사용함

10.3 기계 독해

- HuggingFace 파이프라인으로 기계 독해 수행 :
  - 1. 라이브러리 설치 및 불러오기
    - from transformers import pipeline
  - 2. 질의응답 파이프라인 생성
    - qa = pipeline("question-answering",
      - model="distilbert-base-cased-distilled-squad")
  - 3. 지문과 질문을 전달해 실행
    - result = qa(question=question, context=context)
  - 4. 결과 확인
    - result['answer'], result['score'], result['start'], result['end']
  - 한국어의 경우 KorQuAD로 학습된 모델을 model 인자에 지정하면 됨

10.3 기계 독해

- 기계 독해의 한계와 최신 동향 :
  - 한계 :
    - 지문이 주어져야만 동작하며, 지문 밖의 지식은 활용하지 못함
    - 여러 문단에 걸쳐 추론해야 하는 질문(multi-hop)에 취약함
    - 지문에 없는 내용을 그럴듯하게 만들어내는 환각 문제가 존재함
  - 최신 동향 :
    - 오픈 도메인 QA : 대규모 문서 집합에서 관련 문단을 먼저 검색한 후 독해를 수행함
    - RAG (검색 증강 생성) : 검색된 근거 문서를 언어모델의 입력에 붙여 답을 생성함
    - 이를 통해 답변의 근거를 제시할 수 있고 최신 정보를 반영할 수 있음

10.4 요약 (1/3)

- 토픽 모델링에 대해서
  - 1. 토픽 모델링과 토픽 모델링의 활용 분야를 설명함
  - 2. 문서를 단어 모음(BoW)과 문서-단어 행렬로 표현하는 방법을 살펴봄
  - 3. LSA의 동작 원리(특이값 분해)에 대해서 설명함
  - 4. LDA의 동작 원리(문서 생성 과정과 디리클레 분포)에 대해서 설명함
  - 5. 토픽 개수를 선택하고 응집도로 평가하는 방법을 알아봄

10.4 요약 (2/3)

- 감성 분석에 대해서
  - 1. 감성 분석과 그 응용 분야를 알아봄
  - 2. 감성의 유형과 극성, 강도 등 주요 용어를 정리함
  - 3. 감성 분석에서 사용되는 다양한 도구들을 알아봄
  - 4. TextBlob 라이브러리를 사용해 감성 분석을 해봄
  - 5. 감성 분석에 필요한 데이터를 불러오는 방법을 알아봄
  - 6. 감성 분석 모델 학습과 평가 지표를 알아봄

10.4 요약 (3/3)

- 기계 독해에 대해서
  - 1. 기계 독해의 개념과 필요성을 알아봄
  - 2. 빈칸 채우기, 객관식, 추출형, 추상형 등 과제 유형을 구분함
  - 3. SQuAD와 KorQuAD 데이터셋의 구조를 살펴봄
  - 4. BERT 기반 스팬 예측 모델의 동작 원리를 설명함
  - 5. EM과 F1 지표로 성능을 평가하는 방법을 알아봄
  - 6. 오픈 도메인 QA와 RAG 등 최신 동향을 살펴봄

참고서적

- 전창욱, 최태균, 조중현, 신성진 지음, 텐서플로 2와 머신러닝으로 시작하는 자연어 처리, 위키북스
- 홉슨 레인, 하네스 막스 하프케, 콜 하워드, 파이썬으로 배우는 자연어 처리 인 액션, 제이펍
- 쇼햄 고시, 드와이트 거닝, 예제로 배우는 자연어 처리 기초, 에이콘
- 임희석, 자연어처리 바이블 - 핵심이론 응용 시스템 딥러닝, 휴먼싸이언스
- Devlin et al., BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding, NAACL 2019
- Blei, Ng, Jordan, Latent Dirichlet Allocation, JMLR 2003

질문 및 정리

Q & A

이번 주차 내용에 대해 궁금한 점을 자유롭게 질문해 주세요