

Image Pyramids에서 FPN까지: Multi-Scale Object Detection

Feature Pyramid Networks for Object Detection

(4 주차 : Image Pyramids)

데이터사이언스융합학과
2026710816 이다영


Image Pyramids

다중 해상도 표현 (Multi-scale)

하나의 원본 이미지를 반복적으로 다운 샘플링 (Down-sampling) 하여 서로 다른 해상도를 갖는 이미지들의 계층적 집합을 쌓아 올린 피라미드 형태의 데이터 구조입니다. 상단으로 갈수록 해상도가 낮아지고 하단으로 갈수록 원본 고해상도 정보를 유지합니다.

고정 윈도우 슬라이딩 (Sliding Window)

고정된 크기의 Detector 윈도우를 모든 이미지 스케일 단계별로 훑으며 탐지 수행.



고전 Image Pyramid의 한계와 Pyramid 구조의 진화

(a) Featurized Image Pyramid :

입력 이미지를 여러 크기로 복사해 특징을 추출하는 이미지 피라미드(Featurized Image Pyramid)가 표준으로 쓰임. 연산 및 메모리 비용이 극도로 커 딥러닝 종단간(End-to-End) 학습에 부적합함.

(b) Single Feature Map:


Fast/Faster R-CNN 등은 속도 향상을 위해 피라미드를 포기하고 신경망의 마지막 단일 특징 맵만 활용. 작은 물체 탐지 성능 저하

(c) Pyramidal Feature Hierarchy :


CNN 내부 레이어를 피라미드 처럼 활용. 연산량이 크진 않으나 하위 레이어 피쳐맵은 정보가 약해 객체 인식에 한계가 있음.

(d) Feature Pyramid Network(FPN) :


FPN은 추가적인 연산 비용을 거의 들이지 않으면서, 모든 스케일 레벨에서 고해상도와 풍부한 시맨틱 정보를 동시에 가지는 내부 피쳐 피라미드를 구축함.



(a) Featurized image pyramid



(b) Single feature map



(c) Pyramidal feature hierarchy



(d) Feature Pyramid Network

FPN의 핵심 아이디어 및 구조

Bottom-up pathway (하향식 경로)

백본 ConvNet(예: ResNet)의 순전파 연산 과정입니다.
동일한 해상도를 갖는 레이어들의 집합을 'Stage'로 정의하고, 각 Stage의 마지막 레이어 출력을 참조 특징 맵 $\{C_2, C_3, C_4, C_5\}$ 로 설정

Top-down pathway & Lateral connections (상향식 경로 및 측면 연결)

Top-down: 깊은 레이어의 저해상도 특징 맵을 2X Nearest Neighbor Up-sampling하여 spatial 크기를 키웁니다.

Lateral connection: 해당되는 Bottom-up 특징 맵에 1 x1 Convolution을 적용해 채널 수를 맞추는 뒤, 업-샘플링된 특징 맵과 요소별 더하기(Element-wise addition)로 결합합니다.

Aliasing 제거

업샘플링 과정에서 발생하는 아티팩트(Aliasing)를 줄이기 위해 결합된 맵에 3x3 Convolution을 수행하여 최종 특징 피라미드 $\{P_2, P_3, P_4, P_5\}$ 를 완성합니다.

채널 고정

피라미드의 모든 레벨에서 공통 분류기/회귀기를 공유하므로, 모든 출력 특징 맵의 채널 수 d 를 256으로 고정합니다.




Figure 3. A building block illustrating the lateral connection and the top-down pathway, merged by addition.

Applications 1: FPN for RPN

RPN (Region Proposal Network, 영역 제안 네트워크)

Class-Agnostic Detector : 세부 종류 구분 없이 이미지 내 "물체의 존재 유무(Objectness Score)"와 대략적인 위치만을 빠르게 찾아내는 영역 제안 네트워크

RPN head :

3X3 Conv : 주변 픽셀 맥락(Context)의 특징 추출

1X1 Conv (cls) : 해당 위치의 물체 존재 확률 점수(Objectness Score) 계산

1X1 Conv (reg) : 앵커 상자의 위치 및 크기 보정값(dx, dy, dw, dh) 계산

IoU (Intersection over Union)

Positive Label : $\text{IoU} \geq 0.7$

Negative Label : $\text{IoU} < 0.3$

비교

구분	기존 RPN (Single-Scale)	FPN RPN (Feature Pyramid)
특징 맵	단 1개의 특징 맵 (최상위 단일 층)	5개 피라미드 레벨 (P_2, P_3, P_4, P_5, P_6)
앵커 할당	1개 위치에 스케일 3개 X 비율 3개 (총 9개) 억지 중첩	각 층당 전담 스케일($P_2 \sim P_6$) 1개 X 비율 3개 (층당 3개)
한계 및 개선	해상도 파괴로 인한 소형 물체 탐지 성능 저하	층별 해상도 맞춤 배정으로 다양한 크기 물체 정밀 탐지

Applications 2: FPN for Fast R-CNN

Fast R-CNN (영역 기반 물체 분류 및 정밀 회귀)

Class-Specific Detector : RPN이 제안한 후보 영역(RoI)의 세부 물체 종류(Class)를 분류하고 최종 바운딩 박스 위치를 정밀하게 보정하는 탐지기

RoI Pooling (7x7) : 할당된 피라미드 레벨(P_k)에서 RoI 영역을 7 x 7 크기의 고정 특징 맵으로 추출
2-FC MLP (1024-d) : 추출된 특징을 2개의 연속된 Fully-Connected 레이어에 통과시켜 고차원 특징 학습
Predictor (cls, reg) : Softmax 기반 클래스 분류 및 최종 바운딩 박스 오프셋 미세조정

RoI 피라미드 할당 공식 (RoI Layer Assignment)

$$k = \lfloor k_0 + \log_2(\sqrt{wh}/224) \rfloor.$$

비교

구분	기존 Fast R-CNN (Single-Scale)	FPN Fast R-CNN (Feature Pyramid)
특징 맵	단 1개의 특징 맵 (C4 또는 C5 단일 층)	4개 피라미드 레벨 (P_2, P_3, P_4, P_5)
RoI 추출	모든 RoI를 크기 상관없이 1개의 맵에서 크롭	RoI 크기(스케일)에 따라 최적의 피라미드 레벨(P_k)로 분산 할당
한계 및 개선	작은 RoI의 경우 해상도가 뭉개져 특징 손실	작은 물체는 P_2 (고해상도)에서 잘라내어 세부 특징 및 정밀도 보존

Experiments on Object Detection 1 : FPN for RPN

RPN	feature	# anchors	lateral?	top-down?	AR ¹⁰⁰	AR ^{1k}	AR _s ^{1k}	AR _m ^{1k}	AR _l ^{1k}
(a) baseline on conv4	C_4	47k			36.1	48.3	32.0	58.7	62.2
(b) baseline on conv5	C_5	12k			36.3	44.9	25.3	55.5	64.2
(c) FPN	$\{P_k\}$	200k	✓	✓	44.0	56.3	44.9	63.4	66.2
<i>Ablation experiments follow:</i>									
(d) bottom-up pyramid	$\{P_k\}$	200k	✓		37.4	49.5	30.5	59.9	68.0
(e) top-down pyramid, w/o lateral	$\{P_k\}$	200k		✓	34.5	46.1	26.5	57.4	64.7
(f) only finest level	P_2	750k	✓	✓	38.4	51.3	35.1	59.7	67.6

RPN Proposal 성능 대폭 향상

단일 스케일 대비 성능 압도: C4 피쳐 맵 사용 Baseline 대비 FPN 적용 시 AR 1k가 48.3 → 56.3 (+8.0 point) 대폭 상승

소형 객체 탐지 극대화: 고해상도 피쳐 맵(P2)과 상위 의미 정보 결합으로 소형 객체 ARs 1k가 32.0 → 44.9 (+12.9 point) 폭발적 증가

FPN 핵심 구조 검증

Ablation Study (d~f) Top-down Pathway 필수성 (d): 하위 레이어의 약한 의미 정보를 보완하는 정보 전달이 없으면 AR 1k가 49.5로 급감

Lateral Connection 필수성 (e): 정확한 위치(Spatial) 정보 보존을 위한 측면 연결 제거 시 AR 1k가 46.1까지 하락

Multi-scale 전체 활용 (f): 가장 해상도가 높은 P2 단일 맵(51.3)보다 다중 스케일 피라미드 전체(Pk)를 활용하는 것이 크기 변화 대응에 우수

Experiments on Object Detection 2: FPN for Fast R-CNN

Fast R-CNN	proposals	feature	head	lateral?	top-down?	AP@0.5	AP	AP _s	AP _m	AP _l
(a) baseline on conv4	RPN, $\{P_k\}$	C_4	conv5			54.7	31.9	15.7	36.5	45.5
(b) baseline on conv5	RPN, $\{P_k\}$	C_5	2fc			52.9	28.8	11.9	32.4	43.4
(c) FPN	RPN, $\{P_k\}$	$\{P_k\}$	2fc	✓	✓	56.9	33.9	17.8	37.7	45.8
<i>Ablation experiments follow:</i>										
(d) bottom-up pyramid	RPN, $\{P_k\}$	$\{P_k\}$	2fc	✓		44.9	24.9	10.9	24.4	38.5
(e) top-down pyramid, w/o lateral	RPN, $\{P_k\}$	$\{P_k\}$	2fc		✓	54.0	31.3	13.3	35.2	45.3
(f) only finest level	RPN, $\{P_k\}$	P_2	2fc	✓	✓	56.3	33.4	17.3	37.3	45.6

Table 2. Object detection results using **Fast R-CNN** [11] on a fixed set of proposals (RPN, $\{P_k\}$, Table 1(c)), evaluated on the COCO minival set. Models are trained on the trainval35k set. All results are based on ResNet-50 and share the same hyper-parameters.

Faster R-CNN	proposals	feature	head	lateral?	top-down?	AP@0.5	AP	AP _s	AP _m	AP _l
(*) baseline from He <i>et al.</i> [16] [†]	RPN, C_4	C_4	conv5			47.3	26.3	-	-	-
(a) baseline on conv4	RPN, C_4	C_4	conv5			53.1	31.6	13.2	35.6	47.1
(b) baseline on conv5	RPN, C_5	C_5	2fc			51.7	28.0	9.6	31.9	43.1
(c) FPN	RPN, $\{P_k\}$	$\{P_k\}$	2fc	✓	✓	56.9	33.9	17.8	37.7	45.8

Table 3. Object detection results using **Faster R-CNN** [29] evaluated on the COCO minival set. The backbone network for RPN are consistent with Fast R-CNN. Models are trained on the trainval35k set and use ResNet-50. [†] Provided by authors of [16].

Fast R-CNN 성능 개선

동일 조건 FPN 적용 시 Baseline(C5) 대비 AP가 28.8 → 33.9 (+5.1 point)로 대폭 향상됨.

단일 스케일 피쳐 맵보다 다중 스케일 피라미드가 객체 검출에 훨씬 유리함

Faster R-CNN 통합 모델

ResNet-50 기반 단일 스케일(C4) 대비 AP 31.6 → 33.9 (+2.3 point) 향상.

AP@0.5 수치는 53.1 → 56.9 (+3.8 point) 상승하여, Proposal(RPN)과 Detection 전체 단계에서 FPN의 우수함.

Experiments on Object Detection : COCO

method	backbone	competition	image pyramid	test-dev					test-std				
				AP@.5	AP	AP _s	AP _m	AP _l	AP@.5	AP	AP _s	AP _m	AP _l
ours, Faster R-CNN on FPN	ResNet-101	-		59.1	36.2	18.2	39.0	48.2	58.5	35.8	17.5	38.7	47.8
<i>Competition-winning single-model results follow:</i>													
G-RMI [†]	Inception-ResNet	2016		-	34.7	-	-	-	-	-	-	-	-
AttractionNet [‡] [10]	VGG16 + Wide ResNet [§]	2016	✓	53.4	35.7	15.6	38.0	52.7	52.9	35.3	14.7	37.6	51.9
Faster R-CNN +++ [16]	ResNet-101	2015	✓	55.7	34.9	15.6	38.7	50.9	-	-	-	-	-
Multipath [40] (on minival)	VGG-16	2015		49.6	31.5	-	-	-	-	-	-	-	-
ION [‡] [2]	VGG-16	2015		53.4	31.2	12.8	32.9	45.2	52.9	30.7	11.8	32.8	44.8

Table 4. Comparisons of **single-model** results on the COCO detection benchmark. Some results were not available on the test-std set, so we also include the test-dev results (and for Multipath [40] on minival). [†]: <http://image-net.org/challenges/talks/2016/GRMI-COCO-slidedeck.pdf>. [‡]: <http://mscoco.org/dataset/#detections-leaderboard>. [§]: This entry of AttractionNet [10] adopts VGG-16 for proposals and Wide ResNet [39] for object detection, so is not strictly a single-model result.

COCO Benchmark SOTA 경신

최고 성능 달성 (Single-model): ResNet-101 기반 FPN Faster R-CNN은 COCO test-std 기준 AP 35.8, AP@0.5 기준 58.5를 기록함.

기존 대회 우승 모델 능가: 무거운 Image Pyramid 기법이나 앙상블을 사용한 기존 COCO 2015~2016 우승 모델들(Faster R-CNN+++, G-RMI, AttractionNet 등)의 단일 모델 성능을 모두 제치고 세계 최고 성능(SOTA)을 달성함

Extensions: Segmentation Proposals

확장 적용

FPN은 Object Detection뿐만 아니라, 픽셀 단위 마스크를 추출하는 Instance Segmentation 후보 영역 (Mask Proposal) 생성 작업에도 그대로 확장 적용 가능함.

구조 및 동작 방식: FPN의 각 피라미드 레벨 상단에 작은 크기(5x5 및 7x7)의 MLP를 부착하여 14x14 크기의 마스크(Mask)와 객체 점수(Object Score)를 완전 합성곱(Fully Convolutional) 방식으로 연산함.

결과 분석

기존 SOTA 모델 대비 우수한 성능 및 속도

이미지 피라미드 미사용: 기존 모델(DeepMask, SharpMask)과 달리 무거운 이미지 피라미드 없이 단일 입력만으로 월등한 성능 달성
전체 재현율(AR) 대폭 향상: 기존 최상위 SharpMask(39.8) 대비 FPN 최종 모델은 **AR 48.1 (+8.3 point)** 기록
소형 객체(ARs) 탐지 극대화: 소형 객체 마스크 성능이 **17.4 → 32.6**으로 2배 가까이 폭발적 상승
추론 속도 혁신: 기존 모델(0.49s~1.50s) 대비 FPN 기본 모델은 **0.15초**, 최종 모델은 **0.25초**로 매우 빠름

FPN Mask Proposal Ablation Study

Single MLP (5x5): 단일 5x5 MLP만으로 이미 SharpMask를 제치고 **AR 43.4, 속도 0.15s** 달성
Dual MLP (5x5, 7x7): 두 개 스케일의 MLP 조합으로 커버리지를 높여 **AR 45.7**로 향상
+ 2x mask resolution: 마스크 출력 해상도 2배 확장 시 **AR 46.7** 달성
+ 2x train schedule: 학습 일정을 2배 늘린 최종 모델이 **AR 48.1, ARs 32.6**으로 SOTA 경신

	image pyramid	AR	AR _s	AR _m	AR _l	time (s)
DeepMask [27]	✓	37.1	15.8	50.1	54.9	0.49
SharpMask [28]	✓	39.8	17.4	53.1	59.1	0.77
InstanceFCN [4]	✓	39.2	–	–	–	1.50 [†]
FPN Mask Results:						
single MLP [5×5]		43.4	32.5	49.2	53.7	0.15
single MLP [7×7]		43.5	30.0	49.6	57.8	0.19
dual MLP [5×5, 7×7]		45.7	31.9	51.5	60.8	0.24
+ 2x mask resolution		46.7	31.7	53.1	63.2	0.25
+ 2x train schedule		48.1	32.6	54.2	65.6	0.25

Conclusion

추가 연산 없는 멀티스케일 특징 추출

이미지 피라미드 대비 연산량과 메모리 증가 없이 네트워크 자체 특징 맵만으로 피라미드 구축

소형 객체 인식 성능의 획기적 개선

고해상도 하위 층에 상위 층의 풍부한 문맥 정보를 결합하여 작은 물체 탐지 한계 극복

단일 특징 맵 구조 탈피

최상위 레이어에만 의존하던 기존 방식을 넘어 피라미드 전체 레벨($P_2 \sim P_5$)을 탐지 영역으로 확장

뛰어난 모델 확장성

RPN, Fast R-CNN뿐만 아니라 Segment structural 등 다양한 파이프라인에 즉시 적용 가능한 범용적 구조

속도와 정확도의 최적 밸런스

실시간 처리가 가능한 수준의 빠른 추론 속도를 유지하면서 최고 수준(SOTA)의 검출 정밀도 달성

Related Work

- SIFT**: Lowe, D. G., *"Distinctive Image Features from Scale-Invariant Keypoints"*, IJCV 2004.
- HOG**: Dalal & Triggs, *"Histograms of Oriented Gradients for Human Detection"*, CVPR 2005.
- OverFeat**: Sermanet et al., *"OverFeat: Integrated Recognition, Localization and Detection using Convolutional Networks"*, ICLR 2014.
- R-CNN**: Girshick et al., *"Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation"*, CVPR 2014.
- SPPnet**: He et al., *"Spatial Pyramid Pooling in Deep Convolutional Networks for Visual Recognition"*, ECCV 2014.
- Fast R-CNN**: Girshick, R., *"Fast R-CNN"*, ICCV 2015.
- Faster R-CNN**: Ren et al., *"Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks"*, NIPS 2015.
- FCN**: Long et al., *"Fully Convolutional Networks for Semantic Segmentation"*, CVPR 2015.
- SSD**: Liu et al., *"SSD: Single Shot MultiBox Detector"*, ECCV 2016.
- U-Net**: Ronneberger et al., *"U-Net: Convolutional Networks for Biomedical Image Segmentation"*, MICCAI 2015.

Q & A