

SiLK : Simple Learned Keypoints

(5 주차 : Local Feature Detection)

<https://arxiv.org/abs/2304.06194>

[GitHub - facebookresearch/silk: SiLK \(Simple Learned Keypoint\) is a self-supervised deep learning keypoint model. · GitHub](#)

데이터사이언스융합학과
2025713235 안희철

TABLE OF CONTENTS

① **Intro**

② **Method**

③ **Experiments**

④ **Conclusion**



01 Intro

키포인트 검출과 기술(Description)을 가장 단순하게 학습하는 방법

Keypoint Detection & Description

- 이미지 매칭, 3D 복원, Visual Odometry 등의 기반 기술


기존 연구 흐름

- 수작업 설계(Hand-engineered) : Harris corner, SIFT, HOG 등 사람이 설계한 방법 활용
- 학습 기반(Learning-based) : 검출 성능 향상을 위해 학습 도입

학습 기반 방법의 한계

- 학습 기반 방법마다 백본, 평가 프로토콜, 데이터셋, 지도 방식의 차이 존재
- 여러 요소가 서로 영향을 주어 결과 해석이 어려움 발생

본 논문의 핵심 질문 : " 좋은 키포인트 검출기의 조건은 무엇인가? "



< Figure 1 : (위) 시점 변화 속 매칭결과, 초록색 = 정답, 빨강색 = 오답,
(아래) SiLK가 찾은 왕복 매칭 성공 포인트 >

01 Intro

제안 : **SiLK** — 기존 설계를 분해하고 기본 원리부터 다시 설계

제안 : SiLK (Simple Learned Keypoints)

- 기존 검출기의 설계를 분해해 핵심 구성 요소를 파악
- 각 구성 요소를 기본 원리(first-principle)부터 다시 설계
- Fully-differentiable, Lightweight, Flexible한 구조

성과

- HPatches : Detection Repeatability, Homography Estimation SOTA
- ScanNet : 3D Point-Cloud Registration SOTA
- IMC 2022, ScanNet 카메라 포즈 추정 : SOTA와 대등한 성능

	Keypoint Detection					Descriptors & Matching			Model & Training			
	Learned	Sparse	Cell-based	NMS	Supervision	CA	Matcher	Supervision	Input	Backbone	Data	E2E
SIFT	No	✓	No	✓	-	No	MNN	-	-	-	-	-
SuperPoint	✓	✓	✓	✓	Homo. Adapt.	No	MNN	Rand. Homo.	Grey	VGG	COCO	No
SuperGlue	-	✓	-	-	-	GraphNN	OT	SfM	Grey	VGG	Oxford & Paris	No
GLAMPoints	✓	✓	No	✓	Matching Succ.	No	MNN	-	Grey	UNet	SlitLamp	✓
D2-Net	✓	✓	✓	✓	Triplet Ranking	No	MNN	SfM	RGB	VGG	MegaDepth	✓
R2D2	✓	✓	✓	✓	Matching AP	No	MNN	SfM	RGB	L2-Net	Aachen	✓
DISK	✓	✓	✓	✓	Matching Succ.	No	MNN	SfM	RGB	UNet	MegaDepth	✓
URR	-	No	-	-	-	-	MNN	3D Rendering	RGB	ResNet	ScanNet	✓
LoFTR	-	No	-	-	-	Transformer	MNN,OT	SfM	Grey	FPN	ScanNet,MegaDepth	✓
SiLK	✓	Optional	No	No	Matching Succ.	No	MNN	Rand. Homo.	Grey	Generic	Any Image Set	✓

< Table 1 : 기존 대표적인 특징점 검출 및 매칭 기법과 SiLK 비교 결과 >

02 Method

핵심 아이디어 : "잘 매칭되는 점 = 좋은 키포인트"

```
def loss(image_0, model):
    # get warped image and pixel correspondences
    image_1, corr_0, corr_1 = rand_homo(image_0)

    # apply image augmentations
    image_0 = augment(image_0)
    image_1 = augment(image_1)

    # extract dense descriptors and keypoints
    desc_0, kpts_0 = model(image_0)
    desc_1, kpts_1 = model(image_1)

    # compute similarity matrix
    sim_mat = cosim(desc_0, desc_1)

    # compute the descriptor loss
    # using ground truth correspondences
    loss_desc = nll(sim_mat, corr_0, corr_1)

    # measure matching success
    y = is_match_success(sim_mat, corr_0, corr_1)

    # compute keypoint loss
    # using current matching success
    loss_kpts = bce(kpts_0, y, corr_0)
    loss_kpts += bce(kpts_1, y, corr_1)

    return loss_desc + loss_kpts
```

SiLK 핵심 파이프라인을 파이썬 코드로 정리

1. 이미지 1장에 랜덤 Homography 적용 → 변형 이미지 + 픽셀 정답 대응 생성
2. 밝기, 노이즈, 블러 등 이미지 증강
3. 모델이 두 이미지의 descriptor와 keypoint 확률을 출력
4. 두 descriptor의 유사도 행렬(cosine similarity) 계산
5. Descriptor loss : 정답 대응점끼리 매칭되도록 학습
6. 매칭 성공 여부 → Keypoint loss의 정답으로 사용

→ SiLK 는 별도의 수동 라벨이나 3D 정답 데이터 없이 Self-supervision 방식으로 구체화

< Figure 2 : Pseudo-code : learning keypoints from a single image. >

02 Method

SiLK의 설계 원칙 : **각 구성 요소에서 가장 단순한 선택**

- 키포인트를 코너 같은 모양이 아니라 '매칭이 잘 되는 점'으로 정의
- 구조가 단순해 백본, 해상도, 학습 데이터를 바꿔 보는 실험(ablation)이 쉬움

Design Principle

기존 학습 기반 방법에
붙어 있던 복잡한 장치를
걸어내고, 꼭 필요한
요소만 남긴 구조



픽셀 단위 Sigmoid

셀 단위 softmax 대신 픽셀마다 독립적으로 확률 계산
→ 셀 크기 하이퍼파라미터 제거



NMS 없음

후처리 없이 확률이 높은 Top-k 픽셀만 선택
→ 튜닝할 요소 감소



단순한 매칭과 학습

Cosine 유사도 + MNN 매칭, 한 단계 학습
→ 라벨 없는 아무 이미지로 학습 가능

02 Method

Backbone 1개 + Head 2개의 detect-and-describe 구조

입력

Grayscale 1채널 이미지

Backbone : VGGnp-4

VGG에서 max-pooling을 제거해 해상도를 줄이지 않음 → 픽셀 단위로 정확한 위치 추정

Keypoint Head


3×3 conv → 1×1 conv → 픽셀마다 '키포인트일 확률' 1채널 출력

Descriptor Head

3×3 conv → 1×1 conv → 픽셀마다 128차원 descriptor 출력

Backbone-agnostic


백본을 자유롭게 교체 가능 (VGG, UNet, FPN 등)



< Figure 3 : SiLK 구조 >

02 Method

Self-Supervision : 이미지 1장으로 픽셀 단위 정답 대응 생성



정답 대응 만들기

- 모든 픽셀 중심 좌표에 H를 적용 $\rightarrow I \rightarrow I'$ 방향 대응
- 역행렬 H^{-1} 로 $I' \rightarrow I$ 방향 대응도 계산
- 양방향 일치하는 대응만 정답으로 사용 (이미지 밖, 1:1이 아닌 대응 제거)

< 논문 3.4.1절 내용을 바탕으로 재구성한 개념도 >

이미지 증강과 특징

- 밝기, 대비, 가우시안 노이즈, 스펙클 노이즈, 모션 블러 $\rightarrow$ 조명 변화와 노이즈에 강해짐
- 별도의 사전학습이나 pseudo-label 생성 과정 없이 바로 학습

$\rightarrow$ 라벨 없는 어떤 이미지 데이터셋으로도 학습 가능 (기본 : COCO)

02 Method

Descriptor Loss : **왕복 매칭(Cycle Consistency)** 확률을 최대화


- 목표 : 같은 점의 descriptor끼리 가장 비슷해지도록 학습
- 유사도 행렬 : I의 모든 픽셀 × I'의 모든 픽셀의 cosine similarity
- $P(i \rightarrow j)$: i번째 행에 softmax → i가 j로 갈 확률
- $P(i \leftarrow j)$: j번째 열에 softmax → j가 i로 돌아올 확률

$$P(i \leftrightarrow j) = P(i \rightarrow j) \cdot P(i \leftarrow j)$$

$$L_{desc} = -(\log P(i \rightarrow i') + \log P(i \leftarrow i'))$$

- 비유 : 한국어 → 영어 → 한국어로 번역했을 때 원문이 그대로 돌아오면 좋은 번역

* 행렬 크기가 HW×HW로 커서, 블록 단위로 나눠 계산해 GPU 메모리 문제를 해결




< 논문 3.3절과 3.4.4절 수식에 대한 개념도 >

02 Method

Keypoint Loss : 매칭 성공 여부를 맞히는 분류 문제

- 키포인트 = '매칭에 성공할 확률이 높은 픽셀'
- 정답(y) 만들기 : 현재 descriptor로 Mutual Nearest Neighbor 매칭
 - 왕복 매칭 성공 ($i \rightarrow i' \rightarrow i \rightarrow 1$) (Positive)
 - 실패 $\rightarrow 0$ (Negative)
- L_{key} = Binary Cross-Entropy(키포인트 확률, y)
- 전체 Loss = $L_{desc} + L_{key} \rightarrow$ 두 loss를 동시에 학습
- 추론 시 : 확률이 높은 Top-k 픽셀을 키포인트로 선택 (NMS 없음)

→ 키포인트 헤드 = "이 픽셀은 매칭에 성공할까?"를 예측하는 분류기



03 Experiments

HPatches : 반복성·호모그래피 추정 **모두 1위**

< HPatches : 조명 변화 57장면 + 시점 변화 59장면, Table 2 >

	Repeatability		Hom. Est. Acc.		Hom. Est. AUC		MMA		# of keypoints	
	$\epsilon = 1$	$\epsilon = 3$	$\epsilon = 1$	$\epsilon = 3$	$\epsilon = 1$	$\epsilon = 3$	$\epsilon = 1$	$\epsilon = 3$	pre-match	post-match
SuperPoint (MagicLeap)	0.34	0.61	0.43	0.8	0.2	0.51	0.41	0.72	847	499
SuperPoint (Ours)	0.33	0.52	0.48	0.75	0.26	0.52	0.38	0.53	1143	474
SIFT	0.31	0.52	0.6	0.84	0.34	0.61	0.41	0.55	2189	910
R2D2	0.36	0.72	0.45	0.79	0.2	0.5	0.34	0.75	6088	1967
DISK	0.38	0.69	0.45	0.8	0.22	0.52	0.52	0.84	3349	1794
SiLK (top-10k)	0.62	0.81	0.62	0.87	0.4	0.66	0.59	0.71	10000	4283
SiLK (top-5k)	0.56	0.76	0.6	0.85	0.39	0.64	0.57	0.69	5000	2074
SiLK (top-1k)	0.43	0.61	0.53	0.81	0.32	0.58	0.52	0.63	1000	389

* ϵ : 정답으로 인정하는 픽셀 오차 ($\epsilon=10$ 이 더 엄격)

* Repeatability : 두 이미지에서 같은 점이 다시 검출되는 비율

* Hom. Est. Acc. / AUC : 매칭으로 추정된 호모그래피의 정확도

* MMA : 매칭된 점 쌍 중 올바른 비율

→ $\epsilon=1$ 반복성 **0.62 (기존 방법 0.31~0.38)**

→ 엄격한 기준($\epsilon=1$)일수록 격차가 큼 : 픽셀 단위로 정확한 위치

→ 단, MMA ($\epsilon=3$) 은 DISK(0.84)보다 낮음 (0.71)

03 Experiments

실제 3D 장면에서도 **Sparse 방법 중 최고 수준**

IMC 2022 : 실외 카메라 포즈 추정 (mAA)

	private mAA	public mAA
Sparse Features		
DISK	0.491	0.502
SuperGlue	0.676	0.678
SiLK	0.685	0.684
Dense Features		
LoFTR (MegaDepth)	0.735	0.721

- Sparse 방법 중 1위 : mAA 0.685 (DISK 0.491, SuperGlue 0.676)
- Transformer 기반 dense 방법 LoFTR(0.735)보다는 낮음

ScanNet : 실내 카메라 포즈 추정 (AUC)

Pose Estimation AUC	@5°	@10°	@20°
Sparse Features			
D2-Net [17] + MNN	5.3	14.5	28.0
SuperPoint [16] + MNN	9.4	21.5	36.4
SuperPoint + PointCN [52]	11.4	25.5	41.4
SuperPoint + OANet [53]	11.8	26.9	43.9
SuperPoint + SuperGlue [42]	16.2	33.8	51.8
SiLK + MNN	18.0	34.4	<u>50.4</u>
Dense Features			
DRC-Net [27]	7.7	17.9	30.5
LoFTR (MegaDepth)	16.9	33.6	50.6
LoFTR (ScanNet)	21.5	40.8	57.6

- 단순 MNN 매칭만으로 SuperPoint + SuperGlue보다 @5°, @10°에서 높음

03 Experiments

작은 모델, 작은 학습 이미지로도 **충분한 성능**

백본 크기 (Table 7)

	HPatches			ScanNet			Model		
	R	HAc	MMA	RA	TA	C	Param	FPS	GFLOP
VGGnp-4	0.62	0.62	0.59	98.1	82.9	92.8	942k	12.2	370
VGGnp-3	0.63	0.61	0.58	98.0	84.2	93.5	868k	12.5	330
VGGnp-2	0.63	0.57	0.55	97.3	83.5	92.4	757k	14.3	268
VGGnp-1	0.63	0.57	0.44	94.6	82.1	90.0	461k	18.9	90
VGGnp-μ	0.64	0.56	0.40	93.5	81.1	89.0	76k	36.5	23
FPN [47]	0.58	0.55	0.52	-	-	-	6.6M	17.5	298
UNet [50]	0.60	0.41	0.58	-	-	-	1.3M	25.9	198

- 파라미터 7.6만 개(VGGnp-μ)로도 반복성 0.64 유지, 36.5 FPS
- 큰 백본(FPN 6.6M, UNet 1.3M)은 이득 없음, 단 작을수록 MMA 하락

학습 해상도 (Table 8)

Size	Time	HPatches			ScanNet		
		R	HAc	MMA	RA	TA	C
82 ²	1.7h	0.60	0.58	0.56	98.1	83.5	92.5
114 ²	2.7h	0.62	0.62	0.59	98.1	82.9	92.8
146 ²	5h	0.63	0.59	0.59	98.2	83.3	92.9
178 ²	9.5h	0.63	0.62	0.59	98.1	83.5	92.9
210 ²	18h	0.63	0.61	0.60	98.1	83.4	92.8

- 82×82로 줄여도 성능 거의 동일 → 1.7시간이면 학습 완료
- 학습 데이터(COCO, ImageNet, MegaDepth)를 바꿔도 결과가 비슷함

04 Conclusion

SiLK : **단순함**만으로 SOTA 수준에 도달한 키포인트 학습 방법

단순한 구조와 학습

백본 + 헤드 2개, loss 2개, 한 단계 학습으로 완성

새로운 키포인트 정의

'잘 매칭되는 점 = 좋은 키포인트'라는 정의만으로 SOTA 수준 성능

복잡한 장치 불필요

합성 사전학습, 셀 단위 softmax, NMS, context aggregation 없이도 충분

경량·실시간 응용

초경량 모델로도 충분 → 모바일, SLAM 등 실시간 응용에 유리

Limitation

- 오차를 넓게 허용한 매칭 정확도(MMA@3)는 상대적으로 약함
- 호모그래피(평면 변환)로만 학습 → 실제 3D 시점 변화는 간접적으로만 학습
- 두 이미지를 함께 보는 dense 방법(LoFTR)과는 아직 격차
- 후속 연구 : DeDoDe(2024), DaD(2025) 등으로 이어짐

Thank you
Q&A