

컴퓨터 비전

Local Feature Detection

LoFTR: Detector-Free Local Feature
Matching with Transformers

2025713932

스마트팩토리융합학과
조환희



1. 연구배경 및 동기

2. LoFTR
방법론

3. 트랜스포머

4. 결론 및 요약

1

연구 배경 및 동기

기존의 방식 분석

기존의 방식 및 한계 분석

🔑 기존 방식 (SfM , SLAM)

- 탐지기 기반 : 특징점 우선 추출.
- **순서**: Detection → Description → Matching.
- 근본적 한계: 특징점이 없으면 매칭 불가능.

⚠️ 실패 주요 원인

- 저조도 환경: 뚜렷한 코너점 부재.
- 텍스처 부족 영역: 반복성 있는 특징점 추출 실패.
- 반복 패턴: 좁은 시야각으로 인한 오매칭 발생.

기존의 방식 및 한계 분석

🔑 기존 방식 (SfM , SLAM)

- 탐지기 기반 : 특징점 우선 추출.
- **순서**: Detection → Description → Matching.
- 근본적 한계: 특징점이 없으면 매칭 불가능.



2

LoFTR 핵심 방법론

방법론 확인



LoFTR이란?

LoFTR의 핵심 제안


Detector-Free

특징점 추출 단계 완전 생략.
픽셀 단위 밀집(Dense) 정합 수행.

Transformers

비교 분석 및 정확도 향상

LoFTR이란?



전체 시스템 구조

LoFTR은 4단계로 구성됨

1. Local Feature CNN 단계로 두 이미지에서 $1/8$ 사이즈와 $1/2$ 사이즈의 특징 맵을 추출
2. 추출된 맵을 벡터로 펼치고 위치 정보를 더 한 뒤 LoFTR 모듈(트랜스포머)을 통과시켜 위치와 정보가 반영된 특징을 생성
3. 매칭 모듈로 변환된 특징들을 행렬 계산하여 가장 가까운 이웃(?)을 찾아 매칭을 수행합니다.
4. Coarse-to-Fine Module을 통해 매칭점 주변을 잘라 서프 픽셀 단위의 정밀한 최종 매칭을 합니다.

3



트렌스포머

논문 저자들의 방법

트랜스포머의 활용

LoFTR 2단계: 트랜스포머란?
기존 방식(CNN)은 좁은 영역만 확인 가능
트랜스포머는 넓은 영역을 확인 가능

1. Self-attention과 Cross-attention을 비교
파악하여 고유의 위치 정보를 얻을 수
있음
2. 문제점: CNN 대비 연산량이 매우 높은 단점이
있음.



트랜스포머의 활용

연산 병목 현상 해결

Linear Transformer 도입

기존 복잡도


$O(N^2)$



선형 복잡도

$O(N)$

커널 함수 대체를 통한 행렬 곱셈 순서 최적화.
고해상도 이미지 입력 시 메모리 및 연산량 급증 문제 해결.



Coarse-to-Fine 정밀화

로컬 윈도우 크롭 (Local Cropping)


초기 매칭 좌표 중심 1/2 해상도 특징 맵 영역 크롭.

상관관계 스코어링 (Correlation)

크롭된 영역 내부 중심 픽셀과 주변 픽셀 간 상관도 연산.

서브 픽셀 정밀화 (Sub-pixel Expectation)

히트맵 확률 분포의 기댓값 계산. 서브 픽셀 단위 최종 좌표 획득.



4

실험 결과

결과 값 확인



실험 결과

LoFTR 을 기존 검출기 최신 모델과 비교해본 결과
압도적 1위를 기록하였음


실내 데이터셋과 실외 데이터셋을 활용한 카메라
포즈 추정에서도 모두 소타를 달성하였음.

특히 텍스처가 부족한 영역이 많은 실내 환경에서
기존 방식들이 찾지 못하는 매칭 점을 LoFTR 이 성
공적으로 찾아내는 것을 확인할 수 있음

Category	Method	Homography est. AUC			#matches
		@3px	@5px	@10px	
Detector-based	D2Net [11]+NN	23.2	35.9	53.6	0.2K
	R2D2 [32]+NN	50.6	63.9	76.8	0.5K
	DISK [47]+NN	52.3	64.9	78.9	1.1K
	SP [9]+SuperGlue [37]	53.9	68.3	81.7	0.6K
Detector-free	Sparse-NCNet [33]	48.9	54.2	67.1	1.0K
	DRC-Net [19]	50.6	56.2	68.3	1.0K
	LoFTR-DS	65.9	75.6	84.6	1.0K

Category	Method	Pose estimation AUC		
		@5°	@10°	@20°
Detector-based	ORB [35]+GMS [2]	5.21	13.65	25.36
	D2-Net [11]+NN	5.25	14.53	27.96
	ContextDesc [27]+Ratio Test [26]	6.64	15.01	25.75
	SP [9]+NN	9.43	21.53	36.40
	SP [9]+PointCN [52]	11.40	25.47	41.41
	SP [9]+OANet [53]	11.76	26.90	43.85
	SP [9]+SuperGlue [37]	16.16	33.81	51.84
Detector-free	DRC-Net † [19]	7.69	17.93	30.49
	LoFTR-OT†	16.88	33.62	50.62
	LoFTR-OT	21.51	40.39	57.96
	LoFTR-DS	22.06	40.8	57.62

실험 결과



5

결론

정리



결론

매칭 패러다임 전환

특징점 추출을 생략하는 Detector-free 접근과 Transformer의 성공적 결합.

한계 환경 극복

전체적 시야를 통한 매핑 가능. 저조도 및 텍스처 부족 환경 정합 성공.

효율성 및 범용성

다양한 컴퓨터 비전 과제(SLAM, SfM)에 직접적 활용 가능.



감사합니다.

