


COMPUTER VISION

Working Hard to Know Your Neighbor's Margins: Local Descriptor Learning Loss (NIPS 2017)

고전 컴퓨터 비전 파이프라인과 Descriptor의 주요 특징



🛡 불변성 (Invariance)

조명 변화, 시점 회전, 스케일 왜곡에도 동일 물리 지점은 같은 벡터를 유지해야 함.

⚙ 변별력 (Distinctiveness)

서로 다른 지점의 패치는 임베딩 공간에서 뚜렷하게 분리되어야 한다.

SIFT의 명성과 CNN 기반 전환 시도

15년 간의 표준: SIFT (1999)

그래디언트 히스토그램 기반 128차원 수작업 디스크립터로 파노라마, 3D 복원 주도.


왜 CNN으로 대체하려 했는가?

수작업 필터는 복잡한 비선형 텍스처 및 비균일 조명 변화 대응에 이론적 한계 노출.

예상 밖의 장벽: CNN의 실전 부진

패치 검증은 통과했으나, 광각 스테레오 및 대규모 검색 벤치마크에서 SIFT에 지속 패배.

Calculating Gradient and Orientation



수작업 SIFT 구조: 4x4 그리드 분할 및 8방향 그래디언트 (총 128차원)

구조가 아니라 학습 방법(Negative)이 문제였다

무작위(Random) Negative 학습의 비효율성

●
Anchor

●
Positive

●
Easy Negative


이미 너무 멀리 떨어져 구별하기 쉬운 오답만 학습하면 모델이 더 정교해지지 않음.



HardNet의 핵심 질문

"현재 모델이 가장 헛갈려하는 어려운 오답(Hard Negative)을 집중 학습시키면 어떨까?"

HardNet = Hardest-in-Batch Negative Mining




거리 줄이기

정답은 가깝게

거리 벌리기


가장 헛갈리는 오답은 멀게

HardNet 학습 파이프라인



CNN은 descriptor를 만들고, HardNet의 Loss는 descriptor space를 학습한다.

CNN 아키텍처: 단순하고 호환성 높게



거리 행렬(Distance Matrix) 연산

$d(a_1, p_1)$	$d(a_1, p_2)$	$d(a_1, p_3)$	$d(a_1, p_4)$
$d(a_2, p_1)$	$d(a_2, p_2)$	...	...
$d(a_3, p_1)$	...	$d(a_3, p_3)$	...
$d(a_4, p_1)$	...	...	$d(a_4, p_4)$

- 대각선 (초록색): 정답 쌍 (Positive). 거리가 짧아야 함.
- 비대각선 (회색): 오답 쌍 (Negative 후보들).

Hardest – in – Batch Negative Mining

Distance matrix

$$D = \text{pdist}(a, p)$$

$$\begin{array}{cccc}
 d(a_1, p_1) & d(a_1, p_2) & d(a_1, p_3) & d(a_1, p_4) \\
 d(a_2, p_1) & d(a_2, p_2) & d(a_2, p_3) & d(a_2, p_4) \\
 d(a_3, p_1) & d(a_3, p_2) & d(a_3, p_3) & d(a_3, p_4) \\
 d(a_4, p_1) & d(a_4, p_2) & d(a_4, p_3) & d(a_4, p_4)
 \end{array}$$

(Note: In the original image, $d(a_1, p_4)$ is red with an arrow pointing to p_{4min} , and $d(a_2, p_1)$ is red with an arrow pointing to a_{2min} .)

예를 들어 a_1, p_1 을 positive pair라고 하면:

a_1 기준

$$p^* = \arg \min_{j \neq 1} d(a_1, p_j)$$

p_1 기준

$$a^* = \arg \min_{j \neq 1} d(a_j, p_1)$$

그리고 둘 중 더 가까운 **negative**를 선택합니다.

$$d_{neg} = \min(d(a_1, p^*), d(a^*, p_1))$$

"데이터셋 전체가 아니라, 현재 미니배치 안에서 가장 거리가 짧은(헛갈리는) 오답을 고른다."

최종 관문: Triplet Margin Loss

$$L = \max (0 , 1 + d (a , p) - d (a , n_{\text{hard}}))$$

개선 전 (Loss 발생)

정답 거리 $d(a, p)$ 가
오답 거리 $d(a, n)$ 와 비슷하여 헛갈리는 상태.



학습 목표 (Loss 제로)

정답과는 매우 가깝고, 오답과는 마진($m=1$) 이상 확실히 떨어뜨린 상태.

즉 loss 는 CNN에게
Positive 와는 더 가까워지고, 가장 헛갈리는 negative와는 충분한 margin을 확보하도록 하는 역할을 합니다.

왜 큰 미니배치(Large Batch)가 필수적인가?

배치 16

탐색 풀이 좁아 적당히 먼 Negative만 추출.




Figure 3: Influence of the batch size on descriptor performance. The metric is false positive rate (FPR) at true positive rate equal to 95%, averaged over *Notredame* and *Yosemite* validation sequences.



배치 512

풍부한 오답 풀(Pool) 확보.
훨씬 더 헛갈리는 '진짜' Hard Negative 발굴 가능.




Figure 4: Patch retrieval descriptor performance (mAP) vs. the number of distractors, evaluated on HPatches dataset.

배치가 커질수록 오답 마이닝 퀄리티가 높아져 서술자 성능이 수렴.

패치 검증 성능 대폭 향상 (Brown Dataset)

Descriptor	Mean FPR95 (낮을수록 우수)
SIFT	26.55%
TFeat-M	6.64%
L2Net	3.24%
HardNet+	1.90%

같은 CNN 구조인 L2Net(3.24%) 대비 절반 수준으로 에러 감소.
단순 구조 변경이 아닌 '학습 전략'의 승리.

학습하지 않은 데이터(HPatches)에서도 통할까?

학습 (Training)

Brown (Liberty)



평가 (Unseen Eval)

HPatches

(Verification, Matching, Retrieval)

Task (mAP)

Matching

Retrieval

L2Net

40.8%

58.6%

HardNet

50.3%

65.2%

잠깐, Triplet Loss가 좋아서 성공한 걸까?

Ablation Study를 통한 가설 검증

Sampling 방식 vs Loss 종류

Sampling \ Loss	Softmin	Triplet	Contrastive m = 2
Random + CPR	.349	.286	.083
Classical Hard + CPR	.391	.346	.279
Hardest-in-Batch	.474	.482	.482

"Loss의 종류보다 어떤 Negative를 샘플링하느냐(Sampling Strategy)가 훨씬 중요했다."

HardNet 논문의 핵심 시사점

샘플링의 힘

네트워크를 복잡하게 만드는 것보다, 어떤 데이터를 학습 시킬지가 더 결정적인 차이를 만듦.

학습은 무겁게, 추론은 가볍게

마이닝과 Loss 연산은 학습에만 쓰임. 실전 적용 시엔 가벼운 128-D 추출기 하나로 끝.

범용성 증명

기존 SIFT 파이프라인(128차원)에 그대로 호환되며 최고 성능 달성.

감사합니다.

Q&A