COMPUTER VISION PAPER REVIEW

Anytime Stereo Image Depth Estimation on Mobile Devices (AnyNet)

ICRA 2019
2019 IEEE International Conference on Robotics and Automation
Wang et al. (Cornell Univ.)

인공지능융합학과 홍성무

Stereo Camera Image를 통해 Depth를 파악하는 것이 로보틱스에 중요

Stereo Camera Image

- 인간의 Binocular Vision 을 모사하여 3차원 공간의 원근 거리를 파악
- LiDAR 센서 대비 가격 무게 에너지 효율면에서 우위
- 색상 질감 형태 등 풍부한 Context 제공

Disparity-Depth 와 Stereo Matching

- 좌우 두 카메라가 서로 다른 위치에서 동일 물체를 바라볼 때 시점 차이 발생
- Rectified 된 좌우 영상에 맺힌 동일 픽셀의 가로 위치 차이가 Disparity
- Distance가 작을 수록 Disparity는 커짐
- 핵심 관계식: Depth (Z) = (f × B) / Disparity (d) (f: 초점거리, B: 카메라 간격)
- 좌우 영상에서 짝이 되는 점을 찾아 Disparity Map을 완성하는 것

02 | PROBLEM DEFINITION

빠르게 움직이는 로보틱스를 위한 신속하면서 경제적인 솔루션 필요

기존 SOTA 모델의 한계

- 연산량 세제곱 Cubic 폭증 : H x W x M (가로 x 세로 x 범위)
- 모바일 임베디드 GPU NVIDIA Jetson TX2 에서 이미지 1장당 3초 이상 소요

Option1 고정밀 대형 모델 PSMNet GCNet

- 오차율 2-4% 대의 정교한 Map
- 500만개의 파라미터로 메모리 및 전력 소모 심함
- 연산속도가 느려 움직이는 로봇이 장애물을 피하기 전에 충돌

Option2 저해상도 경량화 모델

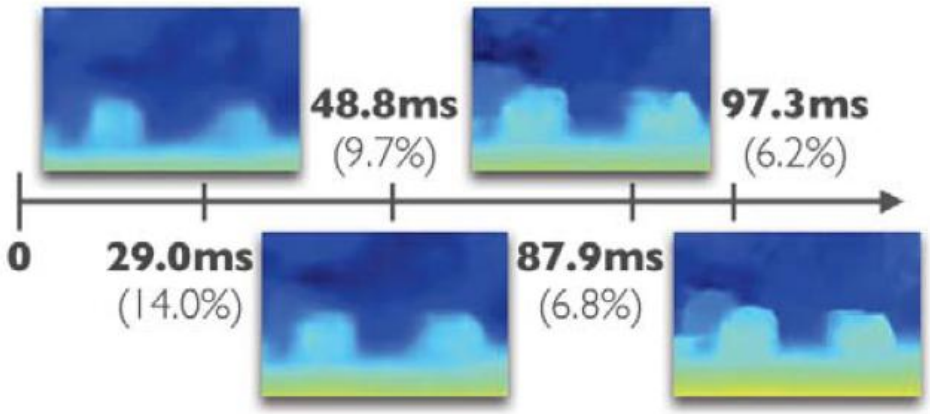
- 빠른 연산으로 움직이는 로봇이 충돌을 피할 수 있음
- 입력 이미지를 줄여 물체 경계가 뭉개지고 오차율 급증
- 정지할 때도 낮은 품질의 맵을 얻어 물건을 집는 등 정밀한 작업 불가

03 | CORE CONCEPT

Anytime Stereo Image Depth Estimation
언제든지 가장 최선의 맵을 제공한다

핵심 원리

- 처음부터 완벽한 고해상도 답을 구하는 것이 아니라 단계별로 계산
- 해상도(W,H)를 낮추거나 범위(M)를 좁게 하거나 둘 중 하나를 반드시 유지
- 전단계에서 연산한 Feature Map과 Disparity를 다음 단계에서 재활용하여 연산 효율화



- 시간이 지남에 따라 Depth 추정이 점차 더 정확해짐
- 언제든지 현재까지 계산된 최선의 Depth Map 추정치 반환
- 초기 추정치는 장애물 회피 기동을 즉각 유발하기에 충분
- 이후 단계는 보다 고도화된 Path Planning 수행하기에 충분
- 시간 아래의 괄호 안 수치는 3-Pixel Error Rate * 을 의미

* 3-Pixel Error Rate : 모델이 예측한 Disparity 값이 실제 정답 Ground Truth 와 비교했을 때 3픽셀 넘게 틀린 픽셀의 비율

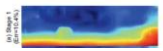
04 | NETWORK ARCHITECTURE

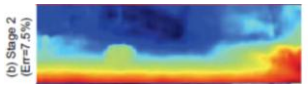
단계적으로 정제하는 파이프라인

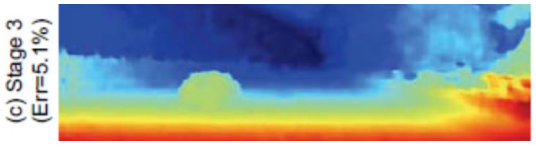
원본 이미지

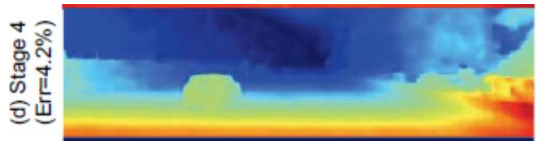


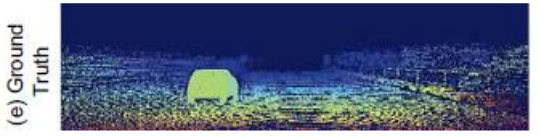
Stage 1 (28.9ms)	Stage 2 (48.8ms)	Stage 3 (87.9ms)	Stage 4 (97.3ms)
약 35 FPS | 14.0%	약 20 FPS | 9.7%	약 11 FPS | 6.8%	약 10 FPS | 6.2%
1/16 스케일의 Feature Map에서 전체 범위 Disparity Map 1 생성	Map1을 2배 확대 (1/8 스케일) 하고 warping하여 오차 구해 더함	Map2를 2배 확대 (1/4 스케일) 하고 warping하여 오차 구해 더함	에지 선명화 필터 SPNet 적용 물체 윤곽선을 다듬어 출력











Ground Truth by LiDAR

*제시된 그림은 단일 샘플영상 1장에 대한 예시임

U-Net Feature Extractor

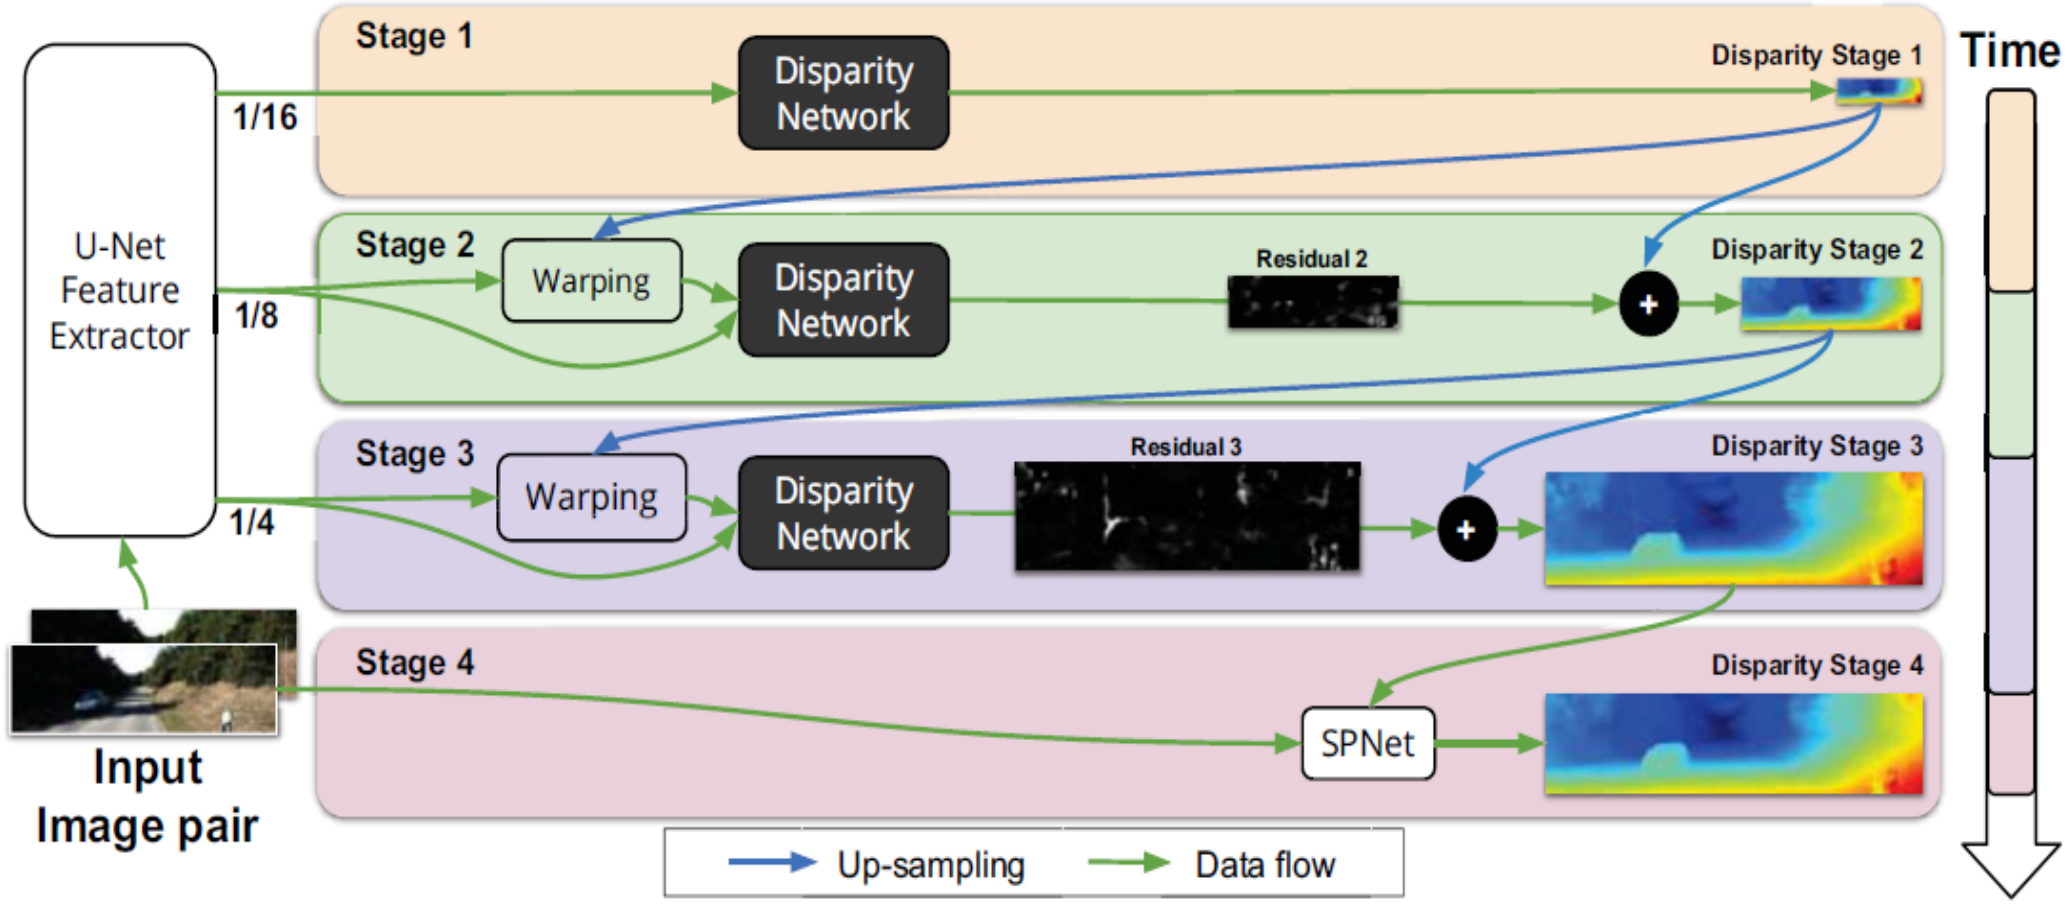
- 원본 좌우 이미지에서 Feature Map을 1/16, 1/8, 1/4 해상도별로 추출
- 1/16 스케일은 Global Context 파악 → 1/8, 1/4 스케일은 Local Detail 복원
- Stage 1에서는 1/16까지만 연산하여 초기 지연 시간 최소화

Disparity Network

- 좌우 이미지의 Feature Map을 입력 받아 Disparity Map 산출
- 좌측 픽셀벡터와 우측에서 이동한 픽셀벡터의 거리 기반 Distance-Based Cost Volume 구축
- 가려짐, 블러 등을 3D Convolution 으로 정규화
- 단순 최소값(Argmin) 대신 미분 가능한 Softmax 확률 가중 평균(Soft Argmax)으로 시차 연속 산출
- Stage 2~3는 Warping 후 잔차 범위 M=5 (±2 픽셀) 만 탐색하여 연산량 증가 방지

* 원본 해상도 기준 Stage 1은 192px, Stage 2는 ±16px, Stage 3는 ±8px 범위 보정

Stage 1에서만 전체 Disparity(M=12)를 계산하고, Stage 2~3는 Warping을 통해 Residual만 보정하여 더해줌으로써 실시간성 확보



Mobile Device 하드웨어를 통해 실제 주행 영상으로 실험

환경 셋업

- NVIDIA Jetson TX2 (드론, 로봇, 휴머노이드에 실제 탑재되는 저전력 보드)
- 학습 데이터 : Scene Flow (합성 데이터) 22,000쌍
- 평가 데이터 : KITTI-2012 & KITTI-2015 (실제 주행 영상) 1242×375 해상도 파인튜닝 및 평가

모델	특성	평가항목
KITTI-2012	카메라만 이동하는 정적환경	Stereo Matching, Optical Flow
KITTI-2015	카메라 및 주변 객체 이동하는 동적환경	Stereo Matching, Scene Flow

파라미터 및 효율 비교

모델	특성	파라미터
PSMNet	초정밀 SOTA	5,200,000
StereoNet	실시간 경량	400,000
AnyNet	본 논문	40,000

08 | RESULTS

시간 오차 품질 모두 베이스라인 모델 대비 우위

단계별 추론 시간 및 3-Pixel Error 비율

데이터셋 / 지표	Stage 1 (1/16)	Stage 2 (1/8)	Stage 3 (1/4)	Stage 4 (SPNet)
TX2 추론 시간 (프레임 속도)	28.9 ms (~35 FPS)	48.8 ms (~20 FPS)	87.9 ms (~11 FPS)	97.3 ms (~10 FPS)
KITTI-2012 오차율 (%)	15.1 ± 1.1 %	9.9 ± 0.6 %	5.7 ± 0.4 %	6.1 ± 0.3 %
KITTI-2015 오차율 (%)	14.0 ± 0.7 %	9.7 ± 0.7 %	6.8 ± 0.6 %	6.2 ± 0.6 %

베이스라인 모델 대비 비교 우위

- TX2에서 30 FPS 이상 달성 가능한 모델은 AnyNet과 StereoNet 뿐
- AnyNet의 오차율이 약 10%p 더 낮아 압도적 우위
- 10~35 FPS (고정밀 ~ 초고속 구간) 의 모든 추론 time budget 구간에서 기존 CNN 및 OpenCV 알고리즘 대비 가장 낮은 오차율 기록

Anytime Polling 결과

- Stage간 완료 간격이 짧아 언제든 요청이 와도 직전단계 결과 반환
- Stage1에서도 물체 감지 충분하며 Stage4에서는 Ground Truth 수준으로 선명

Mobile Device를 위한 Anytime Stereo Image Depth Estimation

학술적 의의

- 추론 속도와 정확도를 실시간 조절하는 최초의 스테레오 네트워크
- 압도적인 경량화와 실용성
- 연산 낭비 줄이는 아키텍처 설계

인간 시각 인지 메커니즘과 부합하는 Physical AI 인터페이스

- 위험 시 반사적으로 빠르게 반응하고 정밀 작업 시 집중하는 이중 구조를 로봇 비전에 구현
  - 보행/주행 모드: 35 FPS 초저지연 모드로 장애물 회피 및 보행 균형 유지
  - 정밀 파지 모드: 멈추어 물건을 집거나 사람과 상호작용할 때는 10 FPS 고정밀 모드
- 컴퓨팅 자원 배분 최적화: LLM, 관절 제어, 비전이 동시에 돌아가는 Mobile Device에서 비전 부하를 상황에 맞게 줄여주는 이상적인 인터페이스

APPENDIX

KITTI 영상 샘플





감사합니다.

