Efficient Depth Estimation for Unstable Stereo Camera Systems on AR Glasses

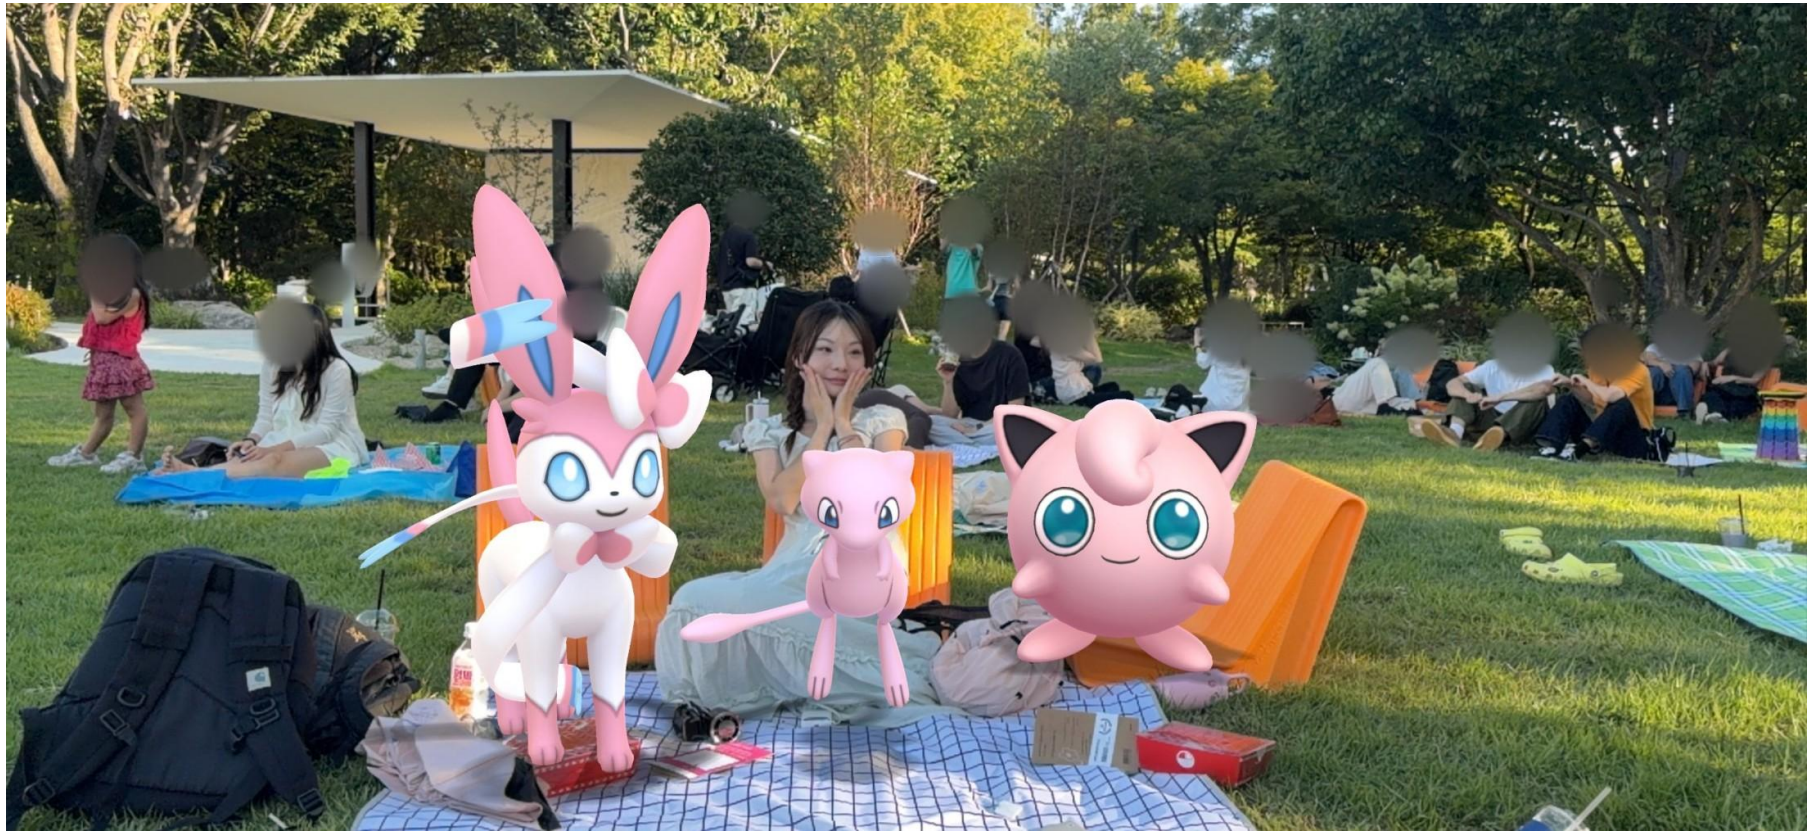
Yongfan Liu, Hyoukjun Kwon · CVPR 2025

데이터사이언스 융합학과 2026710923 강연빈

AR에서 Depth가 필요한 이유

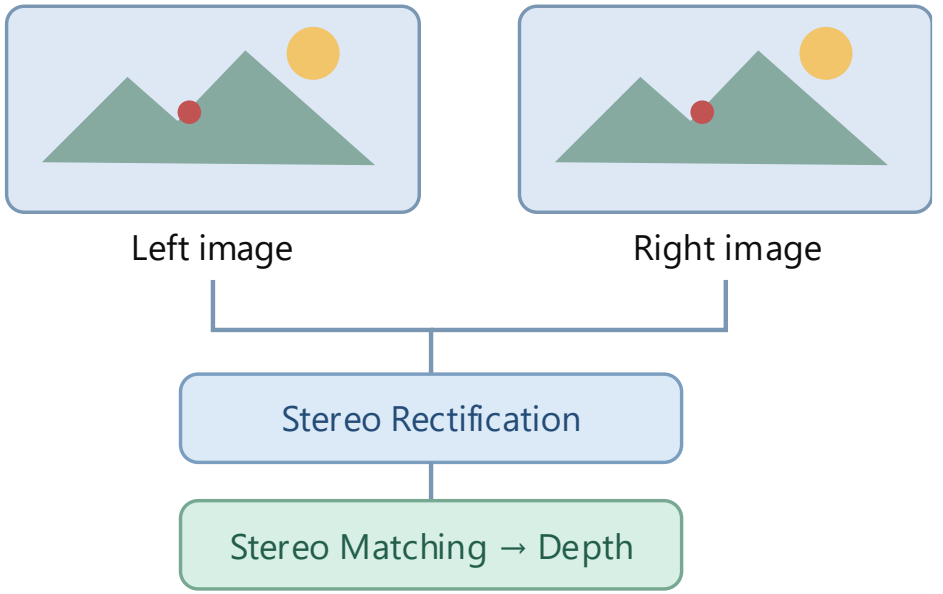
AR에서 가상 물체를 현실과 자연스럽게 합성하려면 정확한 Depth 정보가 필요하다.

Stereo Vision은 두 카메라의 기하학적 관계를 이용해 Depth를 추정할 수 있다.



Background : Classical Stereo Vision

1. **Epipolar Constraint**
   - 대응점 탐색을 epipolar line 위로 제한
2. **Stereo Rectification**
   - epipolar line을 수평 으로 정렬
3. **Stereo Matching**
   - 같은 행에서 대응점을 탐색
4. **Disparity → Depth**
   - 위치 차이로 거리 계산



Problem : Unstable Camera

[Problem 1] Unstable Stereo Cameras

- AR 안경 프레임은 사용자에 따라 변형되거나, 위치가 달라질 수 있다.
- 카메라의 상대 자세(extrinsic) 변화
- 기존 calibration/rectification 정보가 부정확해질 수 있음



출처 : Meta Aria gen2 소개 페이지

Problem : Latency Bottleneck

[Problem 2] High Latency

기존 ARGOS 알고리즘 분석 결과

- Preprocessing 30.2% Cost Volume 29.3% 두 단계가 전체 latency의 약 59.5%

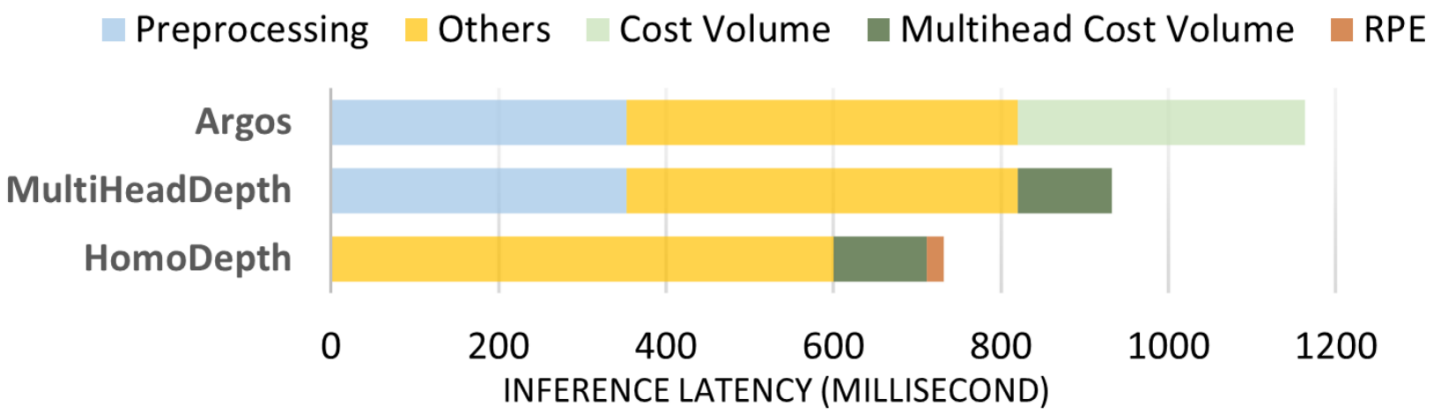


Figure 1, Liu and Kwon, CVPR 2025. Intel i7-12700H laptop CPU

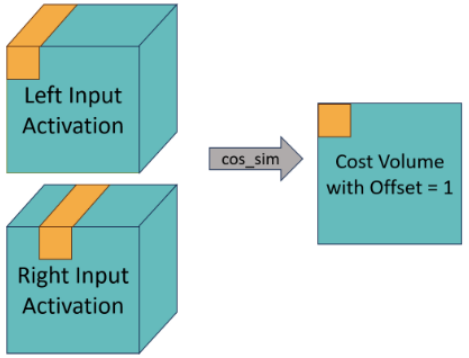
Rectification과 Cost Volume의 비용을 줄이면서도 정확한 Depth를 얻고자한다.

Proposed Method 1 : MultiHeadDepth

기존 Cost Volume의 문제

- 각 픽셀과 disparity 후보에 대해 feature similarity 계산한다.
- Cosine similarity는 norm과 division이 연산이 필요하다.
- GPU/NPU에서 비효율적인 연산이 병목이 될 수 있다.

	DSI	Cost Volume
비교 대상	픽셀 patch	CNN feature
유사도	SAD, SSD, NCC	cosine similarity
저장하는 값	disparity 후보별 매칭 점수	disparity 후보별 매칭 점수
출력 형태	행별 C(i, j)	[N, max_disparity, H, W]



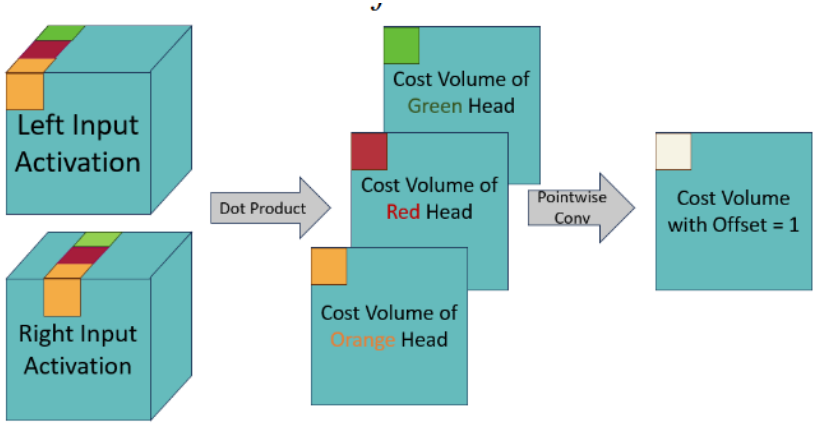
(a) **Diagram of the cost volume with an offset of 1.** The orange blocks indicate pixel vectors in the input activations, whose size is $1 \times number_of_channels$.

Figure 3(a), cost volume with an offset of 1

Proposed Method 1 : MultiHeadDepth

MultiHeadDepth 제안

- Feature를 여러 head로 분할 한다.
- LayerNormalization과 Dot Product로 유사도를 계산한다.
- Group-pointwise convolution 활용하여 Cost Volume의 역할은 유지하면서 연산을 효율화한다.



(b) **Diagram of the multi-head cost volume (3 heads in this case) with an offset of 1.** The orange blocks indicate part of pixel vectors, whose size is $1 \times \frac{number_of_channels}{number_of_heads}$.

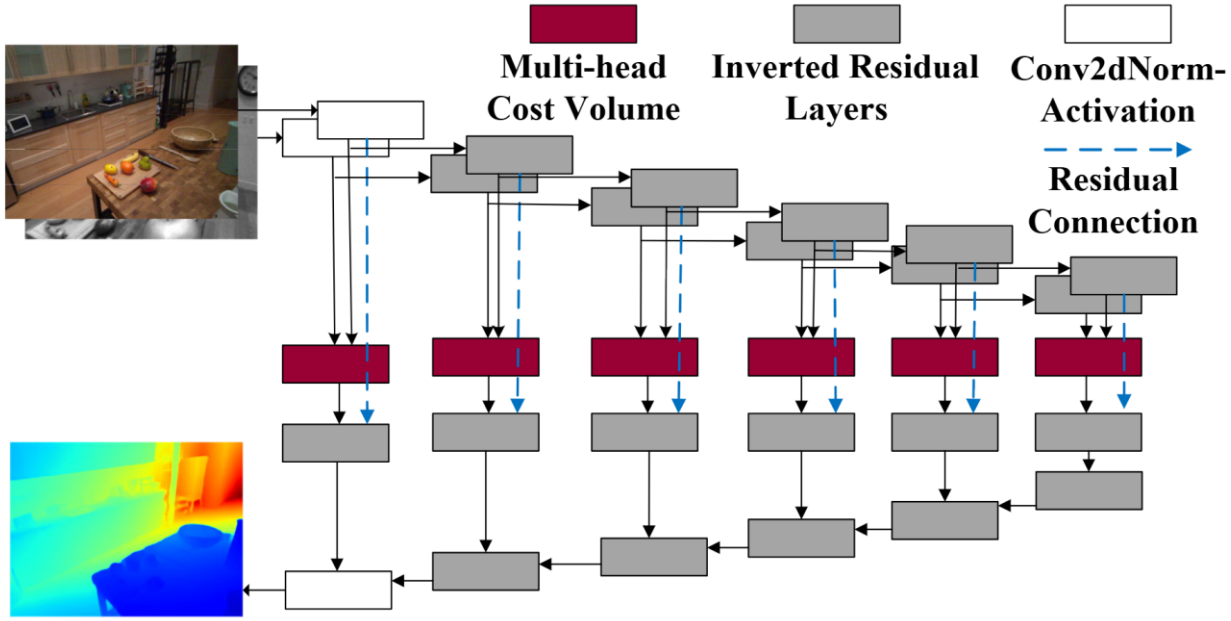


Figure 4. The structure of MULTIHEADDEPTH

Proposed Method 2 : HomoDepth

Rectification preprocessing **Latency**

- HomoDepth는 Depth head와 Homography head가 encoder를 공유하는 multi-task 구조이다.
- 카메라 정렬 관계를 네트워크가 직접 추정 하여 explicit rectification 의존도를 줄인다.

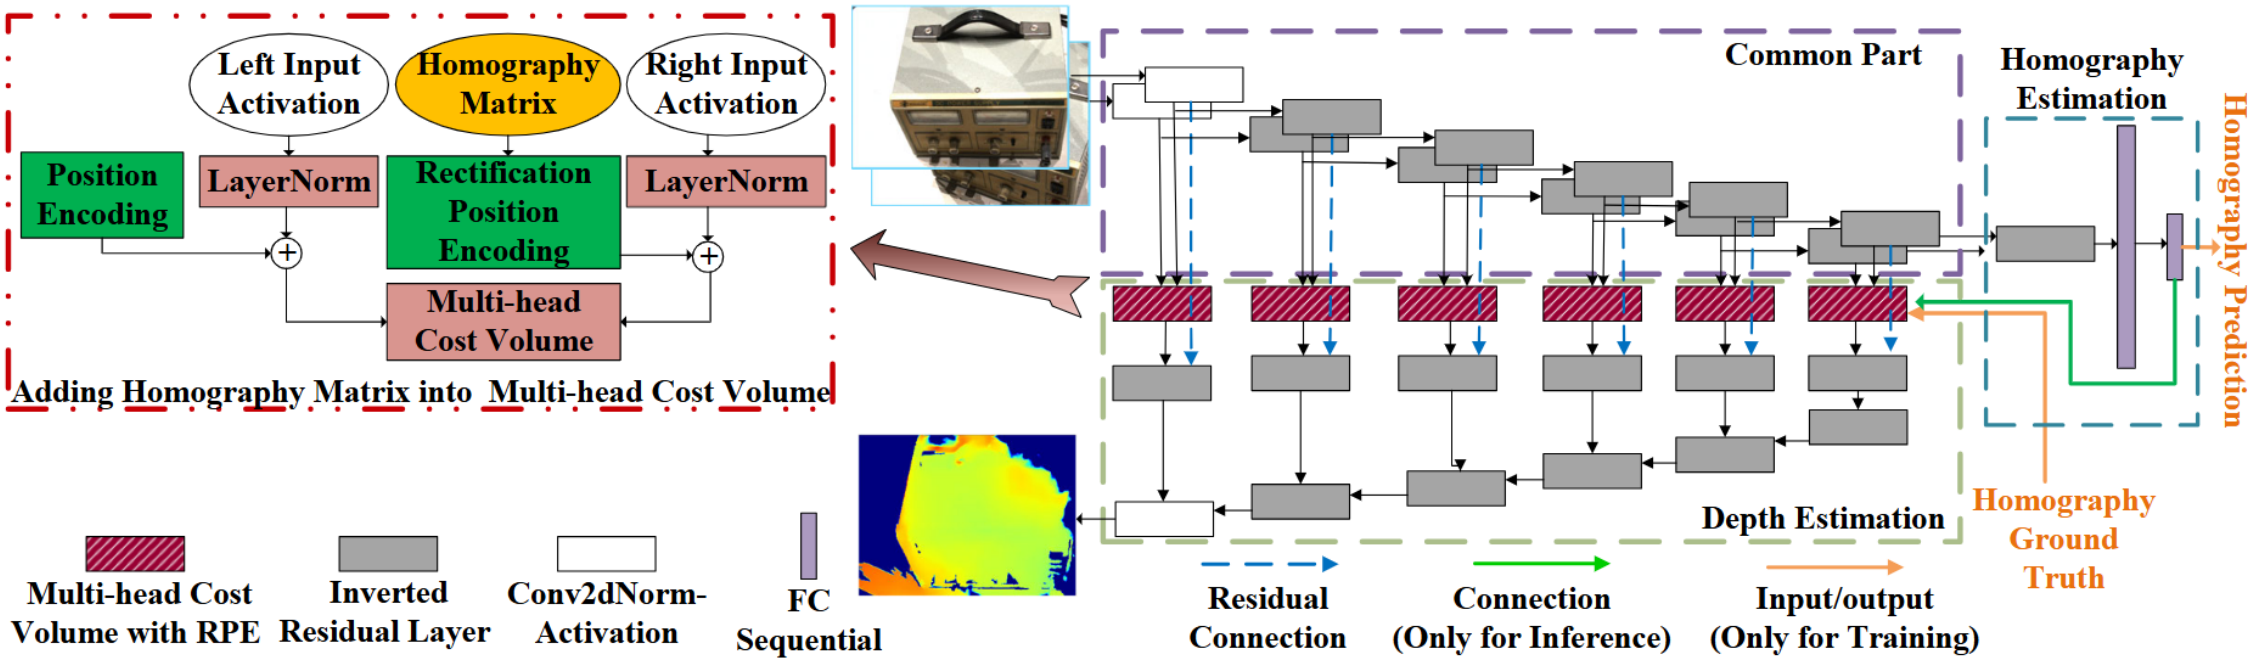


Figure 5, structure of HomoDepth

Proposed Method 2 : HomoDepth RPE (Rectification Positional Encoding)

RPE (Rectification Positional Encoding)

- 예측된 Homography로 좌·우 영상의 위치 관계를 encoding 한다.
- 이미지를 실제로 warp하지 않고 matching에 필요한 위치 정보를 network에 제공 한다.
- Multi-head Cost Volume에서 appearance similarity + positional similarit를 함께 사용한다.
- Rectification 과정의 정보 손실과 preprocessing 비용을 줄이는 것을 목표로한다.

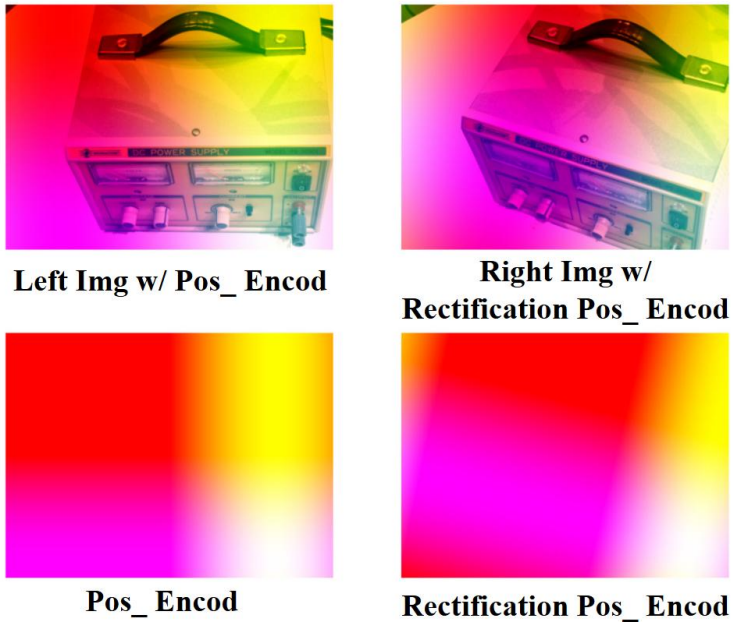


Figure 6, positional encoding and RPE

Results — Accuracy & Latency

MultiHeadDepth

- 정확도 11.8~30.3% 향상 하였고, latency 22.9~25.2% 감소 되었다.

HomoDepth

- explicit rectification 없이 end-to-end latency 최대 44.5% 감소되었다.

Table 4, DTU 계열	ARGOS (PreP 없음)	PreP + ARGOS	PreP + MultiHeadDepth	HomoDepth
AbsRel, DTU	0.122	0.109	0.099	0.098
AbsRel, DTU_df	0.183	0.115	0.107	0.087
AbsRel, Sceneflow_persp	0.232	0.121	0.114	0.097
Latency, CPU (ms)	811.0	1068.3	884.4	761.2
Latency, GPU (ms)	109.0	312.5	312.6	84.5

AbsRel ↓ = Depth 오차 감소. 수치는 데이터셋·측정 기준에 따라 달라질 수 있음.

Limitations & Critical Review

1. Homography approximation
   - 깊이 변화가 큰 3D scene에서는 하나의 homography 근사가 부정확할 수 있다.
2. Homography prediction dependency
   - Homography 예측 오류가 Depth 성능에 전달될 수 있다.
3. Hardware evaluation
   - 실제 상용 AR glasses가 아닌 proxy platform에서 latency를 측정하였다.
4. Dataset limitation
   - 실제 장시간 착용한 실험이 아니며, 프레임 변형 환경에 대한 검증이 제한적이다.

Table 5, latency (ms)	Orin Nano CPU	Orin Nano GPU	Snapdragon CPU	Snapdragon GPU
ARGOS	8774	209	1424	914
MultiHeadDepth	6183	216	1156	617
HomoDepth	6611	203	1512	893

※ ARGOS latency 비교 시 preprocessing 포함 여부를 확인해야 함.

Conclusion , Resources

Conclusion

새로운 Stereo Geometry를 만든 것이 아닌, 기존 Stereo Vision을 실제 AR 환경에 맞게 재설계한 연구

Resource

- Paper: https://openaccess.thecvf.com/content/CVPR2025/papers/Liu_Efficient_Depth_Estimation_for_Unstable_Stereo_Camera_Systems_on_AR_CVPR_2025_paper.pdf
- Code: https://github.com/UCI-ISA-Lab/MultiHeadDepth-HomoDepth