FoundationStereo: Zero-Shot Stereo Matching

대규모 합성 데이터 및 단안 파운데이션 모델 사전 지식 기반 스테레오 깊이 추정 모델 제안
- 도메인별 파인튜닝 없이 제로샷 일반화 성능 확보

Conference: CVPR 2025 · Bowen Wen et al. (NVIDIA)

데이터사이언스융합학과 박인혁

Background — 스테레오 매칭과 파운데이션 모델

Stereo Matching

입력
일정 거리(baseline)를 두고 배치된 좌·우 카메라의 동시 촬영 이미지 쌍

출력
대응점 간 수평 변위인 시차(disparity) 추정. 시차는 깊이에 반비례하므로 깊이로 변환 가능

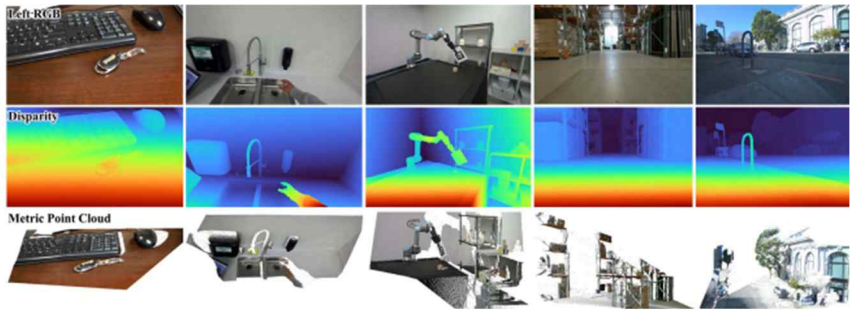


Figure 1. In-the-wild 제로샷 예측 결과

Foundation Model

- 대규모 데이터 학습을 통해 미학습 도메인에서도 추가 학습 없이(제로샷) 동작하는 범용 모델
- 사례: SAM(Segment Anything Model, 분할), DepthAnything(단안 깊이 추정)

Stereo Matching의 현황

- 주요 벤치마크 성능은 포화 수준
- 단, 대상 도메인 파인튜닝이 여전히 주된 방식

→ **스테레오 분야 파운데이션 모델 부재**

Problem — 기존 방법의 한계

1

학습 데이터 규모 부족

주로 Scene Flow(약 4만 쌍) 기반 학습. 데이터 규모의 한계로 인한 일반화 성능 제약

2

Sim-to-Real Gap

합성 데이터로 학습한 모델을 실제 이미지에 적용할 때 발생하는 도메인 격차

3

비국소 정보 활용 한계

3D CNN(Convolutional Neural Network)·GRU(Gated Recurrent Unit) 기반: 국소 연산 위주로 장거리 문맥 반영 미흡. 트랜스포머 기반: 비용 볼륨·반복 정제 구조 부재로 정확도 저하

Key 대응 → ① 데이터셋 · 자기 큐레이션 ② STA(Side-Tuning Adapter) ③ AHCF(Attentive Hybrid Cost Filtering)

Method — Overview

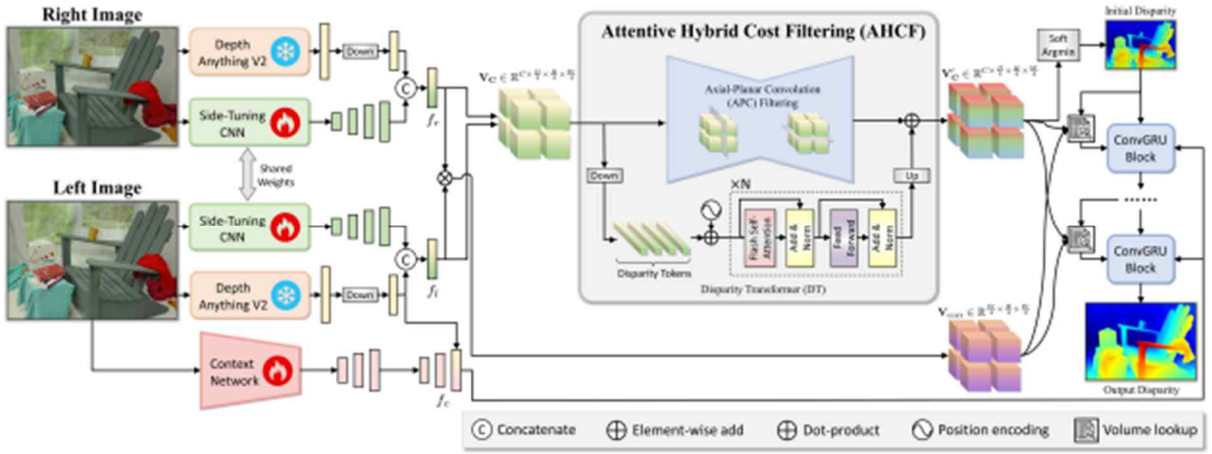


Figure 2. FoundationStereo 전체 구조

01 특징 추출 (STA)

좌·우 이미지로부터 CNN 특징 및 DepthAnythingV2 특징 추출·결합

02 비용 볼륨 구성

시차 후보별 좌·우 특징 비교를 통한 4D 비용 볼륨 구성

03 비용 필터링 (AHCF)

비용 볼륨 필터링 및 초기 시차 추정

04 반복 정제 (GRU)

ConvGRU(Convolutional GRU) 기반 반복 갱신을 통한 최종 시차 맵 산출

Method ① — FSD(FoundationStereo Dataset)

40K
기존 Scene Flow

1M
FSD · 1280×720

- **고사실도 렌더링**
  NVIDIA Omniverse 기반 경로 추적(path tracing)을 통한 사실적 조명·반사 표현
- **장면 다양성**
  실내·실외, 주행, 부유 객체(flying objects) 장면 구성. 고품질 3D 에셋 활용
- **도메인 무작위화**
  baseline, 초점거리, 카메라 자세, 조명, 객체 배치의 샘플 단위 무작위화



Figure 4. FSD 샘플

자기 큐레이션 (Self-Curation)

① FSD 기반 초기 모델 학습

② 학습된 모델로 FSD 재평가, BP-2(2px 초과 오차 픽셀 비율) 60% 초과 샘플을 모호 샘플로 판별

③ 모호 샘플을 신규 생성 샘플로 대체, 총 2회 반복

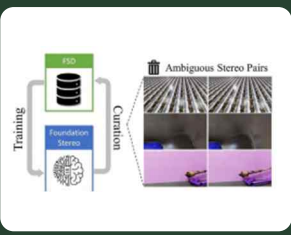


Figure 4 (우). 모호 샘플 예시

Method ② — Side-Tuning Adapter (STA)

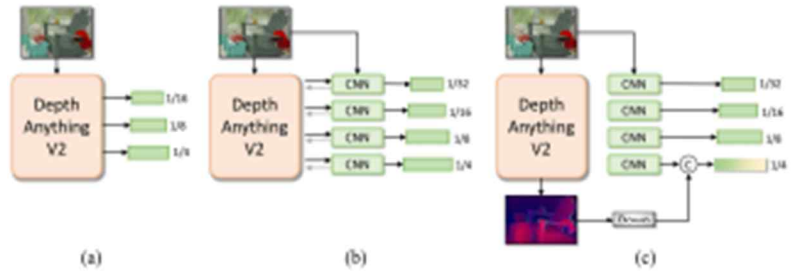


Figure 3 (a)–(c). STA 설계안

설계안 비교

(a) DepthAnythingV2 특징 단독 사용
(b) CNN–ViT(Vision Transformer) 간 양방향 특징 교환
(c) ViT 특징 축소 후 CNN 특징과 연결 → **최고 성능, 최종 채택**

단안 사전 지식 활용

실제 이미지로 대규모 학습된 DepthAnythingV2의 특징 활용을 통한 sim-to-real gap 완화

Side-Tuning 구조

ViT는 고정(frozen), 경량 CNN(EdgeNeXt)만 학습. ViT 미세조정 시 성능 저하 확인

잠재 특징 활용

단안 깊이 출력의 스케일 모호성 문제로 인해 깊이 값 대신 내부 잠재 특징 사용

특징의 용도 분리

1/4 해상도 결합 특징은 비용 볼륨 구성에, 별도 문맥 특징은 GRU 정제 단계에 사용

Method ③ — AHCF (1) Hybrid Cost Volume 및 APC

01 Hybrid Cost Volume

- **비용 볼륨**: 시차 후보별 좌측 특징과 이동된 우측 특징의 비교 결과를 누적한 4D 텐서 (1/4 해상도, C × D/4 × H/4 × W/4)
- **그룹 상관**: 채널을 8개 그룹으로 분할, 그룹별 상관도 산출 → 다양한 유사도 특징 제공
- **연결(concat)**: 좌·우 특징을 14채널로 축소(1×1 conv) 후 연결 → STA 기반 단안 사전 지식 보존

두 방식의 결합으로 Hybrid Cost Volume 구성

02 APC(Axial-Planar Convolution)

- 기존 3×3×3 3D 합성곱: 시차 방향 수용 영역 협소, 커널 확대 시 메모리·연산량 급증
- 3D 합성곱을 **공간 방향(높이·너비)**과 **시차 방향** 합성곱으로 분해
- 연산 부담 억제로 시차 방향 커널 확대 가능 → 수용 영역 확장 (커널 약 17에서 성능 포화)
- Hourglass 네트워크 내 3D 합성곱을 APC로 대체 (다운·업샘플링 층 제외)

Method ③ — AHCF (2) Disparity Transformer

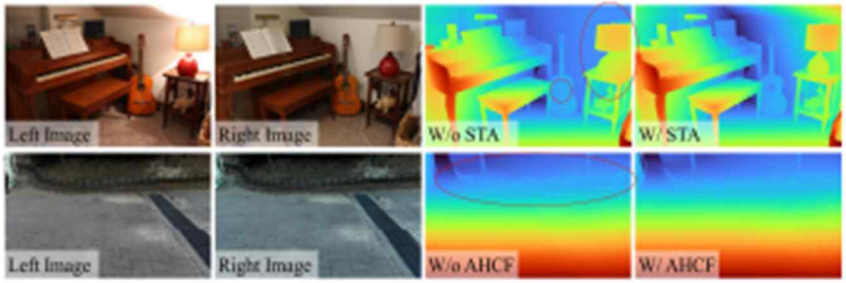


Figure 3 (우). STA·AHCF 적용 효과

초기 시차 추정

- 필터링된 볼륨에 대해 시차 축 softmax 확률 산출
- 확률 가중 평균(soft-argmin)으로 1/4 해상도 초기 시차 산출
- 이후 반복 정제 단계의 초기값으로 사용

시차 축 Self-Attention

픽셀 위치별 전체 시차 후보를 단일 시퀀스로 구성 → 후보 간 장거리 관계의 전역적 추론

연산 효율화

4×4×4 conv(stride 4)로 볼륨 축소(원 이미지 기준 1/16) 후 Transformer 블록 4개 적용, FlashAttention 활용

병렬 구조

Hourglass(APC) 경로와 병렬 연산, 출력 업샘플링 후 합산 (앞·뒤 직렬 배치 대비 우위)

어텐션 범위

4D 볼륨 전체 대비 시차 축 한정 어텐션의 성능 우위 확인 (Middlebury BP-2 2.25 → 1.97)

Method ④ — 반복 정제 (Iterative Refinement)

1. **Look-up**
   현재 시차 기준으로 필터링된 비용 볼륨 및 상관 볼륨의 값 조회

2. **ConvGRU 갱신**
   조회 값, 현재 시차, 문맥 특징을 입력으로 시차 갱신량 예측

3. **Coarse-to-Fine**
   1/16, 1/8, 1/4 해상도의 3단계 ConvGRU 연동

4. **Upsampling**
   학습 22회, 추론 32회 반복 후 convex upsampling으로 원 해상도 시차 맵 산출

학습 설정

손실: 초기 시차 및 전 반복 단계 출력에 대한 지도 학습. 후반 반복일수록 높은 가중치 부여

데이터: FSD 및 공개 데이터셋(Scene Flow, Sintel, CREStereo 등) 혼합

학습: A100 GPU 32장, 200K iterations

평가 벤치마크 데이터 학습 미사용 → 제로샷 설정

Results — Zero-Shot Generalization

Methods	Middlebury BP-2	ETH3D BP-1	KITTI-12 D1	KITTI-15 D1
CREStereo++ [27]	14.8	4.4	4.7	5.2
DSMNet [81]	13.8	6.2	6.2	6.5
Mask-CFNet [49]	13.7	5.7	4.8	5.8
HVT-RAFT [10]	10.4	3.0	3.7	5.2
RAFT-Stereo [36]	12.6	3.3	4.7	5.5
Selective-IGEV [66]	9.2	5.7	4.5	5.6
IGEV [36]	8.8	4.0	5.2	5.7
Former-RAFT-DAM [83]	8.1	3.3	3.9	5.1
IGEV++ [71]	7.8	4.1	5.1	5.9
NMRF [22]	7.5	3.8	4.2	5.1
Ours (Scene Flow)	**5.5**	**1.8**	**3.2**	**4.9**
Selective-IGEV* [66]	7.5	3.4	3.2	4.5
Ours	**1.1**	**0.5**	**2.3**	**2.8**

Table 2. 제로샷 성능 비교 (Middlebury · ETH3D · KITTI)

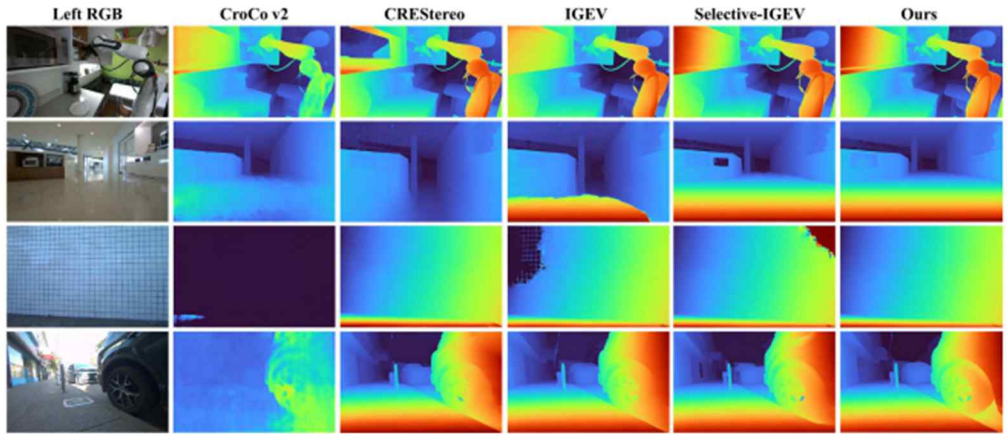


Figure 5. In-the-wild 이미지 정성 비교

Key Result 제로샷 조건 4개 벤치마크 모두 최고 · Scene Flow만 학습해도 기존 방법 대비 우위
In-the-wild 이미지에서도 정성적으로 우수 (비교 모델은 4개 벤치마크로 학습한 체크포인트)

Results — 파인튜닝 모델과의 비교 (ETH3D)

Method	Zero-Shot	BP-0.5	BP-1.0	EPE
GMStereo [73]	✗	5.94	1.83	0.19
HITNet [56]	✗	7.83	2.79	0.20
EAI-Stereo [84]	✗	5.21	2.31	0.21
RAFT-Stereo [36]	✗	7.04	2.44	0.18
CREStereo [34]	✗	3.58	0.98	0.13
IGEV-Stereo [70]	✗	3.52	1.12	0.14
CroCo-Stereo [67]	✗	3.27	0.99	0.14
MoCha-Stereo [14]	✗	3.20	1.41	0.13
Selective-IGEV [66]	✗	3.06	1.23	0.12
Ours (finetuned)	✗	**1.26**	**0.26**	**0.09**
Ours	✓	2.31	1.52	0.13

Table 4. ETH3D 리더보드 (test set) 결과

Ours (zero-shot) — ETH3D 학습 미사용

- **BP-0.5 2.31** : 파인튜닝된 기존 최고(3.06)보다 낮음
- **EPE 0.13** : 기존 최고(0.12)와 비슷
- **BP-1.0 1.52** : 9개 모델 중 5개보다 높음 (최고 0.98)

Ours (finetuned) — 기존 데이터 + ETH3D로 50K step 추가 학습

- **1.26 / 0.26 / 0.09** : 모든 지표 1위

위 9개 모델 · Ours (finetuned): ETH3D 학습 데이터로 파인튜닝

Key Result ETH3D 미사용 제로샷으로 ETH3D 파인튜닝 모델과 비슷한 수준 (일부 지표 우위)
ETH3D로 추가 파인튜닝 시 오류율 절반 이하 · ETH3D·Middlebury 리더보드 1위 (제출 시점)

Discussion — Limitations & Review

Limitations

- **속도**: A100 기준 375×1242 이미지당 0.7초 소요로 실시간 적용 제약. 저자는 증류·가지치기를 개선 방향으로 제시 (별도 후속 연구: Fast-FoundationStereo)
- **투명 객체**: FSD 내 투명 객체 비중 부족 → 데이터 보강 필요
- **(의견)** 기존 모델을 FSD 포함 동일 데이터로 학습한 비교 부재 → 대규모 데이터에서의 구조 기여도 불명확

Review

Strengths

- 데이터 · 사전 지식 · 네트워크 구조의 통합적 접근
- 단안 파운데이션 모델의 스테레오 태스크 적용 방안 제시

Discussion

- 성능 향상의 주된 요인: 데이터인가, 구조인가?
- 논문 근거 ① 같은 데이터(Scene Flow)로도 기존 방법보다 우수 → 구조 + 단안 사전 지식(STA) 효과 (Table 2)
- 논문 근거 ② 같은 구조에서 FSD 추가 시 Middlebury BP-2 2.34 → 1.15 → 데이터 효과 (Table 7)
- 남은 질문: 기존 모델도 FSD로 학습하면 격차가 유지되는가?

→ 관련 연구와 함께 검토 (다음 장)

Discussion — Related Work: 합성 데이터 설계

Yan et al., "What Makes Good Synthetic Training Data for Zero-Shot Stereo Matching?", CVPR 2026

!

연구 개요

- 모델 구조 고정(RAFT-Stereo, 매번 처음부터 학습) 후 합성 데이터 생성 요소별 통제 실험
- 유효 요소: 부유 객체 배치, baseline 및 재질 다양성 / 조명 변화의 효과는 미미
- 약 16만 쌍(WMGStereo-150k)으로 FSD 학습과 경쟁력 있는 성능 (DLNR 기준)
- DLNR 비교 시 FSD와 비슷한 수준 (7개 지표 중 4개 FSD 우위), 두 데이터 결합 학습 시 종합 최고 성능

?

추가 실험 제안

- 해당 데이터 설계 원칙을 반영한 FSD 재구성 시 성능 변화 검증
- FoundationStereo 구조로 두 데이터셋을 각각·결합 학습하여 데이터 기여도 검증 (Yan et al.은 기존 구조로만 비교)

Opinion 데이터는 규모만큼 설계 원칙도 중요. FoundationStereo 구조에서 결합 학습 효과 검증 필요

Summary

정리

01 100만 쌍 합성 데이터셋(FSD) 및 자기 큐레이션을 통한 학습 데이터 한계 해소

02 STA 기반 단안 파운데이션 모델 사전 지식 활용으로 sim-to-real gap 완화

03 AHCF(APC + Disparity Transformer) 기반 장거리 문맥 반영, 제로샷 스테레오 성능 기준 갱신

Q & A