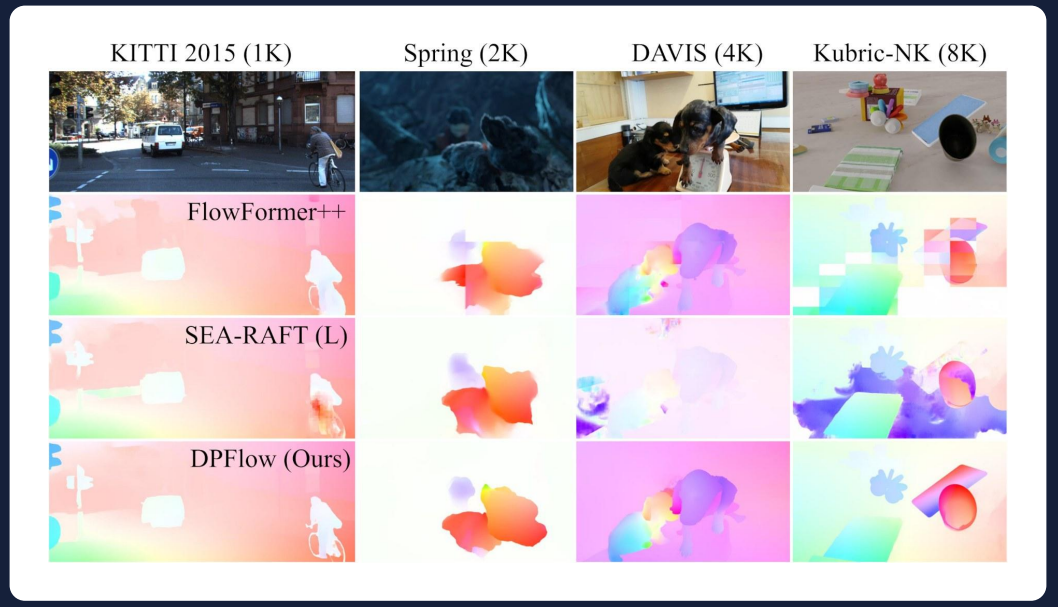
DPFlow

이중 피라미드로 해상도에 적응하는 Optical Flow

해상도가 높아져도, 움직임을 정확히 찾을 수 있을까?

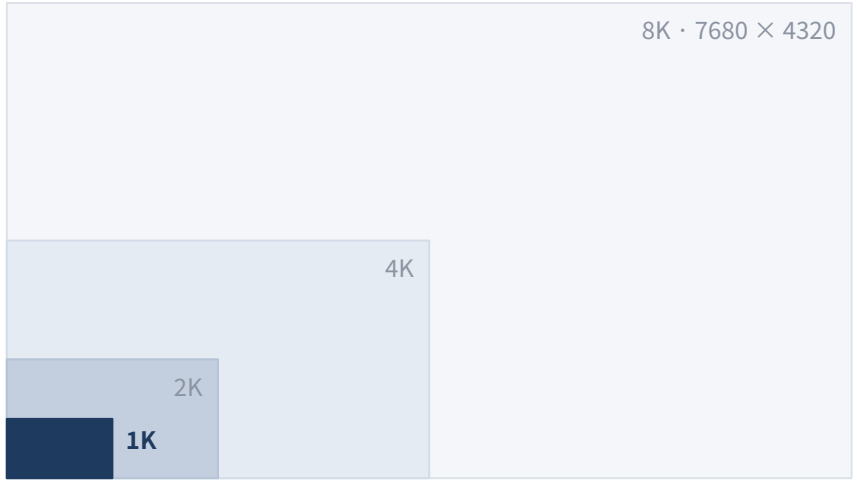


논문 Fig. 1 — 같은 장면을 1K부터 8K까지 추정한 결과

DPFlow: Adaptive Optical Flow Estimation with a Dual-Pyramid Framework · CVPR 2025

Henrique Morimitsu · Xiaobin Zhu · Roberto M. Cesar-Jr. · Xiangyang Ji · Xu-Cheng Yin

영상은 **8K**까지 커졌지만,
대부분의 Optical Flow 모델은
1K 안팎의 데이터로 학습·평가되어 왔다



1K = 960 × 540 (풀HD의 절반)

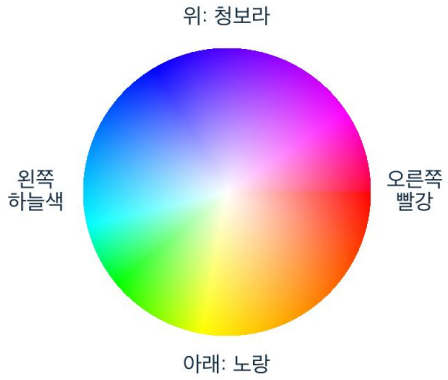
01 **문제와 배경**
고해상도에서 움직임 추정이 어려운 이유

02 **DPFlow의 구조**
이중 피라미드 · CGU · 깊이 조절

03 **실험과 결론**
고해상도 평가 결과와 한계

두 장의 영상에서, 모든 픽셀의 움직임을 찾는다





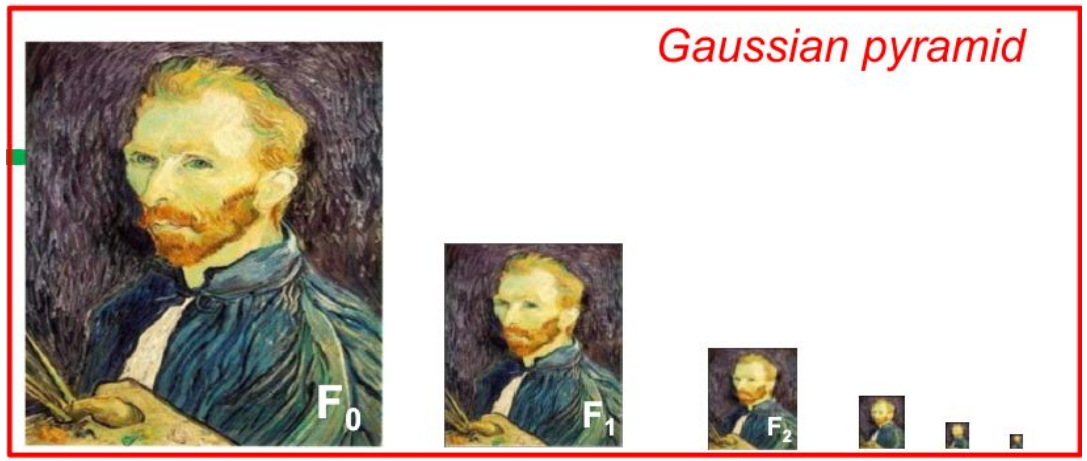
색 = 움직임의 방향

물체의 실제 색이 아님

흰색에 가까울수록 정지,
진할수록 큰 이동

Optical Flow = 두 프레임 사이, 모든 픽셀의 이동량 (u, v)

수업 복습: 피라미드 Lucas–Kanade



Gaussian pyramid — 4주차 Image Pyramids

영상을 줄이면 큰 움직임도 작아진다

1

작은 영상에서 먼저 추정

축소하면 이동량도 작아져 LK 가정이 성립

2

한 단계 큰 영상으로 확대

좌표가 2배 → 이동량도 2배로 맞춘다

3

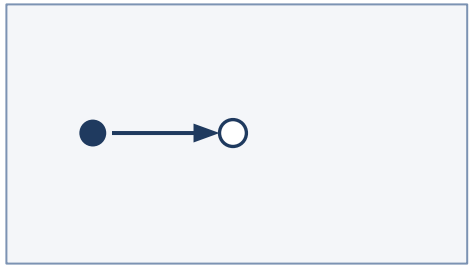
큰 영상에서 오차 수정

Coarse-to-fine 방식

DPFlow도 같은 원리 — 단, 밝기 대신 신경망이 학습한 '특징'을 비교한다

같은 움직임도, 해상도가 2배면 이동량은 2배

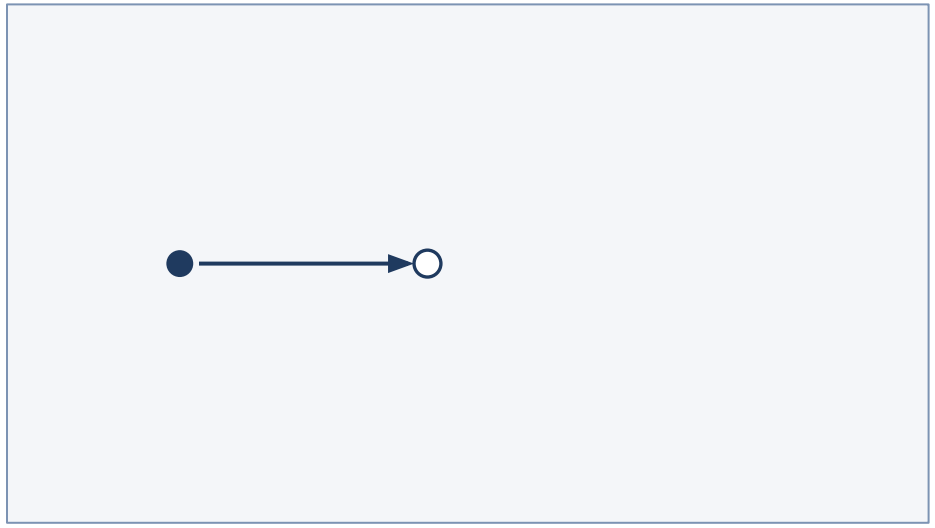
640 × 360



x = 100 → 120

20 px

1280 × 720 (가로·세로 2배)



x = 200 → 240

가로 이동

40 px

실제 움직임은 같지만 픽셀 단위가 촘촘해진다 → 고해상도에서는 더 먼 위치에서 대응점을 찾아야 한다

기존 방법의 세 가지 처리 방식

축소

영상을 줄여서 입력

한계 · 작은 물체·세밀한 움직임 손실

분할 (Tiling)

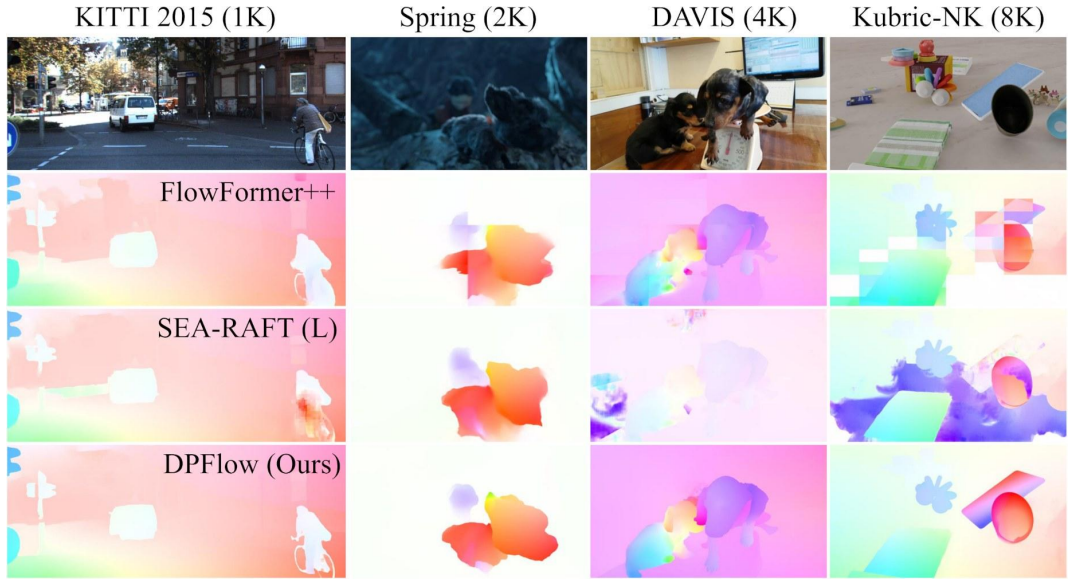
타일로 나눠 따로 처리 (FlowFormer++)

한계 · 전체 맥락 손실 · 사각형 형태의 오류

원본 크기 그대로

고정 구조에 큰 영상 입력 (SEA-RAFT)

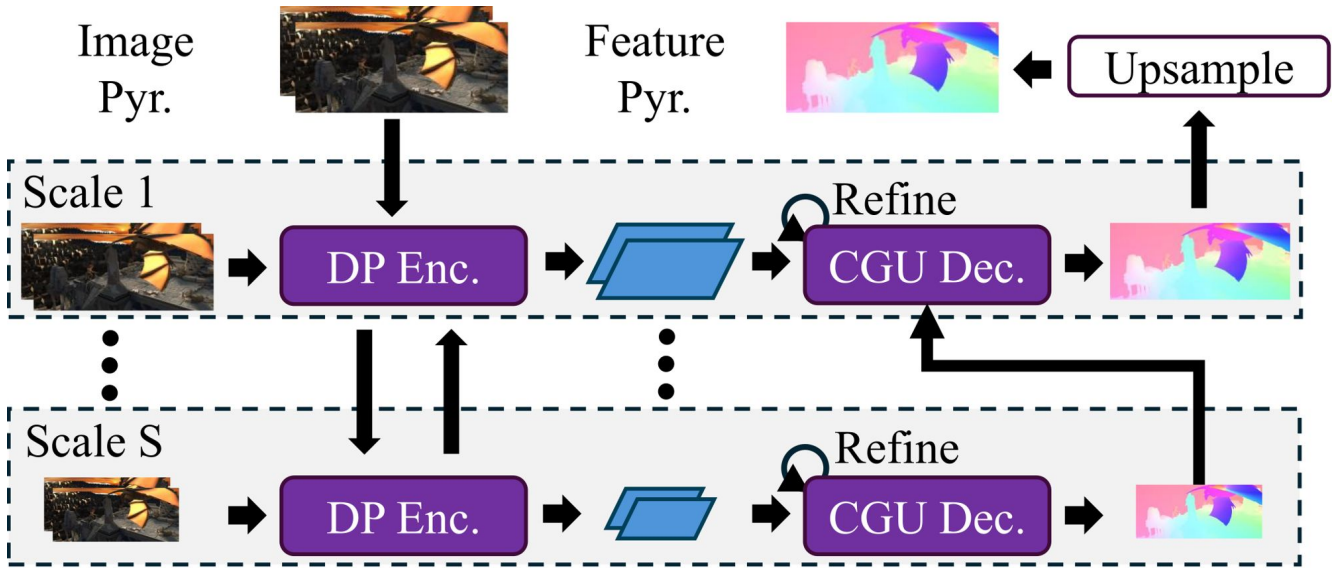
한계 · 학습 크기와 달라 성능 저하



논문 Fig. 1 — 오른쪽 열로 갈수록 고해상도

DPFlow — 입력 크기에 맞춰 모델 구조가 조정된다

전체 구조: Encoder에서 특징 추출, Decoder에서 보정



논문 Fig. 2 — DP Enc. (특징 준비) · CGU Dec. (이동 반복 수정)

핵심 아이디어 3가지

1 **이중 피라미드**

원본 정보와 층 사이 정보를 결합

2 **CGU**

두 영상을 참고해 정보 반영 정도 조절

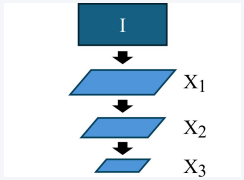
3 **깊이 조절**

입력 크기에 맞춰 층 수 결정

두 영상 입력 → 여러 크기의 특징 → 작은 크기부터 반복 수정 → 픽셀별 Flow (u, v)

원본 정보를 보충하고, 층 사이 정보를 양방향으로 전달한다

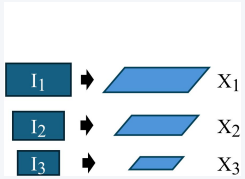
특징 피라미드



+ 층 사이 정보 전달

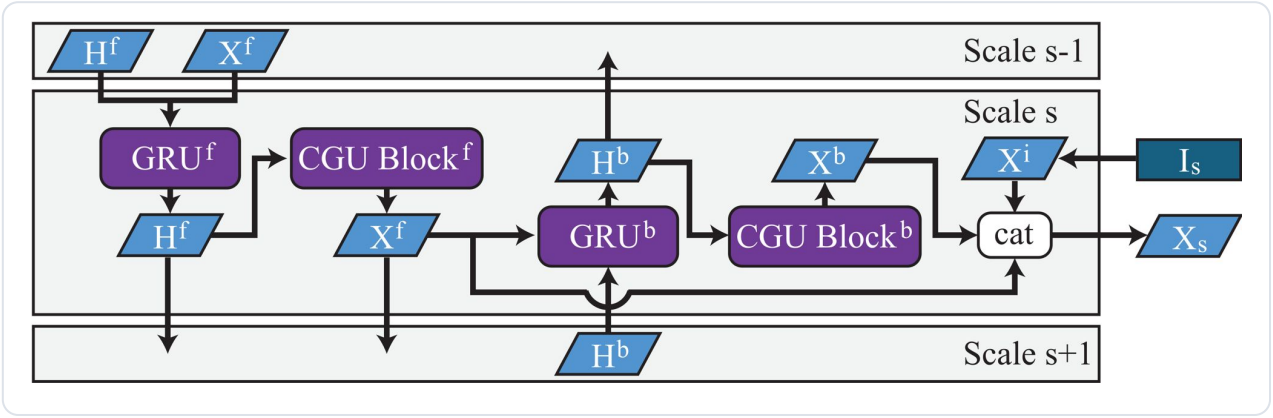
– 원본이 점점 흐려짐

이미지 피라미드



+ 층마다 원본을 직접 봄

– 층끼리 정보 단절



두 피라미드를 하나로 결합 (논문 Fig. 4)

한 층에서 모이는 세 가지 정보

Xf — **순방향**
앞(얕은) 층에서 넘어온 정보

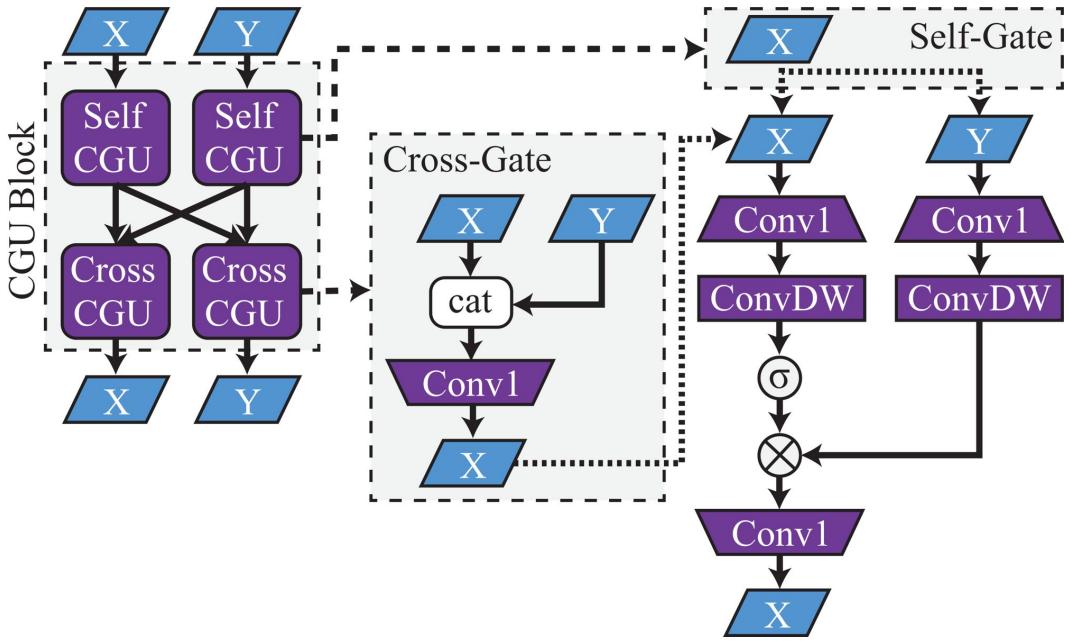
Xb — **역방향**
깊은 층에서 되돌아온 정보

Xi — **이미지**
그 크기로 줄인 원본에서 직접 추출

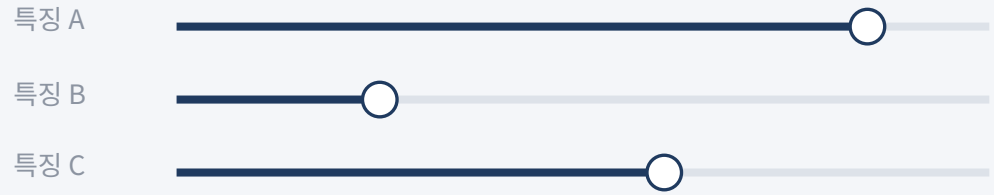
concat(Xf, Xb, Xi) → 합성곱 → 이 층의 특징 Xs

GRU(Gated Recurrent Unit): 이전 정보와 새 정보의 반영 비율을 조절

CGU(Cross-Gated Unit): Encoder와 Decoder에서 특징을 가공한다



논문 Fig. 5



Self-Gate

자기 영상의 특징으로
게이트 값 계산

Cross-Gate

상대 영상의 특징도
함께 참고

왜 Attention 대신 합성곱?
계산량이 작고, 입력 크기가 바뀌어도 그대로 동작한다

Adaptive Depth: 입력이 클수록 피라미드를 깊게



1K	2K	4K	8K
960 × 540	1920 × 1080	3840 × 2160	7680 × 4320
3층	4층	5층	6층

층 수는 자동으로

$$N = 3 + \mathrm{round}[\log_2(\max(1, \frac{d}{d_{1K}}))]$$

N : 피라미드 층 수
d : 입력 영상의 대각선 길이
d_{1K} : 1K 영상의 대각선 길이

해상도 2배 → 한 층 추가

더 작은 크기까지 내려가 큰 이동을 추정

모든 층이 같은 모듈·가중치를 공유 → 재학습 불필요

깊이 조절 자체는 RAPIDFlow에서 시작 · DPFlow는 이를 이중 피라미드와 결합

Decoder: 특징 비교에서 이동량 보정까지

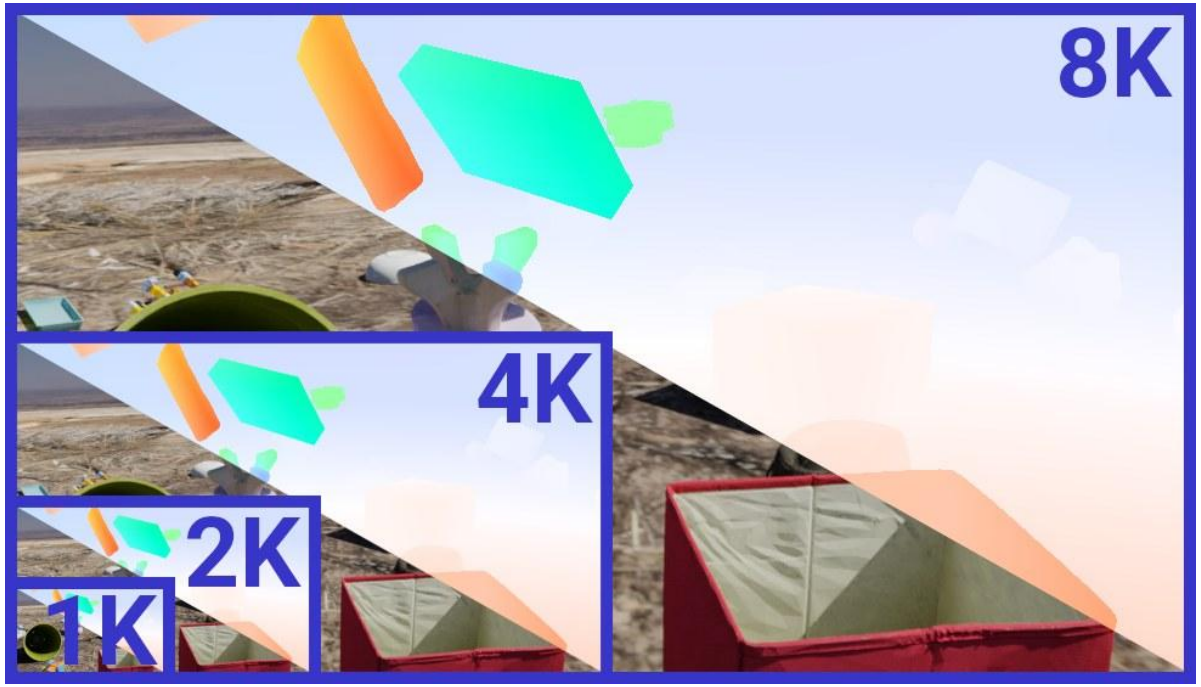




현재 이동량 20 + 수정량 3 = 23

다음 해상도로 확대 → 이어서 보정
마지막: 원본 해상도로 업샘플링

고해상도 평가 데이터셋: Kubric-NK



같은 장면을 1K · 2K · 4K · 8K로 렌더링 (논문 Fig. 6)

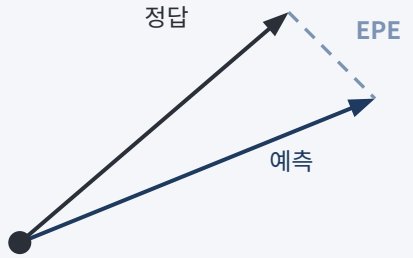
2,400

샘플 수 (600 × 4 해상도)

8K

최대 7680 × 4320

채점 기준: EPE



두 화살표 끝 사이 거리의 평균

단위 px · 낮을수록 좋음

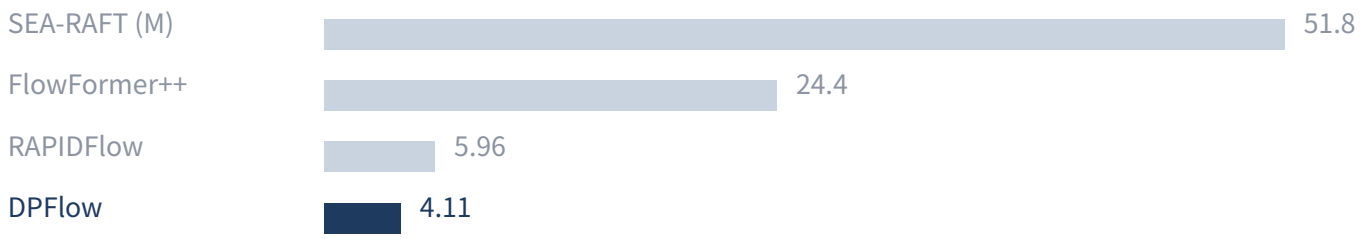
학습에는 고해상도 데이터를 사용하지 않음

해상도가 커질수록, 차이가 벌어진다

방법	1K	2K	4K	8K
SEA-RAFT (M)	0.53	1.53	11.0	51.8
FlowFormer++	**0.46**	1.11	5.39	24.4
RAPIDFlow	0.81	1.23	2.11	5.96
DPFlow	**0.50**	**0.85**	**1.77**	**4.11**

Kubric-NK · EPE (px), 낮을수록 좋음 · 논문 Table 3에서 4개 방법 발췌

8K 오류 비교



−31%

8K 오류, RAPIDFlow 대비

4.11 px

8K EPE · 비교한 방법 중 가장 낮음

참고 · 1K에서는 FlowFormer++ (0.46)가 DPFlow (0.50)보다 낮다. 장점은 고해상도에서 나타난다

정성적 결과: 8K에서도 형태를 유지한다



열: 해상도 1K → 8K · 행: 모델 (맨 아래 DPFlow) · 논문 Fig. 8

DPFlow · 8K (이 샘플 EPE 6.48)

Ablation Study: 구성 요소별 효과

인코더 구성

EPE · Sintel final / KITTI

구성	Sintel	KITTI
기본	2.58	4.50
+ 이중 피라미드	2.51	4.70 ↑
+ 이중 피라미드 + 양방향	2.41	4.13

이중 피라미드만 추가하면 KITTI는 악화 → 양방향까지 사용해야 둘 다 개선

피라미드 깊이

EPE · Kubric-NK

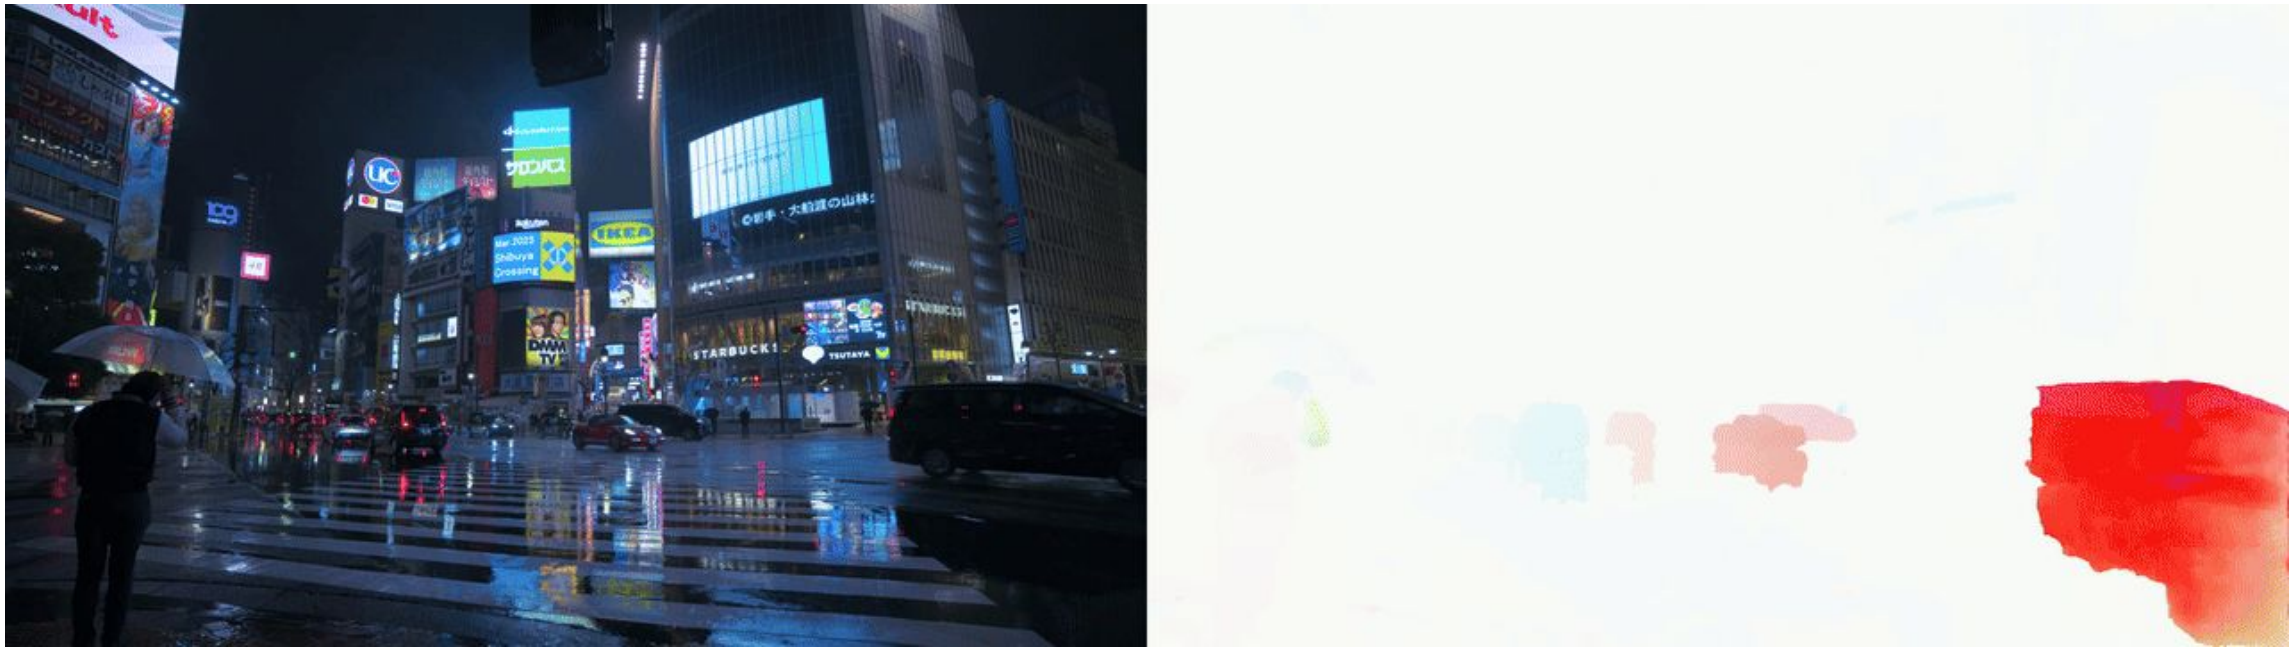
입력	3층	6층
1K	0.50	0.61
8K	14.7	4.11

작은 영상은 얕게, 큰 영상은 깊게 — 8K는 3층 14.7, 6층 4.11

공개 8K 영상의 움직임 추정

입력 영상 · 8K

DPFlow 추정 결과



7680 × 4320 원본 입력 → 피라미드 6층 자동 적용

차량·우산 주변의 움직임을 시각화

출처: Abao Vision, Rainy Night Walk in Shibuya 8K(YouTube) · 52:04–52:07

한계와 적용 범위

모든 평가에서 최고는 아님

흐림·안개 없는 깨끗한 일반 해상도 영상(Sintel clean)에서는 다른 모델이 더 정확하다

합성 데이터 기반 평가

Kubric-NK의 합성 장면만으로는 실제 촬영 환경의 다양한 조건을 모두 평가하기 어렵다

두 프레임 간 추정

긴 영상에서 점을 계속 추적하거나, 8K를 실시간으로 처리하는 것까지 보장하지 않는다

감사합니다

Q & A